



人工智能的数学思维

组织：华东师范大学软件工程学院

时间：2024

目录

第一部分 追问智能	1
前言	2
0.1 从“困难重重”到“显而易见”：智能发展的历史辩证法	2
0.2 数学史：智能追求的发展主线	3
0.3 智能的层次：从模仿到创造	3
0.4 数学：智能的基石与必然逻辑	4
0.5 本书的使命与挑战	4
0.6 致读者	5
第 1 章 引言什么是智能？	6
1.1 什么是智能与人工智能	6
1.2 鹦鹉与乌鸦：何种智能？.	8
第 2 章 智能，生于数学	
简明数学史	13
2.1 萌芽时期：从计数到位值制	14
2.1.1 史前数学：日常需求与实用计算	14
2.1.2 手指：长在身上的计数器	14
2.1.3 荒岛上的自然教育，人类数字文明的缩影	16
2.1.4 数字的位值系统	17
2.1.5 位值制与对数增长在现代计算机中的应用	18
2.1.6 数字：从具象到抽象	18
2.2 初等数学时期：从计算到推理	19
2.2.1 数学的真正诞生：从计算到推理	19
2.2.2 毕达哥拉斯：数与宇宙的关系	21
2.2.3 欧几里得：公理化体系的奠基人	21
2.2.4 阿基米德：数学与物理的桥梁	22
2.2.5 亚里士多德：逻辑与推理	22
2.2.6 古希腊数学的遗产	22
2.3 近代数学时期：变量、函数与微积分	23
2.4 现代数学时期：抽象、结构与计算	23
2.5 三次数学危机：从无理数到不完备	24
2.5.1 第一次危机：无理数的发现与算术信仰的破灭	25

2.5.2	第二次数学危机：微积分基础的争议与解析	25
2.5.3	第三次危机：集合论与逻辑的悖论	26
2.6	小结	28
第3章 智能，成于计算机		
	简明 AI 史	30
3.1	AI 的萌芽期：理论的起源与计算机的诞生	30
3.2	1950-1970 年代：AI 的奠基与早期探索	32
3.2.1	达特茅斯会后早期黄金期：符号主义 AI	33
3.3	1980 年-1987 年：专家系统与知识工程的兴起	36
3.3.1	代表性专家系统	36
3.3.2	知识表示与规则推理	36
3.3.3	知识工程的广泛应用	37
3.3.4	新兴技术：模糊逻辑与贝叶斯网络	37
3.3.5	第二次“AI 寒冬”的反思与转型	37
3.4	人工智能的分化	38
3.5	1990-2010 年代：联结主义和机器学习的兴起	39
3.5.1	2020 年代：大语言模型（LLM）与生成式人工智能（AIGC）的崛起	39
3.6	人工智能主要学派	40
3.6.1	符号主义学派 (Symbolicism)	40
3.6.2	联结学派/连接学派 (Connectionism)：从神经网络到深度学习	42
3.6.3	行为主义学派 (Actionism)	43
3.6.4	三大学派的比较	44
3.6.5	三大学派对比总结	44
3.7	小结：危机与机遇中的 AI 发展之旅	47
参考文献		49
第二部分 参考文献		51
致谢		52

第一部分

追问智能

前言

内容提要

□ 现在看起来的“显而易见”，在当年却是“困难重重”。这句话深刻地概括了人工智能发展的历史轨迹，也揭示了

人类智慧演进的根本规律。今天我们习以为常的技术成就，在其诞生之初都曾面临着巨大的挑战和质疑。

0.1 从“困难重重”到“显而易见”：智能发展的历史辩证法

现在看起来的“显而易见”，在当年却是“困难重重”。

这句话，或许是理解人工智能发展历程最好的钥匙。当我们今天轻松地使用语音助手、享受个性化推荐、见证机器翻译的流畅时，很难想象这些技术背后曾经历过怎样的艰难探索。每一个今天看来理所当然的功能，都是无数研究者在黑暗中摸索、在失败中坚持、在质疑中前行的结果。

人类历史上，每一次重大的技术突破都遵循着相似的轨迹：从被认为不可能，到被视为困难，再到变得显而易见，最终成为日常生活的一部分。这种认知转变的背后，隐藏着科学进步的深层逻辑。

在古代，人们认为飞行是神的特权，人类永远无法像鸟儿一样翱翔天空。莱特兄弟的第一次飞行被许多人视为杂技表演，而非真正的技术突破。然而，仅仅几十年后，航空技术就彻底改变了人类的生活方式。今天，我们把乘坐飞机视为最普通不过的出行方式。

人工智能的发展历程同样如此。1950年，当艾伦·图灵提出“机器能思考吗？”这个问题时，大多数人认为这是科幻小说的幻想。机器怎么可能具有人类独有的思维能力？然而，从1997年深蓝击败国际象棋世界冠军卡斯帕罗夫，到2016年AlphaGo征服围棋巅峰，再到2022年ChatGPT展现出令人惊叹的语言理解能力，我们见证了一个又一个“不可能”变成“显而易见”。

本质上，人类发展史就是一部智能简史。从人类文明最早出现数的概念，到数的标记和运算，从算术到代数、几何、抽象代数、拓扑、群论等越来越复杂和专门的数学分支，数学史的发展主线背后，是对智能的极致追求。

在古代的神话传说中，技艺高超的工匠就可以制作人造“人”，并为其赋予智能或意识。希腊神话中的塔罗斯（Talos）是由火神赫菲斯托斯打造的青铜巨人，负责守卫克里特岛；犹太传说中的泥人哥连（Golem）由拉比用泥土塑造，通过神秘的仪式获得生命。这些古老的想象，预示着人类对创造智能的永恒渴望。

从最初的计数开始，人类就在不断追求计算越来越高效、越来越自动化、越来越智能。算盘的发明让计算摆脱了手指的限制；对数表的出现使复杂运算变得简单；机械计算器的诞生标志着自动化计算的开端。每一步进展，都是在拓展人类智能的边界。

0.2 数学史：智能追求的发展主线

“语言是思想的边界，技术是思想的实现。”这句话深刻地揭示了人工智能发展的哲学内核。人类的每一次技术突破，都是在拓展思想的边界，而技术的进步又反过来推动思想的深化。

语言不仅是交流的工具，更是思维的载体。当我们发明新的概念、创造新的词汇时，实际上是在扩展思维的可能性。计算机科学的发展历程完美地诠释了这一点：从“算法”到“程序”，从“数据结构”到“人工智能”，每一个新概念的诞生都标志着思维边界的拓展。

技术则是思想的物化。当抽象的数学理论转化为具体的算法，当理论模型变成可运行的程序，思想就获得了改变世界的力量。深度学习的发展历程就是这种转化的典型例子：从 1943 年麦卡洛克和皮茨提出人工神经元的数学模型，到 1986 年反向传播算法的完善，再到 2012 年深度卷积网络在图像识别上的突破，理论与实践的相互促进推动了整个领域的飞跃。

数学史的发展主线背后，隐藏着人类对智能的极致追求。从最基础的算术运算，到复杂的抽象代数理论，每一个数学分支的诞生都是为了解决更复杂的问题，实现更高层次的智能。

正如歌德把历史称作“上帝的神秘作坊”，在这个“作坊”里，堆积着对人类来说看似无关紧要的小事。只在极少时候，它们才会被某些时刻点亮，史蒂芬·茨威格称之为“人类的星光时刻”。数学发展史上的每一个重大突破，都是这样的“宿命时刻”——一连串的事件被紧密地编织在一起，经过漫长的发展，然后突然成熟。

欧几里得几何的公理化体系，牛顿微积分的发明，非欧几何的发现，集合论的建立，哥德尔不完备定理的证明——这些“宿命时刻”如繁星般“熠熠生辉、永不熄灭”。它们在数百年的黑暗中闪耀，用数学照亮了人类的历程。

0.3 智能的层次：从模仿到创造

恰以其分地拿捏尺度，显然是智能的外在表现之一。“过犹不及”说得就是这个理。智能不仅仅是计算能力的体现，更是对复杂情况的精准判断和适度响应。

在人工智能的发展过程中，我们可以观察到智能的不同层次。最初的人工智能系统主要依靠规则和逻辑推理，这种“符号主义”的方法虽然在某些领域取得了成功，但面对复杂的现实世界问题时显得力不从心。

随着机器学习的兴起，人工智能开始具备从数据中学习的能力。这种“连接主义”的方法让机器能够识别模式、进行预测，但本质上仍然是对已有数据的统计分析和模仿。

深度学习的突破标志着人工智能向更高层次的跃升。通过多层神经网络的复杂变换，机器开始展现出某种“理解”能力，能够处理自然语言、识别图像、甚至进行创作。然而，这种智能仍然主要基于模式匹配和统计关联。

真正的挑战在于如何让机器具备创造性思维和抽象推理能力。这需要我们重新思考智能的本质，探索认知科学、神经科学、哲学等多个领域的交叉融合。

0.4 数学：智能的基石与必然逻辑

从人脑和手算发展到一定程度，对更高效计算效率的追求必然会导致计算机的发明，进而导致人工智能的诞生。这不是偶然，而是历史发展的必然逻辑。

每一个看似突然的技术突破，背后都有着深厚的历史积淀。计算机的发明离不开数学、物理学、工程学等多个学科的发展；人工智能的兴起建立在计算机科学、认知科学、神经科学等领域的基础之上。

这种必然性并不意味着发展过程是平坦的。相反，每一次重大突破都伴随着激烈的争论、反复的挫折、长期的沉寂。深度学习就经历了三次起伏：1940-1960 年代的感知机热潮，1980-1990 年代的反向传播复兴，以及 2010 年代至今的深度学习革命。每一次低谷都被认为是“AI 冬天”，每一次复兴都被视为“奇迹”。

数学在人工智能发展中扮演着至关重要的角色。从最初的逻辑推理到现代的深度学习，每一次重大进展都离不开数学理论的支撑。线性代数为神经网络提供了计算框架，概率论为机器学习奠定了理论基础，微积分使得梯度下降成为可能，信息论指导着数据压缩和特征提取。

这些数学工具的发展历程同样充满了“困难重重”到“显而易见”的转变。牛顿和莱布尼兹发明微积分时，面临的不仅是技术难题，更有来自学术界的激烈争议。今天，微积分已成为理工科学生的必修课程，其重要性不言而喻。

概率论的发展更加曲折。从帕斯卡和费马研究赌博问题开始，到贝叶斯定理的提出，再到现代统计学的建立，概率论经历了从“数学游戏”到“科学基础”的转变。今天，贝叶斯方法已成为机器学习的核心工具之一。

0.5 本书的使命与挑战

本书试图通过数学的视角，揭示人工智能发展的内在逻辑。我们将探讨那些看似“显而易见”的技术背后的数学原理，回顾那些曾经“困难重重”的问题是如何被一步步解决的。

这是一个充满挑战的任务。人工智能是一个高度跨学科的领域，涉及数学、计算机科学、认知科学、神经科学、哲学等多个学科。要在有限的篇幅内既保持数学的严谨性，又确保内容的可读性，需要在深度和广度之间找到平衡。

我们的目标不仅是传授知识，更是启发思考。希望读者能够理解，今天的“显而易见”正是昨天无数研究者“困难重重”探索的结果，而明天的突破，或许就隐藏在今天看似不可能的想法之中。

正如伏尔泰在《老实人》中所说：“如果没有这场灾难，事物就无法继续进行了。因为一切都是最好的安排。”每一次挫折都是为了更大的突破做准备，每一个“困难重重”的今天都孕育着“显而易见”的明天。

在这个人工智能快速发展的时代，我们既要保持对技术进步的敬畏，也要对未来的挑战保持清醒的认识。数学作为人工智能的基石，将继续指引我们探索智能的奥秘，推动人类文明向更高层次发展。

让我们带着这样的认识，开始这段探索人工智能数学基础的旅程。在这个旅程中，我们将见证“困难重重”如何转化为“显而易见”，体验数学之美如何照亮智能之路。

0.6 致读者

这本书不是一本传统的教科书，也不是一本纯粹的学术专著。它更像是一次思想的漫游，一场关于智能本质的哲学思辨，一段追溯数学与人工智能关系的历史探索。

我们将从最基础的数学概念出发，逐步深入到人工智能的核心算法。每一个公式背后，都有着深刻的思想；每一个算法背后，都有着动人的故事。我们不仅要理解“是什么”和“怎么做”，还要思考“为什么”和“意味着什么”。

在这个人工智能技术日新月异的时代，保持对基础理论的敬畏和对未来发展的思考，或许比掌握具体的技术细节更为重要。因为技术会过时，但思想永恒；工具会更新，但智慧长存。

愿这本书能够成为你探索智能奥秘的指南针，在“困难重重”的学习路上为你点亮一盏明灯，最终让那些看似高深的理论变得“显而易见”。

第一章 引言什么是智能？

内容提要

- 智能的多维度定义与理解
- 人工智能与生物智能的本质区别
- 从哲学、科学到工程的智能观
- 数学思维作为解码智能的钥匙
- 机器智能的进化与发展轨迹

这一章将带领你从哲学、科学和工程的角度出发，追问“什么是智能”。接下来的章节中，我们将深入探讨数学在人工智能中的具体应用，展示数学如何帮助我们创造出越来越强大的智能系统。

1.1 什么是智能与人工智能

智能 (intelligence)，如今已经成为现代生活中很常见的一个词，比如智能手机、智能家居、智能驾驶等。在不同使用场合中，智能的含义也不太一样。比如“智能手机”中的“智能”一般是指由计算机控制并具有某种智能行为的意思。这里的“计算机控制”+“智能行为”隐含了对人工智能的简单定义。

简单地讲，人工智能 (Artificial Intelligence, AI) 就是让机器具有人类的智能，这也是人们长期追求的目标。然而，关于什么是“智能”并没有一个很明确的定义，但一般认为智能是知识和智力的总和，都和大脑的思维活动有关。人类大脑经过了上亿年的进化才形成了如此复杂的结构，但至今仍然没有完全了解其运作原理，以及如何产生意识、情感、记忆等功能。因此，通过“复制”一个人脑来实现人工智能在目前阶段是不切实际的。

从生物学角度看，智能并非人类独有。许多动物，如海豚、鸟类、猩猩，甚至章鱼，都表现出高度的学习能力、问题解决能力以及某种形式的社交智能。然而，人类的智能以其复杂性和多样性独树一帜，在抽象和创造性上尤为突出。人类具有抽象思维，创造了诸多符号系统，并基于此进行高度复杂的推理和想象。从数学公式到哲学思辨，人类通过语言、文字和符号，建立起了庞大的知识体系和文化遗产。我们可以预见未来、反思过去，并通过科学、技术、工具改变现实世界。正是这种智能上的深度和广度，推动了人类文明的发展。

智能是生命进化过程中形成的一种适应性特征。随着人工智能的发展，我们正在见证一种新型智能的崛起。20 世纪中期计算机的发明，标志着一种全新“智能”形式的诞生。这种基于二进制系统和算法逻辑的机器，能够完成许多过去被认为只有人类才能做到的任务，如图像识别、语言翻译、甚至写作创作。机器可以通过算法模拟复杂的推理过程，甚至在某些领域超越人类的能力——它们能够比人类更快地进行大规模计算、更高效地分析海量数据。

这促使我们重新思考：究竟什么是“智能”？它是基于生物特性的一种特有思维能力，还是某种可以通过数学和逻辑建模来实现的计算逻辑？

对于智能的定义，在不同学科中有着不同的阐释：在心理学中，智能被视为一种个体解

决问题、学习和适应环境的能力；在生物学中，智能更多与生物体的行为、神经系统的复杂性相关；而在计算机科学和人工智能领域，智能则被看作是一种能够在复杂环境中执行任务并达成特定目标的能力。

从人工智能的角度看，智能可以被定义为“机器执行通常需要人类智能才能完成的任务的能力”。这些任务包括视觉识别、自然语言处理、学习、推理、决策等。然而，计算机和人类智能之间仍然存在着巨大的差异，特别是在理解、情感和创造力等方面。

机器“智能”是否真的与人类的智能一样？人类的智能伴随着进化而来，经过了数百万年的演变和适应，它不仅仅是一种计算能力，更是情感、直觉、创造力和推理能力的综合体。相对来说，人工智能的发展历史尚短，但其进化速度却让人惊叹。

机器智能的本质在于其基于算法和数据的计算逻辑，而人类智能则包含了情感、意识、创造力等更为复杂和难以定义的元素。智能不仅仅是任务的完成能力，更涉及到意识、理解和体验。也许机器可以在规则内完成任务，优化目标，但它们仍然无法像人类那样拥有感知、情感或独立的创造思维。尽管如此，在这场由人类主导的智能革命中，我们依然是规则的制定者和方向的掌控者。这也是为什么，理解数学思维如何推动人工智能，能够帮助我们更好地把握未来智能发展的关键脉络。

数学在智能中的角色

自古以来，数学不仅是解决问题的工具，更是智能表达与实现的基础语言。数学的力量在于它能够抽象出复杂问题的本质，提供精确的描述和推理方法。

人工智能中的诸多任务，如模式识别、数据分类、预测等，背后都依赖数学模型进行量化和求解。例如，图像识别问题看似复杂，但可以被归纳为一个线性代数问题：图像被分解为像素点，每个像素点通过向量和矩阵的运算来进行处理。同样，神经网络的训练也依赖于微积分中的优化技术，以最小化损失函数，找到最优参数组合。

机器智能的进化：从计算到学习

数学在推动人工智能从简单计算迈向学习与适应中起到了关键作用。最初，计算机的智能主要体现在通过预先编写的规则来执行任务，模拟人类的某些智能行为。随着大数据和深度学习技术的出现，人工智能开始从数据中“学习”，即所谓“机器学习”。这是一场范式的转变：机器智能从依赖人工预定义的规则，转变为通过模型的不断训练和优化进行自我学习。

在这场范式的转变中，数学再次发挥了至关重要的作用。统计学、线性代数、概率论等数学工具，使机器能够从复杂的海量数据中提取有价值的模式和信息，并进行合理决策。这种数学思维下的机器学习能力，使得智能不仅仅是计算结果的简单输出，而是一种能够学习、适应和自我优化的动态过程。这场智能的进化，无疑奠定了人工智能发展的新高度。

数学思维：解码智能的钥匙

人工智能是模拟、延伸和扩展人类智能的理论、方法、技术及其应用系统的综合学科。AI 作为一门跨学科领域，从多个学科中汲取灵感与启发，融合了不同领域的知识与技术。

数学思维不仅仅是对现有工具的应用，更代表着一种解码世界的方式。数学能够帮助我们从表象中剥离出系统的本质，理清复杂事物之间的逻辑关系。在人工智能领域，数学思维是帮助我们更好理解并发展智能的核心钥匙。

人工智能的本质是一种通过数学和计算实现的智能，它利用算法、数据处理和计算资源模拟生物智能的行为。为了理解智能如何通过数学实现，我们可以将其分解为几个关键组成部分：

- **感知与反应**：任何智能体首先需要能够感知环境，并对环境做出适当的反应。这是智能的基础，也是进化中所有生物生存的关键。数学在感知数据的处理上扮演重要角色，例如通过卷积神经网络处理视觉输入。
- **学习与记忆**：智能体不仅是对环境做出反应，还包括从经验（数据）中学习，储存经验用于未来决策。
- **推理与决策**：智能体需要能够进行推理，从已有信息中得出新的结论，从而做出合理的决策。这离不开统计推断、优化等数学方法。
- **创造与适应**：更高级的智能不仅仅是反应式的，而是能够创造性地应对未知的挑战，并在复杂的环境中灵活适应。

人工智能（AI）在这些维度上逐步模仿人类的智能，但它的本质是通过数学和计算实现的。AI 的智能是通过算法、数据处理以及计算资源，以我们在生物智能中所见的行为为目标进行的复杂优化。

1.2 鹦鹉与乌鸦：何种智能？

为了更好地理解智能的不同层次，我们可以借用一个生动的比喻——鹦鹉与乌鸦。

鹦鹉式智能：模仿而不理解

鹦鹉是模仿高手，能够复制人类的语言，甚至在特定情境下做出看似有意识的反应。然而，鹦鹉并不真正理解它模仿的内容，它只是重复我们的话语，而无法将这些词汇与现实世界中的人、物或情景建立联系。这种行为类似于一些现有的人工智能系统，特别是那些专注于模仿和执行特定任务的 AI 模型。这类 AI 可以通过大量数据训练，在特定任务中表现优异，但它们并不真正理解背后的语义或意图。

这种“鹦鹉式智能”可以类比为**弱 AI** 或**窄 AI**。它们擅长于特定任务，但缺乏广泛的推理和创造能力。当前的许多 AI 模型，如语言生成或图像识别，都是在这一框架下运作的——它们通过模式识别和数据驱动的方式执行任务，却没有真正的自主意识或深度理解。

乌鸦式智能：推理与创造

乌鸦向来被认为是最聪明的鸟类之一。与鹦鹉不同，乌鸦不仅擅长模仿，还展现出复杂推理能力、问题解决能力以及创造性的智能。乌鸦是少数能够制造工具的鸟类，能够通过创新思维应对物理世界中的挑战。

我们从小都听过各种“乌鸦喝水”的故事，而国外科学家也曾做过一系列“乌鸦喝水”的变化实验。在这些实验中，研究人员使用了各种不同形状的瓶子和不同密度的物体，观察乌鸦如何应对。令人惊讶的是，乌鸦总能在几次尝试后，快速识别并选择那些能够最快让水位上升的物体。这些实验不仅证实了乌鸦对物理规律的深刻理解，还展示了它们高度的认知能力和推理能力，以及面对复杂问题时的创造性和灵活性。

另一个著名的例子是，乌鸦会将坚果放在马路上，利用来往车辆碾压坚果壳，并观察红绿灯、斑马线等信号来推理交通规则，最终推理出红绿灯与车辆停靠及行人停走之间的复杂因果关系，从而安全地过马路，吃到被碾碎的坚果肉。这是一种远远超出简单反应的行为，展示了乌鸦对物理世界和人类行为之间复杂因果链的深刻理解。

乌鸦的这一行为没有经过大量数据训练或监督学习，它通过少量的尝试与观察，直接推理出解决问题的方法。乌鸦智能正是我们期望的真正的智能——完全自主的智能：观察、感知、认知、学习、推理、执行。这种智能可以比喻为**强 AI** 或**通用 AI**，具备自主学习、推理和适应能力，能够在不同的环境中灵活应对各种任务。

更令人惊叹的是，乌鸦的智能不仅功能强大，功耗也极低。人类大脑的功耗大约在 10-25 瓦之间，而乌鸦的大脑尺寸约为人类的 1%，功耗约为 0.1-0.2 瓦。这意味着乌鸦无需复杂的能源供应系统或冷却设备，就能完成复杂的推理和问题解决任务。相比之下，现代 AI 系统需要高性能计算设备和大量能源，显示了生物智能的高效性。

智能的层次：从鹦鹉到乌鸦

“鹦鹉”与“乌鸦”的比喻在人工智能领域有着深刻的象征意义，这个比喻不仅生动地描绘了智能的不同表现形式，更揭示了**智能发展的本质差异和层次结构**。通过对比这两种截然不同的智能模式，我们能够更清晰地理解当前人工智能的发展阶段，以及未来可能的突破方向。

- **鹦鹉式智能**：擅长特定任务，通过数据驱动的模式识别和模仿来实现，针对某些垂直应用有效，但缺乏深度理解和推理能力。
- **乌鸦式智能**：具备复杂的推理和创造性，能够自主学习、适应环境，展现出高水平的智能灵活性。

这个比喻的深层含义在于，它揭示了智能发展的两条不同路径：一条是基于大规模数据训练和模式匹配的“统计智能”，另一条是基于理解、推理和创新的“认知智能”。

鹦鹉式智能：精确模仿的艺术与局限

鹦鹉作为自然界中最出色的模仿者之一，能够以惊人的准确度复制人类的语言、音调甚至情感表达。这种能力看似简单，实际上需要复杂的神经机制来支撑。鹦鹉通过听觉系统捕捉声音模式，经过大脑处理后，通过精确的肌肉控制重现这些声音。然而，这种模仿虽然在表面上极其逼真，但缺乏对语言内容的真正理解。

当前的人工智能系统，特别是深度学习模型，在很大程度上体现了“鹦鹉式智能”的特征。以计算机视觉为例，现代的卷积神经网络 (CNN) 能够在图像识别任务中达到甚至超越人类的准确率。这些系统通过分析数百万张标注图像，学习到了从像素级特征到高级语义概念的复杂映射关系。然而，这种“理解”本质上是统计相关性的体现，而非真正的概念理解。

在自然语言处理领域，大型语言模型如 GPT 系列、BERT 等，展现了令人印象深刻的语言生成和理解能力。这些模型通过训练海量文本数据，学会了语言的统计规律和上下文关系。它们能够生成语法正确、语义连贯的文本，甚至能够进行复杂的对话和推理任务。然而，深入分析会发现，这些模型的“理解”更多是基于模式匹配和统计推断，而非真正的语义理解。

鹦鹉式智能的优势在于其**可扩展性和一致性**。一旦训练完成，这类系统能够以极高的效率处理大量任务，且性能稳定可预测。它们不会因为情绪、疲劳或其他主观因素而影响表现，这使得它们在许多实际应用中具有重要价值。例如，在医疗影像诊断、金融风险评估、工业质量控制等领域，鹦鹉式 AI 系统已经展现出了巨大的应用潜力。

然而，鹦鹉式智能也存在明显的**局限性**。首先是**泛化能力有限**，当面对训练数据中未曾出现的情况时，这类系统往往表现不佳。其次是**缺乏创造性**，它们只能在已有模式的基础上进行组合和变换，难以产生真正原创的想法。最重要的是，这类系统**缺乏对“意义”的理解**，它们处理的是符号和模式，而非概念和意义本身。

乌鸦式智能：推理与创新的典范

与鹦鹉形成鲜明对比的是乌鸦，这种被誉为“羽毛界爱因斯坦”的鸟类展现出了令人惊叹的认知能力。乌鸦的智能不仅体现在问题解决上，更体现在其**理解因果关系、进行抽象思维和创造性解决问题的能力**上。

科学研究表明，乌鸦具备多项高级认知能力。在著名的“弯钩实验”中，新喀里多尼亚乌鸦贝蒂 (Betty) 能够将直铁丝弯曲成钩状工具，用来从管子中取出食物。这个行为展现了乌鸦对**工具功能的理解**和**目标导向的问题解决能力**。更令人惊讶的是，乌鸦还能够进行**多步骤推理**。在一项实验中，乌鸦需要使用短棍获得长棍，再用长棍获得食物，展现了复杂的**序列规划能力**。

乌鸦的社交智能同样令人印象深刻。它们能够识别个体面孔，记住友好或敌对的人类，并将这种记忆传递给后代。这种**社会学习**和**文化传承**能力表明，乌鸦不仅具备个体智能，还具备**集体智能**的特征。

在城市环境中，乌鸦展现出了惊人的**适应性创新**。它们学会了利用汽车碾压坚果，观察交通信号灯的变化规律，甚至学会了使用人类的工具。这些行为都体现了乌鸦对**复杂环境的**

理解和创造性适应能力。

从神经科学角度看，乌鸦大脑的结构为其高级认知能力提供了基础。虽然乌鸦没有哺乳动物的新皮层，但其前脑区域高度发达，神经元密度极高。这种独特的大脑结构支撑了乌鸦的工作记忆、执行控制和抽象思维能力。

乌鸦式智能的核心特征包括：**因果推理能力**——能够理解事件之间的因果关系；**抽象思维能力**——能够从具体情况中抽取一般规律；**创造性问题解决**——能够发明新的解决方案；**元认知能力**——对自己的认知过程有一定的认识和控制。

两种智能模式的深层对比

鹦鹉式智能和乌鸦式智能代表了两种根本不同的信息处理方式。鹦鹉式智能基于**模式匹配和统计学习**，通过大量数据训练获得特定任务的高性能表现。这种智能模式的优势在于**可扩展性、一致性和效率**，但缺乏**灵活性、创造性和真正的理解**。

乌鸦式智能则基于**因果推理和概念理解**，通过相对较少的经验就能够理解世界的运作规律，并创造性地解决新问题。这种智能模式的优势在于**灵活性、创造性和深度理解**，但在**一致性和可预测性**方面可能不如鹦鹉式智能。

从计算复杂度角度看，鹦鹉式智能通常需要**大量的计算资源和数据**，但一旦训练完成，推理过程相对简单。乌鸦式智能则可能在训练阶段需要较少的数据，但推理过程更加复杂，需要动态的因果推理和创造性思维。

从应用角度看，鹦鹉式智能更适合**结构化、重复性的任务**，如图像识别、语音识别、机器翻译等。乌鸦式智能则更适合**开放性、创造性的任务**，如科学发现、艺术创作、复杂问题解决等。

AI 的未来：向“乌鸦式智能”的艰难迈进

当前的人工智能发展主要集中在鹦鹉式智能的完善上。深度学习、大数据、云计算等技术的发展，使得我们能够构建越来越强大的模式识别和统计学习系统。然而，要实现真正的人工智能——即具备人类水平的通用智能，我们必须向乌鸦式智能迈进。

现有的 AI 系统，即使是最先进的语言模型和图像识别系统，都还处于“鹦鹉式智能”阶段。这些系统依赖于预定义规则、大量数据、大量计算资源来完成特定任务，但缺乏真正的推理和创造能力。虽然这类 AI 能够生成看似“智能”的对话，但它们的智能基于模式识别和数据驱动，与鹦鹉能模仿人类发音但不理解其语义一样。

以 ChatGPT 为代表的大型语言模型，虽然在模仿人类语言并生成连贯对话方面表现出色，但它们并不具备关于“意义”的主观理解。这些模型无法感知、体验或有意识地推理，只是基于统计模式和相关性，根据输入生成最有可能符合上下文的回应。因此，大语言模型更多是“聪明的猜测”，而非真正的理解。这与人类的理解方式存在本质差异。

向乌鸦式智能迈进面临着多重**技术挑战**：

因果推理的实现：当前的 AI 系统主要基于相关性学习，而非因果关系理解。要实现乌鸦式智能，需要开发能够理解和利用因果关系的算法和模型。

常识推理的建模：人类和乌鸦都具备丰富的常识知识，能够在新情况下灵活运用。如何将常识知识有效地编码到 AI 系统中，仍然是一个重大挑战。

创造性思维的算法化：创造性是乌鸦式智能的核心特征，但如何用算法实现真正的创造性思维，目前还没有明确的技术路径。

元认知能力的构建：乌鸦式智能需要具备对自身认知过程的认识和控制能力，这要求 AI 系统具备自我反思和自我改进的能力。

尽管挑战巨大，但已经有一些**有希望的研究方向：**

神经符号 AI：结合神经网络的学习能力和符号系统的推理能力，试图实现既能学习又能推理的 AI 系统。

因果 AI：专门研究因果推理的 AI 技术，试图让机器理解事件之间的因果关系。

元学习：研究如何让 AI 系统“学会学习”，具备快速适应新任务的能力。

认知架构：借鉴认知科学的研究成果，构建模拟人类认知过程的 AI 系统。

AI 的未来发展目标是朝着“乌鸦式的智能”迈进，不仅能够模仿，还能推理、学习、适应，在跨任务和多变的环境中展现出灵活的创造力。实现与生物智能相媲美的灵活性和创造力，正是“强 AI”或“通用 AI”所要追求的方向。

这个转变不仅是技术上的挑战，也是**哲学和伦理上的挑战**。当 AI 系统真正具备了乌鸦式的智能——能够理解、推理、创造时，我们需要重新思考机器与人类的关系，以及智能的本质和意义。

综上所述，人工智能是模拟、延伸和扩展人类智能的理论、方法、技术及应用系统的综合学科。从鹦鹉式智能到乌鸦式智能的发展，不仅代表了技术的进步，更代表了我们智能本质理解的深化。而数学，作为描述和分析复杂系统的精确语言，正是我们理解和实现这一宏伟目标的核心工具。无论是当前的统计学习方法，还是未来的因果推理和创造性算法，都离不开数学的支撑和指导。

第二章 智能，生于数学

简明数学史

内容提要

- 萌芽：结绳计数与位值制
- 初等：几何、公理化与证明
- 近代：变量/函数、微积分与解析几何
- 现代：集合论、逻辑与可计算性
- 三次数学危机（无理数、微积分基础、集合论悖论）

“如果人们不相信数学很简单，那是因为他们没有意识到生活有多复杂。”

— 约翰·冯·诺伊曼

智能的历史可以追溯到人类最早期的思维活动，而数学是其中最重要的基础工具之一。本章将按“萌芽—初等—近代—现代”的时间脉络，说明数学观念如何层层抽象，并在每一步为后来的计算与智能埋下线索。

对于古代人来说，数字的发明源于对数量的需求。无论是借手指计数，还是用其他物体辅助，人类通过千年的发展，逐渐完善了从简单符号到抽象数字的演变。今天看似“自然”的自然数概念，其实是无数社会实践与思想试验的沉淀。正是这些最初的表征与规则，使“可计算的表示”成为可能。

人类对“智能”的探讨源远流长。远在古代希腊时期，哲学家们就已经开始追问：什么是智慧？什么是理性？我们如何通过思维去理解这个世界？从那时起，人们就梦想着创造能自主思考的机器：皮格马利翁（Pygmalion）、代达罗斯（Daedalus）、赫淮斯托斯（Hephaestus）等可被视为传说中的发明家，而加拉蒂亚（Galatea）、塔洛斯（Talos）与潘多拉（Pandora）则可被视为人造生命 [OvidMartin2004, Sparkes1996, Tandy1997]。这些想象后来在科学与工程中转化为“问题—表示—算法—数据”的框架，神话中的愿景开始落地为可检验的系统。

这些问题不仅关乎哲学，还对现代科学和技术的发展产生了深远影响。随着时间推移，这种对智能的追问从哲学的纯理论思辨，逐渐转向了科学与工程的实践领域。早期的数学家如欧几里得、阿基米德以及笛卡尔等，通过逻辑和结构化的思维方式，为计算与智能提供了基础：欧氏公理化对应模型的可验证性；笛卡尔坐标促成连续空间的特征化；阿基米德近似展示了可计算思想的雏形。数学逐渐从实用算术走向系统推理，成为连接抽象理念与工程实现的桥梁。

数学的发展史可以粗分为四期：萌芽、初等、近代与现代。这些分期并非泾渭分明，而是层层叠加与概念外延的扩展。为把握演化主线，接下来我们依次回顾四个阶段的关键观念与方法，并在节末用 *examplebox* 收束为“AI 建模要点”。

2.1 萌芽时期：从计数到位值制

数学的萌芽时期从远古时代延续至公元前 5 世纪，是人类最早利用数学工具应对日常生活需求的阶段。通过手指计数、刻痕和结绳，人类逐渐形成自然数的概念与四则运算雏形，为后续的几何与代数提供了素材和直觉。总体上，这一时期以“就事论理”的经验法则为主，但已显露出从数与形中提炼稳定规则的趋势。

2.1.1 史前数学：日常需求与实用计算

在公元前 5 世纪之前，数学并非独立学科，而是伴随人类生活的需求逐步发展的：牲畜计数、土地丈量、历法制定与贸易核算等场景催生了各种方法。古代美索不达米亚与埃及的泥板和石刻清楚记录了这些活动，展现了数学与生活实践的紧密联系。

“数学”活动最古老的痕迹之一是在美索不达米亚发现的一块泥板（约公元前 2500 年）。泥板记录了这样一个计算：如果谷仓里有 1152000 份粮食，每个人分得 7 份，一共可以分给多少人？结果是 164571 人，即用 1152000 除以 7 的结果。这说明在算术“成书”之前，美索不达米亚的会计师们已经能熟练地进行除法运算。甚至，书写完全有可能就是为了记账才发明的一若真如此，数字就比字母发明得还要早了。

古埃及人发展了基础的几何公式，在建造金字塔时已经能够运用高度和角度的几何关系；美索不达米亚的会计师不仅掌握了加法和乘法，还能解简单的二次方程，用于管理粮食和资源。巴比伦人对天体运动的观察与历法推算也推动了数学的发展。为了精确预测日食、月相以及制定历法，天文学家需要处理大量的时间和角度计算。这些天文观测不仅进一步提升了对测量和计算的要求，也推动了几何与代数的发展。

总体而言，这一阶段的数学活动是解决问题的经验性工具，尚未形成系统理论，但奠定了“数”与“形”的概念基础。这些先于理论的操作共同催化出对“可复用规则”的渴望，从而引向更稳健的记数手段。问题也由一次性的分配与测度，转向对“如何表示与传递数量”的一般方法。

2.1.2 手指：长在身上的计数器

相信你在许多影视剧中都见过这样的一幕：一位算命先生，掐指一算，口中念念有词。这种“掐指一算”看似神秘，实则源自于古老而简便的计数方法。

在远古时代，用手指计数是再自然不过的选择，手指是人类最早的“随身计算器”。它帮助人们轻松应对日常计数需求，如记录牲畜数量、物品交换量，推算季节与节气，安排农耕节日等活动。由此，一个从身体到符号的过渡被打开：手指结构为进制与位权提供了直觉。

手指的构造与多种进制系统有着天然的联系。稍加思考，我们就能找到十进制、二十进制、十二进制等计数法与手指构造的对应关系。

十进制 (Decimal System) 是最常见、最自然的计数方式，与双手十指自然对应。十进制系统在全球的广泛使用，源于人类天生拥有十根手指的解剖学特征。正如爱德华·卢卡斯所言，这是“自然界的一个偶然事件”。



图 2.1: “掐指一算”

十二进制 (Duodecimal System) 则适用于更复杂的计数需求。除大拇指外，四根手指各有三段指节。一只手的拇指轮流指向其余四根手指的各段指节，可以计数 1 到 12。这种方式在古代美索不达米亚和古埃及广泛应用，至今仍用于时间和角度的计数系统中，如 12 小时制、一年 12 个月等。

六十进制 (Sexagesimal System) 则更加复杂。它结合双手来计数。一只手用于计 12（与十二进制相同），另一只手的五根手指则记录 12 的倍数，五轮 12 等于 60。六十进制在古巴比伦时期被发明，沿用至今，广泛用于时间和角度的计量，例如 1 小时 = 60 分钟，1 分钟 = 60 秒，以及 360 度的圆周划分。

二十进制 (Vigesimal System) 也是一种古老的计数法。为了更大范围的计算，一些古代民族不仅用手指，还加上脚趾来计数。例如，中美洲的玛雅文明和阿兹特克文明，以及现今的西非和欧洲部分地区，采用了以 20 为基数的计数法。

二十进制的痕迹在许多语言中依然存在。现代英语中的“score”表示 20 的用法便保留了这一印记。例如，莎士比亚在《圣经》英译本中使用“three score and ten”（20 的 3 倍加 10，表示 70 岁）来指代古稀之年；林肯在《葛底斯堡演讲》中使用“four score and seven years ago”（20 的 4 倍加 7，表示 87）来表达 87 年前的历史。一百年后，马丁·路德·金在其著名的演讲《I have a dream》中说“Five score years ago”（20 的 5 倍，即 100 年前）。英国曾有一个 12 与 20 进制组合的货币系统：1 英镑 = 20 先令，1 先令 = 12 便士。1971 年，英国引入了十进制货币系统，1 英镑 = 100 便士，先令在 1990 年后彻底退出流通。在法语、丹麦语和巴斯克语中也能找到二十进制的痕迹。例如，法语中的数词从 quatre-vingts(80)、quatre-vingts-dix(90)，到 quatre-vingts-dix-neuf(99)。同时，这些语言中还混杂了六十进制的痕迹，如数词 soixante(60) 到 soixante-dix-neuf(79)。

手指不仅是身体的一部分，还是人类最早的天然计算工具。它帮助我们理解和组织世界，并为现代数学中的位值制和进制系统提供了最初的灵感。直到今天，手指仍是许多人在进行简单计算时的本能工具。

2.1.3 荒岛上的自然教育，人类数字文明的缩影

设想你在一次航海探险中遭遇风暴，不幸漂流到了一个无人岛。没有手表和手机，也没有任何现代工具。你很快面临一个问题——如何计算时间？如何记录每天收集的食物？在这种完全回归自然的环境中，你必须依靠最原始的方式来解决这些问题。这个经历，其实正是早期人类如何发明和发展数字的缩影。

手指计数：最简单的工具

你的第一反应可能是用手指来计数。十根手指天生就是人类最便捷的“计算器”，帮助你快速记录简单的数量——比如你捕到的鱼或采摘的果实。手指计数是直观而方便，几乎无需思考就能完成。但很快，你意识到这种方法有明显的局限性：当数字变大，或需要记录更复杂的信息时，手指显然不够用了。更重要的是，手指计数无法保存这些数据，一旦忘记，你的记录便随之消失。（抽象：易得的“工作记忆”vs. 可复查的“外部记忆”。）

刻痕计数：更长久的记录方式

为了更长久地保存记录，你开始在岛上的树木或石头上刻下痕迹。每道刻痕代表一天的过去，或你每天捕获的鱼或采摘的果实数量……。刻痕计数法让你能够更长久地保存这些信息。每天的刻痕不断累积，形成一个记录时间和活动的系统。这种方法虽然简单，却比手指计数更加持久、可靠，也能应对稍微复杂的需求，比如记录日期或特定的事件。然而，随着时间的推移，刻痕的数量增加，管理这些信息变得越来越困难。你开始需要一种更便捷、更灵活的方式来记录和传递这些信息。（AI 启发：从短上下文到外部存储/检索—RAG 的原型。）

结绳记数：更高级的记数法

幸运的是，你发现了一根绳子，这给了你一个新的选择——结绳记数法。通过在绳子上打不同的结，你可以标记不同的天数、事件或物品的数量。不同形状和位置的结可以表示不同的信息。相比于刻痕，结绳计数法更便捷灵活，更易于携带和传递，成为你在荒岛生活中的高级计数工具。（抽象：符号化与压缩编码；启发：离散化/量化。）

你在荒岛上的探索，正是人类数字文明进化的缩影。无论是刻痕还是结绳，这些方法都体现了人类从最初的物理标记到复杂符号系统的演化路径。通过这些自然的计数方法，你逐步掌握了记录、比较和计算的基本概念。这不仅是你个人的“自然教育”，也是数字发明的最初动力——让生活更加便捷和高效。（一句话抽象：需求—表示—外部化—标准化的演化链。）

从需求出发，人的记数方式沿着“即时—留痕—编码”的路径外化与标准化。下文据此上升到一般而稳定的表示——位值制。

2.1.4 数字的位值系统

在人类早期文明中，简单的手指计数和结绳、刻痕等方法已广泛用于记录数字。然而，随着社会的发展，这些物理标记在处理更复杂和更大范围的数字时，显得低效而繁琐。于是，更加抽象的符号系统应运而生，催生了**位值制**这一革命性的数字表示方式，使得复杂的数值能够通过简单的符号位置来表示和计算。

早期的计数系统大多采用**加法规则**。例如，在古代巴比伦的黏土板上，数字是通过符号的重复来表示的：数字“1”用一个符号表示，数字“2”用两个相同符号表示，数字“3”则用三个相同符号。

这种计数方式在中文数字、罗马数字、古印度的婆罗门数字和笈多王朝使用的数字，以及大洋彼岸的玛雅数字中都很常见。大多数古代文明在表示前三个数字时，都采取了同样的方式：重复表示“1”的符号一次、两次、三次。古代的中文“一、二、三”、钟表盘上的罗马数字“I、II、III”、阿拉伯数字也体现了同样的重复方式。可是，从数字4开始，所有的文明就都放弃了这种重复。为什么呢？

研究发现，人类的数感对少于3的数字有天然的反应，但超出这个范围后，单纯的重复符号便变得困难。对一些出生几个月的婴孩进行试验，结果证实人类与生俱来的数感的容量不超过三。

试想一下，数字13若用重复排列“1”的符号13次来表示，无论是对书写还是阅读，都会很低效——怎么能一眼就看出它是13，而不是12或者14呢？

类似的问题在罗马数字系统中也很常见。罗马数字系统中，V表示5，X表示10，L表示50，C表示100。此外，向右添加符号为加，如VI表示数字6，XI表示数字11；相反地，向左添加一个更小数值的符号为减，如IV表示4，IX表示9。尽管使用了加减法规则的计数系统十分直观，但在表示大数时显得十分低效。例如1888年写成罗马数字就是MDCCCLXXXVIII，甚至无法有效表示类似100万那样的数字——除非把1000个M排成一排！

早期加法型记数（如罗马数字）在表达大数与运算效率上受限。位值制用“位置决定权重”的方式，以极少符号表达极大数量，长度近似 $\log x$ 。这不仅简化书写与计算，也带来压缩与编码的思想（最短码长度 $\approx -\log p$ ）。位值制因此成为现代信息处理与计算架构的共通底座。

随着人类文明的发展，许多地区开始引入更为先进的计数法，其中最具革命性的是**位值制计数法**。古巴比伦、中国，尤其是印度和阿拉伯，率先采用了这种创新的位值制计数法。这种计数法的关键在于符号的位置决定了其数值。例如，数字“12”和“21”虽然使用相同的符号，但因为符号位置不同，代表的数值也不同。

位值计数法具有出众的简洁性。通过有限的符号，可以表达任意大的数值。例如， 10^{100} 这个超出了物理限制的天文数字，在位值制下仅需101个符号即可表示——一个“1”后面跟着100个“0”。位值计数法用极短的符号链表示极其巨大的数值。

位值制不仅提高了数字的表示效率，还反映了数字的**对数增长**特性，即随着数字的增大，所需的符号长度呈对数增长，符号数量远远少于数字本身的大小。例如，表达 10^{100} 所需的符号长度约为 $\log_{10}(10^{100}) = 100$ 。一般地，表达任意整数 x 所需的符号数量接近 $\log_{10} x$ 。因此，

从某种意义上，位值计数系统是最简洁、甚至最优的。（信息论视角：最短码长度 $\approx -\log p$ 。）

位值制的引入是人类计数方法的一次重大飞跃。从简单的重复符号到高度抽象的符号系统，位值制极大简化了计算过程，推动了计算和数学的发展，奠定了现代数字系统的基础。（一句话抽象：位权 $\Rightarrow$ 表达与计算的指数增益；AI 启发：词表/位宽/量化。）

2.1.5 位值制与对数增长在现代计算机中的应用

在计算机科学中，在已经排好序的数组中查找某个元素的时间也是数组长度的对数。即使数组规模如同宇宙般庞大，经过几百次迭代后，便能够找到所需的元素——唯一的限制就是光速有限性所带来的信息传播和处理速度的物理极限。

互联网的 URL 是位值制与对数增长在数据处理和网络寻址中的一个典型应用。一个简短的 URL (Uniform Resource Locator, URL, 统一资源定位符) 迅速定位到海量信息。想象一下，你希望在网上搜索某项信息。尽管互联网上的数据量可能以 EB(10^{18} 字节) 甚至 ZB(10^{21} 字节) 计量，只要拥有对应信息的 URL，你几乎瞬间就能找到目标信息。这正是对数增长的强大之处：即使面对巨大规模的数据集，只需少量步骤就能完成检索。

此外，URL 的简短程度令人惊叹，其长度是整个网络大小的对数！这意味着我们可以轻松将 URL 存储在内存中，而 URL 指向的信息量却远远超出了其自身长度。这种简洁有效的特性，展示了对数增长在计算与信息处理中的关键作用。

IPv4 和 IPv6 的设计正是对数增长在实际应用中的另一个实例。IPv4 地址使用 **32 位** 二进制数来表示，每个 IP 地址可以被写成 4 个以点分隔的十进制数（如 192.168.1.1），每部分对应一个 8 位的二进制数。32 位的二进制能够生成 2^{32} ，即约 **43 亿** 个唯一 IP 地址。这在 IPv4 设计之初被认为是足够庞大的数目。然而，随着互联网的迅速扩展，特别是物联网（IoT）设备和移动设备的广泛普及后，IPv4 的 43 亿个地址空间将很快耗尽。

为了解决这一问题，**IPv6** 应运而生。IPv6 使用 **128 位** 二进制数表示，由八组以冒号分隔的 16 进制数构成（如 2001:0db8:85a3:0000:0000:8a2e:0370:7334）。这种 128 位的二进制表示能生成 2^{128} ，即约 3.4×10^{38} 个唯一 IP 地址，相当于为地球上的每粒沙子分配多个 IP 地址。这一数量级足以应对未来几十年甚至几百年内所有联网设备的需求。

IPv4 和 IPv6 的位数与它们能够支持的地址数量之间的巨大落差，展示了对数增长的强大力量。IPv4 仅用 32 位符号就能表示 43 亿个地址，而 IPv6 仅用 128 位符号就能支持 3.4×10^{38} 个地址。随着位数的增加，IP 地址系统实现了指数级的扩展，同时保持了地址表示的简洁性。（AI 去向：索引结构/向量检索/稀疏路由一见 8.2、8.5。）

下一节我们从“表示的效率”转向“表示的抽象度”。

2.1.6 数字：从具象到抽象

几千年来，人类都在探索如何建立数与物的对应关系，现代数字系统的定义正是基于这种探索的延续。一旦人类掌握了计数，数字系统的应用就变得“自然而然”了。或许正因如此，我们才称自然数为“自然”数 (natural number)。然而，实际上，数字的概念一点也不“自然”。

无论是在早期人类在骨头及木棍上有序地刻下划痕，还是结绳或是在容器中放置物品无论是结绳，这些早期方法已代表了相当抽象的符号系统，其中抽象的数学对象与自然中的实际物体之间的分离，同一个数字既可以表示动物的数量，也可以记录借贷量或一个月的天数。自此之后，数学研究的对象不再是必须与实际物体相关的几何图形和数字。研究对象性质的变化，最终引发了解决数学问题的方法的革命。（AI 启发：可迁移表征与多任务共享—抽象层提高，泛化/可解释间的取舍加剧。）

抽象提高了可迁移性，也带来语义漂移与解释性的张力。

2.2 初等数学时期：从计算到推理

公元前 5 世纪开始，数学进入了初等数学时期。这个时期的数学探索更加系统和深入，尤其是在欧几里得几何和代数方程的研究中，数与形的关系得到了更加严谨的探讨，算术、几何、代数和三角等数学分支逐渐成形。

公元前 5 世纪起，欧几里得几何与代数方程的研究使数与形的关系走向严密，算术、几何、代数与三角逐渐定型。核心转变在于：从求值走向论证，从技巧走向体系。

2.2.1 数学的真正诞生：从计算到推理

数学作为一种学科，经历了漫长的演化过程。起初，数学的诞生是为了解决生活中的实际问题—如何计数、测量、交易、管理时间等。在公元前 5 世纪之前，埃及和美索不达米亚等古老文明的数学发展更多地依赖于经验和实际操作，主要集中于如何进行计算，服务于土地测量、建筑工程、会计管理以及天文学等日常需求。

这种实用性的数学（包括算术和几何）在数学史上称为“史前”数学，因为它并不涉及抽象推理，而是围绕日常需求展开。

古代文明的数学多服务于实践；希腊学者把关注点转向命题的可证性。等腰直角三角形三边皆为整数的设想，化为方程 $2x^2 = y^2$ 。穷举无效，转而假设互素并分类奇偶，导出矛盾，因而无解。由此，数学的目标从“得到一个数”变为“给出必然理由”。这一转折打开了更广阔的对象与方法空间。

因此，教科书中的数学史往往是从公元前 5 世纪的希腊开始讲起的，因为希腊数学家让数学从“如何计算”进化到了“为什么如此”。

在公元前 5 世纪的希腊，毕达哥拉斯学派提出了这样一个问题：找出一个等腰直角三角形，使其三边的长度都是自然数。假设等腰直角三角形的直角边长度为 x ，斜边长度为 y 。根据毕达哥拉斯定理（勾股定理）， y^2 就等于 $x^2 + x^2$ 。因此，这个问题最终归结为：找出两个自然数 x 和 y ，使得

$$2x^2 = y^2. \quad (2.1)$$

让我们来试试 4 以内所有 x 和 y 的可能性吧（见表 2.1）。

表 2.1: 4 以内 x 与 y 的所有可能性

x	y	$2x^2$	y^2
1	1	2	1
1	2	2	4
1	3	2	9
1	4	2	16
2	1	8	1
2	2	8	4
2	3	8	9
2	4	8	16
3	1	18	1
3	2	18	4
3	3	18	9
3	4	18	16
4	1	32	1
4	2	32	4
4	3	32	9
4	4	32	16

在上述所有情况里， $2x^2$ 都不等于 y^2 。我们当然还可以在更大的数字范围里继续寻找。事实上，毕达哥拉斯学派很可能寻找了很久，却没能找到解。后来，他们终于相信这个解不存在。他们是怎么说服自己这个解不存在的呢？显然不是穷尽所有的数对，因为这样的数对有无穷多个（且为可数集）。你就算试到 1000 甚至 100 万，证实没有数对能满足条件，可你还是没法保证在更大的数字里面不可能有解.....

既然不能用穷举法，那就试试逻辑推理。不妨假设 x, y 两个数互素。为什么呢？因为若 x, y 至少有一个是奇数时，两者自然互素；反之，若 x, y 都是偶数，则总是可以通过消去公因子来保证 x, y 至少有一个是奇数。据此，我们把数对 x, y 分成以下 3 种情况：

1. x, y 都是奇数；
2. x 是偶数， y 是奇数；
3. x 是奇数， y 是偶数；

我们先从第一种情况开始： x 和 y 都是奇数。此时 (2.1) 的解不存在。因为 y 是奇数，则 y^2 也是奇数。它不可能等于 $2x^2$ ，因为后者必然是偶数。这一论证也同样适用于第二种情况，即 x 是偶数而 y 是奇数。第三种情况即 x 是奇数而 y 是偶数。但在这种情况下，若 $2x^2 = y^2$ 成立，则这个数的一半 x^2 是奇数，同时 y^2 的一半却是偶数——这两个数不可能相等。综上所述，找不到两个自然数 x, y 满足 (2.1)。

为了证明这个问题没有解，毕达哥拉斯学派采用了逻辑推理而不是计算来实现。他们通过分类讨论和推理，证明了无论 x 和 y 是奇数还是偶数，方程 $2x^2 = y^2$ 都不可能有整数解。

这一问题的解决在数学史的发展上具有划时代的意义。它的革命性不仅在于其对未来数学的巨大影响，还在于其抽象性及解决的方法。相比于美索不达米亚泥板上铭刻的诸如“将 1152000 份粮食除以 7 份”的具体问题，毕达哥拉斯学派的问题更为抽象：美索不达米亚的会计师关注粮食的数量，而毕达哥拉斯学派的问题仅涉及数字本身。同样，他们处理的是抽象

的几何形式，而非具体的三角形田地。从从粮食的份数到数字，从实际的土地测量转向几何学的抽象思考，迈向抽象这一步的意义不可小觑。田地的面积无非几平方千米，而抽象的几何对象则可以轻松超越这一尺度，进入无限的范围。

古希腊数学家不再满足于计算结果，而是开始重视推导过程。他们通过严谨的逻辑推理，逐步构建了数学证明和公理系统。这一从计算到推理的转变，被视为数学的真正诞生，使得数学从日常的计算工具演变为以推理和抽象为核心、具有高度抽象和严谨逻辑的独立学科。

一个平方数不可能是另外一个平方数的两倍—这个由毕达哥拉斯学派在 2500 多年前得到的结果，迄今在数学上仍占有重要地位。它证明了，一个短边为 1 米的等腰直角三角形中，斜边的长度为 $\sqrt{2}$ ，约 1.414，但这个数无法通过两个自然数 y 和 x 的比值得到。这揭示了，某些几何关系无法通过自然数的四则运算（加、减、乘、除）运算得到，暗示了更广泛的数系—实数的存在。这一发现让数学进入了一个全新的领域—从实际问题中抽象出纯粹的数学对象并通过推理得出结论。虽然这一发现具有革命性，但毕达哥拉斯学派并没有进一步发展出实数的概念。对他们而言，这一结论动摇了他们对自然数“万物皆数”的信仰，甚至引发了哲学上的困惑与争议。然而，几百年后，这一发现启发了数学家们发展出实数理论，为数论和分析学的诞生奠定了基础。（AI 启发：超出“有理”可表达性的现象推动了更大状态空间的建模—如连续表征与实值网络。）

2.2.2 毕达哥拉斯：数与宇宙的关系

数学的哲学化起点源自古希腊的毕达哥拉斯学派。毕达哥拉斯 (Pythagoras) 及其追随者提出了“万物皆数”的思想，认为宇宙的本质可以通过数来理解。这一理念激励了希腊数学家们将数学视作解读自然现象的工具。毕达哥拉斯定理（即勾股定理）是这一学派最著名的成就之一，标志着数学开始从经验性计算向理性推理的迈进，开启了数与形结合几何学研究。（AI 去向：几何先验 → 物理世界建模；见 9.2 几何深度学习。）

2.2.3 欧几里得：公理化体系的奠基人

如果说毕达哥拉斯奠定了数学的哲学基础，那么欧几里得 (Euclid) 则为数学建立了逻辑结构。他的《几何原本》(《Elements》) 是古代数学史上最具影响力的著作之一，也是现代数学公理化体系的奠基之作。

欧几里得通过公理和定理的形式，系统地将几何学结构化，强调了证明的重要性。欧几里得展示了如何从少数的基础假设（公理）出发，通过严密的逻辑推导，推导出一系列复杂的几何命题。这种公理化方法对后世的数学家产生了深远影响，甚至成为了现代数学研究的重要框架。欧几里得的几何不仅仅是关于形状和空间的学问，更标志着数学作为一种基于推理的演绎学科的正式诞生。（AI 启发：明确假设集 $\Rightarrow$ 可复现实验与安全边界；见 10.1 可验证与可信 AI。）

2.2.4 阿基米德：数学与物理的桥梁

阿基米德（Archimedes）是古希腊另一位杰出的数学家，他不仅在数学领域取得了重大的突破，还在物理学、机械学等领域做出了重要贡献。阿基米德将几何与物理现象紧密结合，开创了利用数学模型解决物理问题的先例。

他在几何领域的突破，如圆周率的近似计算、浮力定律及流体静力学基本定理的证明，展示了数学在物理学应用中的强大力量。阿基米德的工作不仅扩展了数学的应用范围，还展现了数学在解释自然现象中的力量。（AI 去向：连续量的近似—数值稳定/误差控制；见 8.2 优化与数值性。）

2.2.5 亚里士多德：逻辑与推理

亚里士多德（Aristotle）是古希腊著名的哲学家。亚里士多德认为，数学不应只停留在经验性的层面，而应该通过演绎推理去发现隐藏在事物背后的逻辑关系。他提出的三段论和归纳法，帮助数学家们更好地理解和构建逻辑推理过程。这种逻辑推理体系推动了古希腊数学的进一步发展，数学家们开始通过推理和证明而非直观的经验得出结论。（AI 启发：符号推理与统计学习的互补；见 11.3 神经—符号融合。）

算术与几何这两大分支的创立，标志着数学开始作为一门理论化学科的诞生，逻辑推理和证明逐渐成为数学的核心方法。与此同时，代数学在这一时期取得了重要进展，自然数、有理数和无理数的运算逐渐成为代数的核心主题。除此之外，这一阶段的代数学还开始引入虚数，推动了数的概念向更广的领域扩展。

2.2.6 古希腊数学的遗产

通过抽象思维和逻辑推理，建立了数学作为一种独立学科的基础。古希腊数学家们的贡献不仅仅是发现了一些几何定理和代数法则，更重要的是他们发展了数学思维的方式—通过演绎、证明、公理化等方法，将数学从经验性工具转变为一种严谨的科学。这一传统不仅奠定了现代数学的基础，还推动了之后数千年数学和科学的进步。（一句话抽象：证据链 $\Rightarrow$ 可靠知识；AI 去向：可解释与可证明的系统。）

中世纪的阿拉伯数学家翻译了希腊经典，并引入了印度的十进制数和“零”的概念。阿尔·花刺子密（al-Khwarizmi）等数学家对代数学的发展做出了巨大贡献，他的著作奠定了代数理论奠定了坚实的基础。（“algorithm”一词即源于其姓名的拉丁化形式。）

中国的《九章算术》和印度的基础代数成就，也为初等数学的发展增添了重要内容。中国古代数学强调实用性，广泛应用于农业、建筑和税务管理；而印度数学则对数论和代数的早期发展做出了杰出贡献。这些不同文化的数学成果，最终共同塑造了初等数学的广阔基础。

这一时期涵盖了公元前 5 世纪到 17 世纪前的数学发展。数学不再仅限于解决实际问题，而是向抽象领域迈进。古希腊数学通过几何学和数论的研究，构建了数学推理和证明的数学体系。这一阶段的数学成就不仅构成了今天中学数学的主要内容，还对现代数学的基本理论

结构产生了深远的影响。

2.3 近代数学时期：变量、函数与微积分

从 17 世纪开始，随着资本主义的崛起和工业革命的推动，数学进入了一个全新的阶段——变量数学时期。这一时期的数学从研究静态图形和数量问题逐步转向关注变化与运动问题，变量和函数的引入是更好描述运动和变化的关键。

牛顿和莱布尼茨分别独立发明了微积分，标志着数学史上一个重要的转折点。微积分提供了一套精确描述连续变化与瞬时变化的数学工具，成为解决诸如速度、加速度、曲线下面积等问题的强大工具。牛顿通过微积分为物理学中的万有引力定律奠定了理论基础，而莱布尼茨则将微积分符号化并推广到欧洲，极大地推动了数学的发展。微积分不仅让数学得以分析瞬时变化，还为后续的数学分析开创了新的方向。

解析几何的诞生是这一时期的另一个重大突破。笛卡尔通过引入坐标系，将几何与代数结合起来，使得复杂的几何图形、物理的运动及其空间关系可以通过代数方程来精确描述。借助于笛卡尔坐标系，数学家们能够用代数表达曲线、直线的关系，从而简化了几何中的很多问题。解析几何不仅为物理学中的动力学提供了有力工具，还为现代数学的发展铺平了道路。

近代数学时期的另一个重要分支是概率论。概率论起初由费马和帕斯卡为了研究赌博中的随机事件而诞生，但很快超越了这一领域，成为研究不确定性和随机现象的重要工具。费马还对数论做出了重要贡献，提出了许多关于素数与数之间关系的问题，激发了后世数学家对数论的广泛研究。欧拉、拉格朗日等人进一步推动了数论的发展，探讨了代数结构和数论的基本问题。

与此同时，分析学作为微积分的延续，成为这一时期的核心数学分支。通过函数和极限概念的引入，数学家们能够处理无穷小量和变化中的量，开创了分析学的时代。数学分析不仅成为这一时期的核心理论，不仅解决了古希腊时期悬而未决的几何问题，还广泛渗透进了物理学、天文学和工程学，极大地推动了科学的进步。（AI 启发：梯度/最优化—现代深度学习的计算内核。）

总的来说，近代数学时期不仅为数学的进一步抽象化奠定了基础，还通过微积分、解析几何和概率论的兴起，彻底改变了人类对世界的理解方式。数学在这一时期的变革性进展，成为了现代数学发展的根基，也为科学技术的进一步进步提供了强有力的工具。（一句话抽象：变化、空间与不确定性三件套；AI 去向：优化、几何表示、概率图模型。）

2.4 现代数学时期：抽象、结构与计算

从 19 世纪中叶起，数学进入了一个高度抽象化和系统化的阶段，被称为现代数学时期。这个时期的数学阶段不仅延续了之前的分析学发展，还引入了全新的几何和代数理论。代数、几何和分析学等传统学科在此期间发生了质的飞跃，数学的研究对象和方法也逐渐向高度抽象化发展，推动了数学成为一门更加系统和广泛应用的科学。

现代数学的一个显著特征是对数学基础的重新审视与抽象概念的扩展。罗巴切夫斯基和黎曼的非欧几何，颠覆了传统欧几里得平面几何观，提出了球面和鞍面等不同几何结构，揭示了更为广泛的空间和结构关系。拓扑学作为新的分支，也在 19 世纪逐渐兴起，打破了传统几何的局限，成为数学研究连续性、边界与形态的重要工具。

同时，现代数学的发展离不开对无穷概念和数学基础的深入研究。康托尔的集合论，为处理无穷大的数学研究提供了严格的工具，将无穷大和无穷小的概念精确化，成为现代数学和数理逻辑的基础理论之一。集合论的发展不仅使数学在抽象层面上得以统一，还激发了对数学自身基础的研究。集合论和数理逻辑的兴起为数学理论提供了全新的理论框架，希尔伯特、哥德尔等数学家在此领域的工作，使得数学的公理化体系进一步得到发展与完善。

20 世纪，统计学、拓扑学、泛函分析等新分支陆续创立，使数学更多元化、更富实用性。数学在众多领域的应用范围得到了前所未有的扩展，数学在物理学、工程学、经济学以及其他自然科学和社会科学等各个学科中的作用变得愈加重要。(AI 去向：统计学习理论、泛函空间中的核方法与 RKHS。)

现代数学时期的另一个重要推动力是计算机的发明和信息技术的迅猛发展。20 世纪中期，图灵、冯·诺依曼等科学家为计算机科学奠定了理论基础，计算理论逐渐成为数学的重要分支。计算机的强大计算能力使得复杂的数学问题得以快速求解，同时也极大地推动了数理逻辑和算法理论的发展，数学的潜能和边界更进一步发掘。(一句话抽象：可计算/复杂度的边界塑造了“可做之事”。)

随着数学的抽象化与理论化趋势日益加深，数学在深入自然科学领域的同时，还广泛渗透到信息科学、工程学、经济学、社会科学等多个领域，推动了现代社会各个层面的进步。现代数学逐渐成为理解自然世界、构建理论模型和推动技术创新的核心力量。

总之，现代数学时期是数学高度抽象化、系统化的阶段。数学基础理论的深入研究与应用范围的广泛扩展，使得数学不仅在理论层面得到了重大发展，也成为了推动科学和技术进步的关键推动力。通过集合论、非欧几何、拓扑学和计算理论的引入与发展，数学在 20 世纪的进步为现代社会的各个领域带来了不可忽视的影响。(AI 去向：可计算性/复杂度 → 算法选择与系统设计的第一性约束。)

2.5 三次数学危机：从无理数到不完备

数学发展的历程中，曾三次面临深刻的理论挑战，这些危机不仅推动了数学的变革，也影响了其作为一门科学的根本性质。这三次数学危机分别发生在古希腊时期、17 世纪微积分的创立期以及 19 世纪末的集合论时代。每一次危机都促使数学家重新审视基本概念，重整方法论，进而把数学从工具性实践推高到更为抽象而严密的层次。(一句话抽象：边界被突破—再公理化—再出发。)

2.5.1 第一次危机：无理数的发现与算术信仰的破灭

第一次数学危机发生在古希腊，起因是**无理数**的发现。毕达哥拉斯学派主张“万物皆数”，但这里的“数”是指整数或整数之比，即有理数。他们认为世界的规律可以通过数与比例来完美解释，这一思想赋予了数学一种神秘的普适性。

然而，对边长为 1 的等腰直角三角形的考察显示斜边为 $\sqrt{2}$ ，不能表示为任意两个整数之比。这类“不可公度性”的发现，彻底动摇了毕达哥拉斯学派“万物皆数”（即万物皆有有理数之比）的信念，引发了数学史上的第一次重大危机。

无理数的存在打破了古希腊数学家对数字和比例的简化认识，表明数的体系并不完备，迫使数学家们不得不重新审视数的定义。（AI 去向：连续表征与几何先验一见 9 章。）

希腊人的直接应对不是立刻“发明”新数，而是**退回几何**：以线段、面积等几何量为操作对象，通过相似与比例关系间接处理“不可公度”量，暂不强求把一切写成有理数。欧几里得在《几何原本》系统化了这一做法，特别是第十卷区分可公度与不可公度线段，并借助欧多克索斯的**比与比例理论**回避了对“比值算术化”的执念——即便两段线没有公共度量单位，也能在几何中讨论“比”的相等与传递性；黄金分割便是典型例子。与此并行，连分数与欧几里得算法揭示了不可公度的结构性：当比例化归过程无法在有限步终止时，意味着超出有理数的尺度。

经过两个多千年的几何化安置，“无理量”主要以几何客体存在。17 世纪以后，随着代数和解析几何的发展，人们逐步承认仅靠有理数不足以支撑连续量的计算，无理量从几何比率过渡为算术中的合法公民，在方程、函数与近似计算中获得常规地位。19 世纪，柯西以极限刻画收敛与导数，魏尔斯特拉斯建立 ε - δ 语言，德德金用“截断”定义实数，柯西—康托尔以柯西列完备化给出等价刻画： $\mathbb{R}$ 被严格定义为完备有序域，有理与“无理”由此统一。此番危机在对象层面扩张了“数”的外延，在方法层面巩固了“由证明而非经验近似给出理由”的标准。（AI 启发：当离散词表不足以承载现象，引入连续表征与可微优化；见第 9 与第 8 章。）

无理数危机的解决是数学史上的一大转折点，经过了数代数数学家的努力。虽然无理数的发现带来了危机，但最终促使了数学向更高的层次发展。几何学的抽象化、代数学的进步以及实数体系的确立，标志着数学摆脱了毕达哥拉斯学派的局限，迈入了新的发展阶段。这场危机不仅将数的概念从有理数扩展到无理数，还为后来的数学分析和数论奠定了坚实的基础。

2.5.2 第二次数学危机：微积分基础的争议与解析

第二次数学危机出现在 17 世纪，伴随着**微积分**的诞生。微积分由牛顿和莱布尼茨独立提出，是解决变化率和曲线面积等问题的强大工具。

虽然在解决实际问题上取得了巨大的成功，但微积分的早期发展在理论上存在许多模糊之处，尤其是关于**无穷小量**（infinitesimals）的使用，引发了深刻的数学危机。微积分的核心思想之一是使用无穷小量来定义变化率和累积变化。比如，导数被定义为“函数的瞬时变化率”，而积分则表示曲线下面积的无限累加。然而，当时的数学家并没有严格定义什么是无穷小量，它既不能被归为零，也不是某个确定的数，以致于在某些推导过程中无穷小量一会等于 0，一会又不等于 0。这种模糊性使得微积分缺乏严密的逻辑基础，许多数学家无法接受

微积分作为严格数学工具的合理性。贝克莱等学者猛烈批评了微积分理论，指出其在逻辑上存在的缺陷，“微积分似乎依赖于‘幽灵般的消失量’”。

解决这一危机的关键在于**极限**（limit）概念的引入。17 世纪末至 18 世纪初，数学家们逐渐认识到，无穷小量可以通过极限概念加以精确描述。极限理论通过定义函数在某一点附近的行为，能够描述无穷小量趋于零的过程，避免对模糊无穷小量概念的依赖。

19 世纪，柯西和魏尔斯特拉斯等数学家通过引入**极限理论**，对极限、连续性、导数和积分的定义进行了重新审视，对微积分进行了严密的逻辑重构。

柯西首次明确使用极限概念来定义导数和积分，奠定了现代分析学的基础。而魏尔斯特拉斯则通过对极限的精确定义，彻底摆脱了无穷小量的概念，构建了严谨的微积分体系。极限概念取代了无穷小量，导数被定义为函数在某一点的瞬时变化率，积分则作为求和的极限。这一重新定义消除了无穷小量的模糊性，将微积分从模糊的直觉推导转变为明确的、严格的数学定义，确保了微积分中的推导和计算具有严格的逻辑基础。通过这种方式，微积分危机得到了全面解决，数学家们能够自信地使用微积分来解决变化率和复杂的动态问题。（AI 去向：梯度传播与稳定性分析一见 8.2。）

第二次数学危机的解决，标志着数学从经验性工具走向了更加严谨的理论体系。通过引入极限概念和分析学的系统化构建，数学家们不仅解决了微积分中的基础问题，还推动了现代数学分析的诞生。这一危机的解决具有深远的意义，不仅使微积分成为物理学、天文学、工程学等领域的基础工具，还推动了整个数学的发展。微积分危机的解决使得数学家们对数、函数和极限有了更深刻的理解，并奠定了未来分析学和数理逻辑的基石。

2.5.3 第三次危机：集合论与逻辑的悖论

第三次危机发生在 19 世纪末至 20 世纪初。康托尔创立**集合论**，用对角论证区分了可数与不可数（ $\mathbb{N}$ 与 $[0,1]$ 基数不同），证明幂集 $\mathcal{P}(X)$ 严格大于 X 本身；无穷不再是单一概念，而有层级与算术。辉煌背后，朴素的“任意性质确定一个集合”（不受限制的理解公理）却诱发自指式矛盾：**罗素悖论**断言“所有不包含自身的集合所成的集合”无论是否包含自身都矛盾；**Burali-Forti** 悖论显示“所有序数的集合”不可成立。问题骤然从“算得对”转为“体系是否自治”。

化解路径分叉而互补：其一，**形式化与公理化**。希尔伯特计划期望用有限方法证明数学的无矛盾性；证明论与可计算性随之萌芽。其二，**类型论**（罗素）以分层语法禁止自指，从源头切断悖论结构；后经演化影响了编程语言与验证（简单类型、依赖类型、同伦类型论等）。其三，**策梅洛—弗兰克尔 (ZF) 集合论**以外延、公理分离、替换、无穷、正则等公理约束“能当作集合”的对象，连同**选择公理**形成 **ZFC**，成为主流基础。更具颠覆性的，是**哥德尔不完备性定理**：只要体系足够强（能编码算术），就存在真而不可证的命题（第一定理），且体系无法用自身证明自身无矛盾（第二定理）。随后的独立性成果（如连续统假设 **CH** 由哥德尔与科恩分别证明在 **ZFC** 下不可判定）进一步揭示：一致性可相对证明，完备性不可苛求。

为了形象地说明罗素悖论，我们可以借用著名的**理发师悖论**：“他只为那些不自己剃须的人剃须”的理发师，谁给他剃须？无论理发师是否自己剃须，都会违反规则，这是一种**自指性**

悖论，在逻辑上无法自治。罗素悖论暴露出在集合论的基本定义中存在自相矛盾的逻辑缺陷，动摇了整个数学体系的逻辑一致性。

为了解决这一危机，数学家们开始重新审视数学的逻辑基础，试图通过更加严密的逻辑系统来修补集合论的悖论，并确保数学体系的完整性和一致性。解决这一危机的主要路径有以下几方面：

1. **形式系统的引入** 以希尔伯特为代表的数学家提出了**形式系统**的思想，即通过定义一组公理和推理规则，将所有数学命题都归结为形式符号的推理。在这种系统中，所有推理必须严格按照形式化规则进行，以确保逻辑的自治性。希尔伯特的“公理化计划”试图通过一组完备的公理和逻辑规则构建数学的基础，确保数学推理的一致性和完备性，并证明数学体系的无矛盾性。然而，这一计划在哥德尔的不完备性定理面前遭遇了挑战，但它奠定了数学逻辑的基础，为后来的形式逻辑系统和数学结构提供了工具。（AI 去向：形式规约与可验证合约—见 10 章。）
2. **类型论的提出** 罗素本人提出了**类型论**（Theory of Types），该理论通过对集合进行分层，将集合划分为不同的类型，禁止集合包含自身或同类类型的集合，从而避免自指性带来的矛盾。这种层次化的集合结构避免了自指的产生，有效消除了罗素悖论带来的自相矛盾。类型论在逻辑学和计算机科学中的应用仍然具有重要意义，尤其在编程语言理论中得到了广泛应用。（AI 去向：类型系统 → 静态检查与安全沙箱。）
3. **公理化集合论** 集合论的进一步发展得益于**策梅洛-弗兰克尔公理系统**（Zermelo-Fraenkel set theory, ZF）。这一系统通过一套精心设计的公理，对集合的构成和操作进行了规范化处理，避免了自指和无限回归等问题，消除了罗素悖论的根源。ZF 公理化系统通过严格的公理定义，为集合论提供了一个无悖论的逻辑基础，确保了数学推理的可靠性。举个例子：以“正则性公理”禁止集合自含，从根本上排除了“自我成员”的构型。
4. **哥德尔不完备性定理** 尽管公理化的集合论解决了逻辑悖论问题，但库尔特·哥德尔（Kurt Gödel）的**不完备性定理**（Gödel's Incompleteness Theorem）揭示了一个新的局限性：在任何足够复杂的公理系统中，都存在一些命题，既无法在系统内部证明其真伪，也无法推翻。这一结果否定了希尔伯特的完备性计划，证明了即便数学可以通过形式系统避免自相矛盾，也无法保证其逻辑的完备性。数学在本质上是无法完备的。（AI 去向：可证明性边界对“全能对齐”的否定—务实转向评测与约束优化。）

尽管如此，哥德尔不完备性定理并未动摇数学的基础，反而让数学家更加意识到逻辑系统的局限性。数学家因此更加重视逻辑学的精密性，推动了数理逻辑和元数学的进一步发展。

第三次数学危机通过公理化、形式系统、类型论和逻辑分析的多重努力得到了有效解决。这一危机不仅推动了数学基础理论的深入研究，也促使数学家对逻辑一致性和严密性的要求更为严格。通过策梅洛-弗兰克尔公理化体系，数学家为现代集合论提供了无悖论的基础。尽管哥德尔的不完备性定理提出了数学体系不完备的本质限制，指出数学系统永远不可能完美无缺，但它同时也为数学逻辑的发展提供了新的方向。（一句话抽象：形式系统保障一致性，不保完备性—工程上以规约与监控兜底。）

这一危机的解决，使得数学从逻辑上更加稳固，并为后续的数学研究奠定了更高标准的严谨性。数学基础的重建不仅加强了数学逻辑的力量，还推动了现代数学向更高层次的抽象发展，为数理逻辑、模型论和计算理论等新兴学科的诞生铺平了道路。

这些三次数学危机深刻影响了数学的演进，促使数学家们不断重新审视基本概念，并推动了数学向更高的抽象层次发展。每一次危机的解决不仅重塑了数学的结构，还推动了新领域的诞生，使数学始终在挑战中突破，走向新的高度。

总体而言，三次危机推动数学沿三条主轴升级：其一，扩张对象—从 $\mathbb{Q}$ 到 $\mathbb{R}$ （容纳无理）；其二，澄清语义—以极限、测度等精化“可算性”的语义；其三，自知其限—以公理与证明论重塑基础并承认不完备。危机并未削弱数学，反而让它在更高层级上达成稳定与自治。

2.6 小结

纵观以上四个时期，数学的发展脉络清晰呈现。数学从最初解决日常问题的工具，逐步演化为一门以逻辑推理和抽象思维为核心的科学。数学史既是一部理论创新史，也是一部与社会发展和科学进步紧密相连的演进史。

从萌芽阶段的经验性计算到古希腊数学家奠定的逻辑推理基础，再到近代变量数学的飞跃和现代数学的高度抽象化，数学经历了从实用工具到抽象学科的跨越。随着社会与科学的持续发展，数学也成为了理解世界、解决问题和推动技术进步的核心力量。（复盘：本章每节“examplebox”即为 AI 建模的落地锚点。）

纵观历史，数学的应用几乎渗透到了每一个领域中。它不仅是科学的语言，更是推动人类文明进步的强大引擎。人类历史上的每一个重大事件的背后都有数学的身影，它以其独特的抽象性和严谨性，塑造了我们对世界的理解和改造：

- 达芬奇的绘画（15-16 世纪）：文艺复兴巨匠达芬奇在其艺术创作中广泛运用了数学原理，如透视法、黄金比例和人体解剖学的精确测量，使得其作品在视觉上达到和谐与真实，展现了艺术与科学的完美融合。
- 哥白尼的日心说（16 世纪）：哥白尼通过复杂的数学计算和天文观测数据，构建了日心说模型，挑战了统治西方思想千年的地心说。他的工作依赖于几何学和三角学，为现代天文学和物理学奠定了基础。
- 牛顿的万有引力定律（17 世纪）：牛顿运用其发明的微积分工具，精确描述了物体间的引力作用，揭示了行星运动的普遍规律。万有引力定律的提出，是数学与物理学结合的典范，极大地推动了科学革命。
- 马尔萨斯的人口论（18 世纪）：马尔萨斯运用数学模型，特别是指数增长的概念，分析了人口增长与资源供给之间的关系，提出了人口增长快于食物供给的理论，对经济学、社会学和生态学产生了深远影响。
- 巴赫的 12 平均律（18 世纪）：巴赫的《平均律键盘曲集》是音乐与数学完美结合的典范。12 平均律的音高关系基于精确的数学比例，使得音乐在任何调性下都能保持和谐，展现了数学在美学和艺术中的深层结构。

- 孟德尔的遗传学（19 世纪）：孟德尔通过对豌豆杂交实验数据的统计分析，发现了遗传的基本规律，如分离定律和自由组合定律。他的工作是生物学中运用概率和统计学方法的早期范例，开创了现代遗传学。
- 晶体结构的确定（19 世纪）：晶体学的发展离不开群论和几何学的应用。数学家和物理学家利用对称性原理和 X 射线衍射数据，精确推导了晶体的内部原子排列结构，这对于材料科学和化学的发展至关重要。
- 人人平等（所有的直角都相等）、三权分立的政治结构（19 世纪）：虽然“人人平等”和“三权分立”是政治哲学概念，但其背后蕴含着数学的公理化思想和逻辑结构。例如，“所有的直角都相等”体现了普遍性和一致性原则，这与法律和政治制度追求的公平、普遍适用性有异曲同工之妙。三权分立的制衡机制，也体现了系统设计中的平衡与优化思想。
- 无线电波的发现（19 世纪）：麦克斯韦基于数学方程组（麦克斯韦方程组）预言了电磁波的存在，并揭示了光是一种电磁波。他的理论统一了电、磁、光现象，为无线电通信技术的发展奠定了坚实的数学物理基础。
- 巴贝奇的“机械”计算机（19 世纪）：查尔斯·巴贝奇设计的差分机和分析机，是现代计算机的先驱。这些机械装置的运作原理完全基于数学逻辑和算法，旨在实现自动化计算，标志着计算科学的萌芽。
- 达尔文的进化论（19 世纪）：达尔文的自然选择理论虽然主要基于生物观察，但其核心思想，如变异、遗传和适应性，在现代生物学中已广泛通过统计学和群体遗传学模型进行量化和验证，数学为理解进化过程提供了严谨的框架。
- 爱因斯坦的相对论（20 世纪初）：爱因斯坦的狭义相对论和广义相对论，彻底改变了人类对时间、空间、质量和引力的理解。这些理论的提出和验证，都离不开复杂的张量分析、微分几何等高级数学工具。
- DNA 双螺旋疑结的打开（20 世纪）：沃森和克里克在构建 DNA 双螺旋结构模型时，运用了晶体学数据（由罗莎琳德·富兰克林和莫里斯·威尔金斯提供）和几何对称性原理。数学在解析分子结构、理解遗传信息编码方面发挥了关键作用。
- 冯·诺依曼的二进制编码和现代计算机（20 世纪）：冯·诺依曼体系结构奠定了现代计算机的基础，其核心是二进制编码和存储程序概念。这使得复杂的逻辑运算和数据处理能够通过简单的 0 和 1 进行，是数学逻辑和计算理论的伟大实践。
- 图灵机（20 世纪）：阿兰·图灵提出的图灵机模型，是现代计算机科学的理论基石。它以抽象的数学方式定义了“可计算性”，为算法、程序设计和人工智能的理论发展提供了根本性的框架。
-

（总收束：本章以“现象—抽象—启发—取舍—去向”形成可迁移的学习闭环，后续章节将据此展开各模块的可操作细节与练习。）

第三章 智能，成于计算机

简明 AI 史

内容提要

- Definition of Theorem
- Property of Cauchy Series
- Ask for help
- Angle of Corner
- Optimization Problem

— 傅鹰

— 约翰·冯·诺伊曼

人工智能 (AI) 的发展史和数学史一样，是一部不断突破技术限制、追求理解智能本质的进化历程。从最初的理论奠基，到今天无处不在的智能应用，AI 的发展经历了多个阶段，每一个阶段都为未来奠定了新的基础。

3.1 AI 的萌芽期：理论的起源与计算机的诞生

AI 的概念可以追溯到 20 世纪中叶，然而其理论根基则来自更早的数学与逻辑学研究。事实上，AI 的出现并非偶然，它是人类在探索计算的更高效率和智能模拟道路上的自然延续。

回顾数学史，不难发现，人类的进步始终伴随着对**更高计算效率**和**更强智能模拟**的追求。从最早的数数工具，到代数、几何的兴起，再到微积分和分析学的创立，每一次数学理论的突破，都是为了解决日益复杂的问题，并提升计算的效率和智能化程度。**举个例子**。

随着数学理论的发展，特别是近现代数学时期数理逻辑和计算理论的提出，人工智能的理论基础逐步形成。然而，在 AI 真正出现之前，人类已经通过多个世纪的努力，逐步发明了各种计算机器，以减轻人类在计算方面的负担。人类很早就认识到，计算不必局限于脑力或手工操作，一些重复性和繁复的计算可以通过机械的方法来执行，从而提高效率，减少人为误差。

其中最著名的早期计算工具之一便是中国古老的**算盘**。**算盘**的发明可以追溯到公元前数百年，它是一种基于十进制系统的手动计算工具，广泛应用于商业、税务和日常生活中，用于快速进行加减乘除运算。尽管原理简单，但算盘展示了人类利用工具来加速复杂计算的思想，代表了早期机械化计算工具的雏形。

随着时间的推移，机械计算设备逐渐变得更为复杂和精密。1642 年，法国数学家**布莱兹·帕斯卡** (Blaise Pascal) 发明了第一台机械计算器——“帕斯卡计算器”，它可以执行十进制加法运算，标志着机械与数学计算结合的开端。1678 年，德国数学家**莱布尼兹** (Gottfried Wilhelm

Leibniz) 进一步改进了帕斯卡的设计, 发明了能够执行十进制数乘除运算的机械计算机, 揭示了机械计算在复杂运算中的巨大潜力。

不仅是机械计算工具, 自动化的思想也融入了各类生产工具的设计中。19 世纪, **雅卡尔织机**通过打孔卡片来控制织物图案的变化, 展示了早期的编程思想。这种通过机械手段实现将繁复的任务自动化的理念, 预示着计算机自动化编程的雏形, 间接推动了后来智能技术的发展。

19 世纪, 随着工业革命的推进, 人类对计算的需求愈加迫切, 特别是在天文学、工程学和金融领域。大量数字和复杂方程式问题已远超出人类的手工能力, 催生了更多计算机器的发明。1821 年, 英国数学家**查尔斯·巴贝奇** (Charles Babbage) 设计了“差分机”, 这是一种专门用于提高乘法速度和改进对数表精度的机械计算装置。尽管由于设计成本过高, 差分机的后续发展以失败告终, 但巴贝奇在 1834 年设计的“分析机”被认为是通用计算机的雏形, 通过打孔纸带输入程序和数据, 预示了现代计算机的基本理念。尽管“分析机”最终因技术局限也未能实现, 但巴贝奇的思想奠定了现代计算机的概念基础: 通过程序控制的通用计算机。

20 世纪初, 数学家如**大卫·希尔伯特**、**库尔特·哥德尔**和**阿兰·图灵**提出了关于计算与逻辑的基本理论, 为人工智能的萌芽提供了肥沃的土壤。**阿兰·图灵**在 1936 年发表的《论可计算数》一文中, 提出了**图灵机**的概念, 奠定了现代计算理论的基础和框架。图灵机是一种模拟计算过程的抽象数学模型, 这一思想不仅为后来电子计算机的发明打下了坚实的理论基础, 也为人工智能提出了一个关键问题——**机器能否像人类一样思考?** 1950 年, 图灵提出了著名的**图灵测试**, 作为判断机器是否具备智能的标准, 开启了对机器智能的早期探索。图灵的思想对随后的人工智能发展产生了深远的影响, 确定了未来人工智能的发展方向。

20 世纪, 电子技术的突破使计算机摆脱了传统机械部件的限制, 转向实用电子开关、电路板和真空管, 使计算速度提高了无数倍, 实现了前所未有的效率飞跃。

真正具有突破性的发明出现在 1942 年, 美国的**约翰·阿塔纳索夫** (John Vincent Atanasoff) 和**克利福德·贝瑞** (Clifford Berry) 制造了第一台电子计算机——**Atanasoff-Berry 计算机 (ABC)**, 首次使用二进制来表示数据, 并通过电子开关代替了机械部件, 标志着从机械计算向电子计算的重大转变, 尽管它尚无法进行编程。

随后, **ENIAC**, 由**约翰·冯·诺依曼** (John von Neumann) 等人设计, 成为世界上第一台通用电子计算机。**ENIAC** 不仅能进行复杂的计算, 还采用了冯·诺依曼的存储程序架构, 即将程序和数据存储在计算机内存中。这一架构成为现代计算机的基础, 大幅提高了计算机的灵活性和计算效率。

这些电子计算机的发明, 不仅标志着计算能力的巨大飞跃, 也为人工智能的早期发展提供了关键的技术平台。电子计算机使得机器能够在更大规模上执行复杂的计算和推理任务, 推动了智能模拟从理论走向实践, 开启了自动化计算的新纪元。**AI** 作为一种思想和技术, 诞生在数学、逻辑和计算科学的交汇点上, 标志着智能模拟从理论走向实践的新时代。

因此, **AI** 的发展历程, 既是人类追求越来越高效计算的延续, 也是计算思维逐步外化并加速进化的体现。从算盘、机械计算器到电子计算机, 每个阶段的技术进步都使计算变得更加高效和智能化, 推动了从人工计算到机器计算的转变。这一趋势也为 **AI** 的诞生铺平了道路,

使得机器不仅能执行运算，还具备了模拟人类思维、学习和决策的潜力。AI 正是这一智能化趋势的巅峰成果，是人类不断努力提升计算能力和模拟智能行为的必然延伸。

3.2 1950-1970 年代：AI 的奠基与早期探索

1950 到 1970 年代，人工智能开始从理论走向实践。1950 年代被视为人工智能的正式起点。在此期间，数学、逻辑学、计算机科学和神经科学的交汇，为人工智能的早期发展铺设了道路。

阿兰·图灵的贡献无疑是这个时期最为重要的起点。1950 年，他在论文《计算机与智能》中提出了衡量机器是否具备智能的标准——“图灵测试”。图灵通过设想一台机器与人类对话的情境，开启了对机器是否能够模拟人类智能的讨论，奠定了早期人工智能研究的理论基础。

约翰·冯·诺依曼的工作对 AI 的发展也产生了重要影响。1940 年代，冯·诺依曼提出了自复制自动机的理论，并在计算机设计中推广了“存储程序”的概念，这使得计算机能够按照程序指令自动执行复杂任务。冯·诺依曼的计算机架构为人工智能提供了强大的硬件基础，也为智能程序的实现铺平了道路。

增加参考文献《面对面的办公室》

成就一生的会议

约翰·麦卡锡（John McCarthy）是 AI 奠基时期最关键的人物之一。他的思想和研究引领了 AI 这一全新领域的诞生和早期发展。

1948 年，年轻的麦卡锡在普林斯顿大学听了冯·诺依曼关于自复制自动机的报告后，激发了他对“用计算机模拟人类智能”的强烈兴趣。1949 年，麦卡锡在普林斯顿数学系攻读博士学位时首次在论文中提出了“用计算机来模拟人类智能”的想法，尽管当时这一概念十分模糊，但已展现出 AI 作为独立研究领域的雏形。在冯·诺依曼的鼓励和支持下，麦卡锡将主要研究方向定为在机器上模拟人的智能，特别是将下棋问题作为重点课题之一。此后，为了减少计算机需要考虑的棋步，麦卡锡发明了 α - β 剪枝算法。这一方法有效地减少了计算量，至今仍是解决人工智能问题中一种常用的高效方法。

麦卡锡和贝尔实验室的**克劳德·香农**（Claude Shannon）——“信息论”的创始人，在人工智能方面的若干深入探讨之后，他们萌生召开一次研讨会的共识。1956 年，在洛克菲勒基金会的一笔微薄的赞助下，他们邀请到当时哈佛大学的**马文·明斯基**（Marvin Minsky）和 IBM 工程师罗彻斯特等几位学者，在达特茅斯学院组织了这次夏季研讨会。

在达特茅斯会议上，“人工智能”一词降临，备选名字有“自动机研究”、“复杂信息处理”、“机器智能”与“控制论”，与会者最终选择了“人工智能”（Artificial Intelligence），简洁而富有指向性。

“……学习的每一方面或智力的任何其他功能，原则上都可以准确地描述，并由机器模拟。我们将尝试制造能够使用语言、提炼抽象概念的机器的方法，……如果一批优秀的科学家在一起研究一个夏天，那么这一领域中的一个或多个问题就能得到显著的推进。”这种大胆的设

想不仅为 AI 的核心研究方向指明了道路，也传达出一种对机器智能的乐观信念——即智能行为是可以被精确模拟的。

这次会议成为众多奠基者的灵感之源，确立了人工智能学科的基础框架，使“人工智能”这一领域获得科学界的认可，并为未来几十年的研究奠定了重要的学术基础。

汇集了 10 位科学家，持续 2 个月的达特茅斯会议是计算机史上的一座里程碑。会议的主要参与者后来都在计算机科学和人工智能领域取得了杰出的成就。

- **约翰·麦卡锡 (John McCarthy)**：作为达特茅斯会议的主要发起人，麦卡锡不仅提出了“人工智能”这一术语，还在麻省理工学院 (MIT) 建立了第一个 AI 实验室，开发了 AI 的主要编程语言之一——Lisp，为 AI 的符号处理和逻辑推理奠定了基础。1971 年，麦卡锡因其在 AI 领域的杰出贡献而获得图灵奖。
- **马文·明斯基 (Marvin Minsky)**：人工智能和认知科学的先驱，达特茅斯会议的主要参与者之一。明斯基在 MIT 建立了著名的 AI 实验室，将人工智能的研究扩展到学习和认知的复杂领域。他于 1969 年获得图灵奖，彰显了其在 AI 理论和方法上的重要贡献。
- **克劳德·香农 (Claude Shannon)**：作为信息论的创始人，香农在达特茅斯会议上的参与为 AI 带来了信息处理的理论支持。他通过“信息熵”概念，为通信和数据处理打下了数学基础，推动了 AI 在数据传输和编码方面的进展，为机器学习和模式识别等 AI 技术的日后发展提供了理论依据。
- **艾伦·纽厄尔 (Allen Newell) 和赫伯特·西蒙 (Herbert Simon)**：这两位科学家不仅在达特茅斯会议上推动了 AI 的发展，还共同开发了早期的 AI 程序，如 Logic Theorist 和 General Problem Solver (GPS)，这些系统奠定了符号主义 AI 的基础。两人于 1975 年共同获得图灵奖，以表彰他们在逻辑推理和问题求解的 AI 系统上的创新。西蒙还因在经济学和认知科学的交叉研究中取得的杰出成果，于 1978 年获得诺贝尔经济学奖。
- **纳撒尼尔·罗切斯特 (Nathaniel Rochester)**：作为 IBM 计算机设计团队的一员，罗切斯特在达特茅斯会议上带来了对硬件和计算机体系结构的深刻理解，为 AI 的技术发展提供了重要支持。他为符号主义 AI 的实际应用提供了硬件基础，使得 AI 研究在之后的几十年中得以快速发展。

达特茅斯会议不仅是 AI 发展的里程碑，更是奠基者们各自成就的起点。他们在日后的研究和创新中，将符号处理、逻辑推理、信息论、经济学等跨学科思想融入 AI 之中，为这门新兴学科注入了多元化的基础。这次会议标志着人工智能领域的正式诞生，掀起了未来几十年 AI 研究的浪潮，因此，1956 年也被称为“AI 元年”。

3.2.1 达特茅斯会后早期黄金期：符号主义 AI

在达特茅斯会议之后，人工智能进入了早期探索阶段，其核心概念逐步成型。研究者们围绕“机器能否像人类一样思考”这一问题展开了深入探索，人工智能从学术设想走向实际研究，并取得了一系列早期的重要成果。

1958 年，明斯基和麦卡锡在麻省理工学院建立了世界上第一个人工智能实验室——MIT AI

Lab。同年，麦卡锡发明了 **Lisp** 编程语言。**Lisp** 的灵活性和符号处理能力使其成为 AI 研究的首要编程语言之一，尤其是在自然语言处理和知识表示等领域。

20 世纪五六十年代，大多研究者都聚焦于自上而下的研究方向，**符号主义 AI (Symbolic AI)** 是这一时期的主流，即主张通过符号操作来建立人脑模型从而模拟智能。这一时期的 AI 研究主要聚焦于**符号处理**和**规则推理**，形成了一种“强 AI”乐观主义的思潮。科学家们设想，通过逻辑推理和符号处理，机器能够像人类一样解决问题，甚至达到通用智能的水平。早在 1956 年，西蒙和纽厄尔预言“10 年之内，计算机将成为国际象棋世界冠军”。1966 年，西蒙再次乐观预言“20 年内，机器能完成人能做到的工作”。

研究者们开发了早期的专家系统和逻辑推理系统，如阿伦·纽厄尔和赫伯特·西蒙等人研发的 **Logic Theorist** 和不依赖于具体领域的通用问题求解器 **General Problem Solver**，尝试模拟人类解决问题的逻辑推理过程，展示出机器进行逻辑推理的潜力。**机器定理证明**是这一时期最先取得重大突破的领域之一。1956 年，**Logic Theorist** 由阿伦·纽厄尔和赫伯特·西蒙等人在兰德公司开发，被认为是首个具有“人工智能”特征的计算机程序，**Logic Theorist** 的目标是模拟人类的逻辑推理能力，能够自动证明逻辑定理。**Logic Theorist** 可独立证明罗素和怀特海所著《数学原理》第二章的 38 条定理，1963 年能证明该章的全部 52 条定理，甚至为其中一个定理上找到了比原作者给出的证明更为简洁的证明。这一成就引起轰动，显示出计算机在某些逻辑推理任务中的潜力。

其它成果包括：

- 1958 年，华人数学家王浩在 IBM704 上仅用 5 分钟便证明了《数学原理》有关命题演算的 220 条定理。
- 1963 年，IBM 公司研制出平面几何的定理证明程序。
- 1963 年，Slagle 发表了一个符号积分程序 **SAINT**，可自动计算输入函数的积分表达式。4 年后推出的升级版 **SIN**，达到专家级水准。

这些为机器定理证明的“封闭”逻辑系统系统的成功为后续 AI 系统奠定了基础，但也暴露出符号 AI 系统明显的局限性——只能处理严格定义的逻辑问题，难以应对更复杂的、不确定的现实问题。

以手写字母识别 (如图3.1) 为例，手写字母在形态上具有高度的变化性和不确定性。不同人书写的“A”可能形态差异很大，甚至同一个人也会因速度、情绪等不同而写出不同的“A”。如果让 **Logic Theorist** 识别手写字母“A”和“B”，它会陷入困境，因为符号主义 AI 依赖预先设定的规则进行逻辑推理，要求字母形态稳定且符合固定定义。而现实中的手写字母形态多样，难以满足这些硬性规则，因此，符号主义 AI 在这种不确定、变化多样的环境下表现不佳。

虽然这些早期 AI 系统在模拟人类逻辑推理能力上取得了成功，能够解决简单的逻辑问题，但在面对复杂多变的现实问题时，它们的表现力和适应性明显不足，难以应对更广泛的智能任务。这一局限性表明，符号主义 AI 在处理现实中的不确定性问题时仍面临巨大挑战。



图 3.1: 手写数字识别

自我学习

与此同时，AI 研究者也开始探索机器学习的可能性，机器学习领域获得不少突破。1959 年，阿瑟·塞缪尔（Arthur Samuel）研制了一款跳棋程序，能够通过自我对弈提升棋艺。1962 年，它击败美国州冠军。这款程序被认为是早期**机器学习**的范例，展示了机器通过经验不断提高性能的潜力，标志着 AI 研究从预设规则向基于学习的方向发展。1956 年，Selfridge 研制出第一个字符识别程序，开辟了模式识别这一新领域。

1974-1980 年代初：第一次“AI 寒冬”

虽然早期的符号 AI 研究取得了显著进展，但随着研究的持续推进，符号 AI 的局限性日益显现。尽管符号 AI 擅长逻辑推理，且在特定任务上表现出色，但在应对现实世界的复杂性和不确定性问题时，特别在处理非结构化数据方面，表现出了明显的不足。

1965 年，机器定理证明领域遇到了瓶颈。例如，计算机推了数十万步也无法证明“两个连续函数之和仍是连续函数”。萨缪尔的跳棋程序停留在了州冠军的水准，难以突破。更糟糕的问题出现在**机器翻译**领域，计算机在自然语言理解与翻译中表现得极其差劲。例如，翻译程序将英语句子“The spirit is willing but the flesh is weak.”（心有余而力不足）翻译成俄语，再回译成英语时，得到的句子竟变成了“The wine is good but the meet is spoiled.”（酒是好的，肉变质了）。这种笑话般的错误凸显出符号 AI 在处理语言模糊性方面的无力。

1970 年代的乐观情绪（如通用智能）推动了大量 AI 项目的启动，然而，随着这些项目未能达最初的预期，尤其是在应对现实世界的复杂性方面暴露出显著局限，加上计算资源需求高，导致了随后 1974 年开始的第一次“AI 寒冬”——投资者和政府机构对 AI 研究的资金支持大幅削减，研究热情和社会关注下降，许多 AI 项目被取消，研究活动在 1974 年至 1980 年间大幅缩减，AI 研究陷入低谷期。

尽管如此，低谷期的 AI 领域并非全无进展，反而通过知识工程和专家系统的兴起找到了新的突破口。

3.3 1980 年-1987 年：专家系统与知识工程的兴起

从 1980 年至 1987 年，AI 研究进入了一个新的阶段，以**专家系统**和**知识工程**的兴起为代表。美国计算机科学爱德华·费根鲍姆指出，传统的人工智能过于强调通用求解方法的作用，忽略了具体的领域知识。因此，他提出了基于知识的专家系统。**知识工程**是利用人工智能技术来构建专家系统的一种方法。**专家系统**是基于符号逻辑的 AI 系统，通过将专家的知识编码为计算规则，帮助机器在特定领域中进行推理和决策，模仿领域专家解决问题的过程。

3.3.1 代表性专家系统

典型的专家系统包括医学诊断系统 **MYCIN** 和化学分析系统 **DENDRAL**，它们分别在医疗和化学领域取得了显著成效。通过嵌入领域专家的知识，专家系统在复杂任务中展现出较高的决策能力，推动了知识工程成为 AI 研究的重要分支。

- **DENDRAL**: 开发始于 1965 年，由斯坦福大学的爱德华·费根鲍姆 (Edward Feigenbaum) 和约书亚·莱德伯格 (Joshua Lederberg) 带领的团队创建。**DENDRAL** 则是一种用于化学分析的系统，能够根据分子结构推断化学物质。它被认为是第一个成功的专家系统，标志着知识工程的开端。
- **MYCIN**: 开发始于 1972 年，由斯坦福大学的布鲁斯·布坎南 (Bruce Buchanan) 和爱德华·肖特利夫 (Edward Shortliffe) 领导的团队创建。**MYCIN** 是一个医学专家系统，专注于诊断血液感染并推荐抗生素。它通过一系列规则模拟专家在诊断细菌感染时的决策过程，其规则系统和推理机制为后续专家系统的发展影响深远。

虽然 **DENDRAL** 和 **MYCIN** 的开发始于 1960 年代末至 1970 年初，但它们在 1970 年代后期到 1980 年代中期得到实际应用和广泛推广，成为知识工程的核心。这些专家系统的成功验证了知识工程的可行性。各种专家系统陆续涌现，尤其在医疗、化学分析、工程设计和商业决策等特定任务中，标志着 AI 技术的一个实用转变。研究者们从这些成功中看到了基于知识的 AI 应用的巨大潜力，开始着重于知识获取、知识表示和推理机制的系统性开发。这一时期成为专家系统和知识工程在实际应用中迅速扩展的高峰期。

3.3.2 知识表示与规则推理

专家系统的成功得益于对**知识表示**和**推理机制**的深入研究。**知识表示**是指如何在计算机中存储和处理专家的领域知识，而**规则推理**则是通过符号操作来进行逻辑推理的过程。在专家系统中，领域专家的知识被转换为计算机可以处理的规则集，从而模拟专家的判断。这种规则系统让计算机能够在特定领域中像人类专家一样做出高效的决策。

3.3.3 知识工程的广泛应用

DENDRAL 和 MYCIN 的成功验证了知识工程的可行性后，推动了更广泛的行业应用。知识工程通过获取和编码人类专家的知识，为 AI 系统提供了专业化的领域知识，并形成了软件产业的一个新分支。知识工程的兴起不仅推动了专家系统的广泛应用，也促成了 AI 技术在全球范围内的合作和竞争。

受知识工程的激励，日本的第五代计算机计划、英国的阿尔维计划、西欧的尤里卡计划、美国的星计划和中国的 863 计划陆续推出，尽管这些计划的目标并不完全针对 AI，但 AI 是其重要组成部分，成为提升国家科技竞争力的一部分。

3.3.4 新兴技术：模糊逻辑与贝叶斯网络

在这一时期，AI 领域还从知识工程中衍生出了新的学科分支，如模糊逻辑和贝叶斯网络。模糊逻辑提供了一种处理灰色区域的推理方式，使 AI 能够在信息不完全的情况下也能做出决策。贝叶斯网络则通过统计方法来处理不确定性，被广泛应用于诊断、预测和决策系统中。这些方法通过处理不确定性和模糊性，有效弥补了传统符号主义 AI 在处理复杂现实问题上的局限。

3.3.5 第二次“AI 寒冬”的反思与转型

20 世纪 80 年代中期，专家系统和知识工程在医疗诊断、工程设计、化学分析等狭窄领域表现出色，但伴着随大量实践的累积，其局限性也逐渐显现。知识获取成为了最大的瓶颈：专家系统高度依赖领域专家的知识输入和精确的规则，知识获取和维护成本高昂，系统缺乏灵活性和自适应性，难以应对多样和动态的现实需求。此外，硬件技术和计算资源的限制也不足以支撑更大规模的 AI 系统发展。

随着专家系统的商业化受阻，AI 进入了第二次寒冬。1987 年至 1993 年之间，投资者和政府逐渐减少了对 AI 的资金支持，许多原本大规模投资的 AI 项目被迫中止。日本的“第五代计算机计划”因未能在智能计算取得预期成果而停滞，其他国家的大型 AI 项目也相继缩减，导全球范围内的 AI 研究热潮急速降温。在这次寒冬期内，AI 研究的资金大幅削减，许多研究人员转向其他领域。

第二次的 AI 寒冬虽然带来了低谷，却促使 AI 领域反思技术路径，重新审视符号主义 AI 的局限性。研究者和行业逐渐认识到，仅凭符号规则和知识编码不足以实现真正的智能。

知识工程和专家系统的应用展现了 AI 技术在特定领域的应用潜力，推动了 AI 从学术研究向实用化的转变。尽管专家系统存在明显局限，但这些实践经验和技术积累为之后的机器学习、神经网络等数据驱动方向的复兴提供了宝贵启示，推动 AI 研究进入了新的发展阶段。

寒冬的沉寂期反而带来了新的视角，促使研究者在方法和技术上寻求突破和创新。这些反思和积累成为推动 AI 转型的重要动力，为现代 AI 的崛起，尤其是后续深度学习的发展，奠定了坚实的基础。

3.4 人工智能的分化

1987 年以后，人工智能分化为六大学科：

- 计算机视觉 (模式识别，图像处理等)
- 自然语言理解与交流 (语音识别、合成、对话等)
- 认知与推理 (各种物理和社会常识等)
- 机器学习 (各种统计建模、分析工具和计算方法)
- 机器人学 (机械、控制、设计、运动规划、任务规划等)
- 博弈与伦理 (多代理人 agents 的交互、对抗与合作、机器人与社会融合等)




图 3.2: “1987 年后人工智能的分化”




图 3.3: “1987 年后人工智能的分化”



图 3.4: “1987 年后人工智能的分化”

可以看出来，人工智能在全面模拟人的智能，不仅是大脑智能，还包括眼睛智能，耳朵智能，手智能，口智能。

3.5 1990-2010 年代：联结主义和机器学习的兴起

20 世纪 80 年代，**机器学习**由原本的边缘分支成为关注的焦点。研究者发现，如果采用完全不同的世界观，即让知识通过自下而上的方式涌现，而不是让专家们自上而下地设计出来，机器学习的问题其实可以得到很好解决。

自下而上的涌现智能的方案很早就提出过，但没有引起注意：一批人：可通过模拟大脑结构（神经网络）来实现（联结学派）另一批人：可从那些简单生物体与环境互动的模式中寻找答案（行为学派）20 世纪 80-90 年代，传统的人工智能符号学派、联结学派、行为学派三足鼎立。

早期的学习算法开始在符号 AI 的基础上发展，成为 AI 从符号主义向数据驱动方法转型的基础。

尽管 1987-1993 年期间的 AI“寒冬”导致研究资金减少，学术界对神经网络等方向的探索仍在继续。特别是在 1990 年代后期，联结主义和机器学习的复兴为 AI 注入了新的活力。研究者们开始着力于数据驱动的学习算法，这些研究逐步成为现代 AI，尤其是深度学习的起点。

进入 90 年代后，AI 研究逐渐从符号主义（基于符号的 AI）转向数据驱动的机器学习（**基于数据的 AI**）。在计算机能力提升和数据量爆发增长的推动下，机器学习逐渐成为 AI 研究的主流。通过统计学习和数据驱动的模式识别，A 系统能够大数据进行训练，显著提升识别和决策的准确性。

在这一阶段，**神经网络**的复兴尤为关键。虽然早期的神经网络（如感知机）在 1960 年代就已提出，但因计算能力受限，没有达到理想效果。1990 年代后，神经网络在计算能力提升的推动下重新焕发生机，显示出巨大潜力。**1997 年，IBM 的“深蓝”战胜国际象棋冠军卡斯帕罗夫**，标志着 AI 在某些特定任务上的重大突破，成为该领域的重要里程碑。

到了 2010 年代，**深度学习**技术的突破推动了 AI 的飞速发展。基于**卷积神经网络（CNN）**和**递归神经网络（RNN）**等深度学习模型的广泛应用，AI 在图像识别、语音识别、自然语言处理等多个领域取得了显著进展。2012 年，**AlexNet** 在 ImageNet 竞赛获胜，奠定了深度学习在图像识别领域的领先地位。2016 年，谷歌的 **AlphaGo** 战胜围棋世界冠军李世石，进一步展示了深度学习和强化学习在复杂问题处理上的强大能力，为 AI 新时代拉开了序幕。

3.5.1 2020 年代：大语言模型（LLM）与生成式人工智能（AIGC）的崛起

进入 2020 年代，人工智能在语言处理和内容生成领域迎来了崭新的突破。**大语言模型（LLM）**和**AI 生成内容（AIGC）**技术的兴起，标志着 AI 在自然语言理解、图像生成等跨模态任务上的重大进展。这一阶段的 AI 系统不仅限于执行特定任务，还展示出强大的语言生成和创意能力，推动了 AI 在内容生成、对话系统、设计创作等多元领域的应用。

大语言模型（LLM）通过海量文本数据的训练和数十亿参数的深度优化，使得 AI 具备了对自然语言的复杂理解和生成能力。**GPT 系列、BERT**等模型的出现，让 AI 能够生成具有上下文连贯性和逻辑性的文本内容，实现更自然、更智能的人机互动。这些模型不仅能处理简

单的文本任务，还能在医学、法律、科技等领域为人类提供辅助性建议。LLM 的创新，尤其在教育、客服和专业问答等领域的广泛应用，使得 AI 能够更深入地理解和模拟人类语言的多样性和细腻性，逐步拓宽了人工智能的应用范围。

与此同时，**AI 生成内容 (AIGC)** 技术使 AI 从信息处理者发展为创意生成者。AIGC 让 AI 不仅可以理解和操作文本，还能够在图像、视频、音乐等领域生成内容，为人类的创意需求提供助力。例如，基于扩散模型和生成对抗网络 (GANs) 的图像生成器能够创作出栩栩如生的图像，甚至具备了艺术创作的初步能力。AIGC 技术使 AI 在广告、娱乐、设计和教育等多个领域得到了广泛应用，不仅缩短了内容创作的时间，还为人类的创作过程带来了新鲜的灵感和可能性。

LLM 和 AIGC 的兴起不仅丰富了 AI 的应用场景，更重要的是，它让 AI 在情感识别、语言生成和创意表达方面具备了更强的适应性，使得 AI 从单纯的“工具”逐渐演变为可以合作、创新的“伙伴”。AI 能够生成具有人性化特质的内容，从而在客服、医疗和心理咨询等对人类情感需求更高的领域中提供更加贴近人类需求的服务。

2020 年代的 LLM 和 AIGC 的进展，标志着 AI 从知识服务者走向创意合作者的转变。这一阶段的 AI 不仅展示了生成文本、图像等复杂内容的能力，也在理解人类表达和模拟创意思维上迈出了一大步。LLM 和 AIGC 带来了前所未有的机遇，将继续推动 AI 技术在更多领域的应用与普及，引领人类进入一个充满创新和智慧的新时代。

3.6 人工智能主要学派

人工智能从诞生至今，经历了一次又一次的繁荣与低谷，其发展历程大体上可以分为“推理期”，“知识期”和“学习期”。[0]

在人工智能的研究中，不同学派以各自的方法和理论基础探索智能的本质。这些学派的差异体现在如何定义智能、模拟智能的方法以及应用的领域中。三大主要学派包括**符号主义学派**、**联结主义学派**和**行为主义学派**，它们分别代表了对智能问题的三种主要思维方式。

3.6.1 符号主义学派 (Symbolicism)

符号主义学派：知识驱动的推理与表现

符号主义学派，又称**逻辑主义**或**符号处理学派**，是 AI 发展的早期重要分支之一。符号主义学派的理论基础源于 20 世纪中期的认知科学和数理逻辑。符号主义学派主张，人类的知识和认知可以通过符号加以形式化，且问题解决可以通过符号操作（如逻辑推理）完成。因此，符号主义学派主要专注于建立规则和逻辑系统，尝试通过符号和规则来模拟人类的高级思维过程，包括推理、规划和知识表示。

符号主义学派基于对问题的“高阶”解释，核心思想是智能行为能够通过逻辑规则和知识库来模拟，依赖于启发式搜索和基于规则的推理系统，试图用知识与经验的积累来填补信息

空白。这种“If-then”式的推理方式使符号主义在规则明确的任务中表现出色，被广泛应用于医疗诊断、金融分析等领域的专家系统。

符号主义学派的成果与应用

符号主义学派的代表性成果包括早期的专家系统（如 MYCIN 和 DENDRAL）、逻辑定理证明系统（如 Logic Theorist）、推理系统和象征性规划系统。

- **人机对弈：“深蓝”战胜卡斯帕罗夫** 1997 年 5 月 11 日，IBM 的超级计算机“深蓝”在国际象棋比赛中战胜了国际象棋大师卡斯帕罗夫，标志着符号主义 AI 的一次里程碑事件。深蓝经过四位国际象棋特级大师的训练，储存了 100 年来几乎所有国际特级大师的开局和残局下法，利用启发式搜索可在 1 秒钟内计算两亿步棋。这种超强搜索能力，使得“深蓝”通过规则匹配和快速推理“险胜”人类选手，显示了符号主义在明确规则系统中的强大计算能力。
- **知识问答：Watson 战胜人类选手** 2011 年 2 月 14-16 日，在《危险》问答比赛中，IBM 的超级计算机 Watson 战胜人类选手。Watson 是个自然语言处理高手。它能够快速理解主持人的提问，并调用广泛的知识库回答问题。它的知识涵盖时事、历史、文学、科学、艺术、流行文化、体育、地理、文字游戏等多个领域，甚至理解语言的隐含意思，比如字谜和双关语，甚至还装满诸如莎士比亚戏剧的独白。Watson 充分体现了符号主义 AI 在自然语言理解和知识问答中的突破性进展。
- **医疗应用：Watson Health** IBM Watson 还被应用于医疗领域，基于大量医学数据和患者数据，为药物研发和个性化健康管理提供支持。例如，在癌症免疫治疗方面，Watson 从数百万篇医学论文的 2500 万篇摘要、400 万条病人数据以及 1861 年以来的药物专利中提取信息，为个性化治疗提供方案。此外，在糖尿病管理上，Watson 能够对来自 1 万名匿名患者的电子健康记录、医保数据和其他公共数据进行实时分析和预测，提前 3-4 小时预测血糖波动，预测准确率达 75-86%，帮助患者有效管理健康。

符号主义 AI 的优势与局限

符号主义具有以下优势：

1. **可解释性**：符号主义的推理过程与人类的思维方式基本一致，因而具有很强的可解释性，使人们能够理解和追踪系统的推理过程。
2. **鲁棒性强**：符号规则系统在处理结构化、规则明确的问题时表现出色，具有较高的稳定性，尤其适用于特定领域内的任务。
3. **逻辑推理能力**：符号主义系统能够执行复杂的逻辑推理，适用于处理涉及高级认知的任务，如规划和知识表示等。

20 世纪 80 年代后，符号主义学派的发展逐渐减缓，主要原因在于其依赖的“演绎逻辑和语义描述”以及或“形式化方法”不可能为所有的对象建立模型。符号主义系统需要对问题抽象出一个精确数学意义上的解析式数学模型，通过构建理想的数学模型和逻辑规则来模拟智能

行为。一旦模型建立，计算任务与能力就被唯一地确定。确定的算法无法表示现实世界问题所固有的测不准性和不完备性：世界是动态的、复杂的，无法用一个模型来表达。此外，图灵意义下的可计算问题都是可递归的，但可递归并不是解决问题的唯一途径。虽然符号处理可以应对某些递归性问题，但对于智能的全面理解和表现，符号主义学派的框架显然不够完整。

符号主义学派的主要局限性可归纳如下：

1. **知识依赖性**：符号主义系统依赖于大量准确、结构化的知识和规则，但人类知识难以全面准确地形式化，这种依赖性限制了系统在现实问题中的表现。
2. **缺乏灵活性**：符号主义系统只能应对预先定义的问题，难以适应动态、复杂和不确定的环境。这种限制使其在处理非结构化问题时表现不佳。
3. **条件与分枝问题**：在复杂的动态系统中，符号主义面临两大瓶颈：**条件问题 (Qualification Problem)**，即难以穷尽智能行为的所有先决条件；**分枝问题 (Ramification Problem)**，即无法枚举智能行为的所有隐含结果。符号主义系统因此难以应对复杂环境中的不确定性和隐含影响。
4. **应用领域狭窄**：尽管符号主义模型在逻辑推理和规则明确的任务中表现出色，但在感知、语言理解等模糊和动态性较强的任务中，由于对人工定义的规则和知识库的依赖，其适应性较差。

符号主义学派在 AI 发展的早期取得了显著成就，为人类理解和模拟智能行为提供了框架和方法。然而，随着应用需求的增加和技术环境的变化，符号主义的局限性逐渐显现，学界认识到，为应对复杂的动态环境，还需结合其他学派的思维方式。符号主义的贡献在于奠定了知识驱动的 AI 基础，展示了通过逻辑推理模拟人类智能的可能性，为之后联结主义与行为主义的发展开辟了道路。

3.6.2 联结学派/连接学派 (Connectionism)：从神经网络到深度学习

20 世纪 80 年代之后，随着计算能力的提升和神经科学的深入研究，人工智能的重心逐渐转向**联结主义学派**，也称**人工神经网络学派**。联结主义学派认为智能的产生并非依赖于符号和逻辑规则，而是源于大脑中成千上万个神经元的联结和计算。正如其支持者所言，“高级的智能行为是从大量神经网络的连接中自发出现的”。

联结主义学派主张通过模仿大脑神经元网络的工作原理来实现智能。大脑由一万亿个神经元细胞通过错综复杂的相互连接形成了复杂的认知和决策能力。特别关注如何通过数据训练来自动调整网络参数，使系统能够在数据中自发学习和优化。其核心思路是模仿神经元的工作方式，构建多层网络结构，调整神经元之间的连接权重，使得系统逐渐具备特定的识别和判断能力。例如，神经网络的训练过程就是通过不断调整权重，逐步优化输出结果的过程。不同于符号主义学派的知识驱动，联结主义的这一训练机制强调**数据驱动的学习**，即依靠大量的数据输入，使系统在学习自动调整网络参数，以形成稳定的模式识别和分类能力。

联结主义学派的重要进展包括从早期的**感知机模型**到更复杂的**卷积神经网络 (CNN)**、**递归神经网络 (RNN)** 等模型，最终发展到现代**深度学习**模型。这些模型推动了 AI 在图像识别、

自然语言处理、生成式 AI 等领域的广泛应用，成为现代 AI 的重要工具。这一学派的成就在近年来引发了广泛关注和思考。

尽管联结主义学派推动了人工智能的飞跃式进展，但其局限性也不容忽视。首先，联结主义模型对大量数据的依赖较高，若数据不足或质量不佳，模型的表现可能会大幅下降。其次，随着神经网络层次增加，其计算复杂度也随之提高，导致训练和运行成本显著增加。其次，神经网络通常被视为“黑箱”，即难以解释其内部决策依据。这一“黑箱”问题主要源于以下几点：

- **多层非线性结构**：神经网络的层层变换过程使其难以还原具体决策路径，庞大的参数量也导致分析“哪些特征在决策中起了关键作用”变得困难。
- **局部特征依赖性**：模型往往基于局部特征组合来进行决策，而缺乏对整体决策过程的全局视角。例如，在图像分类中，模型可能依赖某些局部图案作出决策，使得预测依据难以解读。
- **数据驱动缺乏推理链**：联结主义模型倾向于基于统计特征进行预测，缺乏类似符号主义系统的逻辑推理链，不便于展示推理过程。

尽管存在可解释性方面的挑战，联结主义的理论和技術构建了现代神经网络的基石，极大地推动了现代 AI 的发展。在下一章中，我们将进一步探讨联结主义的核心思想、模型结构及其应用实践。

3.6.3 行为主义学派 (Actionism)

行为主义学派源于 20 世纪中叶，其理论基础来自行为主义心理学和生物学对动物行为的研究，认为智能体可以通过与环境的交互获得经验，从而逐步学习最优的行为策略。行为主义学派主张智能的形成基于行动与环境反馈的相互作用，智能体在反复试错中调整自身策略，优化行为序列，以实现既定目标。

行为主义学派的早期探索主要集中于模仿昆虫等低等生物的行为模式。简单生物无需复杂的大脑结构，也不会按照传统的方式进行复杂的知识表示和推理来执行智能行为，仅通过直接的环境交互就能实现适应性行为。例如，昆虫能够灵活移动、快速反应、躲避捕食者的攻击；小小的蚂蚁所组成的庞大蚁群展现出高度写作的群体智能。这些生物体的行为为行为主义学派提供了灵感。随着计算能力的提升，行为主义方法逐渐被应用于机器人控制、游戏策略等领域，特别适合在高不确定性和动态环境中构建智能体行为。

行为主义学派的一个典型实现是**强化学习**（Reinforcement Learning, RL）算法，尤其是 Q 学习和深度强化学习（DRL）。这些方法通过奖励机制引导智能体在环境中逐步优化策略。例如，AlphaGo 挑战围棋世界冠军的成功便是强化学习和深度学习结合的成果。AlphaGo 在与环境的持续交互中，逐步学习复杂博弈中的最佳策略，展示了人工智能在自我优化和复杂决策方面的潜力。

MIT 机器人专家 Rodney Brooks 设计的模仿昆虫的机器人正是这一学派的经典案例。通过四肢和关节的协调，这些机器人能够在复杂地形中灵活爬行，巧妙避开障碍物，无需复杂

的大脑控制。类似地，波士顿动力公司（Boston Dynamics）开发的四足机器人在不同地形和环境中表现出高度的适应性和鲁棒性。这些机器人的行为不依赖于复杂的认知模型或高级符号推理，而主要依靠局部传感器数据、反馈控制和运动算法来实现稳定的运动与环境适应，在一定程度上可以被称为“无脑机器人设计”。这种设计理念类似于昆虫等简单生物的直接感知-行动环的反应式行为，展示了行为主义学派在机器人开发和运动控制中的实际价值。

尽管行为主义学派取得了诸多进展，仍面临明显的局限性：

1. **高维度和复杂环境下的学习效率低**：行为主义学派在高维、复杂环境中往往需要大量交互才能收敛到合理策略，试错成本较高。
2. **奖励依赖**：行为主义模型依赖奖励反馈引导学习，当目标明确时效果良好，但在奖励稀疏或模糊的情况下，学习效果可能较差。
3. **难以实现高阶智能的自然涌现**：尽管行为学派在模仿昆虫和群体智能方面取得了一定成果，但对于实现更高层次智能行为的涌现机制，行为学派难以给出明确解释和实现路径，因此在复杂任务的应用中受到限制。

尽管行为学派在模拟高级智能方面仍有不足，其在机器人技术、自动驾驶等实际应用中展示了极强的适应性和应用潜力。

3.6.4 三大学派的比较

3.6.5 三大学派对比总结

人工智能的发展经历了显著的转型：从依赖人工规则的符号主义学派，到借助经验和反馈的联结主义与行为主义学派，AI 的核心方法从“推理期”和“知识期”逐渐过渡到“学习期”。这种变化反映了 AI 在应对复杂问题时，从自上而下的规则构建转向自下而上的经验学习。符号主义学派强调人工设计规则和知识库来解决问题，而联结主义学派和行为主义学派则更关注如何通过数据驱动的方式从经验中学习知识。

人工智能发展过程中，**符号主义学派**、**联结主义学派**和**行为主义学派**分别从不同角度探索智能的本质。每一学派都有其独特的理论基础、代表方法和应用领域，也各有特色。符号学派主要关注智能的逻辑和推理过程，模拟智能软件的工作方式；联结学派则通过模仿大脑神经元结构，试图在“硬件”层面上还原智能；而行为学派则基于简单生物体与环境互动的模式，从动态环境中找寻适应性智能。

1. **符号主义学派 (传统人工智能)**：以逻辑和符号操作为基础，符号主义学派侧重于通过规则和知识库模拟人类的逻辑推理能力。其典型方法包括基于规则的专家系统，主要应用于知识明确、规则清晰的领域，如医疗诊断和金融分析。符号主义的优势在于其强大的可解释性，推理过程清晰可见，便于理解。然而，符号主义在处理复杂、不确定的环境时表现有限，因为它依赖于结构化的知识库和固定规则，难以应对环境的动态变化。符号主义的知识设计是**自上而下**的，主要通过逻辑设计和专家知识进行知识建模，但人类的知识和经验往往难以精确描述，并且复杂的推理过程增加了计算难度。
2. **联结主义学派**：借鉴神经科学，联结主义学派通过构建人工神经网络来模拟大脑的学习

和感知机制。其代表模型包括卷积神经网络（CNN）、递归神经网络（RNN）等，强调通过数据驱动的学习，在大规模数据中自动调整参数，广泛应用于图像识别、语音识别和自然语言处理等领域。联结主义学派的优点在于其强大的数据处理能力，可以自适应复杂数据环境；联结主义的知识形成是**自下而上**的，通过模拟神经网络结构涌现知识。然而，其“黑箱”性质导致可解释性不足，且训练过程依赖大量数据和计算资源。

3. **行为主义学派**：基于行为主义心理学和生物学对动物行为的研究，行为主义学派强调通过智能体与环境的交互来优化行为策略，其典型实现是强化学习。行为主义方法更适合动态和不确定环境中的智能体训练，例如自动驾驶、机器人控制和游戏对抗。行为主义的特点是**试错式学习机制**，使得智能体在持续反馈中逐步优化策略。然而，其高维度环境中的学习效率较低，且高度依赖明确的奖励信号，难以实现对高阶智能的自然涌现。

学派间的比较：

- **理论基础**：符号主义学派依赖符号和逻辑推理，经由专家自上而下基于逻辑来构建知识系统；联结主义学派模仿神经网络的结构，自下而上实现知识的涌现；行为主义学派则从智能体的行动和环境反馈中寻找最优策略，构建出适应性的智能。三者代表了不同的智能观：符号主义偏向于逻辑和推理，联结主义倾向于模式识别和学习，行为主义重视试错与适应。
- **适用领域**：符号主义适用于规则明确、知识体系完善的场景；联结主义适合海量数据驱动的模式识别任务；行为主义则在动态、非结构化的环境中表现突出，如自动驾驶和机器人控制。
- **** 优劣势 ****：符号主义具有良好的可解释性，但灵活性有限；联结主义具备强大的感知与模式识别能力，但对数据依赖性高，且可解释性不足；行为主义适应性强，但在高维度和奖励稀疏的环境下学习效率较低，难以实现复杂智能的涌现。

三大学派的各自特长和局限使得现代人工智能研究趋向于融合不同方法。例如，将符号逻辑引入神经网络以提升可解释性，或将强化学习与深度学习结合以应对复杂策略任务。通过综合符号推理、神经网络和交互学习的优势，现代 AI 逐渐朝着多模态、多层次的智能系统发展，在更多领域实现了实际应用。

表 3.1: 三大学派的比较

学派	主要观点	优势	局限性
符号主义	符号和规则模拟人类智能	擅长结构化问题和逻辑推理	难以处理非结构化和动态环境
联结主义	神经网络模拟大脑联结	数据驱动，自动学习	需要大量数据，解释性不足
行为主义	交互和反馈强化行为学习	适用于策略优化和动态决策	需要大量交互，目标不明确时效率低

三大学派的方法论

表 3.2: 人工智能主要学派

符号主义学派	联结主义学派	行为主义学派
认知即计算 - 起源于 2300 年前，更关注哲学、逻辑学和心理学，将学习视为逆向演绎 - 使用符号、规则和逻辑来表征知识和进行逻辑推理 常用算法： 规则和决策树	认知即网络 - 起源于上世纪 40 年代，专注物理学和神经科学 - 使用概率矩阵和加权神经元来动态地识别、分类、归纳 常用算法： 深度学习神经网络、反向传播	感知-行动 - 起源于上世纪 40 年代 - 在遗传学、进化生物学、控制论的基础上，生成变化，为特定目标获取其中最优解 常用算法： 遗传算法、蚁群算法、强化学习




图 3.5: 智能金字塔

3.7 小结：危机与机遇中的 AI 发展之旅

纵观人工智能的成长历程，它既是一场理解智能的探索，也是一场应对挑战的征途。AI 的发展如同蜿蜒的河流，经历过激荡的浪潮，也度过了平静的深潭。在数次寒冬的洗礼后，AI 不断焕发新的生机，展示出危机中的无限机遇。

每一次技术突破和危机，都塑造了 AI 的未来方向。

1. 达特茅斯会议后的开创期（1956 年 - 1970 年代初）：1956 年的达特茅斯会议首次提出“人工智能”概念，开启了 AI 的黄金时代。研究者尝试用逻辑推理和符号操作来模仿智能，开发了 Logic Theorist 和 General Problem Solver 等符号主义 AI 的早期成果，虽为初探，却为智能探索奠定了基础。

2. 第一次 AI 寒冬（1974 年 - 1980 年代初）：由于符号主义 AI 无法解决现实问题的模糊性和不确定性，以及高昂的资源消耗，AI 研究在此期间陷入低谷，资金支持大幅削减。这场寒冬也促使研究者反思符号主义 AI 的局限性，重新思考智能的实现路径，为下一阶段的知识工程发展铺平了道路。

3. 专家系统和知识工程的兴起（1970 年代末 - 1980 年代中期）：第一次 AI 寒冬后，DENDRAL 和 MYCIN 等专家系统展示了 AI 在医疗、化学分析等领域的实际应用潜力，使 AI 逐渐从实验室走向商业应用，知识工程兴起。但由于专家系统过度依赖手动编码的知识和固定规则，逐渐暴露出适应性不足的局限。

4. 第二次 AI 寒冬（1980 年代末 - 1990 年代初）：专家系统的高昂维护成本和对环境的适应性限制使得全球的 AI 项目纷纷缩减以至于停滞，AI 再次进入低谷。但这场寒冬促使 AI 领域认识到，仅靠符号规则难以实现真正智能，推动了方法上的转型。

5. 联结主义和机器学习的崛起（1990 年代 - 2010 年左右）：以神经网络和数据驱动方法为基础，联结主义和机器学习的蓬勃发展，标志着 AI 从符号主义迈向数据驱动的新时代。机器学习逐渐成为主流方法，通过模式识别和大数据训练，使 AI 具备了在各种任务中自我改进的能力。1997 年，IBM 的“深蓝”战胜卡斯帕罗夫，这一里程碑事件展现了机器学习在复杂决策中的潜力，也宣告了数据驱动 AI 的初步胜利。

6. 深度学习的快速发展（2010 年代）：在计算能力提升和数据量增加的支持下，深度学习技术在图像识别、语音识别、自然语言处理等领域取得突破性进展，使 AI 再度迎来黄金期。2016 年，AlphaGo 战胜李世石，标志 AI 在复杂推理问题上的新高度。寒冬中的积累与反思，转化为深度学习这一数据驱动方法的强大推动力，成就了 AI 新时代的辉煌。

7. 大语言模型（LLM）与 AIGC 的崛起（2020 年代）：近年来，基于数十亿参数和海量数据训练的大规模语言模型（如 GPT 系列和 BERT）与 AI 生成内容（AIGC）技术迅速崛起。LLM 具备深度语言理解和生成能力，能进行逻辑连贯的文本生成，开创了更加自然的智能人机互动。AIGC 进一步拓展了 AI 的创作边界，使 AI 从信息回答者进化为创意合作伙伴，广泛应用于创意内容生成、广告、教育和娱乐领域。

在危机与机遇交织的 AI 发展史中，每一次危机都意味着新的机遇。两次寒冬带来低谷，但也促使 AI 领域在反思中寻找新方向，逐渐摆脱了对符号逻辑的单一依赖，向数据驱动和自

适应学习的方向迈进。

知识工程为 AI 的应用打开了大门，而机器学习和深度学习的崛起则奠定了现代 AI 的基础。

今天，AI 的视野已从实验室扩展到生活的方方面面，从模仿人类思维到自主学习，从专注特定领域到应对复杂决策。AI 的历程是一部充满智慧与勇气的进化史，展现了智能的无限潜力。我们期待 AI 继续向前，为人类揭示智能的更多可能性，并引领我们在未知中发现更广阔的世界。

参考文献

- [0] “A Logical Calculus of Ideas Immanent in Nervous Activity”. In: *Bulletin of Mathematical Biophysics* 5 (1943), pp. 127–147.
- [0] Yoshua Bengio. “Practical recommendations for gradient-based training of deep architectures”. In: *Neural networks: Tricks of the trade: Second edition*. Springer, 2012, pp. 437–478.
- [0] George Cybenko. “Approximation by superpositions of a sigmoidal function”. In: *Mathematics of control, signals and systems* 2.4 (1989), pp. 303–314.
- [0] Kunihiro Fukushima and Sei Miyake. “Neocognitron: A new algorithm for pattern recognition tolerant of deformations and shifts in position”. In: *Pattern recognition* 15.6 (1982), pp. 455–469.
- [0] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. “Multilayer feedforward networks are universal approximators”. In: *Neural Networks* 2.5 (1989), pp. 359–366.
- [0] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. “Universal approximation of an unknown mapping and its derivatives using multilayer feedforward networks”. In: *Neural networks* 3.5 (1990), pp. 551–560.
- [0] David H Hubel and Torsten N Wiesel. “Receptive fields and functional architecture of monkey striate cortex”. In: *The Journal of physiology* 195.1 (1968), pp. 215–243.
- [0] Han Jiawei, Kamber Micheline, and Pei Jian. *Data Mining: Concepts and Techniques*. -3rd. Morgan Kaufmann, 2011.
- [0] Fukushima K and Miyake S. “Neocognitron: A self-organizing neural network model for a mechanism of visual pattern recognition”. In: *Competition and cooperation in neural nets*. Springer, Berlin, Heidelberg, 1982, pp. 267–285.
- [0] Diederik P Kingma and Jimmy Ba. “Adam: A method for stochastic optimization”. In: *arXiv preprint arXiv:1412.6980* (2014).
- [0] Yann Le Cun, Boser Brian, and et al. Denker John S. “Handwritten digit recognition with a back-propagation network”. In: *Advances in neural information processing systems*. 1990, pp. 396–404.
- [0] Yann Le Cun et al. “Handwritten digit recognition: Applications of neural net chips and automatic learning”. In: *Neurocomputing: Algorithms, Architectures and Applications*. Springer. 1990, pp. 303–318.
- [0] Yann LeCun et al. “Backpropagation applied to handwritten zip code recognition”. In: *Neural computation* 1.4 (1989), pp. 541–551.

- [0] Yann LeCun et al. “Gradient-based learning applied to document recognition”. In: *Proceedings of the IEEE* 86.11 (1998), pp. 2278–2324.
- [0] Minsky Marvin and A Papert Seymour. “Perceptrons”. In: *Cambridge, MA: MIT Press* 6.318-362 (1969), p. 7.
- [0] Warren S McCulloch and Walter Pitts. “A logical calculus of the ideas immanent in nervous activity”. In: *The bulletin of mathematical biophysics* 5 (1943), pp. 115–133.
- [0] Tom Mitchell. *Machine Learning*. McGraw-Hill Education, 1997.
- [0] Michael Nielsen. *Neural Networks and Deep Learning*. Accessed: 2025-03-03. 2015. URL: <http://neuralnetworksanddeeplearning.com/>.
- [0] Hastie T, Tibshirani R, and Friedman J. 统计学习基础 (*The Elements of Statistical Learning*). 北京: 世界图书出版公司, 2015.
- [0] Alan Turing. *Computing Machinery and Intelligence*. Oxford, 1950.
- [0] Vladimir Naumovich Vapnik. 统计学习理论的本质. 清华大学华夏出版社, 2000.
- [0] Ashish Vaswani et al. “Attention is all you need”. In: *Advances in neural information processing systems* 30 (2017).
- [0] 于剑. 机器学习—从公理到算法. 北京: 清华大学出版社, 2017.
- [0] [意] 翁贝托·博塔兹尼. 余婷婷译. 尖叫的数学—令人惊叹的数学之美. 湖南科学技术出版社, 2021.
- [0] 周志华. 机器学习. 清华大学出版社, 2016.
- [0] Vladimir N. Vapnik. 张学工译. 统计学习理论的本质. 北京: 清华大学出版社, 2000.
- [0] 张玉宏. 深度学习之美—AI 时代的数据处理与最佳实践. 电子工业出版社, 2018.
- [0] 张玉宏. 深度学习之美: AI 时代的数据处理与最佳实践. 电子工业出版社, 2018.
- [0] Tom Mitchell. 曾华军等译. 机器学习. 北京: 机械工业出版社, 2002.
- [0] 王珏, 周志华, 周傲英. 机器学习及其应用. Vol. 4. 清华大学出版社有限公司, 2006.

第二部分

参考文献

致谢

写作是一项孤独的事业。形单影只，与键盘为伴，上一秒文思泉涌，下一秒却自我怀疑。但从某些方面来说，作家这一职业实质上具有社会性。每位作者都可以反思哪些人激发了他们的创作灵感，并深深感谢那些深刻影响了他们创作的作家、思想家、研究者，以及各种不同的思想。

无论他们是否知道，下列人士都给予了我特别的启发与帮助，谨致谢忱：

我们无比感谢本书的中英文版稿件贡献者和论坛用户们。他们帮助增添或改进了书中内容并提供了有价值的反馈。特别地，我们要感谢每一位为这本中文版开源书提交内容改动的贡献者们。这些贡献者的 **GitHub** 用户名或姓名是（排名不分先后）：..... 谢谢你们为每一位读者改进这本开源书。

本书的初稿在中国科学技术大学、上海财经大学的“深度学习”课程以及浙江大学的“物联网与信息处理”课程和上海交通大学的“面向视觉识别的卷积神经网络”课程中被用于教学。我们在此感谢这些课程的师生，特别是连德富教授、王智教授和罗家佳教授，感谢他们对改进本书提供的宝贵意见。

此外，我们感谢 **Amazon Web Services**，特别是 **Swami Sivasubramanian**、**Raju Gulabani**、**Charlie Bell** 和 **Andrew Jassy** 在我们撰写本书时给予的慷慨支持。如果没有可用的时间、资源以及来自同事们的讨论和鼓励，就没有这本书的项目。我们还要感谢 **Apache MXNet** 团队实现了很多本书所使用的特性。另外，经过同事们的校勘，本书的质量得到了极大的提升。在此我们一一列出章节和校勘人，以表示我们由衷的感谢：引言的校勘人为金颢，预备知识的校勘人为吴俊，深度学习基础的校勘人为张航、王晨光、林海滨，深度学习计算的校勘人为查晟，卷积神经网络的校勘人为张帜、何通，循环神经网络的校勘人为查晟，优化算法的校勘人为郑帅，计算性能的校勘人为郑达、吴俊，计算机视觉的校勘人为解浚源、张帜、何通、张航，自然语言处理的校勘人为王晨光，附录的校勘人为金颢。

感谢将门创投，特别是王慧、高欣欣、常铭珊和白玉为本书的两位中国作者在讲授“动手学深度学习”系列课程时所提供的平台。感谢所有参与这一系列课程的数千名同学们。感谢 **Amazon Web Services** 中国团队的同事们，特别是费良宏和王晨对作者的支持与鼓励。感谢本书论坛的 3 位版主：王鑫、夏鲁豫和杨培文。他们牺牲了自己宝贵的休息时间来回大家的提问。感谢人民邮电出版社的杨海玲编辑为我们在本书的出版过程中所提供的各种帮助。

感谢中英文草稿的数百位撰稿人。他们帮助改进了内容并提供了宝贵的反馈。感谢 **Anirudh Dagar** 和唐源将部分较早版本的 **MXNet** 实现分别改编为 **PyTorch** 和 **TensorFlow** 实现。感谢百度团队将较新的 **PyTorch** 实现改编为 **PaddlePaddle** 实现。感谢张帅将更新的 **LaTeX** 样式集成进 **PDF** 文件的编译。

特别地，我们要感谢这份中文稿的每一位撰稿人，是他们的无私奉献让这本书变得更好。他们的 **GitHub ID** 或姓名是（没有特定顺序）：

我们感谢 **Amazon Web Services**，特别是 **Swami Sivasubramanian**、**Peter DeSantis**、**Adam**

Selipsky 和 Andrew Jassy 对撰写本书的慷慨支持。如果没有可用的时间、资源、与同事的讨论和不断的鼓励，这本书就不会出版。

最后，我们要感谢我们的家人。谢谢你们一直陪伴着我们。

表 3: 术语对照表

中文	英文	定义 (≤20 字)	首次出现
泛化	generalization	在新样本上保持性能	第 7 章
归纳偏好	inductive bias	学习算法内在偏向	第 7 章
对抗样本	adversarial example	微扰使模型误判的输入	第 10 章
表示学习	representation learning	从数据自动提取特征	第 8 章
因果图	causal graph	变量因果关系的有向图	第 12 章

表 4: 通用符号约定

符号	含义	域/形状/单位	默认约定	首次出现
$\mathbf{x}$	输入特征向量	$\mathbb{R}^d$	列向量, 粗体表 向量	第 7 章
y	监督标签	$\{0, 1\}$ 或 $\mathbb{R}$	分 类/回 归 上 下 文 限 定	第 7 章
$\hat{y}$	模型预测	同 y	argmax 或 回 归 输 出	第 7 章
$\mathbf{W}$	权重矩阵	$\mathbb{R}^{n \times d}$	行 对 应 单 元, 列 对 应 特 征	第 7 章
b	偏置	$\mathbb{R}$	标 量	第 7 章
$\mathcal{L}$	损失函数	—	统 一 写 作 “损 失 (loss)”	第 7 章
λ	正则系数	$\mathbb{R}_{\geq 0}$	L2 默 认 为 权 重 衰 减	第 7 章
η	学习率	$\mathbb{R}_{> 0}$	SGD/Adam 上 下 文 说 明	第 7 章
$\sigma(\cdot)$	激活函数	—	章 内 注 明 具 体 形 式	第 7 章
ϵ	扰动幅度	$\mathbb{R}_{\geq 0}$	对 抗 样 本/数 值 稳 定	第 10 章