

人工智能十年展望（二）：边际成本决定竞争力，算法龙头主导格局优化



陈星宇

SAC 执证编号: S0080121020020
xingyu3.chen@cicc.com.cn


于钟海

SAC 执证编号: S0080518070011
SFC CE Ref: BOP246
zhonghai.yu@cicc.com.cn

魏鹤霏

SAC 执证编号: S0080121070252
guanfei.wei@cicc.com.cn

纵轴：相对值 (%)



股票名称	股票评级	目标价格	P/E (x)	
			2021E	2022E
科大讯飞-A	跑赢行业	78.00	62.3	46.2

中金一级行业：科技

资料来源：万得资讯，彭博资讯，中金公司研究部

- 软件及服务 | 人工智能十年展望（一）：底层模拟人脑，算力决定上限 (2021.07.13)

更多作者及其他信息请见文末披露页

观点聚焦

投资建议

AI 行业处在商业落地初期，目前呈现场景多、需求碎片化的行业痛点。本文指出边际成本是未来 AI 竞争的核心要素，我们认为，龙头有望率先实现 AI 行业的“工业革命”，并受益于数据-模型的反馈优化机制带来的先发优势，未来将占据较高份额。我们预计 AI 核心的平台、算法层将朝着一超多强的格局演变，持续底层投入的龙头企业能够建立成本及全栈技术的护城河，并通过大模型的技术路线解决碎片化的问题，在未来竞争中占领高地。

理由

边际成本是未来十年 AI 行业竞争核心要素，AI 平台及算法层有望演进为类似基础软件的分化格局，龙头规模效应优势明显。各行业的数字化转型意味着大量 AI 模型需求，AI 模型通用性低导致项目碎片化、交付效率低是行业目前痛点，未来高生产效率、低边际成本是 AI 竞争焦点。龙头厂商通过全栈底层能力提升实现 AI 模型的工业化生产，从根本上提升效率。另一方面，用于 AI 模型的算力增长、算法效率优化呈现新“摩尔定律”，且基于数据-模型反馈机制，龙头算力、算法正向循环强化巩固先发优势，我们预计 AI 在关键的平台层、算法层有望形成龙头遥遥领先的分化格局。

持续底层投入才能铸就技术成本、效率的护城河，国内目前底层技术自研能力较为稀缺。在 AI 技术体系内，软件框架是核心，目前主要由海外巨头引领，国内仅少数巨头具备底层自研能力。算力层方面，AIDC 能力国内稀缺，我们认为，AI 公司自建算力中心或将成为未来趋势，同时自建 AIDC 实现 AISC 算力云化是突破英伟达 CUDA 生态壁垒的关键；平台层方面，基于软件训练框架、生产平台、部署框架等，AI 算法行业有望迎来“工业革命”，实现效率的大幅提升。算法层则借力大算力下通用模型带来的海量场景模型发挥规模效应，降低边际成本。

大模型技术路线是解决碎片化问题的突破点，技术、资本壁垒较高，是 AI 巨头之间的战场。传统的精妙模型在长尾需求中暴露短板，近年大模型发展加速，是实现通用 AI 的重要方向。大模型+小模型是降低算法边际成本的关键架构，但技术和算力壁垒高，常见开源框架对于大模型场景的性能支撑不足，通过自主框架进行底层定制优化是实现大模型的关键。

盈利预测与估值

建议关注科大讯飞、商汤科技（未上市）。

风险

国内技术进步、生态建设不及预期，行业竞争加剧，海外出口管制风险。

目录

一、算法边际成本是未来十年 AI 市场竞争焦点.....	6
目前 AI 行业痛点在于碎片化、边际成本高	6
大模型时代强者愈强，数据-模型反馈优化机制决定先发优势	8
AI 新“摩尔定律”下，龙头凭借边际成本优势有望主导一超多强格局.....	10
二、AI 大装置：持续底层投入铸就技术成本技术护城河，国内底层自研能力稀缺	16
AI 技术体系架构：软件框架是核心，全栈能力铸就护城河	16
算力层：自研芯片+自建 AIDC 是破局英伟达 CUDA 生态极佳路径	19
平台层：工业级的算法生产流程掀起 AI 算法的工业革命	23
算法层：海量模型解决项目标准化问题	29
三、大模型是解决碎片化问题的突破点	31
大模型是 AI 行业重要的产业趋势	31
大模型技术、资本壁垒高，是 AI 巨头之间的博弈	33
基于底层大装置+大模型，AI 有望向基础软件分化格局演变	36
风险提示	38

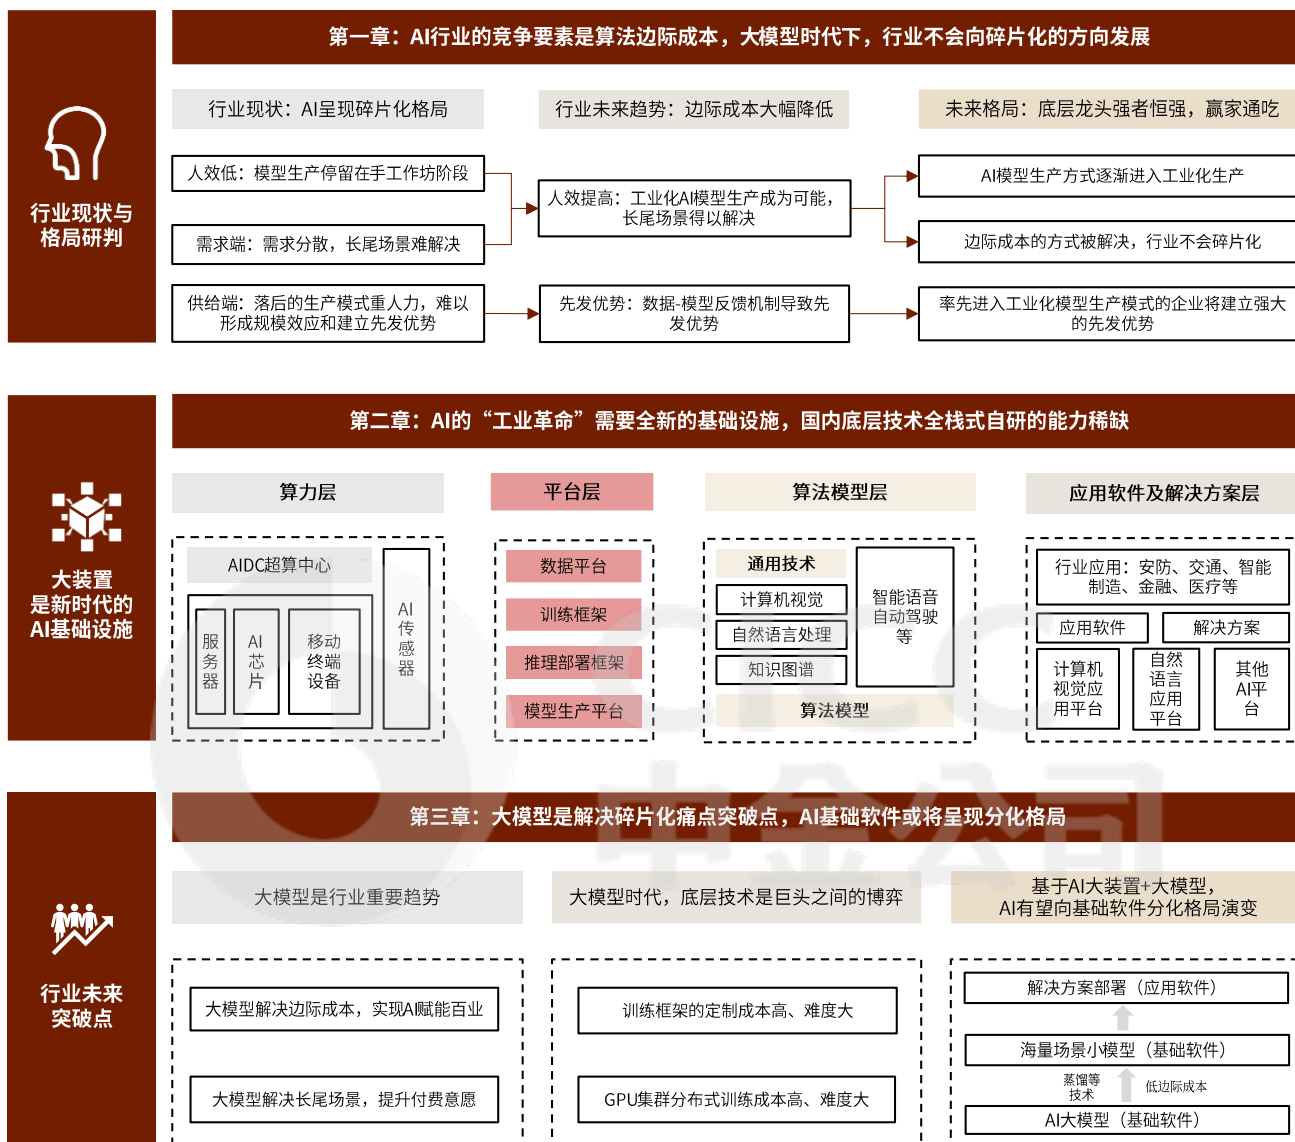
图表

图表 1: 全文章节结构框架.....	5
图表 2: 目前 AI 项目开发的流程繁琐, 数据阶段和训练评估阶段的循环占用了大量时间.....	6
图表 3: 弱人工智能阶段长尾场景种类繁多导致项目碎片化.....	7
图表 4: AI 从引起业界广泛关注到目前不足 10 年.....	8
图表 5: 参数规模越大的 GPT-3 小样本学习能力更强.....	9
图表 6: 复杂商用场景不同模型少样本学习达到的结果 (与学习 full lable 数据的结果对比)	9
图表 7: 数据量不足容易带来过拟合问题, 更多的数据有利于更好的模型.....	10
图表 8: 企业使用 AI 底层框架企业占比调研情况.....	11
图表 9: 我国 AI 公司技术层次分布 (2020 年)	11
图表 10: 我国 AI 企业应用领域分布 (2020 年)	11
图表 11: AutoML 在数据、模型和优化三个环节减少对深度学习专家的依赖	12
图表 12: AI 龙头有望率先解决长尾场景, 完成商业模式的闭环, 解决碎片化问题.....	13
图表 13: 算力增长和算法的效率增长均呈现出新“摩尔定律”	14
图表 14: 以摄像头为例, 未来摄像头数据需要 AI 代替人工完成自动分析	15
图表 15: 摄像头领域国内龙头对国内外竞争对手的优势	15
图表 16: AI 行业整体技术体系架构	17
图表 17: 国内外典型深度学习软件框架情况	18
图表 18: 不同深度学习软件框架技术栈对比	18
图表 19: 深度学习模型优化流程	19
图表 20: 深度学习模型典型超参数	19
图表 21: 人工智能芯片应用情况	20
图表 22: cuDNN5+ Torch 帮助 LSTM RNN 加速最多达 6 倍 (与 Torch-RNN 相比)	20
图表 23: CUDA 生态系统具体内容.....	21
图表 24: 大规模预训练模型算力需求增长.....	21
图表 25: 全球 AI 超算进展梳理	22
图表 26: 深度学习模型平台	23
图表 27: KDnuggets 综合评分前十的 AI 训练框架.....	24
图表 28: GitHub 收藏数和贡献率排名 TOP16 的框架.....	24
图表 29: SenseParrots 发展历程.....	24
图表 30: 主流开源框架对比 (大部分开源框架设计时未充分考虑多 GPU 支持能力)	25
图表 31: 国内自主模型生产平台使用多种先进技术优化大模型训练能力.....	26
图表 32: 加速芯片对不同精度计算的理论计算峰值	26
图表 33: 目前推理部署框架主要部署在设备端和云端	27
图表 34: 推理框架有三种较为矛盾的需求, 难以同时做到极致	27
图表 35: SensePPL 相对于 Caffe 的比较加速比.....	28
图表 36: 量化流水线提供高效率、低成本的系统层面优化部署方式.....	28
图表 37: 数据处理相关工作是 AI 落地的难点和痛点	29
图表 38: OpenMMLab 发展主要节点梳理	30
图表 39: 现有深度学习模型的神经元总量、稠密度与人类还有较大差距.....	31
图表 40: 智慧城市占人工智能市场行业近一半份额 (2020 年)	32

图表 41：大规模预训练模型对于算力需求呈指数增长	33
图表 42：内存/硬件数据通信能力速度远慢于峰值计算能力增长	34
图表 43：ResNeSt269 训练时的显存墙问题	35
图表 44：扩大带宽将导致带宽利用率将持续降低	35
图表 45：底层框架对于大模型的实现至关重要	35
图表 46：蒸馏技术是类似于老师-学生传递知识的过程	36
图表 47：商汤科技 AI 赋能百业实现方式	37
图表 48：可比公司估值表	38



图表 1：全文章节结构框架



资料来源：中金公司研究部


一、算法边际成本是未来十年 AI 市场竞争焦点

目前 AI 行业痛点在于碎片化、边际成本高

AI 行业碎片化的本质在于模型生产仍停留在“手工作坊”时代

目前 AI 项目落地还停留在“手工作坊”阶段，存在重复造轮子情况，边际成本高。目前国内大部分 AI 项目的落地是以项目制的形式，主要包括需求阶段、打光阶段、数据阶段、算法设计阶段、训练评估阶段、部署阶段和运维阶段。其中，数据阶段和训练评估阶段往往需要多次循环，专家驻场收集数据并训练模型，发现指标无法满足需求后再重新进入数据阶段，一个项目往往需要专家团队驻场数月完成。

图表 2：目前 AI 项目开发的流程繁琐，数据阶段和训练评估阶段的循环占用了大量时间




资料来源：极市平台公众号，中金公司研究部

目前大部分场景数据规范性差、长尾，且采集方法落后，导致工作量较大。由于中国工业等下游行业信息化程度低，数据采集方式落后，有些工厂的工单完全靠工人手工记录，传感器也可能由于部署位置不佳导致未采集到关键信息。目前大部分下游企业没有建立起以数据为 KPI 的考核机制，工人不重视数据记录方式和质量。自然系统的数据凌乱、长尾、不可预测甚至高度熵，导致 AI 项目的工作量大、项目成本高，部分 AI 项目落地时经济性差。

碎片化的本质原因在于现阶段 AI 模型的通用性低，模型生产还停留在“手工作坊”的时代，单个模型只适用特定任务。即使同样的算法在不同场景落地，也会演化出非常不同的版本，会给技术积累产生很大的挑战。例如，在工厂场景下检测零部件、在医疗图像中检测病理特征，虽然本质上都是检测，但是两种情形下要获得准确结果都需要大量数据、实验和参数，一旦场景和任务发生变化，就需要重新收集、标注数据、训练模型。由于客户需求多样，以至于几乎每个项目都要重复进行这一流程，研发流程难以复用，重度依赖人力，边际成本很高。

图表 3：弱人工智能阶段长尾场景种类繁多导致项目碎片化



资料来源：量子位，中金公司研究部

需求端：数字化意味着大量模型需求，高生产效率，低边际成本是关键

全社会的数字化是人工智能的重要目标，同时也意味着巨量的建模需求。随着数字信息世界、物理世界融合，产生的数据量是以前的成千上万倍，以无人车为例，一辆无人车每天产生的数据量大约 5-10T。数字化社会海量的数据只能交给机器处理，因此需要非常复杂的算法来识别和检测，在机器处理完成后再传递给人员。一个人平均每天接触物体 600 个，若每三个物体进行一次组合，发生变化超过 3500 万次，即 3500 万种组合，且组合之间还会发生关联，其模型需求远大于目前业界效率所能达到的量级。

由于模型数量限制，目前设备智能多为单点智能，未来其功能丰富度和完善度提升空间较大。目前大多数智能设备只能做到单点智能，具备一种或两种特定的智能功能，背后原因主要是 AI 模型数量少、通用性差因而覆盖行业少，目前大量的行业渗透才刚刚起步。我们认为，未来随着专用机器学习芯片、微型传感器和高带宽网络价格下降，每一个智能化设备都将融合十几种甚至上百种智能功能，更好地发挥出设备的价值。

巨量的模型需求需要较高的 AI 模型生产效率、较低的算法边际成本。如果要完成设备数字化的建设，必然需要涵盖社会的方方面面，像人脸识别这类流量大、数据多、投入产出比高的场景占少数，还存在大量的范围广、差异大、频次低的长尾场景，这样广泛的场景凭借定制化开发的技术路线难以实现全面的数字化覆盖。

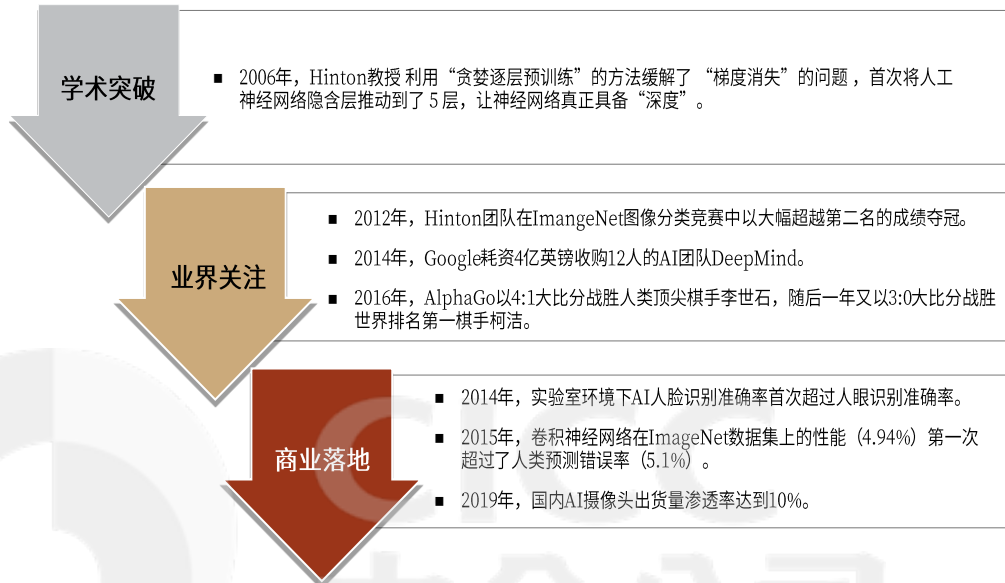
供给端：AI 人才稀缺、基础设施不完善导致项目落地成本高

技术层面，深度学习作为一门新的学科人才稀缺。深度学习是独立发展于传统计算机技术体系之外的新学科，上世纪 90 年代的互联网潮流吸引了大部分计算机科研和工作人员，也导致了深度学习的沉寂，直到 2012 年 Hinton 带领的团队在 ImageNet 挑战赛中大幅降低图片识别错误率，深度学习行业才开始被业界和资本关注，到现在不到十年时间，相关人才的培养还未成体系，一定程度上造成人才稀缺。早期深度学习受各方质疑，全球范围内极少数人专注于此领域研究，导致人才供给非常稀缺。从全球来看，

针对深度学习的人才争夺非常激烈：

- ▶ 2013 年，Google 耗资 4400 万美元收购 Hinton 的研究团队 DNNResearch，该团队当时仅三人，且无任何产品及生产计划。
- ▶ 2014 年，Google 耗资 4 亿英镑收购 12 人的 AI 团队 DeepMind。

图表 4：AI 从引起业界广泛关注到目前不足 10 年



资料来源：Omdia，中金公司研究部

工程层面，行业基础设施建设不完善，具备工程实践经验的人才稀缺。深度学习作为一门新学科，其算法所需底层设施与普通编程区别较大，目前基础设施建设仍然不完善，GTP-3 被推出后，业界才对大模型方向坚定了信心，意识到 AI 超算中心等底层投入的重要性，目前能接触到大算力资源等基础设施的研究人员非常有限。另外，深度学习是一门工程学科而非自然学科，理论知识在处理实际问题时会面临很多挑战，例如数值稳定性、优化参数的调整、模型训练的时间要求，其落地依赖实践过程中的经验积累，目前具备工程经验的人才较少。

深度学习人才稀缺导致整体项目实现难度、成本高，未来解决方案落地推广的核心方向在于降低边际成本。早期 AI 落地多以项目定制为主要形式，场景落地的过程中可能需要上百人的团队驻场，就像在不同的场景里盖楼，通过堆人来解决，这样重人力的落地方式和 AI 人才稀缺性造成 AI 项目的人力成本很高，AI 的落地仅限于人效高的场景，长尾场景解决方案的投入产出比让甲方和乙方望而却步，因此 AI 不能做到赋能百业，我们认为，未来解决方案落地的方向在于降低边际成本。

大模型时代强者愈强，数据-模型反馈优化机制决定先发优势


大模型时代下，AI 模型进入工业化生产模式，规模效应导致马太效应

大模型预训练的难题被攻克，预训练大模型成为降低边际成本的关键。GPT-3 的出现让业界充分认识到，大模型是产业未来趋势。即先使用海量数据预训练大模型，得到一

套模型参数，然后用这套参数对模型进行初始化，再进行训练，预训练大模型能大幅降低对数据量的需求。我们在系列报告一《[人工智能十年展望\(一\)：底层模拟人脑，算力决定上限](#)》中提到，传统的模型训练方式是反向传播算法，先对网络中的参数进行随机初始化（预训练大模型中不是随机初始化的），再利用随机梯度下降等优化算法不断优化模型参数，这种方式下对数据需求量较大，需收集大量数据并反复调整模型，因此边际成本高。


进行新任务学习时，大模型显著降低对数据量的需求。根据知名研究机构 OpenAI 的一项英文单词预测的训练，1750 亿参数的 GPT-3 在面对不包含在训练集中的新颖任务时，达到相同精度所需的数据比小模型更少。GPT-3 作为实验室产物，其后被证明在复杂商用场景下效果仍然有待提高。但 AI 公司通过对训练框架的优化等技术，能大大提升复杂商用场景下的少样本学习能力。以华为盘古大模型为例，盘古大模型在少样本学习中，展现出了远超其他参数相对较小、实验室状态下产出的大模型。

图表 5：参数规模越大的 GPT-3 小样本学习能力更强



资料来源：OpenAI，中金公司研究部

图表 6：复杂商用场景不同模型少样本学习达到的结果（与学习 full table 数据的结果对比）




资料来源：华为开发者社区，中金公司研究部

基于预训练大模型的时代到来，模型生产的效率提高、边际成本降低。包括商汤科技、百度、华为等国内 AI 龙头企业在 GPT-3 面世之前就前瞻认识到，基于预训练大模型的 AI 模型工业化方式是未来趋势，并在训练框架、算力平台等底层技术设施上大力投入，目前已经在工业化 AI 生产的方式上拥有较强的先发优势。以商汤科技为例，通过压缩预训练大模型来生产小模型，一年能生产数万个 AI 模型，且对数据量需求大幅降低，对边际成本的控制业内遥遥领先，从而掌握定价权。

数据-模型反馈机制为龙头企业带来较强的先发优势

数据-模型反馈优化机制是深度学习技术的重要特点。由于深度学习生产的本质在于通过向神经网络模型喂数据，通过数据训练调整神经网络模型的参数和权重（类似人脑神经网络的学习原理），研究人员只需要调整超参数，所以深度学习模型的准确性很大程度上是数据驱动的。数据量大、质量高、多样性强很大程度上解决了训练过拟合的问题，是好模型的基础。因此，人工智能的数据反馈机制是由深度学习底层技术原理所决定的。

图表 7：数据量不足容易带来过拟合问题，更多的数据有利于更好的模型



资料来源：fast.ai，中金公司研究部

数据反馈机制意味着先发优势，抢占标杆客户是目前 AI 行业的重要竞争点。由于深度学习模型是数据驱动的，控制其他因素时，有了更多、更优质的数据往往就意味着更优质的模型，因此 AI 行业独特的数据反馈机制造就了行业的先发优势。在当下处于 AI 大规模商业化落地的早期阶段，跑马圈地、抢占优质的大客户是 AI 行业关键竞争点，因为更多、更优质的客户意味着更多的数据，有利于模型的迭代及竞争壁垒的打造。

AI 新“摩尔定律”下，龙头凭借边际成本优势有望主导一超多强格局


AI 模型正经历从“手工作坊”到工业化生产的转变

AI 的工业化时代需要新的底层基础设施，高强度的底层投入才能解决生产效率问题。只有在底层硬件、训练框架、算法模型、通用技术上大力投入，才能解决生产效率问题，如果不投入底层技术，AI 项目难以摆脱以重人力方式落地的限制，AI 公司不得不在应用层投入大量人力。看起来，与应用层 AI 公司类似，大力投入底层技术设施的 AI 公司同样保持着数千人的研发团队，但其建立起了远远更强的竞争优势。

由于 AI 底层投入资金量大、风险大，全球仅个别巨头在 AI 底层投入重金，国内企业大多布局风险更低的应用层，仅少数企业在 AI 技术底层大力投入。底层投入资金需求大、时间长、风险高，实力雄厚的美国互联网巨头对 AI 底层技术战略性投入力度较大，但中国的 AI 产业主要受需求拉动，大多数 AI 公司布局应用层。从 AI 各个底层技术层面看，底层技术的布局具有较高的风险：

- 深度学习平台方面：国内大部分公司的 AI 研发都选择使用外资巨头开源的 TensorFlow、PyTorch 等深度学习底层框架，包括网易、京东、360、联想、美团等科技企业，仅有商汤、华为、百度等少数企业自研深度学习底层训练、推理框架。


图表 8：企业使用 AI 底层框架企业占比调研情况




资料来源：《德勤中国成长型 AI 企业研究报告：迈向巅峰之路》，中金公司研究部

- ▶ 算法方面：算法研发是一个高风险的事情，算法的领先需要庞大的队伍投入，需要研究人员不断突破算法的极限，持续在顶级期刊中发表论文。
- ▶ 硬件方面，为了支持框架和算法，需要计算力大，但大量 GPU 并联计算会导致严重内存墙和算力墙等问题，大幅增加训练的成本，因此需要对硬件和框架做深度优化。商汤科技在硬件、超算中心上连续多年数亿的高强度投入，为研发提供专用计算能力的支持。

图表 9：我国 AI 公司技术层次分布（2020 年）



图表 10：我国 AI 企业应用领域分布（2020 年）



■ 截至2020年我国人工智能样本企业的应用领域分布单位（单位：%）

资料来源：中国新一代人工智能发展战略研究院，中金公司研究部

资料来源：前瞻产业研究院，中金公司研究部

通过底层投入，AI 模型生产和部署正在经历从“小作坊”到工业化生产的转变。以商汤科技 AI 大装置为例，与“手工作坊”式 AI 模型的打造方式不同，传统 AI 大装置是更像是流水线工厂，可以从底层上对各种场景的算法模型进行抽象，底层上使用各种算法工具模块，通过组合算法套件模块化的进行新场景的定制，以很低的边际成本规模化生产、部署 AI 模型。

龙头厂商通过全栈底层能力的提升，在效率上实现千倍提升，率先实现从项目制向标


准化服务转变，AI 行业开始分化。以商汤为例，受益于多年来在底层技术的持续投入，其算法的生产效率显著提高。根据公开资料，商汤部分算法的生产效率在过往 5 年中提升了约 1000 倍，同样精度的一个算法模型，5 年前可能需要 10 个研究员花半年时间来研发，现在只需要一个研究员花三天就可以完成研发。

大模型+大装置解决边际成本问题，碎片化痛点有望解决

AI 行业不会向碎片化的方向发展，而是强者愈强。在大模型路线下，除了需要的训练数据量更少，模型精度更高外，AI 模型的边际成本还会受益于三个因素的影响大幅降低：底层基础设施可复用、模型研发流程可复用、研发流程自动化。因此 AI 行业将出现强者愈强的马太效应，我们认为，AI 行业不会向着碎片化的方式发展。

- **底层基础设施可复用，降低边际成本。**目前的 AI 项目与项目之间关系不紧密，由于每个项目单独执行，高昂的算法、算力等 AI 生产要素的成本是影响 AI 大规模落地的关键因素。以商汤科技的 AI 大装置为例，公司将多年累积的硬件、框架和 AI 算法和落地经验结合起来，一起融合到 AI 大装置，尽可能的减少重复研发。
- **模型研发流程可复用，大模型提升 AI 通用性。**在大模型压缩制造小模型的工业化生产方式下，AI 公司可以生产大量的、覆盖不同场景的模型。这样，在遇到新场景的情形下，可以通过将原有的模型模块化组装，快速制造新模型，无需针对新场景再次定制化生产。
- **研发流程自动化（AutoML），开发门槛降低，人员成本降低。**目前 AI 模型生产有很多步骤难以摆脱人工参与，从提取数据到预处理、优化、预测，过程中涉及的问题包括是否采用数据增强、损失函数、神经网络层数、拓扑关系的确定、计算量的分配都需要深刻理解 AI 的专家来控制 and 执行，对专家的高需求和供给的错配导致工资水涨船高，这是 AI 落地边际成本高的的重要原因。

图表 11：AutoML 在数据、模型和优化三个环节减少对深度学习专家的依赖



资料来源：CSDN，中金公司研究部

AutoML 能自动执行 AI 流程中的大部分工程性任务，自动化的程度的提高减少了 AI 模型生产过程中对人工的需求量。此外，由于开发人员可以专注于客户需求，机器学习的使用门槛也会降低，AI 落地过程中不再需要招聘深度理解 AI 工程的专家，使得开发人员的成本降低。目前以第四范式为代表的龙头积极布局 AutoML 技术。


具备规模效应的 AI 企业将在算法生产建立强大的先发优势

依靠底层技术投入，AI 龙头的先发优势和规模效应主要体现在如下方面：

- ▶ **底层投入技术、人才、资金壁垒高，时间窗口短：**底层技术投入属于高风险、回报周期长的项目，仅有国内外少数龙头企业能大力投入。由于底层基础设施中算力和算法的摩尔定律，率先投入基础设施企业能在技术迭代中与竞争对手迅速形成代差，因此底层基础设施投资的时间窗口期短，仅有商汤、百度、华为等前瞻投入。
- ▶ **通用大模型+小模型的方式减少定制化：**通过不断在算法、算力和数据上的突破极限，生产智能程度尽可能高的通用模型，减少进入新场景时定制化带来的数据收集、算法生产等边际成本。
- ▶ **算法生产上建立数量级的领先，模块化生产大幅降低进入新场景的边际成本：**通过大量的模型积累，AI 企业可以沉淀可复用的算法底层模块，再模块化组装的方式生产 AI 模型，由于积累的算法模块丰富度高、覆盖面大，进入新场景时能通过模块化组装的方式大幅降低边际成本。

由于数据-模型反馈优化机制的存在，规模效应会带来强大的先发优势，龙头公司进一步掌握定价权。由于边际成本低，诸如商汤等龙头公司能够率先解决长尾场景，满足客户的商业场景的闭环。此外，由于基础设施的完善投入，模型的投入产出比降到很低，因此取得在 AI 行业的定价权。抢占更多的细分领域的关键客户后，龙头能得到更多的数据，进一步优化自身的模型，积累更丰富的算法库，从而有了更低的边际成本。因此数据反馈机制导致规模效应会带来强大的、难以复制的先发优势。

图表 12：AI 龙头有望率先解决长尾场景，完成商业模式的闭环，解决碎片化问题



资料来源：WAIC2021，中金公司研究部


AI 基础设施的算力、算法呈现新“摩尔定律”，AI 行业或将出现类似半导体行业的龙头独大格局。龙头本身算法效率领先，相同算力下能训练生产更优质的模型，同时最先进的 AI 模型约每几个月算力需求就会扩大一倍，构建高并行效率的 AIDC 的难度更高，成本更大。我们认为，随算法和算力的持续迭代，AI 行业将出现强者愈强的马太效应，行业有望形成类似半导体行业龙头独大的格局，边际成本领先的龙头如商汤等将持续领跑。

- ▶ **算力方面，**根据斯坦福大学和麦肯锡联合发布的《2019 人工智能指数报告》，2012 年之前最先进 AI 模型计算量每两年翻一倍；2012 年之后计算量每 3.4 个月翻一

番，从 2012 年到 2020 年 3 月已增长 30 万倍。

- 算法方面，OpenAI 发现最高效的 AI 模型，所需的算力每 16 个月就会减少 1/2。

图表 13：算力增长和算法的效率增长均呈现出新“摩尔定律”



资料来源：OpenAI，中金公司研究部

远期待来看，物理世界的数字化有望带来全新的商业模式，AI 工业化生产的龙头企业凭借先发优势有望率先推动新场景、新商业模式。随着 AI 模型的积累复用和落地效率提升，人工智能技术有望重塑社会的工作流程，带来成倍的效率增长，并在 B 端和 C 端建立新的商业模式。但这样的愿景背后需要强大的算力、强大的空间感知能力、海量信息的实时的提取和更新能力等等，率先实现 AI 的工业化生产的企业有望建立起不断强化的竞争壁垒，并实现这样的远期商业模式的愿景：

- **B 端：**龙头企业可以构建基于城市物理空间的数字化搜索的引擎和推荐系统，将虚拟世界的搜索转化到物理世界的搜索，实现物理世界的搜索引擎，为全新的商业模式、商业场景打下基础。
- **C 端：**通过元宇宙，将类似现实世界的虚拟世界投射进去，通过 VR 眼镜在其中游览。在元宇宙当中，所有现实世界的商业模式都可以在其中再造。

全社会数字化转型对于 AI 需求迫切，生产部署效率提升是关键。社会信息化过程中进行了信息基础设施建设，这些基础设施带来的大量的数据，产生的数据需要人处理，因此牵制了大量的人力。社会数字化转型的下一个阶段需要智能化，需要 AI 来处理这些信息，解放人力。以城市治理过程为例，发现、派遣、处置、结案四个环节目前都通过人工完成，但其中三个环节都可以被 AI 替换，只有处置必须人员完成。

图表 14：以摄像头为例，未来摄像头数据需要 AI 代替人工完成自动分析



资料来源：《纽约时报》，中金公司研究部

数字化、智能化时代带来较大的潜在市场空间。根据 HIS 调研，全球 2020 年存量摄像头接近 7.7 亿只，预计 2021 年将超过 10 亿只，乐观估计，如果一个摄像头通过 AI 产生 1 万元降本增效价值，目前优质 AI 摄像头的芯片、算法全套成本达到几千元以上，我们预计，未来技术部分成本只要达到人民币 1000 元/个，摄像头的智能化市场就达到万亿规模。

安防场景难度高，涉及大量长尾场景，龙头企业能快速建立竞争优势。摄像头的 AI 模型涉及大量的长尾场景，具备底层基础设施和工业化模型生产能力的厂商才能高效、低成本的解决这些场景，以国内 AI 龙头商汤科技为例，商汤通过代码加速、模型压缩、更优的网络设计建立起诸多竞争优势，包括属性多、精度高、模型小、速度快等。

图表 15：摄像头领域国内龙头对国内外竞争对手的优势

精度高		模块小、速度快			属性多			
维度	测试准确率	代码加速	模型压缩	网络设计和训练	维度	某国际品牌	某国内竞品	SenseTime
性别	0.977	指令集的优化	稀疏	更好的设计	性别	√	√	√
眼镜/太阳镜	0.959	并行	量化	更好的训练	年龄	√	√	√
口罩	0.972		定点化		情绪	√		√
种族	0.989				颜值			√
睁/闭眼	0.991				眼镜		√	√
张/闭嘴	0.985				太阳镜			√
胡须	0.98				种族		√	√
年龄	3.08岁				睁闭眼			√
表情	0.982				张闭嘴			√
					胡须	√		√
					帽子			√
					朝向	√	√	√
					口罩			√
					质量			√

资料来源：2019 商汤人工智能峰会，商汤科技官网，商汤科技公众号，中金公司研究部

二、AI 大装置：持续底层投入铸就技术成本技术护城河，国内底层自研能力稀缺

AI 技术体系架构：软件框架是核心，全栈能力铸就护城河

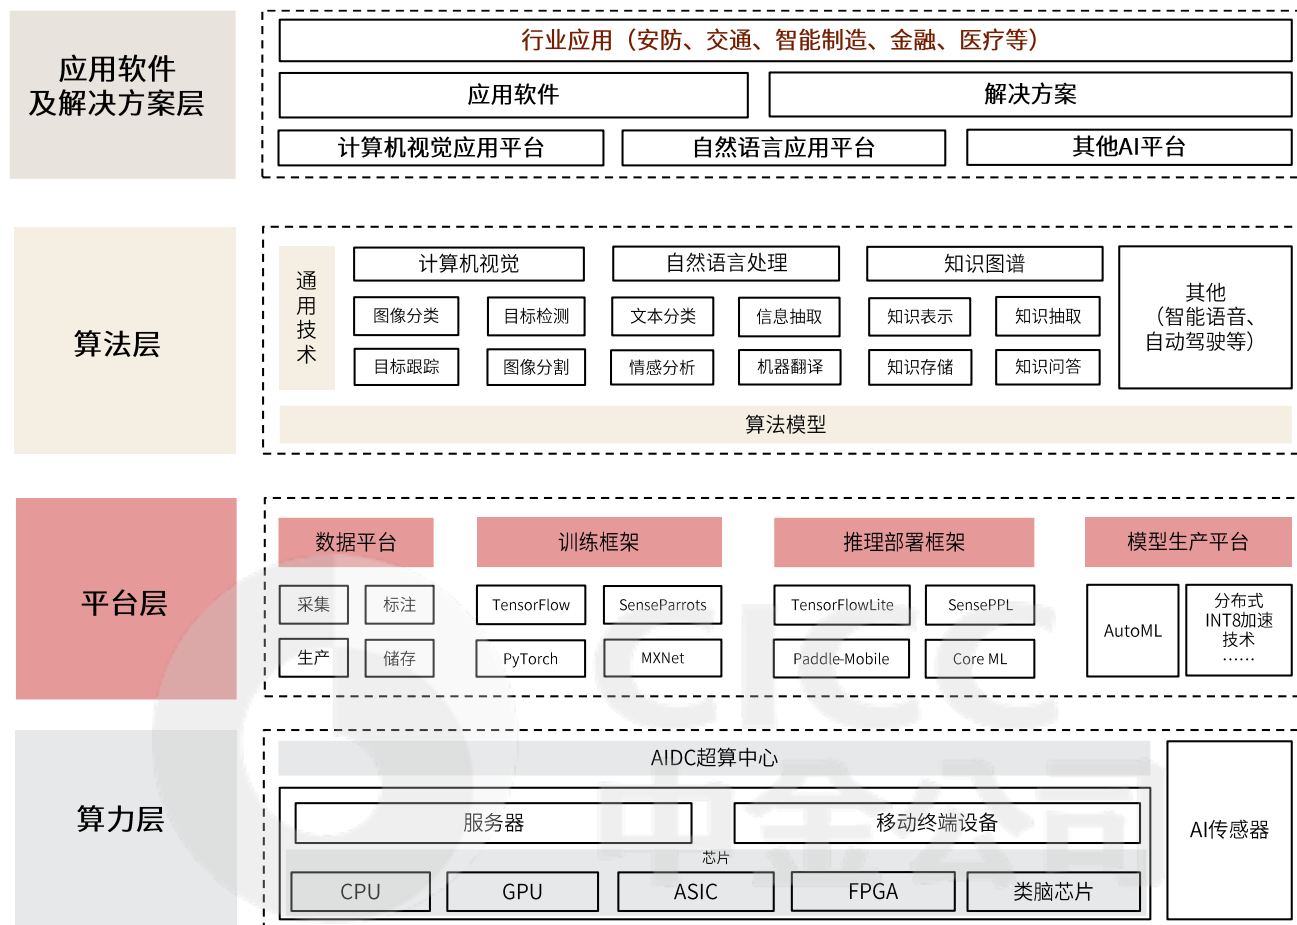
AI 技术体系分为算力、平台软件、算法、应用软件及解决方案

深度学习分为训练(training)和推断(inference)两个环节：训练需要海量数据输入，训练出一个复杂的深度神经网络模型；推断指利用训练好的模型，使用待判断的数据去“推断”得出各种结论。

AI 产业技术体系架构可划分如下：

- ▶ **算力层：**包括芯片和 AIDC。
 - 芯片：AI 芯片需要具备极强的并行计算能力，英伟达在人工智能产业生态中提供关键底层软硬件能力，训练环节 GPU 是目前主流，而 CUDA 生态是英伟达主要壁垒；推断环节，ASIC 是主流，在牺牲通用性的情况下 ASIC 能够做到比 GPU 更高的效能。
 - AIDC：智算中心需要根据算法进行深度优化，提高并行计算效率。基于 AI 芯片的超算中心近年来发展迅速，是 AI 模型算力需求指数级增长趋势下的必然，我们认为，未来 AI 算力以云服务的方式提供将逐渐成为趋势。
- ▶ **平台软件层：**平台层是支撑 AI 大规模训练生产、部署的技术体系，包括训练框架、模型生产平台、推理部署框架、数据平台。其中训练、部署软件框架是整个技术体系的核心，软件框架作为深度学习算法的工程实现，是巨头竞争的核心点，各大厂建设算法模型数据库，将其封装为软件框架，为应用开发提供集成软件工具包，为上层应用开发提供了算法调用接口。
 - 训练软件框架：实现深度学习训练算法的模块化封装。
 - 模型生产平台：实现模型的工业级生产。
 - 推理部署框架：实现模型生产完成后的工业级高效、自动的部署。
 - 数据平台：包括数据采集、数据标注、数据生产、数据存储等功能。
- ▶ **算法模型层：**算法模型本质上是特殊的软件，是 AI 企业公司在科研和产业经验中的先进算法在平台上的沉淀，丰富的算法工具可以为各行各业的企业赋能，通过模块化的方式为特定场景提供 AI 能力。
- ▶ **应用软件及解决方案层：**应用软件与算法软件不同，仍属于信息化时代传统软件范畴，基于 AI 算法模型的赋能之后，以解决方案的形式实现场景落地，同样是 AI 产业链中必不可少的一环。

图表 16：AI 行业整体技术体系架构



资料来源：中国信通院，中金公司研究部

软件框架是整个 AI 技术体系的核心，巨头以开源软件框架为核心打造生态：通过使用者和贡献者之间的良好互动和规模化效应，形成实质标准体系和生态，除苹果等少数公司外，开源框架是主流。

- ▶ 主流训练软件框架：TensorFlow（谷歌）、pyTorch（脸书）、Caffe/2（脸书，图像处理领域生态积累深厚）、MXNet（亚马逊）、CNTK（微软）、SenseParrots（商汤）、PaddlePaddle（百度）
- ▶ 主流推断软件框架：推断计算量相对小很多，往往限定性能及功耗，典型的有 TensorRT（英伟达）、TensorFlow Lite（谷歌）、SensePPL（商汤）等
- ▶ 现有格局：谷歌早期在软件框架领域领先，美国其他巨头探索模型互换、模型迁移以联合对抗谷歌；早期 Facebook 在学界地位较高，近年来其 pyTorch 为代表的技术框架在工业界发展势头较好，有赶超谷歌之势。维护力量、贡献人员决定了算法库扩展及时性、API 水平，软件框架规模效应较强。国内仅商汤、百度等极少数企业具有自研底层软件框架能力。

图表 17：国内外典型深度学习软件框架情况

	框架	机构	支持语言	简介
海外	TensorFlow	谷歌	Python/C++/Go/...	神经网络开源库
	Caffe	伯克利	Python/C++	卷积神经网络开源框架
	CNTK	微软	C++	深度学习计算网络工具包
	pyTorch	Facebook	Python/C++/C	机器学习算法开源框架
国内	SenseParrots	商汤	Python/C	机器学习算法开源框架
	PaddlePaddle	百度	Python/C++	深度学习开源平台

资料来源：CSDN，中金公司研究部


软件框架分析：以 TensorFlow 为例

TensorFlow 由 Google Brain 团队主要支撑，与 Facebook 推出的 pyTorch 一道成为全球主要活跃社区，以功能全面，兼容性好、生态完备著称。Tensorflow 主要提供以下内容：

- 基于图（Graph）的张量计算引擎（基础的概率统计、线性代数的计算模块）
- 大量的外围库（训练样本库、应用数据库、模型参数库、模型代码库）
- 大量的领域模型（以文字处理、语音识别、图像处理、目标识别等为主）

开源框架具有强大的规模效应。人工智能开源软件框架生态的核心，是通过使用者和贡献者之间的良好互动和规模化效应，形成现实意义的标准体系和产业生态。不同框架的维护力量、发展思路不同，贡献人员、算法库扩展及时性、API 水平不同。绝大多数的深度学习框架的组件都有共通之处，由类似的技术堆栈组成，对这些组件的不同实现造成框架的不一样。

图表 18：不同深度学习软件框架技术栈对比



资料来源：CSDN，中金公司研究部


基于开源框架的模型训练具体是做什么？——调节超参数，生成参数

参数是由数据驱动调整：神经网络训练的最终目标是找到一套合适的模型参数（简单理解为神经网络权重 W 和 bias b ），但参数是在训练过程中自动更新生成的。

超参数由训练者人工输入并调整优化，超参数是训练过程中的“调节旋转”，用于控制模型的结构、效率，常见超参数有：

- Learning rate 学习率
- Num of iterations 迭代次数
- Num of hidden layers 隐层数目

图表 19：深度学习模型优化流程



资料来源：CSDN，中金公司研究部

图表 20：深度学习模型典型超参数

超参数	如何影响模型容量
学习率	调至最优，提升有效容量
损失函数	调至最优，提升有效容量
批样本数量	过大过小，容易降低有效容量
丢弃法	比率降低会提升模型的容量
权重衰减系数	调至最优，提升有效容量
优化器动量	调至最优，可能提升有效容量
模型深度	同条件下，深度增加，模型容量提升
卷积核尺寸	尺寸增加，模型容量提升

资料来源：CSDN，中金公司研究部

算力层：自研芯片+自建 AIDC 是破局英伟达 CUDA 生态极佳路径

AI 作为一门新学科，其所需要的算力不同于传统信息科学，需要从芯片、AIDC、传感器到算法的深度改造和适配。AI 大模型训练成本非常高，以 GTP-3 为例，训练一次的成本达到约 1200 万美元。AI 超算中心训练大模型时采用超大规模、并行计算的异构算力，技术难度非常高，不能简单地使用芯片和传感器，往往需要自研 AI 芯片、AI 传感器、训练框架和算法，并需要进行深度的适配和优化以减小能耗。


芯片层面：英伟达凭借 CUDA 生态占据产业链核心位置

AI 训练环节，GPU 是目前主流；推断环节，ASIC 是主流。

- CPU：擅长统领全局等复杂操作，但不擅长处理并行计算场景。
- GPU：GPU 提供多核并行计算能力，核心数量非常多，拥有更高的浮点运算能力和访存速度。2012 年起深度学习迎来了真正的大爆发，很大程度上归因于深度学习之父 Hinton 将 GPU 应用于深度学习训练，相比之前 CPU 等硬件能大幅度提升训练速度，从而满足高性能模型的算力需求。
- ASIC：特定用途集成电路，在控制功耗的同时不断提升专用计算能力，对 AI 芯片进行定制，在特定场景下实现芯片的高性能和低功耗，解决对卷积、残差网络等各类 AI 计算模型的大量计算需求。但与 GPU 相比，ASIC 芯片软件生态差距较大。

- FPGA：现场可编程门阵列，集成大量基本门电路及存储器，主要特点是可编程。灵活性高，性能/功耗适中。


图表 21：人工智能芯片应用情况



资料来源：商汤科技公众号，中金公司研究部

英伟达在人工智能产业生态中提供关键底层软硬件能力。以 cuDNN 为例，它是 NVIDIA 深度神经网络软件开发包中的一种加速库，为神经网络中的卷积、池化、归一化和激活函数层等标准流程提供高度优化的实现方式。基本所有的深度学习框架都支持 cuDNN 加速工具，例如：Caffe、TensorFlow、PyTorch 等。

图表 22：cuDNN5+ Torch 帮助 LSTM RNN 加速最多达 6 倍（与 Torch-RNN 相比）



资料来源：英伟达《Optimizing Recurrent Neural Networks in cuDNN 5》、中金公司研究部
注：所使用的 GPU 为 Tesla M40，CPU 为至强 E5-2698

CUDA 生态是英伟达主要壁垒。英伟达从 2007 年开始前瞻转型 HPC（高性能计算，High Performance Computing），在 10 年时间内大力投入统一计算设备架构 CUDA 生态。目前 CUDA 生态已形成丰富、完善的软件工具库，使研发人员能专注于自己的研发领域，不用再花大量时间学习 GPU 相关知识。在经过数年艰苦经营后，CUDA 成为了人工智能开发者的首选，其生态是英伟达在 AI 领域主要的护城河。

图表 23：CUDA 生态系统具体内容

生态系统	具体内容
编程语言与 APIs	提供使用 C/C++ 语言的开发环境和诸多第三方工具链，可直接在 GPU 上开发、优化和部署应用程序。
库	能支持多个领域的加速下降，包括图像视频处理库、深度学习库、通信库、并行算法库、第三方库等。
分析和调试工具	CUDA 生态系统提供高效地编写所需的程序所有分析和调试工具。
数据中心工具和群集管理	为开发人员和 DevOps 提供 AI 和 HPC 软件生命周期每一步的软件工具。
CUDA 生态与 GPU 加速应用	提升 GPU 的大规模并行性能，加速深度学习训练和推理。

资料来源：CSDN，中金公司研究部

超算层面：重资本构建厚城墙，ASIC 云化是突破英伟达生态壁垒的极佳策略

简单的硬件积木式堆叠效率低，AIDC 建设技术难度高。计算性能受制于高速互联网络，而数据拥堵会大大降低系统效率。此外，硬件的积木式堆叠的加速效果不会线性增长，会导致更低的系统效率，甚至出现多个 GPU 还不如单个 GPU 的情况，同时导致过大功耗，增加 AIDC 超算中心计算成本。

AI 超算中心是 AI 时代的新型数据中心，需要大量落地经验。由于 AI 算法属于计算密集型算法，海量的数据处理任务和人工智能的训练和推理更适合 GPU、FPGA、ASIC 等并行计算能力强的芯片。超算中心中硬件的架构设计至关重要，需要考虑到网络、存储、电源、散热、管理和软件等多方面因素，以实现超低延迟和高带宽访问，建设过程需要大量行业实践经验。

AI 模型对算力需求的指数级增长是建造 AI 超算中心的重要原因。2018 年业界充分认识到大模型的威力后，模型的参数规模越来越大，对算力的需求也越来越大。2012 年到 2018 年间，芯片的计算性能仅提升了 30 多倍，但从算法对 AI 模型所需的算力来看，AlexNet 到 AlphaGo Zero，算法对算力的需求却提升了 30 万倍。因此，建造超大规模的人工智能超算中心是 AI 下一阶段发展的方向。

图表 24：大规模预训练模型算力需求增长

时间	机构	模型名称	模型规模	单个 GPU 计算时间
06/2018	OpenAI	GPT	110M	3 天
10/2018	Google	BERT	330M	50 天
02/2019	OpenAI	GPT-2	1.5B	200 天
07/2019	Facebook	RoBERTa	3.3B	3 年
10/2019	Google	T5	11B	66 年
06/2020	OpenAI	GPT-3	175B	355 年

资料来源：MEET 2021 智能未来大会，中金公司研究部

自建 AIDC 与算法有协同效应，AI 公司自建算力中心或将成为趋势。超算中心巨额的计算成本和技术难度一直是阻止 AIDC 建设的重要因素，而自建算力的情形下，可以提高算法和算力的适配程度，降低计算成本。AI 公司自建算力，能让算法和算力采用统一接口，使数据流程和模型开发流程的每一个步骤都做到标准化和自动化，并为算法适配合适的硬件。同时，GPU 的并行计算效率可以持续提高，降低算力损耗。

超级计算是多种复杂基础学科的交叉学科，国内相关人才稀缺。超算是一门复杂的交

叉学科，内容包括计算机科学、计算数学、行业应用领域和知识三方面构成，同时掌握三方面知识的人才极其稀缺，业界也称超算人才为“超人”。根据国家超级计算深圳中心主任冯圣中估计，国内和全球和每年仅有分别约 50 和 100 位超算博士毕业。

超算中心作为 AI 底层技术，初期投入大不确定高，国内仅少数厂商前瞻布局。由于 AIDC 的研发难度高，且 GPT-3 面世之前业界对于大模型路线仍抱有疑虑，投入 AIDC 的资金需求大、不确定性高，仅有商汤、百度、华为等少量企业能前瞻投入 AIDC。以商汤为例，早在 2018 年，商汤科技就基于对行业的预判，认识到 AI 超算中心建设的必要性并开始研制原型机，原型机总投资接近 7 亿元，当时国内几乎没有可参考案例与试验场地。目前上海临港的 AI 超算中心也是基于早先原型机的研制成果和进行设计。

由于超算中心对于训练大模型、降低算法成本至关重要，国内外巨头纷纷超前布局 AI 超算中心。由于超算中心是计算大模型的关键，国内外巨头均在近几年大力投入 AIDC 基础设施。以微软为例，2019 年微软向 OpenAI 投资 10 亿美元自研 AI 超算中心，希望未来逐渐实现通用人工智能，这台超算中心算力峰值每秒可执行 23.5 到 61.4 个万亿浮点运算，相当于全球第五大超算中心。

图表 25：全球 AI 超算进展梳理

公司	时间	投资规模	算力
微软	2020 年 5 月	10 亿美元	使用 28.5 多万个 CPU 核心及 1 万多个 GPU，每个 GPU 服务器的网络连接能力为 400GBps，总算力居于世界超算 Top5。
谷歌	2021 年 5 月	-	推出新一代人工智能 ASIC 芯片 TPU v4，主要与 Pod 相连发挥作用，每一个 TPU v4 Pod 中有 4096 个 TPU v4 单芯片，能达到 1 exaFLOP 级的算力。
特斯拉	2021 年 6 月	-	使用 5760 个自研 GPU，总算力达到 1.8EFLOPS。
商汤	预计 2021 年底	40 亿人民币	包含 2 万块 GPU，能提供 3740 Pflops 算力。
腾讯	预计 2021 年下半年	450 亿人民币	由 8 栋高标准数据中心组成，其中单栋数据中心可提供 10 万个 GPU 计算能力，算力达到 1400Pflops/s。
华为	预计 2021 年下半年	-	基于自研昇腾芯片，计划下半年建设 20 多个人工智能计算中心。

资料来源：CSDN，中金公司研究部

国内 AI 公司近年来大力投入智算中心，目前进展领先。国内 AI 厂商重视 AI 基础设施，近年来大力投入 AIDC 建设，以商汤科技上海临港在建的 AIDC 为例，其包含两万块 GPU，能提供 3740 PFlops 算力，1 天内可处理时长 23600 年的视频，是目前亚洲最大的 AI 超算中心。商汤 AIDC 完整训练一次 GPT-3 仅需一天，其目标是未来进行更大规模参数模型的训练。

超算中心需配合自研训练框架才能充分释放效能，国内龙头框架技术全球领先。大模型分布式训练的实际性能高度依赖底层硬件的使用效率，而训练框架硬件平台与硬件平台耦合程度较高，深度学习框架需要基于底层异构芯片，支持超大规模模型的训练。目前的开源训练框架难以解决内存墙和显存墙的问题，并不适用超大模型的训练，因此需要自研训练框架。国内龙头企业自研框架如 SenseParrots、MindSpore 已经能完成高性能的分布式大型网络的并行训练，训练框架技术全球领先。


自研芯片+自建超算，是国内 ASIC 突破英伟达 CUDA 生态壁垒的极佳策略。寒武纪等国内 ASIC 厂商芯片相对于英伟达 GPU 在性能上并无劣势，英伟达的核心壁垒在于 CUDA 生态，但 ASIC 更高的定制化造成生态更难以形成。但通过自建超算、基于私有

的软硬件极致优化 ASIC，再以云服务的方式提供封装好的算力，则可以解决 AISC 通用性差的问题，是突破英伟达 GPU 生态壁垒的极佳战略。

平台层：工业级的算法生产流程掀起 AI 算法的工业革命

平台层是支撑 AI 大规模训练生产、部署的技术体系，连接算力层和算法层。机器学习平台指的是将机器学习从理论变成实际应用的一整套工程，最底层是训练框架，决定了 AI 模型的上限；其次是模型生产平台，影响 AI 模型生产的效率；第三层和第四层分别是推理部署框架和数据平台。如下图所示，深度学习模型平台一般分成四层：

图表 26：深度学习模型平台




来源：华为官网，商汤科技官网，中金公司研究部

训练框架


目前美国巨头在训练框架领域遥遥领先，国内仅有少数企业自研框架。由于人工智能人才储备远多于中国，且积累时间较早，美国在基础层与技术层的布局领先中国，目前美国谷歌与脸书两大互联网巨头分别拥有 TensorFlow 与 Pytorch 等行业主流框架，而国内仅有商汤、百度、华为、旷视等少数企业自研训练框架。根据著名数据科学网站 KDnuggets，ArXiv 论文使用数量前十、KDnuggets 评分前十的框架均来自海外巨头。

图表 27: KDnuggets 综合评分前十的 AI 训练框架



资料来源: KDnuggets, 中金公司研究部


图表 28: GitHub 收藏数和贡献率排名 TOP16 的框架



资料来源: GitHub, 中金公司研究部

自研底层框架门槛高、窗口期短,龙头企业能吸纳到足够的顶尖 AI 人才进行自研。自研 AI 框架门槛很高,需要顶尖的 AI 人才,而吸引大量 AI 顶尖人才以进行框架的自研,只有极少数龙头企业能完成。以商汤科技为例,其在深度学习的研究全球领先,2012 年 CVPR 接收的两篇深度学习论文全部来自于商汤,2013 年 ICCV 接收的 8 篇深度学习论文有 6 篇来自商汤。2016 年,商汤被 GTC 评为世界前十 AI 先锋实验室之一。国内 AI 龙头企业比肩海外巨头的 AI 顶尖人才吸引力是其自研框架的基础。

图表 29: SenseParrots 发展历程



资料来源: WAIC, 中金公司研究部

相比于开源框架,自研底层框架能够实现更高的性能上限。海外的开源框架已经几乎建立了垄断地位,但其框架设计时间早,未考虑到大模型的技术实现,随着 AI 进入工业化时代,实现大规模的产业落地,海外的开源框架开始在很多方面出现局限性,包括在网络结构、设备兼容、性能与功耗均衡和各种自动化设计等,海外 AI 框架提供的能力无法契合业界需求。国内商汤、百度、华为等龙头公司自研的框架在设计之初就考虑到到大模型的内存墙和显存墙等问题,能实现更高的性能上限,以 SenseParrots 为例:

- SenseParrots 起点高,静态网络多机多卡的优化性能好。2015 年第一代 SenseParrots 发布,该框架深度优化了算力调度、内存分配、数据 IO 等性能,在静态卷积网络训练的多项性能指标上,力压当时的开源训练框架。通过对内存优

化、数据 IO 和通讯的优化，SenseParrots 能在训练超大网络时保持有限显存占用；加速性能方面，其在 64 卡上仍然能做到接近线性加速。

- ▶ 由于对静态网络多机多卡的优化达到极致，SenseParrots 多项性能保持领先。第一代 SenseParrots 训练出 1207 层的卷积神经网络，成为当时公开的最深的卷积神经网络；商汤科技还根据第一代框架研发出 PolyNet，打破了单网络在 ImageNet 图像识别上的性能记录，并保持该记录接近一年。在深层神经网络的支持，商汤科技在 ImageNet 和 ActivityNet 等一系列比赛中取得多个冠军。

自主框架能适应 AI 的产业落地，具备自主性和协同效应。虽然主流的开源框架利用先发优势，生态建设方面遥遥领先，但这类框架所提供的能力无法契合 AI 大规模落地的产业需求，因为这类开源框架更多是面向普及应用的。但产业界需要工业级的模型生产平台，自主框架能为 AI 技术赋能百业提供有力的支撑：

- ▶ 自主性：有了自研框架之后，公司在研发过程中能选择自身发展道路，不受开源框架能力的限制。且研发过程中有很多不同于社区的需求，需要及时提供技术支持。
- ▶ 协同效应：训练框架需要和底层硬件做深度适配，需要在多 GPU 并行计算效率和加速性能上做深度优化，自研框架更有利于公司对软硬件进行持续的适配和优化。

在算法框架的自主性和先进性支撑下，自研框架能为大量企业提效赋能。以商汤和百度为例，商汤 SenseParrots 框架的 GPU 集群的并行处理效率损失仅为 10% 左右，计算速度提升接近 900 倍，远强于开源框架的方案。百度 PaddlePaddle 框架使用 NCCL 提供的多 GPU 和多节点通信技术，能支持千亿规模参数、数百节点的高效并行训练，提供强大的深度学习并行技术。

图表 30：主流开源框架对比（大部分开源框架设计时未充分考虑多 GPU 支持能力）

	编程语言	教程和培训材料	CNN模型能力	RNN模型能力	架构:易用性和模块化前端	速度	多GPU支持	Keras兼容性
Theano	Python, C++	++	++	++	+	++	+	+
Tensor-Flow	Python	+++	+++	++	+++	++	++	+
Torch	Python, Lua	+	+++	++	++	+++	++	
Caffe	C++	+	++		+	+	+	
MXNet	R, Python, Julia, Scala	++	++	+	++	++	+++	
Neon	Python	+	++	+	+	++	+	
CNTK	C++	+	+	+++	+	++	+	

资料来源：DEVOPEDIA，中金公司研究部

模型生产平台

基于训练框架，模型平台可大幅优化数据流程和模型生产流程的耗时，实现 AI 算法大规模生产，核心竞争点在于训练效率、加速能力和可扩展性等。在 AI 落地工程中，通常数据流程和模型生产流程占工程耗时占比最长。而模型生产平台能通过标准数据接口、数据增强技术、数据前处理技术等技术提高 AI 落地效率。

国内龙头模型生产平台推出时间晚，但架构更完善，起点高，在部分技术领域做到全

球领先。国内的开源框架由于开源时间晚，虽然生态上有劣势，但是在搭建时考虑未来需求，架构更完善，起点更高，其搭建过程中使用了多种先进技术，例如 INT8 训练加速技术大幅减少了卷积神经网络的训练时间。

图表 31：国内自主模型生产平台使用多种先进技术优化大模型训练能力

	分布式模型训练	INT8 训练加速技术	显存优化技术
实现能力	能够支持大规模分布式的模型训练，提供高性能计算优化、可用性、易用性和灵活性保证，可在多个平台上进行快速对接和部署，在模型生产过程中提供全链式服务。	INT8 通过将网络的输入、权重和梯度量化到 8 比特，缩短了卷积神经网络的训练时间，训练过程取得相对浮点训练的 22% 的加速。	对内存进行的极致的优化，解决了超大模型训练过程中，模型并行或流水并行导致 GPU 集群计算效率大幅降低的问题。

资料来源：CVPR 2020，中金公司研究部

图表 32：加速芯片对不同精度计算的理论计算峰值

	fp32算力	fp/int16算力	int8算力
Ascend310	-	-	16T
MLU270	-	64T	128T
T4	8.1T	65T	130T
GTX1080TI	11T	-	44T


资料来源：商汤科技公众号，中金公司研究部

推理部署框架

推理部署指把已经训练好的模型放在云端或设备端并运行。当 AI 模型经过复杂的训练之后，往往需要较大的计算性能，只能部署在云端的计算中心。也可以将模型压缩成很小的模型，直接部署在终端设备进行推理。硬件方面，目前云端推断主要使用云服务器+FPGA 芯片代替 GPU 和 CPU，谷歌使用自研的 ASIC 芯片为 AI 训练和推理同时提供服务。设备端推断则一般通过芯片的高度定制化以实现低功耗。

如同训练框架，推理部署框架的生态同样是核心竞争要素之一。为开发者提供足够友好、易用的工具环境，让其迅速获取深度学习加速算力，从而降低深度学习模型研发和训练加速的成本和研发周期，是推理部署框架的核心竞争要素，目前云计算巨头如谷歌与芯片巨头英伟达等均推出推理部署框架，国外开源框架如英伟达 TensorRT 和英特尔 OpenVINO 形成较强生态，竞争较为激烈。

图表 33：目前推理部署框架主要部署在设备端和云端



资料来源：雷锋网，中金公司研究部

深度学习推理部署框架需求分散，研发门槛相对较低，自研厂商相对较多。不同于深度学习模型训练具备相对明确的需求，推理框架的需求相对分散，主要有三个，精度需求、易用需求、性能需求。由于几乎不可能出现一个框架同时在三个需求上做到极致，如 TensorRT 和 OpenVINO 虽然性能挺好，但是支持的平台单一，进行模型转换存在精度和掉点的问题。因此竞争格局会相对较为分散。


图表 34：推理框架有三种较为矛盾的需求，难以同时做到极致

推理框架需求	
精度需求	希望算法最终的精度能够和训练时候的精度一致，保证算法效果
易用需求	避免在各种模型格式之间转换，因为转换失败率高，成本高。
性能需求	算法运行时间非常苛刻，需要压榨 CPU、GPU、NPU 的极限性能。

资料来源：旷视科技公众号，中金公司研究部

国内部分厂商自研推理框架性能卓越。国内目前的云端推理框架基本都依赖对 TensorRT 和 OpenVINO 的集成，芯片厂商在 AI 业务落地过程中会提供计算库，使用芯片厂商计算库导致 AI 业务落地的全链条端到端的效率低，在计算性能、内存占用和功耗等方面离业界差距较大。而国内 AI 龙头自研推理框架推出时间点晚，充分考虑推理框架的各种需求，且不受海外芯片厂商计算库限制，还具备明显性能优势，如商汤 SensePPL 有通用性、全自研、高性能、多后端、开源五大亮点。在多种 AI 视觉模型的推理当中，SensePPL 的端到端性能超过了 TensorRT 和 OpenVINO，在各类终端上加速比都大幅超越 CAFFE 推理框架。

图表 35: SensePPL 相对于 CAFFE 的比较加速比

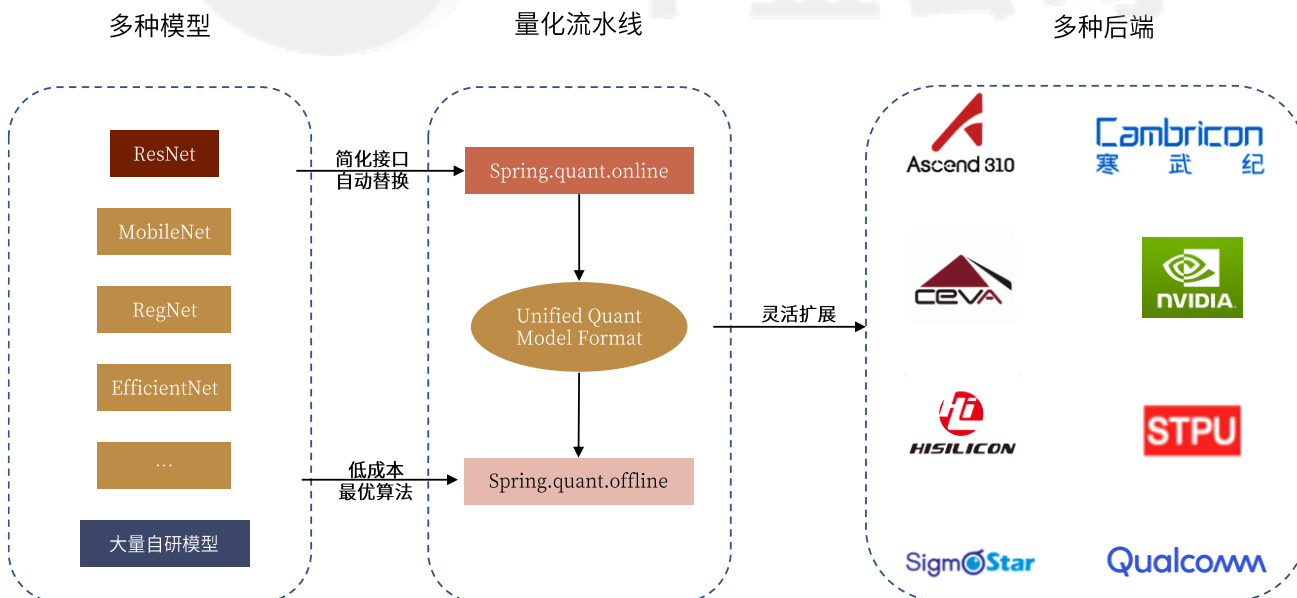


资料来源: CSDN, 中金公司研究部

未来大模型时代, AI 进入工业化生产, 自动化是提高部署环节的核心重点。在过去“手工作坊”式的 AI 生产流程中, 低效的人工部署是一大痛点。工业化生产 AI 模型的时代, 头部 AI 公司如商汤每天能产出数百个 AI 模型, 不可能全部靠人来手工调试进行模型部署, 背后必须要有一套自动化系统。这套自动化系统不仅需要能够处理常规任务, 还需要处理各种长尾场景 (hard case 和 corner case)。

AI 算法的工业化生产需要一套工具, 提供工业级的模型量化效率。为满足工业级的量化需求, 国内 AI 龙头商汤提出一套量化生产工具, 将不同类型的网络模型输入这套生产工具, 就可以得到适应 AI 部署的模型。针对不同的情景, 商汤提供在线量化和离线量化两种方案, 并提供统一量化的接口, 将其适配到不同芯片上, 使其适应各种后端。

图表 36: 量化流水线提供高效率、低成本的系统层面优化部署方式



来源: GTIC 2021, 商汤科技, 中金公司研究部

通过软硬件的协同, 龙头 AI 企业铸就效率护城河。率先进入工业化 AI 生产模式的龙头企业, 能率先进行大量网络结构、大量推理库和各类芯片的优化和适配, 结合丰富的 AI 落地场景, 能建立起一个规模庞大的数据库来优化三者的匹配, 并且持续迭代和完

善。我们认为龙头 AI 企业如商汤、华为、百度能领先于同类企业建立起这种壁垒，反过来优化模型的实际生产，铸就效率护城河。

经验沉淀建立的效率护城河带来模型的高效率开发。以商汤科技为例，目前该公司已沉淀训练过的超过 20 万个模型和 10 万个不同的网络结构，同时支持 11 种硬件，当面对新的网络结构时，可以通过查询该数据库高效地进行硬件和框架的适配，大大加速了进入新场景时模型的开发速度。

数据平台

数据平台主要目的是将数据处理过程中与 AI 关键算法相关性较弱的步骤流程化，大大提升开发者的效率。数据平台主要任务主要包括数据存储、数据标注、数据加密等，其与算法训练框架、模型工厂形成一个闭环的体系，让数据发挥出更大价值。

数据平台提供数据的标注和自动训练，打造模型工业化生产的闭环。数据流程包括数据采集、数据标注、模型训练、模型评估，是 AI 项目中最为耗时的流程，而在很多智能化场景中，新场景和新应用的需求不断变化，因此必须将数据流程自动化从而提高模型生产效率。以商汤科技 SenseSpring 深泉模型生产平台为例，其将数据规模化，集合 SenseFoundry 方舟城市级开放视觉平台后能打通数据采集、数据标注、模型训练、模型评估、模型部署、业务系统上线的全流程。

图表 37：数据处理相关工作是 AI 落地的难点和痛点



资料来源：第四范式公众号，中金公司研究部

通过在数据流程持续发力，龙头可提高 AI 模型开发能力。在数据标注和数据生产环节，通过自动化标注的人脸图像数据并将其应用于监督学习模型训练中，可低成本扩大数据集规模。数据储存与数据安全环节，商汤则通过对联邦学习的前瞻探索实现了不直接访问原始数据的情况下，利用分布式生成对抗网络结构进行联邦学习，解决了数据分散、数据隐私问题等问题。

算法层：海量模型解决项目标准化问题

算法层基于平台层之上，包括丰富的算法模型工具箱。算法层是 AI 企业公司在科研和产业经验中的先进算法模型在平台上的沉淀，AI 企业使用丰富的算法工具为各行各业赋能，通过模块化的方式提高部署效率。

算法层模块化组装解决解决长尾场景，大大提升客户付费意愿。除了高频应用场景的算法外，算法工具箱通常也包含低频和长尾场景的算法，足够大的算法工具链积累能大

幅降低扶梯逆行、城市火灾和垃圾检测等长尾场景的解决难度，而传统方式是通过专家驻场大量收集数据再训练，但长尾场景往往数据量小训练结果差，传统的项目制开发人力成本高且效果差，无法解决客户痛点，造成付费意愿低。

算法模型规模效应很强，大模型压缩出海量小模型，结合小模型的模块化组装，大大降低算法的边际成本。更强的通用性算法可以快速压缩出海量的模型，快速帮助企业在各个下游场景将 AI 落地，更多的模型对场景的覆盖也会更广，企业受益于更多的经验有利于锻造更好的模型。当进入新的场景时，企业可以从工具链中以模块化组装的方式快速生产新模型，而不必重新组织人员收集数据进行开发。以商汤科技为例，目前已经推出 13000 多个技术模型和 17000 多个商业模型，通过模型数量的不断增加，能够解决长尾场景的碎片化问题，形成标准化的解决方案。

国内百度、商汤等龙头将算法工具链进行系统性开源，有望吸引开发者补足生态弱势。深度学习在机器视觉领域一直没有出现系统性的开源架构，谷歌和脸书等科技巨头只在单点的算法层面上开源。而在国内龙头如商汤从 2019 年开始，陆续开放全套的算法工具箱，包括计算机视觉基础库、物体检测工具箱、行为理解工具箱和服饰分析工具箱等，OpenMMLab 是全球首个覆盖深度学习在机器视觉大部分领域的系统性开源。

图表 38：OpenMMLab 发展主要节点梳理

发布时间	发布内容	特点
2018/10/1	MMCV（计算机视觉基础库）	OpenMMLab 的核心，拥有通用的 IO 接口，支持图像和视频处理
	MMDetection 物体检测工具箱	高度模块化设计，支持多种算法框架
2019/6/1	MMAction 行为理解工具箱	实现多种动作分析算法框架，持有多种流行数据集，支持视频动作分析
2020/7/1	MMSegmentation 语义分割	模块化设计、统一超参、算法丰富
	MMDetection3D 3D 目标检测	模块化设计、算法丰富、分布式训练优化、集成拓展 MMDetection
2021/1/1	MMTracking（目标跟踪）	业内首个开源、统一的视频感知工具箱，可进行视频对象检测、多对象跟踪
2021/4/1	MMGeneration	一个强大的生成模型工具箱，典型的算法为生成对抗网络（GAN）
	MMOCR（文字识别检测）	支持多种用于文本检测、文本识别以及关键信息提取的业内先进模型
2021/5/1	MIM	系列算法库的统一命令行工具，为启动、安装、扩展及模型库管理提供了统一界面


资料来源：智东西，中金公司研究部

三、大模型是解决碎片化问题的突破点

大模型是 AI 行业重要的产业趋势

生物智能发展是量变到质变的过程，意味着 AI 的发展也是模型参数、连接数的不断增加的过程，即具备通用性的人工智能必然需要大模型、大算力的支持。我们在上篇系列报告提到，低级的动物智能进化到人的智能的过程中，并没有明显的分界线，从具备初级智能的寒武纪时代生物线虫（302 个神经元，7000 个突触）到人脑（ 10^{11} 个神经元、 10^{15} 个突触），智能本质上是神经元个数、连接数量变到质变的过程。

图表 39：现有深度学习模型的神经元总量、稠密度与人类还有较大差距




资料来源：阿里云《人工智能应用实践与趋势》，中金公司研究部

早年业界一度认为小模型、小算力是方向，但行业落地实践证明其短板明显。2012 年 AI 商业以来，业内外对于大规模参数的通用模型一直存在质疑，因为此前的共识是精妙的算法是未来方向，即通过更优质的算法和更高的模型精度，减少对算力的需求，因此 AI 在各行业落地过程中一直追求对算力和执行的精准部署，对算力的需求越少越好。但是这种模式的问题逐渐出现：

- ▶ **精妙模型路线无法让 AI 赋能千行百业。**商汤刚起步时，也走精妙模型的路线（如同国内其他大多数 AI 公司），为手机厂商和互联网公司供应 AI 方案，但公司扩张过程中开始进入智慧城市、智慧地产、智能物联网、智慧教育等 To B/G 行业后，精妙模型路线无法解决长尾需求的痛点就暴露出来。
- ▶ **在很多场景下，长尾需求成为 AI 商业化价值闭环的关键部分，精妙模型路线因为投入产出比低无法解决。**以份额占人工智能行业近一半份额的智慧城市项目为例，其中人脸识别项目等流量大、高频和数据多的头部应用落地难度低且投入产出比高，成为 AI 公司竞争激烈的领域。但低频长尾场景如防火防灾、电梯事故、垃圾乱扔由于投入资源多研发难度高，不受 AI 公司青睐。但长尾场景的解决情况严重影响客户对整套解决方案买单的意愿。由于长尾场景太多，难以针对每一个场景单独收集数据并训练，通过大参数模型直接解决长尾场景的路线几乎成为必然。

图表 40：智慧城市占人工智能市场行业近一半份额（2020 年）



资料来源：艾瑞咨询，中金公司研究部


受限于开源训练框架和底层基础设施，早年业界对超大规模参数预训练模型的实现质疑较多。2020 年参数量达到 1750 亿的 GPT-3 被 OpenAI 推出，其以出色的成绩震惊世人，也让业界对超大模型的趋势有了充分认知。但在此之前，业界都对大模型路线抱有质疑，因为训练超大规模参数模型的技术难度和成本让绝大部分人望而却步，只有如 OpenAI 这样一直对超大模型抱有坚定信仰和情怀，背后又有微软、特斯拉等巨头的财力支持的机构才敢于探索超大模型训练的可能性。

复盘产业发展，深度学习模型所需算力的指数级增加，背后原因是通用性带来的参数指数级增加。以 2012 年到 2018 年最先进的算法所需算力为标准，从 AlexNet 到 AlphaGo Zero，算法对算力的需求提升了 30 万倍。这种指数级增长的背后原因是 AI 模型的表达越来越丰富，模型越来越通用，参数也就越来越多，算力要求也指数级增长。

2018 年后，超大规模参数模型的趋势明显加速。观察当前国内外 AI 巨头在超大规模预训练模型的探索，可以看出人工智能行业未来的发展趋势，是在输出方向大致确定的情况下，通过更大的模型和更多的数据，“大力出奇迹”地撞出结果：

- ▶ OpenAI 近年来持续打造大参数模型，其在 2020 年发布的 GPT-3 以 1750 亿参数量轰动全球。
- ▶ 2021 年 1 月 Google 发布了 Switch Transformer 自然语言模型，参数量达到 1.6 万亿规模。
- ▶ 2021 年 6 月，北京智源人工智能研究院发布全球最大预训练模型“悟道 2.0”，参数量达到 1.75 万亿，取得多项世界级创新突破。

图表 41：大规模预训练模型对于算力需求呈指数增长



资料来源：MEET 2021 智能未来大会，中金公司研究部

从技术演进看大模型是实现通用 AI 的重要方向。虽然距离完全达到人类智能水平的 AI，还有很长一段路要走。过去的人工智能公司也倾向于选择人效高的场景先落地人工智能。但近几年在长尾场景等问题导致了对更通用的人工智能的刚需，在国内外巨头纷纷投入大量资源攻克通用人工智能难题的推动下，一些通用的语言模型、视觉模型甚至多模态模型也开始逐渐取得突破。


大模型技术、资本壁垒高，是 AI 巨头之间的博弈

大模型时代，应用层公司无力进行底层技术的探索

超大规模参数模型技术探索所需技术、资本壁垒高，是巨头之间的战场。在 AI 模型参数量疯狂增长的背后，人工智能的竞争已经成为大公司之间的角逐，GPU 集群的使用成本极高，GPT-3 训练一次的成本达到上千万美金，且 GPU 集群并行计算的工程难度非常高，大部分公司没有财力支持这样的训练和研发。

除了资本壁垒，GPU 集群计算的技术难度较高，存在内存墙等典型技术挑战。由于模型参数规模很大，往往只能采用分布式的策略将训练扩展到多个 GPU（一般使用 GPU+GPU 的异构计算）上，突破单个 GPU 内存容量和带宽的限制，减少训练时间。但内存墙不仅出现在芯片内，也出现在芯片间，而芯片间的通信瓶颈比片上数据搬运更慢、效率更低，通信量和数据传输量影响了 GPU 集群的训练效果。根据伯克利 RISELab 统计，过去 20 年硬件峰值计算能力增加了 90000 倍，但内存/硬件互连带宽只提高了 30 倍。

图表 42：内存/硬件数据通信能力速度远慢于峰值计算能力增长



资料来源：UCBerkeley RISELab, 中金公司研究部

训练框架是大模型时代的另一难点，现有开源框架无法直接训练超大模型。如果使用现有的开源分布式训练框架，无论用多大规模的 GPU 集群，都需要几个月以上才能完成 GPT-3 这样模型的训练，时间和人力成本极高。OpenAI 实验室在对开源框架做了深度定制和优化的情况下，才在可接受的时间内完成了 GPT-3 的训练，自研底层分布式训练框架的难度高，即使基于开源框架的深度优化和定制也存在较高门槛，应用层公司较难实现突破。

自主底层框架能力、算法效率及成本是实现大模型关键

大模型训练过程面临大量的技术挑战。要显著提高模型精度，需要同时大模型与大数据，单独使用一个只能取得有限的突破。而当模型和数据规模同时增大，就意味着训练时间大大增加，为提高训练速度，可以通过大量计算资源进行分布式训练，即通过数据并行、模型并行和流水并行将单卡的负载拆到多卡上。但分布式训练过程中，大模型和大数据来带的显存墙和内存墙会影响训练，因此必须使用大规模训练技术。但大规模训练技术同样面临诸多困难，包括：


- ▶ **显存问题：**模型训练的显存占用峰值很高，可能会触碰显存墙而导致训练停止，因此必须对模型进行进一步优化；
- ▶ **通信问题：**深度学习迭代式训练需要大量的局部数据交换，但网络的传输速率远不能匹配 GPU 或 TPU 等专用加速芯片的运算速率，将导致训练速度变低。而如果直接扩大带宽，会导致带宽利用率将持续降低，使得高带宽的增益非常有限。
- ▶ **计算挑战：**一方面，大模型和大数据带来了极高的算力需求，另一方面，在引入各项技术的同时又降低了计算资源的利用率。因此需要考虑采用什么样的分布式架构，才能保证在节点数很多时仍然能保持较好的加速比。

图表 43: ResNeSt269 训练时的显存墙问题



资料来源: 商汤科技公众号, 中金公司研究部

图表 44: 扩大带宽将导致带宽利用率将持续降低

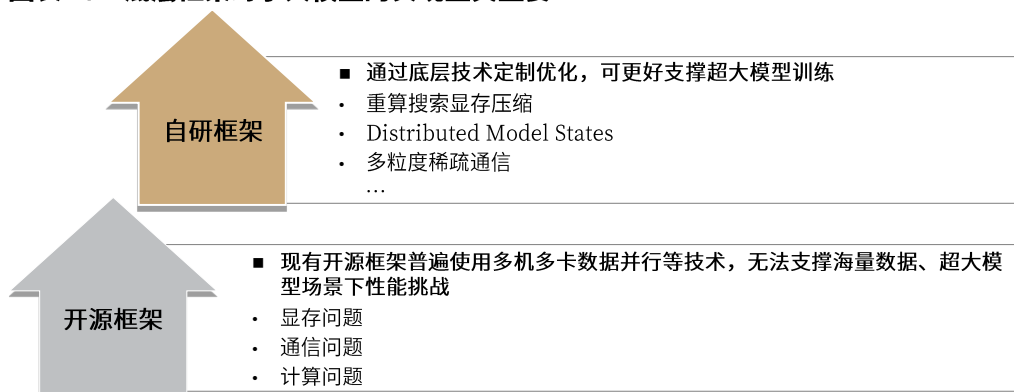


资料来源: 商汤科技公众号, 中金公司研究部

大模型的训练技术壁垒高, 因为大规模训练技术面临的是综合性的问题, 无法一对一的通过单项技术解决。大规模训练需要在各项优化中做出权衡, 最后交付一个近乎完美的解决方案, 此方案既需要保证足够的计算资源, 又依赖于深度学习框架的运行效率。我们认为, 从技术研究的角度看, 大模型是未来 AI 技术的前进方向, 也是 AI 公司构建起算力壁垒和性能壁垒的重要手段。

底层自研框架是实现大模型关键, 开源框架所提供支撑不足。训练框架是实现大模型的关键, 因为训练框架的空间决定了深度学习发展的天花板, 而训练框架的能力决定了深度学习发展的速度。目前海外开源框架在网络结构、设备兼容、性能与功耗均衡和各种自动化设计等均出现局限性, 无法契合行业需求。由于大部分国内 AI 厂商做应用层面技术, 而较少涉足基础 AI 技术层面, 选择自研训练框架的厂商很少, 拥有开源框架的就更少, 因此国内 AI 厂商自研的开源框架非常稀缺。

图表 45: 底层框架对于大模型的实现至关重要



资料来源: 商汤科技公众号, 中金公司研究部


大模型训练需要极强算力支持、成本高昂, 仅少数头部机构布局, 且需要底层技术投入降低成本来支持。大模型的训练需要极强的算力支撑, 以微软与 OpenAI 合作建造的 Azure 人工智能算力平台为例, 该算力平台投资约 10 亿美元, 使用该超算中心训练一次超大模型 GPT-3 大约花费 1200 万美元。伴随大模型和大数据而来的, 是对新一波以算力为核心的 AI 基础设施的需求, 需要从 AI 全栈技术的各个层面去优化性能。

基于底层大装置+大模型，AI 有望向基础软件分化格局演变

大模型+小模型是降低算法边际成本、解决碎片化痛点的关键架构

基于具备一定通用性的大模型，通过少量的增量训练蒸馏出小模型，是解决长尾问题的关键技术架构。从模型训练到部署，需要通过剪枝、量化、蒸馏等模型压缩技术实现更高的经济性及快速推理。以蒸馏为例，可以将结构复杂、参数规模庞大的大模型，压缩成结构简单、易于部署的小模型，相比于直接生产的小模型，大模型蒸馏出的小模型具有更强的泛化能力。

图表 46：蒸馏技术是类似于老师-学生传递知识的过程



资料来源：ICCV2019，华为云，中金公司研究部

大模型+小模型的方式能有效降低 AI 落地边际成本。由于避免了“手工作坊”式的 AI 生产方式，不需要每做一个项目就派出大量专家花数月驻场收集数据、调试模型、训练模型，并且对长尾场景的解决为客户创造了更多价值。用足够多的数据和足够大的算法去训练一个足够大的通用模型，再通过量化、剪枝、知识蒸馏等模型压缩方法把大模型变小，高效的进行模型生产，并且由于算法足够多，能够覆盖各种长尾场景，大大降低了复制成本。


从满足客户需求的角度看，大模型+小模型的应用是行业必然趋势。由于大部分 AI 公司采用的精细化模型路线处理长尾场景效率低效果差，其选择争抢如人脸识别等流量大、高频、数据多的应用场景。但只有解决了长尾场景的各种痛点需求，客户对解决方案买单的意愿才会显著提高。大模型是解决长尾场景有效办法，因此我们认为，大模型是未来 AI 行业的必然趋势。通用模型的打造需要投入很多资源，但在长尾问题解决上效果也十分显著。

AI 底层基础软件或将呈现分化格局，AI 赋能百业指日可待

通过大模型+小模型模式解决边际成本和碎片化问题，实现 AI 赋能百业。基于底层技术投入，大模型+小模型可以以低门槛、低成本方式快速输出 AI 服务，将 AI 从成本高昂的“定制、手工作坊的模式”，提升为“工业化生产模式”。以一个亿分之一级别精度的行人识别模型为例，2015 年时，商汤需要 10 个研究院花 6 个月的时间开发，而现在只需要 1 个研究员用 3 天时间就可以达到同样的效果，GPU 资源使用量降到原来的一半，边际成本大幅下降。

- ▶ 如在城市治理中，商汤 SenseFoundry 方舟城市开放平台率先试点“AI+一网统管”，实现 AI 研判处置全闭环管理，有效解决垃圾识别、共享单车乱堆放等城市痛点长尾问题。
- ▶ 在医疗行业，商汤科技 SenseCare 智慧诊疗平台能够全面满足骨科、影像科、病理科、肝外科、心内科、放疗科、胸外科等多科室的临床诊疗需求。平台提供全面的智能辅助疾病诊断，覆盖超过 13 个人体部位和器官，覆盖“诊-疗-愈”全流程。

图表 47：商汤科技 AI 赋能百业实现方式



资料来源：艾瑞咨询，英特尔，商汤科技，中金公司研究部

图表 48：可比公司估值表

股票代码	公司名称	财报货币	收盘价 08-20	市值 (百万 元)	净利润 (财报货币 百 万)			市盈率			营业收入 (财报货币 百万)			市销率			EV/EBITDA		
					2020	2021	2022	2020	2021	2022	2020A	2021E	2022E	2020	2021	2022	2020	2021	2022
中国企业																			
002230.SZ	科大讯飞*	CN	51.70	118,937	1,364	1,845	2,488	84.3	62.3	46.2	13,025	17,126	22,348	9.1	6.9	5.3	43.0	35.3	28.1
688088.S	虹软科技*	CN	45.00	18,270	251	351	466	72.7	52.1	39.2	683	956	1,317	26.7	19.1	13.9	65.3	43.2	30.9
BIDU.US	百度*	CN	137.6	311,489	22,472	30,614	14,282	14.0	17.4	15.0	107,07	125,80	138,50	2.9	2.6	2.3	9.4	14.6	12.0
平均值				237,20	9,492	12,69	5,746	51.8	39.9	33.5	46,708	56,136	54,058	11.6	8.7	7.2	37.1	29.2	23.7
海外企业																			
AI.US	C3.AI	USD	45.51	30,763	-56(a)	-	-	N.M.	N.M.	N.M.	183(a)	245(a)	329(a)	N.M.	19.3(a)	14.4(a)	N.M.	N.M.	N.M.
NUAN.US	微妙通讯	USD	55.04	112,549	21	244	271	N.M.	72.4	65.1	1,479	1,377	1,479	11.4	12.6	11.7	37.9	53.1	43.1
PLTR.US	PALANTIR	USD	24.01	304,884	-1,166	342	448	N.M.	148.2	118.9	1,093	1,495	1,940	27.0	31.4	24.2	N.M.	112.2	84.6
平均值				149,39	-400	158	203	N.M.	110.3	92.0	918	1,039	1,249	19.2	21.1	16.8	N.M.	82.7	63.8

注：标*公司为中金覆盖，采用中金预测数据；其余使用市场一致预期

标有(a)的数值所对应的年份为本列顶部所示年份之后的一年

资料来源：万得资讯、彭博资讯、公司公告、中金公司研究部

风险提示

- 国内技术进步、生态建设不及预期。**AI 基础技术如训练框架、AIDC 的研发和建设需要投入大量资源，如果国内 AI 公司无法投入足够资源，可能整体技术进步将会放缓。在开源生态的建设上，国内 AI 公司有一定的后发劣势，如果国内 AI 公司无法吸引足够的开发者，可能影响到开源生态的建设。
- 行业竞争加剧。**国内融资环境良好，创业公司通过上市、一级市场可吸纳较多资本，但 AI 公司在应用层较多，如果无法通过技术进步实现场景深化，行业竞争集中在场景落地，竞争加剧将会造成行业整体盈利下降。
- 海外出口管制风险。**尽管外资巨头开发的深度学习框架都大多为开源，但理论上仍不能排除国内公司面临的供应链风险，需要借助商汤、百度、华为等国内龙头 AI 厂商底层自研软件框架保障整体产业链可靠性。

法律声明

一般声明

本报告由中国国际金融股份有限公司（已具备中国证监会批复的证券投资咨询业务资格）制作。本报告中的信息均来源于我们认为可靠的已公开资料，但中国国际金融股份有限公司及其关联机构（以下统称“中金公司”）对这些信息的准确性及完整性不作任何保证。本报告中的信息、意见等均仅供投资者参考之用，不构成对买卖任何证券或其他金融工具的出价或征价或提供任何投资决策建议的服务。该等信息、意见并未考虑到获取本报告人员的具体投资目的、财务状况以及特定需求，在任何时候均不构成对任何人的个人推荐或投资操作性建议。投资者应当对本报告中的信息和意见进行独立评估，自主审慎做出决策并自行承担风险。投资者在依据本报告涉及的内容进行任何决策前，应同时考量各自的投资目的、财务状况和特定需求，并就相关决策咨询专业顾问的意见对依据或者使用本报告所造成的一切后果，中金公司及/或其关联人员均不承担任何责任。

本报告所载的意见、评估及预测仅为本报告出具日的观点和判断，相关证券或金融工具的价格、价值及收益亦可能会波动。该等意见、评估及预测无需通知即可随时更改。在不同时期，中金公司可能会发出与本报告所载意见、评估及预测不一致的研究报告。

本报告署名分析师可能会不时与中金公司的客户、销售交易人员、其他业务人员或在本报告中针对可能对本报告所涉及的标的证券或其他金融工具的市场价格产生短期影响的催化剂或事件进行交易策略的讨论。这种短期影响的分析可能与分析师已发布的关于相关证券或其他金融工具的目标价、评级、估值、预测等观点相反或不一致，相关的交易策略不同于且也不影响分析师关于其所研究标的证券或其他金融工具的基本面评级或评分。

中金公司的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。中金公司没有将此意见及建议向报告所有接收者进行更新的义务。中金公司的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见不一致的投资决策。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现。过往的业绩表现亦不应作为日后回报的预示。我们不承诺也不保证，任何所预示的回报会得以实现。分析中所做的预测可能是基于相应的假设。任何假设的变化可能会显著地影响所预测的回报。

本报告提供给某接收人是基于该接收人被认为有能力独立评估投资风险并就投资决策能行使独立判断。投资的独立判断是指，投资决策是投资者自身基于对潜在投资的目标、需求、机会、风险、市场因素及其他投资考虑而独立做出的。

本报告由受香港证券和期货委员会监管的中国国际金融香港证券有限公司（“中金香港”）于香港提供。香港的投资者若有任何关于中金公司研究报告的问题请直接联系中金香港的销售交易代表。本报告作者所持香港证监会牌照的牌照编号已披露在报告首页的作者姓名旁。

本报告由受新加坡金融管理局监管的中国国际金融（新加坡）有限公司（“中金新加坡”）于新加坡向符合新加坡《证券期货法》定义下的认可投资者及/或机构投资者提供。提供本报告于此类投资者，有关财务顾问将无需根据新加坡之《财务顾问法》第 36 条就任何利益及/或其代表就任何证券利益进行披露。有关本报告之任何查询，在新加坡获得本报告的人员可联系中金新加坡销售交易代表。

本报告由受金融服务监管局监管的中国国际金融（英国）有限公司（“中金英国”）于英国提供。本报告有关的投资和服务仅向符合《2000 年金融服务和市场法 2005 年（金融推介）令》第 19（5）条、38 条、47 条以及 49 条规定的人士提供。本报告并未打算提供给零售客户使用。在其他欧洲经济区国家，本报告向被其本国认定为专业投资者（或相当性质）的人士提供。

本报告将依据其他国家或地区的法律法规和监管要求于该国家或地区提供。

特别声明

在法律许可的情况下，中金公司可能与本报告中提及公司正在建立或争取建立业务关系或服务关系。因此，投资者应当考虑到中金公司及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。

与本报告所含具体公司相关的披露信息请访 <https://research.cicc.com/footer/disclosures>，亦可参见近期已发布的关于该等公司的具体研究报告。

中金研究基本评级体系说明：

分析师采用相对评级体系，股票评级分为跑赢行业、中性、跑输行业（定义见下文）。

除了股票评级外，中金公司对覆盖行业的未来市场表现提供行业评级观点，行业评级分为超配、标配、低配（定义见下文）。

我们在此提醒您，中金公司对研究覆盖的股票不提供买入、卖出评级。跑赢行业、跑输行业不等同于买入、卖出。投资者应仔细阅读中金公司研究报告中的所有评级定义。请投资者仔细阅读研究报告全文，以获取比较完整的观点与信息，不应仅仅依靠评级来推断结论。在任何情形下，评级（或研究观点）都不应被视为或作为投资建议。投资者买卖证券或其他金融产品的决定应基于自身实际具体情况（比如当前的持仓结构）及其他需要考虑的因素。

股票评级定义：

- 跑赢行业（OUTPERFORM）：未来 6~12 个月，分析师预计个股表现超过同期其所属的中金行业指数；
- 中性（NEUTRAL）：未来 6~12 个月，分析师预计个股表现与同期其所属的中金行业指数相比持平；
- 跑输行业（UNDERPERFORM）：未来 6~12 个月，分析师预计个股表现不及同期其所属的中金行业指数。

行业评级定义：

- 超配（OVERWEIGHT）：未来 6~12 个月，分析师预计某行业会跑赢大盘 10%以上；
- 标配（EQUAL-WEIGHT）：未来 6~12 个月，分析师预计某行业表现与大盘的关系在-10%与 10%之间；
- 低配（UNDERWEIGHT）：未来 6~12 个月，分析师预计某行业会跑输大盘 10%以上。

研究报告评级分布可从<https://research.cicc.com/footer/disclosures> 获悉。

本报告的版权仅为中金公司所有，未经书面许可任何机构和个人不得以任何形式转发、翻版、复制、刊登、发表或引用。

V190624
编辑：樊荣



中国国际金融股份有限公司

中国北京建国门外大街 1 号国贸写字楼 2 座 28 层 | 邮编: 100004

电话: (+86-10) 6505 1166

传真: (+86-10) 6505 1156

纽约

CICC US Securities, Inc
32nd Floor, 280 Park Avenue
New York, NY 10017, USA
Tel: (+1-646) 7948 800
Fax: (+1-646) 7948 801

伦敦

China International Capital Corporation (UK) Limited
25th Floor, 125 Old Broad Street
London EC2N 1AR, United Kingdom
Tel: (+44 - 20) 7367 5718
Fax: (+44 - 20) 7367 5719

新加坡

China International Capital Corporation (Singapore)
Pte. Limited
6 Battery Road, #33-01
Singapore 049909
Tel: (+65) 6572 1999
Fax: (+65) 6327 1278

香港

中国国际金融（香港）有限公司
香港中环港景街 1 号
国际金融中心第一期 29 楼
电话: (852) 2872-2000
传真: (852) 2872-2100

上海

中国国际金融股份有限公司上海分公司
上海市浦东新区陆家嘴环路 1233 号
汇亚大厦 32 层
邮编: 200120
电话: (86-21) 5879-6226
传真: (86-21) 5888-8976

深圳

中国国际金融股份有限公司深圳分公司
深圳市福田区益田路 5033 号
平安金融中心 72 层
邮编: 518048
电话: (86-755) 8319-5000
传真: (86-755) 8319-9229