

人工智能十年展望（三）：AI 视角下的自动驾驶行业全解析




陈星宇

SAC 执证编号: S0080121020020
xingyu3.chen@cicc.com.cn

邓学

SAC 执证编号: S0080521010008
SFC CE Ref: BJV008
xue.deng@cicc.com.cn

于钟海

SAC 执证编号: S0080518070011
SFC CE Ref: BOP246
zhonghai.yu@cicc.com.cn

股票	股票	目标	P/E (x)	
名称	评级	价格	2022E	2023E
中科达-A	跑赢行业	177.00	66.8	48.6
四维图新-A	跑赢行业	21.00	175.3	96.7

中金一级行业：科技

资料来源：万得资讯，彭博资讯，中金公司研究部

- 软件及服务 | 人工智能十年展望（二）：边际成本决定竞争力，算法龙头主导格局优化 (2021.08.22)
- 软件及服务 | 人工智能十年展望（一）：底层模拟人脑，算力决定上限 (2021.07.13)

更多作者及其他信息请见文末披露页

观点聚焦

投资建议

自动驾驶是AI落地的重要场景之一，2012年之后深度学习技术快速发展带动自动驾驶技术迅速进步，近年来Transformer大模型等技术进一步提升了自动驾驶算法能力，2022年开始落地的大算力芯片及车厂自建AIDC的趋势也为大模型提供了底层支持，我们看好中长期自动驾驶行业的发展，在数据端具备优势的厂商有望率先实现突破。

理由

深度学习是自动驾驶技术发展的分水岭，近年来Transformer大模型是重要产业趋势，算法是各大厂商大力布局的核心能力。深度学习作为“软件2.0”，是自动驾驶发展的核心驱动力，在感知层面大幅提高图像识别准确率，在决策层面深度强化学习有效提升算法能力。我们认为未来深度强化学习与传统专家规则将会广泛共存。以Transformer为代表的大模型由于在海量数据预训练、鲁棒性、泛化能力方面较CNN优势明显而成为主流路线，其出现也使得掌握数据优势的企业能形成高效的数据闭环，有望为自动驾驶算法带来颠覆性突破。

数据是决定量产能力的胜负手。深度学习是数据驱动的AI，需要海量数据“喂养”。数据获取依赖车载传感器：特斯拉坚持选择视觉摄像头主导的传感器方案，完成数据闭环，构建深厚壁垒；其他厂商选择激光雷达、摄像头等多传感器融合方案，激光雷达降价速度是行业发展关键，我们认为未来激光雷达作为安全冗余具有现实需求。此外，数据量是两类方案竞争的核心要素，数据标注的自动化水平、标注质量和效率是关键竞争点。

算力现阶段决定自动驾驶技术上限，巨头纷纷先行布局。高级自动驾驶中算力先行于算法，目前自动驾驶AI芯片呈以英伟达为主导的“一超多强”格局，特斯拉引领域控制器架构变革，催化芯片厂商格局变化与量产进程，2022是自动驾驶大算力芯片开启的元年。我们预计未来芯片竞争中大算力与能效比为首要竞争要素，开放性生态的重要性日趋提升。云端层面，AIDC提供处理大量回传数据所需的大算力，对于训练大模型至关重要，特斯拉等巨头在技术和资金方面具备天然优势。类似自有电商业务需求孕育了亚马逊、阿里巴巴等CPU时代云计算巨头，我们认为自动驾驶等AI巨头具备GPU/ASIC云计算市场的天然先发优势。

盈利预测与估值

建议关注毫末智行（未上市）、小马智行（未上市）、图森未来、驭势科技（未上市）、momenta（未上市）。

风险

技术进步不及预期、行业竞争加剧、政策风险。

目录


算法：深度学习为自动驾驶发展分水岭，大模型是重要趋势	5
深度学习是自动驾驶技术发展的分水岭及底层推动力	5
Transformer 等大模型是人工智能产业的重要趋势	11
感知算法：多传感器数据融合+定位，实现车辆环境感知	15
决策算法：自动驾驶中的核心挑战与难点	19
数据：决定量产能力的胜负手	23
深度学习是数据驱动的 AI，数据积累是现阶段自动驾驶核心竞争点	23
视觉 vs 激光雷达？算法、成本、数据综合作用下的最优解	24
数据体系的自动化水平、效率是关键竞争点	28
算力：大算力芯片元年开启，AIDC 助力大模型能力跃升	33
车端：2022 开启大算力芯片落地元年	33
云端：AIDC 提供强算力后盾，助力算法模型能力快速提升	37

图表

图表 1：全文章节结构框架	4
图表 2：典型自动驾驶技术架构：感知、决策、执行	5
图表 3：自动驾驶与人工智能发展历程对比	6
图表 4：特斯拉 FSD 自动驾驶系统深度学习代码比例不断提升	7
图表 5：深度学习使得 2012-2016 年 ImageNet 图像识别错误率快速下降	7
图表 6：强化学习在深度学习出现后进入发展新阶段	8
图表 7：典型的“感知-决策-控制”序列式架构	9
图表 8：端到端技术架构举例	9
图表 9：数据驱动的决策规划、模块化方法和端到端方法的对比	9
图表 10：各主流自动驾驶玩家发展时间节点梳理	10
图表 11：深度学习之后的 AI 模型对于计算量的需求加速增长，6 年增加 30 万倍	11
图表 12：近年来国内外主要 AI 巨模型	11
图表 13：不同参数量 GPT-3 模型的十项计算任务准确率	11
图表 14：Vision Transformer 的典型网络结构	12
图表 15：特斯拉利用 Transformer 实现多摄像头数据融合	13
图表 16：随着数据量提升，Vision Transformer 的预训练效果优于 CNN	14
图表 17：特斯拉量产车数量增长趋势	15
图表 18：典型车型车载传感器配置情况	15
图表 19：自动驾驶各类传感器对比	15
图表 20：典型自动驾驶车辆传感器基本配置	16
图表 21：前融合（紧耦合）将多传感器结合使用	16
图表 22：后融合（松耦合）将各自传感器结果再融合	16
图表 23：特斯拉感知算法结构分为四大部分	17
图表 24：多传感器融合定位算法流程示意图	18
图表 25：高精度地图预制过程	18
图表 26：SLAM 模型生成	18
图表 27：自动驾驶决策规划分类	19

图表 28: 场景感知是感知与决策的交汇环节	20
图表 29: 感知系统与决策系统的对接方式	20
图表 30: 规划控制核心目标是实现安全、舒适、效率三者最佳平衡	21
图表 31: 强化学习和模仿学习相结合够解决真实环境下各种各样的视觉运动任务	21
图表 32: 特斯拉混合规划系统的五个步骤	22
图表 33: 数据驱动的 AI	23
图表 34: 自动驾驶能力发展曲线	23
图表 35: 主流车型传感器配置方案	24
图表 36: 自动驾驶厂商累计加州路测里程数	24
图表 37: 人与特斯拉自动驾驶能力体系对比	25
图表 38: 特斯拉 Autopilot 里程数	26
图表 39: 激光雷达价格走势, 2017-2023E	27
图表 40: 多传感器数据融合过程	27
图表 41: 毫末自动驾驶数据智能体系 MANA	28
图表 42: 云测数据开发的自动驾驶标注工具集示例	29
图表 43: 特斯拉 Operation Vacation (运营假期) 模式	30
图表 44: 特斯拉数据生产的三个阶段	30
图表 45: 特斯拉“影子模式”(Shadow Mode) 原理	31
图表 46: 特斯拉 HydraNet 网络	32
图表 47: 自动驾驶各级别对应像素数、数据量以及算力需求(估计值)	33
图表 48: 各供应商自动驾驶芯片发展进程概览	35
图表 49: 各供应商自动驾驶芯片发展进程概览	35
图表 50: 巨头竞争节奏时间轴	36
图表 51: 四品牌智能驾驶芯片竞争优势	37
图表 52: GPU 迭代速度慢于模型参数迭代速度, 催生更大算力需求	38
图表 53: 特斯拉 D1 芯片提供充足带宽, 速度远快于 GPU	38
图表 54: 全球主要超算中心排名(按 FP32 算力)	39
图表 55: 特斯拉与谷歌 AI 超算中心	39

图表 1：全文章节结构框架



资料来源：中金公司研究部

算法：深度学习为自动驾驶发展分水岭，大模型是重要趋势


深度学习是自动驾驶技术发展的分水岭及底层推动力

自动驾驶算法架构：感知、决策、执行

算法对于自动驾驶的效果至关重要。自动驾驶作为人工智能技术重要应用场景之一，其技术体系由算法、算力、数据三部分构成，其中算法的有效性影响自动驾驶的每一个环节，从感知环节的特征提取到神经网络的决策，都需要依赖算法改进来提高障碍物检测准确性和复杂场景下的决策能力。典型的自动驾驶技术架构包括感知（定位）、决策、执行三部分：

- ▶ **感知是自动驾驶车辆的“眼睛”，**通过各类传感器对行驶路径进行识别，定位和追踪车辆周围物体以获取车辆环境信息，并融合、处理环境信息及车内信息。用于自动驾驶感知的传感器主要包括激光雷达、毫米波雷达、超声波雷达及视觉传感器，其中视觉传感器又包括单目和多目彩色摄像头。
- ▶ **决策是自动驾驶车辆的“大脑”，**对道路拓扑结构信息、实时交通信息、交通参与者信息和车辆自身状态等感知数据进行进一步分析，做出决策和预测后给出车辆控制策略并发出相应指令，决策系统主要包括车辆行为决策模块及轨迹规划模块。
- ▶ **执行是自动驾驶车辆的“手脚”。**接收决策系统给出的指令，通过车辆稳定系统 ESC、线控制动 eBooster、线控转向 EPS 等执行机构精确地控制加速程度、制动程度、转向幅度、灯光控制等驾驶动作。

图表 2：典型自动驾驶技术架构：感知、决策、执行




资料来源：《自动驾驶技术概论》（王建、徐国艳、陈竞凯、冯宗宝，2019），中金公司研究部

深度学习驱动自动驾驶技术进入加速发展期

自动驾驶技术的发展分为三个阶段，1970 年代兴起于自科研机构，2000 年科技巨头入局，但发展进程较缓。2012 年以 Hinton 在 ImageNet 大赛中引入深度学习算法为节点，深度学习进入蓬勃发展期。次年，自动驾驶作为 AI 的重要落地应用之一，进入高速发展快车道。

- **1970s-1999：科研机构及学术院校推动无人驾驶兴起。**1984 年美国国防高级研究计划署 DAPRA（The Defense Advanced Research Projects Agency）联合陆军共同发起了自主地面车辆 ALV（Autonomous Land Vehicle）研究计划；这段时期国外著名大学也先后开始无人驾驶汽车的研究，如美国卡内基·梅隆大学 NavLab 智能车辆、意大利帕尔玛大学 ARGO 试验车等。
- **2000-2013：DAPRA 无人驾驶挑战赛激起研究热潮，科技巨头入局。**2004-2007 年，DAPRA 累计举办了三届无人驾驶挑战赛，激起更多科研机构投入，目前主流的任务规划、行为规划、动作规划无人驾驶规划系统的分层设计即成形于 DAPRA 城市挑战赛；2009 年，谷歌组建团队开始研发无人驾驶技术。
- **2014 至今：车企全面布局，自动驾驶开始加速式发展。**2013 年，奥迪、福特、沃尔沃、日产、宝马等传统汽车制造商纷纷布局无人驾驶汽车，国内互联网巨头百度也开始了无人驾驶汽车的研究，创业公司不断涌现，商业化进程加速。2019 年 1 月，NVIDIA 在 CES 2019 上推出全球首款商用 L2 级自动驾驶系统。2021 年 12 月，奔驰在德国获批，成为全球首个 L3 级别自动驾驶能够上路行驶的汽车企业。

图表 3：自动驾驶与人工智能发展历程对比




资料来源：CSDN，中金公司研究部

深度学习是自动驾驶技术发展的核心驱动力，2012 年为深度学习元年。2012 年深度学习率先在图像识别领域产生标志性突破，由 Geoffrey Hinton 课题组通过其构建的深度学习神经网络 AlexNet 成功将图片识别错误率降低了 10.8pcts，引起了全球业界的高度关注，随后几年深度学习产业飞速发展，2015 年斯坦福人工智能实验室主任李飞飞团队在 ImageNet 开放数据集上识别准确率首次达到人类水平，也使得相关领域大规模的商业化落地成为可能。

自动驾驶在深度神经网络算法出现后开启了加速式发展。目标检测及图像识别作为自动驾驶的关键技术，高度受益于深度学习算法的突破，成为人工智能算法率先落地的场景之一。[特斯拉人工智能总监 Andrej Karparthy](#) 认为深度学习为代表技术是软件 2.0，即以神经网络训练的形式编写的代码软件，而软件 1.0 则是由人类编写的逻辑代码的传统方式。以特斯拉为例，其自动驾驶深度学习网络 HydraNet 包含 48 个神经网络，能够同时检测 1,000 种物体，并正在越来越多地使用以神经网络训练的形式编写的代码软件 2.0 代替人类编写的逻辑代码软件 1.0，来构建其自动驾驶策略。

图表 4：特斯拉 FSD 自动驾驶系统深度学习代码比例不断提升




资料来源：特斯拉 AI day，中金公司研究部整理

感知算法：直接受益于深度学习红利，高速发展

感知算法在过去 10 年充分受益于深度学习带来的性能红利。感知模块是目前自动驾驶中深度学习应用最广泛的模块，深度学习拥有多层非线性神经网络结构，能够将低层特征变换成更为抽象的高层特征，并以无监督或有监督的方法对输入特征进行变换，从而提升了分类或预测的准确性。尤其在计算机视觉感知领域，深度学习能够提取出拥有自适应特性的高层特征，有效适应待识别目标的外观变化，模型鲁棒性和泛化能力得到大幅提高。

图表 5：深度学习使得 2012-2016 年 ImageNet 图像识别错误率快速下降



资料来源：机器之心，中金公司研究部

决策算法：深度强化学习赋能决策算法

传统强化学习在感知与求解能力瓶颈明显。强化学习是一种典型的序贯决策方式，不要求预先给定训练数据，而是通过接收环境对动作的反馈获得学习信息以迭代模型。强化学习侧重于寻优策略，对于事物的感知表达能力偏弱。在复杂的现实决策任务中，标准的强化学习算法无法对大规模输入进行抽象表征，有效求解策略的能力不足，因此应用场景较为受限。

深度学习与强化学习结合蕴含巨大想象空间。为解决强化学习的弊端，综合高维数据抽象感知能力的深度强化学习算法（Deep Reinforcement Learning, DRL）兴起。2013 年人工智能研究团队 DeepMind 提出深度 Q 网络（Deep Q Network, DQN）和蒙特卡洛树搜索算法。基于该算法的围棋程序，“AlphaGo”以 4:1 战胜世界冠军李世石，使得深度强化学习成为人工智能领域的新热点。近年来，深度强化学习在自动驾驶中的车道保持、超车决策、主动制动、交通流调度等多场景落地应用，并不断拓展其范围边界。


图表 6：强化学习在深度学习出现后进入发展新阶段



资料来源：OpenAI, 《Adaptive Bitrate Streaming in Wireless Networks With Transcoding at Network Edge Using Deep Reinforcement Learning》(Y Guo, R Yu 等, 2020), 中金公司研究部整理


端到端的技术是深度强化学习在自动驾驶中的典型应用。目前自动驾驶决策存在两类技术架构：典型的“感知-决策-控制序列式架构”和“端到端”架构。典型的序列式架构按照设定规则，对全场景数据感知后进行决策，再由车辆控制单元执行决策指令。端到端的技术架构与人脑决策机制更为相似，没有人为规则限制，将全部外界环境数据、车辆自身数据输入算法后，便可输出最终的决策。端到端的技术架构能克服传统方式依赖先验环境建模，带来的边界的问题，可以实现直接从感知到控制功能的映射。

图7：典型的“感知-决策-控制序列式架构



资料来源：CSDN，中金公司研究部

图8：端到端技术架构举例




资料来源：Nvidia，中金公司研究部

端到端架构的弱解释性限制了应用，我们预计未来较长时间内深度强化学习仍将在“感知-决策-执行”体系中发挥作用。目前端到端的技术路径主要存在以下问题：

- ▶ **可解释性弱。**图像到执行的直接映射具有“黑箱”的特性，工程师难以从中发现规律或给出解释，因此，端到端技术的安全性难以保障。
- ▶ **灵活性差。**端到端是简单的图像输入到车辆控制单元输出的直接映射，当感知设备或者执行机构发生变动，就需要重新完成数据收集和训练，使得端到端的算法模型灵活性差。

深度强化学习融合传统专家规则的技术方案将会得到较为广泛的应用。由于仅基于规则的技术路径和深度强化学习这一端到端的路线均存在难以规避的劣势，目前业界提出了深度强化学习融合专家规则的解决方案。在典型的“感知-决策-执行”架构体系中，将驾驶员经验提纯的规则与深度强化学习方法融合使用，是更为安全可行的自动驾驶决策算法发展路径。例如，毫末智行将策略函数的构建划分成学习部分与不可学习部分，学习部分基于深度强化学习算法，目标为奖励函数最大化（包括舒适性、安全性、超车机会等）；而不可学习部分保留必要的约束，使策略能够严格保障安全底线，同时提供更好的性能。

图9：数据驱动决策规划、模块化方法和端到端方法的对比




资料来源：《A survey of deep learning techniques for autonomous driving》（S Grigorescu, B Trasnea 等，2020），中金公司研究部

多方入局自动驾驶，深度学习是布局重点

近十年来科技企业、造车新势力、传统车企都开始大力发展自动驾驶技术，市场参与者可分为两大类：一类以谷歌 Waymo、百度等科技企业为主要代表，发展目标为直接向主机厂提供完整 L4-L5 级别算法；另一类则以特斯拉等整车厂为代表，通过销售整车获取真实路况数据，从而凭借大数据优势占领市场，不断迭代 L3、L4 及以上的自动驾驶级别。两路径中，深度学习都是市场参与者们发力的重点。

图表 10：各主流自动驾驶玩家发展时间节点梳理




资料来源：万得资讯，《自动驾驶技术概论》（王建、徐国艳、陈竞凯、冯宗宝，2019），中金公司研究部

Transformer 等大模型是人工智能产业的重要趋势

大模型是人工智能产业的重要发展方向。由于人工智能的细分场景和细分应用过多，传统开发模式下针对每一个特定场景都定制一套全新算法，行业开发工作冗余、效率低且成本高。大规模预训练模型能够解决以上痛点，成为重要发展趋势，在谷歌、特斯拉等国际巨头中形成共识，即先使用海量数据预训练大模型，得到一套模型参数，然后用这套参数对模型进行初始化，再进行训练；在特定领域落地时，通过大模型蒸馏出小模型，大幅降低对新场景中数据量的需求，使得模型小样本学习能力和泛化能力大幅提升。从业界大模型参数量来看，目前全球多家人工智能实验室和巨头均在持续提升大模型的规模。

图表 11：深度学习之后的 AI 模型对于计算量的需求加速增长，6 年增加 30 万倍



资料来源：OpenAI，中金公司研究部整理


大模型提高 AI 模型的智能程度，提升了 AI 模型的通用性。根据 OpenAI 的研究人员对 GPT-3 的计算能力测试，在十项计算能力测试中，小模型的性能明显差于大模型，即使是 130 亿参数的模型处理二位数加减法的准确率也只有 50%左右，处理其他运算的准确率还不到 10%，远低于 1,750 亿的 GPT-3 完整版模型。此外，通过压缩大模型批量化生产小模型的方式能生产大量的、覆盖不同场景的模型，无需针对每个场景都单独定制生产，提高各个行业的 AI 模型生产效率。

图表 12：近年来国内外主要 AI 巨模型

巨模型名称	研发机构	推出时间	参数量（十亿）
M6	阿里达摩院	2021年8月	10,000+
悟道2.0	北京智源人工智能研究院等	2021年6月	1,750
Megatron-Turing	微软、英伟达	2021年10月	530
源1.0	浪潮人工智能研究院	2021年9月	245.7
GPT-3	OpenAI	2020年5月	175
Turing-NLG	微软	2020年2月	17.2
T5	谷歌	2019年10月	11
Megatron-LM	英伟达	2019年8月	8.3
GPT-2	OpenAI	2019年2月	1.5

资料来源：OpenAI，英伟达，谷歌，微软，浪潮人工智能研究院，北京智源人工智能研究院，阿里达摩院，中金公司研究部

图表 13：不同参数量 GPT -3 模型的十项计算任务准确率




资料来源：OpenAI，中金公司研究部

以 Transformer 为代表的大模型是自动驾驶算法的重要发展方向。Transformer 最早由谷歌在 2017 年提出，主要被用于机器翻译的神经网络模型。Transformer 通过一维卷积和注意力机制的设计，实现了出色的算法并行性，适合 CPU 的运行环境，因此迅速在自然语言处理（NLP）领域流行起来。目前 Transformer 模型几乎取代了基于 RNN 的算法在 NLP 中的地位，并逐渐被引入计算机视觉（CV）领域。特斯拉和毫末智行已经宣布将 Transformer 引入自动驾驶系统中，来实现自动驾驶系统感知智能和认知智能的大幅优化。

Transformer 在大规模数据训练、鲁棒性、泛化能力等方面表现突出，因而在自动驾驶领域较传统 CNN 优势明显。 CNN 特殊的组织结构，即卷积层和池化层的共同作用使得 CNN 能较好地提取图像的特征，过去在图像识别领域得到了广泛的应用。但是 CNN 的缺点在于过于依赖局部信息，从而导致一定程度的不可靠性。而 Transformer 的整个网络结构完全是由 Attention 机制组成，其核心使用多头注意力机制（Multi-head self-attention），能够理解不同区域语义元素之间的关系，因此 Transformer 具备比 CNN 更明显的优势：

- ▶ **大规模数据训练：**当使用大规模数据集进行训练时，CNN 性能所带来的收益会随着数据量的增大逐渐出现饱和的趋势，而 Transformer 的饱和天花板更高，随着数据量的增大，Transformer 训练后的性能相对 CNN 的优势越来越大。自动驾驶属于需要使用大规模数据集训练的场景，更容易发挥 Transformer 的优势。
- ▶ **高鲁棒性、强泛化能力：**面对图像的扰动、遮挡等情况下，Transformer 具备很强的鲁棒性和泛化性。在自动驾驶感知识别中，光照、雨雪遮挡、阴影、重叠等因素会严重制约 CNN 模型的性能，导致其出现错误的判断，而 Transformer 依靠多头注意力机制能够更好地处理这类问题。

图表 14：Vision Transformer 的典型网络结构




资料来源：《An Image is Worth 16x16 Words Transformer for Image Recognition at scale》（Alexey Dosovitskiy, Lucas Beyer 等，2021），中金公司研究部

Transformer 具备强大的序列建模能力、全局信息感知能力，因此在感知过程中的多模态融合方面具备较大优势。Transformer 早期主要被用于 NLP，由于 Transformer 所具备的超强的序列建模能力和全局信息感知能力，它几乎取代了基于 RNN 的算法在 NLP 中的地位，并进一步推进了 NLP 领域的研究。由于 Transformer 所具备的全局信息感知能力，其能捕获全局信息从而对目标建立远距离的依赖，并提取出更强大的特征，近年来逐渐被引入到 CV 领域。

- ▶ **序列建模能力：**序列建模能力指让 AI 模型处理序列数据，预测接下来的情况，比如音乐、翻译等场景。相比于 CNN 和 RNN，Transformer 凭借其注意力机制拥有较强的长序列建模能力，和逐步传播相比，它直接将任意两个位置的隐藏状态连接起来，所以更容易捕捉到全局信息。通过将视觉领域的信息从时间和空间维度划分为序列数据，就可以在机器视觉领域利用 Transformer 强大的序列建模能力。
- ▶ **全局信息感知能力：**Transformer 的主要模块，即多头注意力机制（Multi-Head Self-Attention）可以同时感知到输入序列的全局信息，这是 Transformer 相比于 CNN 的巨大优势。在 CNN 中信息只能从局部开始，被感知到的区域随着层数的增加而增大，Transformer 从输入开始之后的每一层结构中都可以看到所有的信息，并建立基本单元之间的关联，因此 Transformer 能够处理更加复杂的问题。

由于 Transformer 可以很好地在空间-时序维度上进行建模，目前特斯拉和毫末智行等行业龙头通过 Transformer 在感知端提升模型效果。特斯拉从安装在汽车周围的八个摄像头的视频中用传统的 ResNet 提取图像特征，并使用 Transformer、CNN、3D 卷积中的一种或者多种组合完成跨时间的图像融合，实现基于 2D 图像形成具有 3D 信息输出。毫末智行的 AI 团队正在逐步将基于 Transformer 的感知算法应用到实际的道路感知问题，如车道线检测、障碍物检测、可行驶区域分割、红绿灯检测&识别、道路交通标志检测、点云检测&分割等。

图表 15：特斯拉利用 Transformer 实现多摄像头数据融合




资料来源：特斯拉 AI day，中金公司研究部

除感知环节外，Transformer 同样有望在决策规划等环节提升模型效果。Transformer 不仅能处理各类视觉检测任务（车辆检测、车道线检测、交通标志检测、红绿灯检测等）、各类分割任务（可行驶区域检测、全景分析等）和 3D 点云的检测和分割（障碍物的检测等）任务，也有潜力提升后续的规划和控制的相关技术。我们认为，Transformer 技术的进一步应用，有望为自动驾驶的各类算法落地带来成倍的效率提升，并快速提升各项视觉性能指标。

通过无监督预训练，Transformer 大幅提升了预训练模型的性能。自动驾驶产生海量数据，如果全部进行标注将带来巨大成本，因此使用无需标注的无监督学习对提升模型效果、降低训练成本至关重要。而在使用大规模数据集进行预训练时，Vision Transformer 训练效果明显优于 CNN 模型。此外，据谷歌发表论文 Scaling Vision Transformers¹显示，Vision Transformer 的参数量已经达到 20 亿之多，经过在 30 亿规模数据集上的训练，其性能达到了业界最高水准。

图表 16：随着数据量提升，Vision Transformer 的预训练效果优于 CNN




资料来源：Towards data science，中金公司研究部

Transformer 为代表的大模型能充分发挥大数据价值，特斯拉、毫末等具备数据优势的企业均选择大模型路线。我们认为，在自动驾驶逐渐从 L2 级辅助驾驶向全自动驾驶进步的过程中，用于训练的数据量是关键，拥有数据多的公司更容易在模型迭代过程中领先，Transformer 的出现使得掌握数据的企业能形成高效的数据闭环，使用大量数据持续升级其大模型。目前特斯拉拥有 200 万辆级的量产车，根据毫末智行官方网站，其辅助驾驶系统 HWA 预计未来 3 年内有望搭载 100 万辆长城汽车。百万级的搭载量意味着每年数百亿级里程，有望为自动驾驶算法带来颠覆性突破。

¹ <https://arxiv.org/pdf/2106.04560.pdf>

图表 17：特斯拉量产车数量增长趋势



资料来源：INSIDEEVS，中金公司研究部

图表 18：典型车型车载传感器配置情况

车型	摄像头个数	摄像头类型
特斯拉ModelX	8	3个前视摄像头+1个后视摄像头+4个侧视镜头（左右各一个侧方前视和侧方后视）
特斯拉Model3		
特斯拉ModelS		
蔚来ET7	11	4个环视+1个主摄像头+1个长焦摄像头+1个后视摄像头+4个侧视镜头（左右各一个侧方前视和侧方后视）
理想ONE	5	4个环视+1个辅助驾驶前摄像头
小鹏P7	14	4个环视+10个自动驾驶高感知摄像头
奔驰S	6	1个前视双目摄像头+1个后视摄像头+4个环视摄像头

资料来源：各公司官网，佐思汽研，中金公司研究部

感知算法：多传感器数据融合+定位，实现车辆环境感知

感知算法实现类人眼视觉的部分功能。感知算法利用传感器收集环境数据，完成行驶路径识别及周边物体识别的任务。具体而言，感知算法需要对道路交通标志标线、交通设施以及车辆、行人、地面其他物体进行识别和辨认。常用自动驾驶车辆感知器主要包括超声波雷达、毫米波雷达、激光雷达、视觉传感器等，不同传感器的感知性能及适用情形存在差异。超声波雷达适用于短距离测距，毫米波雷达用于测距及速度，激光雷达适合于为环境 3D 建模收集数据，视觉传感器则对行人、交通标志标线等细节有更强的感知能力。

图表 19：自动驾驶各类传感器对比

传感器类型	超声波传感器	毫米波雷达	激光雷达	视觉传感器
远距离探测	弱	强	强	较强
探测角度	120度	10~70度	15~360度	30度
夜间环境	强	强	强	弱
全天候	弱	强	强	弱
不良天气环境	一般	强	弱	弱
温度稳定性	弱	强	强	强
车速测量能力	一般	弱	强	弱
路标识别	×	×	×	√
主要应用	泊车辅助	自适应巡航控制、自动紧急刹车	实时建立车辆周边环境的三维模型	车道偏离预警、车道保持、盲区监测、前车碰撞预警、交通标志识别、全景泊车
成本	低	适中	高	适中

资料来源：《一本书读懂智能网联汽车》（崔胜民，2019），中金公司研究部

高级别自动驾驶往往需要更多种类及数量的传感器。传感器配置种类和数量与自动驾驶级别相关，目前典型的自动驾驶传感器方案为：多个环视及前视摄像头配合 10 个以上超声波雷达及多个侧向、前向毫米波雷达。若要实现高级别自动驾驶功能，通常还需配置激光雷达。


图表 20：典型自动驾驶车辆传感器基本配置

传感器	数量	最小感知范围
环视摄像头（高清）	4	8m
前视摄像头	1	50度/150m
超声波雷达	12	5m
侧向毫米波雷达（24GHz）	4	110度/60m
前向毫米波雷达（77GHz）	1	15度/70m
激光雷达	1	110度/100m

资料来源：《一本书读懂智能网联汽车》（崔胜民，2019），中金公司研究部


多传感器融合是感知系统的主流发展方向。多传感器方案融合使用摄像头及毫米波雷达乃至激光雷达。视觉摄像头能够提升系统的细节感知及推理能力，例如通过分析摄像头提取行人的面部表情、身体方向及运动姿态，预判行人的潜在意图。与此同时，雷达传感器能够弥补摄像头在作用距离、测距精度及特殊场景下的性能劣势，实现高精度探测。根据特斯拉 CEO 马斯克，特斯拉坚持使用视觉主导的方案，即采用摄像头作为主要传感器。除特斯拉外，其他车企及自动驾驶厂商均选择包含激光雷达的多传感器融合系统。

图表 21：前融合（紧耦合）将多传感器结合使用



资料来源：CSDN，中金公司研究部

图表 22：后融合（松耦合）将各自传感器结果再融合




资料来源：CSDN，中金公司研究部

特斯拉通过多种模型分别实现特征提取、多摄像头融合、时序特征提取、多任务联合学习等功能，进而组合形成感知网络。近年来，特斯拉等自动驾驶技术能力排名前列的厂商越来越多的在感知算法层面采用神经网络模型，通过构造包含 48 个神经网络的 HydraNets 多任务神经网络系统，特斯拉目前能够实现同时检测 1,000 种物体。其整体模型主要分为四大部分，每部分均采用深度学习相关模型构建：

- **图像特征提取：**主干网使用 RegNet 对单传感器采集到的原始图像进行分级处理，提取图像的多层次特征，而后使用 BiFPN 模型对多层次特征进行融合。
- **多摄像头融合：**使用 Transformer 网络对多摄像头数据进行融合以构建周围环境的矢量空间，实现图像数据从 Image space 到 Vector space 的转换。特斯拉的 Transformer 神经网络能够同时接收 8 个摄像头的的数据输入，不仅能有效提升矢量空间数据集精度，提升了模型训练速度，还能产生更具可解释性的模型，因而 Transformer 模型也是特斯拉感知算法结构的核心。
- **时序特征提取：**利用 RNN（Recurrent Neural Network）提取时序特征，将时间维度加入周围环境的矢量空间，基于过往发生的经验来处理任意时序的输入序列，预测环境物体即将发生的动作，例如行人是否要过马路。

- **多任务联合学习**：构建了带有时间标记的周围环境矢量空间后，不同任务可以利用矢量空间数据开展学习任务，例如车道线检测等。整套网络采用了多种已存在的模型结构的创新组合，提高了模型的学习能力。

图表 23：特斯拉感知算法结构分为四大部分




资料来源：特斯拉 AI day，中金公司研究部

定位是感知环节中的重要部分，往往通过组合 GPS、惯性导航、SLAM 等技术实现。构建好周围环境的时空模型外，车辆自身实时定位便成为自动驾驶的首要任务，确定自身位置后车辆才能够根据驾驶目标进行一系列行驶决策。常见的定位技术包括 GPS、惯性导航（Inertial Navigation System, INS）、航迹推算（Dead-Reckoning, DR）、高精度地图、SLAM（Simultaneous localization and mapping, 同步定位与建图）等，各种技术均有局限，在实际落地中往往组合使用，其中高精度地图方案以及 SLAM 方案较为常见：


- **高精度地图方案**：供应商预制的高精度地图采用预先加载的方式安装在自动驾驶软件系统中，车辆调用高精度地图并结合传感器收集的实时环境信息即可不断更新自身位置。目前四维图新等市场前列的高精度地图供应商已经能够提供城市内 10cm 级别的高精度地图与定位服务、高精度语义地图格式和兼容标准地图格式。
- **SLAM 方案**：车辆行驶过程中传感器不断采集数据输入 SLAM 算法模型并实时生成地图。目前地图生成的方式分为两类，第一类不参考外部信息，仅融合使用里程仪、罗盘、加速度计等内部传感器数据，但该方法长时间累计误差较大。目前市面通用第二类多传感器融合方式，即依靠内部传感器估计自身运动，同时使用摄像头、激光雷达等外部传感器获取环境信息并保存分析，在下一时点比较环境特征以对自身位置进行矫正。早期 SLAM 主要依赖雷达等具有深度信息的传感器数据，近年来基于摄像头数据的视觉 SLAM 发展较快。

图表 24：多传感器融合定位算法流程图




资料来源：CSDN，中金公司研究部

图表 25：高精度地图预制过程



资料来源：百度地图，中金公司研究部

图表 26：SLAM 模型生成




资料来源：CSDN，中金公司研究部

决策算法：自动驾驶中的核心挑战与难点

决策层是自动驾驶系统中难度极高的部分，需要高效的 AI 模型和大量训练数据。决策层指依据感知到的道路信息、交通信息、车辆自身信息来进行决策判断，选择适当工作模型并制定相应控制策略，对底层控制执行模块下达指令。在车道保持、车道偏离预警、车距保持、障碍物警告等场景中，决策系统需要预测本车及相遇的其他车辆、车道、行人等在未来一段时间的状态，且不同人对不同情况所做出的驾驶策略也有所不同，因此决策算法的优化需要高效的人工智能模型和大量的训练数据，以覆盖各种各样的长尾场景。

自动驾驶的决策系统主要包括行为决策、路径规划两大部分。行为决策系统对车辆涉及的交通参与者进行建模并预测其行为，再将各方信息汇总后交由路径规划系统做出决策。决策系统按照层级一般可划分为认知层、任务层、规划层三层，分别负责驾驶情景认知、驾驶行为决策、局部路径规划，最终决定车辆形式的最优路径。

图表 27：自动驾驶决策规划分类




资料来源：《自动驾驶汽车拟人化决策系统的关键技术研究》（忻隆，2019），中金公司研究部

驾驶情景认知

场景感知是感知和决策交汇环节，向决策环节输出场景的语义表达和物体的结构化表达。根据下面的自动驾驶任务划分流程图，感知模块与决策模块各被分为三部分，场景感知位于两者的交汇环节。感知层算法的核心任务是将各种摄像头、雷达等传感器的输入数据转换成计算机能理解的车辆所处场景的语义表达、物体的结构化表达，包括物体检测、识别和跟踪、3D 环境建模、物体的运动估计等。

图表 28：场景感知是感知与决策的交汇环节



资料来源：《Deep Reinforcement Learning for Autonomous Driving: A Survey》(B Ravi Kiran, Ibrahim Sobh, 2021)，中金公司研究部

图表 29：感知系统与决策系统的对接方式




资料来源：百度 Apollo，中金公司研究部

驾驶行为决策

感知模块连接行为决策、路径规划模块。在感知系统完成对环境的特征识别之后，通过四个流程操控控制规划系统，即输入数据-形成矢量空间-输出给神经网络-输出给规划控制系统，最终由规划控制系统向车辆输出转向、加速等指令。此外，控制规划系统同时具备多个目标，如特斯拉自动驾驶规划控制技术的核心目标是在安全、舒适、效率三者之间实现最佳平衡。

决策规划算法主要分为三种类型。决策系统融合了多传感器信息，再根据驾驶需求进行任务决策，在特定的约束条件下，规划出两点之间的多条安全路径，之后在这些路径当中选择一条最优路径，作为车辆行驶轨迹。目前自动驾驶汽车常用的决策算法主要有三种类型：基于神经网络的决策、基于专家规则“if-then”、和两者的混合路径。

图表 30：规划控制核心目标是实现安全、舒适、效率三者最佳平衡




资料来源：特斯拉官网，中金公司研究部

自动驾驶规划的关键难点在于非凸面和高维。自动驾驶规划的模型是离散的，没有单一的最优解，而且随着场景变化而高速地动态变化，离散模型的计算很复杂，难以得到高效的解决。目前自动驾驶面临的关键难点在于非凸面和高维：

- ▶ **非凸面**：轨迹规划的约束包括遵守交通规则、避免碰撞、轨迹在车辆控制上可实现，但是这样的优化目标在数学上往往是非凸的，造成优化结果不够稳定，因此如何将轨迹规划的优化问题构建成一个凸问题是当前行业的瓶颈之一。
- ▶ **高维**：规划系统需要对大约未来 10s 的情况做出预测，而且规划本身是在三维空间中进行的，这类高维度的计算对自动驾驶算力要求较高，如何利用算法来合理降维，也是困扰业界的难点。

深度强化学习、模仿学习是决策领域热点趋势。目前以强化学习和模仿学习为代表的决策方法是热点趋势，强化学习指通过将驾驶问题建模为马尔可夫决策过程来学习如何从环境表示中给出最优解。简言之，该策略通过将自动驾驶策略建模成从环境的状态到动作的实时映射，驾驶策略通过输出动作并应用在驾驶环境中，得到下一时刻的状态和奖励。


图表 31：强化学习和模仿学习相结合够解决真实环境下各种各样的视觉运动任务



资料来源：arXiv，中金公司研究部

特斯拉采用“粗略搜索+凸空间内的连续优化”的混合规划系统，实现平滑的运动轨迹。特斯拉采用混合规划系统，首先让感知数据通过向量空间的粗略搜索，然后经过凸空间内的连续优化，形成平滑舒适的运动轨迹。具体流程包括接收矢量数据集、粗略搜索结果、投射为线性模型、解决线性问题四大流程。特斯拉借助这种高效混合算法，可以在 1.5 毫秒中作出 2,500 次的不同情况模拟，并快速选择最舒适、安全、高效的行为规划。

图表 32：特斯拉混合规划系统的五个步骤



资料来源：特斯拉官网，中金公司研究部

随着神经网络在规划控制使用上越来越多，处理复杂规划的能力持续提升。近年来，在视觉识别、语音识别、语音合成、机器翻译等程序中的神经网络越来越多，规划控制也已经开始引入神经网络。如特斯拉逐渐在规划控制中引入更多的神经网络策略来应对开放、无序的道路场景，实现了规划控制试错次数的大幅减少。

最后，整车的软硬件结合架构设计是高级别自动驾驶的难题。由于自动驾驶系统复杂度高，涉及到很多传感器的交互融合，每一个硬件的可靠性都会影响到自动驾驶系统的整体可靠性。在进行整车软硬件结合架构设计时，往往需要整车厂和自动驾驶提供商深度合作，一旦涉及设备种类和数量的调整，往往会对整个系统的运行产生较大影响，因此需要大量的测试和验证。


数据：决定量产能力的胜负手

深度学习是数据驱动的 AI，数据积累是现阶段自动驾驶核心竞争点

深度学习是数据驱动的 AI

底层技术决定了数据要素在深度学习中的核心地位。在深度学习时代，数据、算法、算力是构造 AI 的三大要素。由于深度学习的理论基础保证了当输入数据量足够大时，深度神经网络能够逼近任意的函数，且样本数越多，模型越能够收敛至数据背后的真实函数，因此数据要素是深度学习的核心。


图表 33：数据驱动的 AI



资料来源：《无人驾驶原理与实践》（申泽邦、雍宾宾、周庆国、李良，2019），中金公司研究部

深度学习需要海量数据“投喂”，未来较长时间内数据积累都将是自动驾驶核心竞争点。深度学习是自动驾驶算法的核心，而深度学习依赖于数据的反馈。若自动驾驶产品无法在大量的车队上实现量产，就难以发现深度学习算法网络存在的问题，自动驾驶算法的迭代也将停滞。因此我们判断，未来较长一段时间内，数据的持续积累将是各大自动驾驶厂商的核心竞争点。以毫末为提出的自动驾驶能力发展曲线为例，其产品力核心迭代动力来自于数据规模。

图表 34：自动驾驶能力发展曲线



资料来源：毫末智行 AI day，中金公司研究部


数据积累依赖感知层面传感器的配置。目前市场上存在两类配置方案：一类为使用摄像头作为主要传感器、不采用激光雷达感知数据的视觉方案，目前仅特斯拉一家使用，百度 2021 年底发布的 ANP 系统也采用了该方案；第二类为以激光雷达为主导的多传感器配置方案，Waymo 等 L4 厂商及其他 L2 厂商均选择该技术路线。

图表 35：主流车型传感器配置方案

品牌	特斯拉	蔚来	小鹏		理想	Waymo	Baidu
车型	Model 3	ES6/8	P5	P7 (XPILLOT 3.0)	One		ANP系统
摄像头	8 (3前视, 2侧方前视, 2侧方后视, 1后视)	4/10	13	14	5	29	12
超声波雷达	12	12	12	12	12	12	12
毫米波雷达	1	5	5	5	1	6	5
激光雷达	0	0	2	0	0	5	0
							

资料来源：特斯拉官网，蔚来官网，小鹏官网，理想官网，佐思汽研，百度 Apollo 官网，中金公司研究部

图表 36：自动驾驶厂商累计加州路测里程数



资料来源：加州交通管理局 DMV，中金公司研究部

视觉 vs 激光雷达？算法、成本、数据综合作用下的最优解

摄像头、激光雷达等各类传感器配置方案各有优劣。自动驾驶技术主要包括感知、规划控制、决策、执行等环节，感知环节主要包括以 Waymo 为代表的激光雷达主导方案，与以特斯拉为代表的视觉主导方案两类技术路线。激光雷达方案全方位测距能力强，尤其是对深度的探测能力；视觉方案分辨率更高，在当前阶段成本优势明显。


纯视觉路线：特斯拉坚持“第一性原理”，打造类人的自动驾驶系统

特斯拉坚持“第一性原理”，认为视觉主导是实现 L4 自动驾驶的可行路线，且成本优势明显。2021 年 5 月，特斯拉在美国销售的 Model 3/Y 车型取消毫米波雷达，完全使用纯视觉解决方案。马斯克坚持“第一性原理”，认为自动驾驶感知过程能仅通过摄像头模拟人眼功能来实现。特斯拉坚持选择视觉主导方案的主要原因是：

- 传感器的本质是传输数据流，摄像头每秒传输的数据量是雷达传感器的 100 倍，即使 1280x960 分辨率的摄像头相比其他传感器仍为“数据富余”；
- 雷达采集的数据信噪比低，耗费精力融合雷达数据的成本效益比较低。

特斯拉自动驾驶技术逻辑：将自动驾驶系统看作生物体，摄像头是眼睛，AI 算法模型与芯片构成神经与大脑。特斯拉选择数据富余的摄像头作为“眼睛”，并持续开发自己的“神经”及“大脑”——深度人工神经网络算法以及于 2016-17 年开始自研 FSD 芯片。此外，特斯拉通过建设自动驾驶的超算集群不断训练能力更强的“大脑”，而仿真系统则类似人类在驾校学习的过程，最终通过大量车队的影子模式不断反馈迭代，特斯拉的自动驾驶的“大脑”可以不断学习实际驾驶过程中的经验，提升驾驶水平。

图表 37：人与特斯拉自动驾驶能力体系对比




资料来源：Tesla AI Day，Tesla 官网，中金公司研究部

特斯拉路线的关键是通过车辆销量支撑的海量数据，而采用低价的摄像头才能实现车辆销售放量，获得海量数据积累。特斯拉自动驾驶自成一环：行驶在道路上的每辆特斯拉都是“数据收集器”，通过车载摄像头收集数据并上传云端，形成庞大且真实的自有数据池。数据输入自建的神经和大脑——自研芯片及自动驾驶算法，实现软硬件的同步优化。Autopilot 的“影子模式”完成该学习闭环，影子模式下若用户驾驶行为与 Autopilot 的决策对比不一致，该场景数据将会被传回云端，进行算法修正。特斯拉闭环模式的重点是高销量，而当前阶段激光雷达价格仍远高于摄像头，安装激光雷达的车辆价格高昂，难以实现特斯拉百万量级的车辆销量。

特斯拉积累的物体标签数据量达 1.5PB，远超其他自动驾驶厂商。根据特斯拉人工智能总监 Andrej 在 CVPR 2021 上的发言，截至 2021 年 6 月底，特斯拉拥有百万量级的车队，已经收集了 100 万个 36 帧 10 秒时长的高度差异化场景视频数据，约占用了 1.5PB 的存储空间，获得了 60 亿个包含精确深度、加速度的物体标注，共进行七轮影子模式迭代流程。特斯拉纯视觉版本自动驾驶系统已经积累了近 1,500 万英里的数据，其中 170 万英里在 Autopilot 启动情况下收集。这个数据远远领先于其他自动驾驶厂商，也是特斯拉路线优势的极大体现。

图表 38：特斯拉 Autopilot 里程数



资料来源：Lexfridman，中金公司研究部
注：数据截至 2021 年 1 月 1 日


激光雷达路线：众多厂商布局，降价速度是核心，数据融合是趋势

激光雷达能够精准感知速度和距离，具备高可靠性，是大部分自动驾驶厂商发力的方向。与摄像头相比，激光雷达的速度、距离探测能力较强。通常激光雷达的角速度不低于 0.1mrad，即能够分辨 3km 距离上相距 0.3m 的两个目标；其距离分辨率可达 0.1m，速度分辨率能达到 10m/s 以内。此外，激光雷达还具备较强的抗有源干扰能力，可靠程度高。在高级别自动驾驶系统中，高精度速度和距离感知能力是必备能力，因此众多厂商都选择将激光雷达作为高级别自动驾驶的感知方案。

成本高昂是使用激光雷达的痛点，未来激光雷达降价速度成为该技术路线能否大规模应用的关键。激光雷达并非完美解决方案，成本高昂是其应用的最大障碍，且不仅体现车辆生产中，后续对激光雷达这一基础硬件进行更新升级的成本也同样是痛点所在。根据[中金研究汽车组调研](#)，每台可量产激光雷达成本已由 2017 年的 US\$75,000 下降至 2021 年的 US\$1,000，未来激光雷达的大规模应用将依赖于成本的进一步下降。

此外，激光雷达存在数据信噪比低、细节丢失、雨雪天气探测能力减弱等问题。为了远距离探测，激光雷达会牺牲一定的细节信息，出现获取数据不够丰富，信噪比较低的问题。同时激光雷达自身存在雨雪天气下探测能力大幅减退的缺陷，目前技术界正在尝试通过融合其他传感器数据的方式弥补激光雷达的不足。

图表 39：激光雷达价格走势，2017-2023E



资料来源：Livox 官网，中金公司研究部


数据、算法、算力、成本综合作用下的最优解

从技术角度看，视觉主导与激光雷达技术路径之争，本质上是 AI 算法+硬件逼近人脑能力的速度，与激光雷达等可选硬件对数据量、算法弥补程度及其降价速度之间的竞争。对于具备数据优势的特斯拉路线，其技术重点在于提高深度神经网络大脑的辨识能力、语义分辨和可靠性，同时证明视觉信息具备不逊色于激光雷达点云数据的目标测速和测距潜能。而对于多传感器融合的激光雷达技术路线，我们认为，首先，激光雷达降价速度是核心扰动因素，未来激光雷达的大规模应用将依赖于成本的进一步下降；其次，快速处理激光雷达的结构化数据，大幅度降低视觉信号对于后端算法处理的压力，形成更优的组合感知方案是该路线研发的重中之重。

需求端：考虑到消费者对于生命安全愿意付出溢价，激光雷达作为安全冗余在很长时间都具备现实需求。对于消费者来说，自动驾驶安全性是其底线诉求。即使视觉主导路线实现完全自动驾驶技术可行，消费者仍然会追求激光雷达辅助的安全冗余。从这个维度我们判断，未来较长一段时间内激光雷达都存在现实需求。

供给端：大多数自动驾驶厂商不具备明显数据量优势，仍寻求多传感器融合方案。特斯拉视觉主导路线的基础是百万级别销量与 1.5PB 真实行车数据。商汤科技、毫末智行等其他自动驾驶厂商的数据存量和积累速度无法与特斯拉匹敌，难以满足视觉主导方案需要海量数据量“投喂”的需求，因此，几乎都选择激光雷达、毫米波雷达、摄像头等异源传感器融合方案作为发展方向。

图表 40：多传感器数据融合过程



资料来源：CSDN，中金公司研究部


未来格局：我们认为，无论视觉主导还是激光雷达路线，很长时间内有效数据量为核心竞争要素。特斯拉自动驾驶模式形成了数据和学习闭环，竞争壁垒较高。其他自动驾驶入局者中，主机厂存在数据优势，但自动驾驶算法能力较弱。特斯拉形成了“Autopilot 收集数据-FSD 芯片与 Dojo 超算训练-影子模式修正-自动驾驶软件 OTA 升级”的闭环，竞争优势明显。尽管其他主机厂拥有数据优势，但其在感知、决策及执行层面的算法、芯片研发能力都较为欠缺，难以赶超龙头厂商。

数据体系的自动化水平、效率是关键竞争点

自动驾驶从 L2 向 L4 的迭代，非结构化数据依赖大量人工标注。目前自动驾驶主流算法模型主要以有监督的深度学习为主，因此数据质量决定自动驾驶系统模型质量的上限。由于无监督学习尚不成熟、产出模型质量较低，在自动驾驶这类安全性要求极高的场景可用性较低。使用 AI 进行数据标注也较为困难，只能实现简单场景下的数据处理，因此目前 AI 模型的训练数据生产仍然需要依赖人工标注，标注内容包括可行驶区域、各类障碍物、建筑、植被、各类车辆、车道分界线、红绿灯等。

数据体系的自动化水平及相关技术对于解决训练数据生产的成本、效率问题至关重要，壁垒较高。高自动化水平的数据体系具有较高的研发门槛，大部分数据标注公司难以进行自动化标注系统的研发，需要专业的研发人员和行业 knowhow。自动驾驶的自动化标注方案往往需要包括场景数据库、定制化数据采集标注、数据标注和数据管理平台等服务。以云测数据为例，其自动驾驶标注工具集历经多年研发，包括点云融合跟踪、点云语义分割、图像全景分割、点云智能贴合、点云多帧复制、多边形切割等各类智能辅助工具。以毫末数据智能体系 MANA 为例，数据收集、处理、标注和 AI 训练的成本和速度对自动驾驶系统的成本和迭代速度至关重要。

图表 41：毫末自动驾驶数据智能体系 MANA



资料来源：量子位，中金公司研究部

图表 42：云测数据开发的自动驾驶标注工具集示例




资料来源：云测数据，中金公司研究部

目前自动驾驶企业在数据处理环节较多依赖第三方数据标注厂商。由于对自动驾驶训练数据的标注和筛选需要消耗大量的资源，很多智能驾驶企业和车企都选择将数据标注交给第三方企业完成。第三方厂商可以通过自建数据场景实验室、数据标注基地，自研数据标注系统、数据采集系统，开发数据生产流程，为智能驾驶领域的企业提供定制化的数据采集、数据标注服务，从而同时满足数据标注效率、质量和隐私安全性，加速自动驾驶产业化落地进程。

以特斯拉为代表的车厂不断打造自研数据标注平台，提高自动化水平，正在逐渐使用自动标注替代手工标注。采用第三方标注具有效率低、反馈慢等痛点，导致标记、分析、处理训练数据的延迟较高，特斯拉自建超过一千人的数据标注团队，分成人工数据标注、自动数据标注、模拟仿真、数据规模化四个团队，技术层面已经完成了从 2D 标注到 4D 标注和自动标注的进阶，自动标注工具可以通过一次标注就实现所有摄像头多视角、多帧画面同步标注，同时也能就时间维度进行标注。


通过自研的离线数据自动标注和自动训练框架，特斯拉实现无人工干预的识别网络。特斯拉对高难度的标注任务，采用名叫“Operation Vacation”的流程处理。将对应物体的识别网络的设计、训练、测试和放入 Data Engine 平台的相关工作，系统直接对其进行操作，无需外部人工干预。不同图像的识别标记任务虽然是独立的，但是其中具备大量性质相同的处理流程和环节，可以直接调用上游任务识别的原型。因此，特斯拉自动驾驶团队可以将大部分的工作交给 Data Engine 和大量已经存在的 Prototype 来处理，而优化和参数调优，也放在大循环内执行，人工只进行极少的干预，且只会在模型训练效果差、无法收敛等异常状态下发挥作用。

图表 43：特斯拉 Operation Vacation（运营假期）模式



资料来源：特斯拉官网，中金公司研究部

图表 44：特斯拉数据生产的三个阶段




资料来源：特斯拉官网，中金公司研究部

根据特斯拉 AI Day，目前特斯拉数据生产主要包括三个阶段：

- ▶ **手动标记：**1,000 人的标记团队与工程师合作，手动标记照片（2D）、三维图像（3D）和三维图像视频（4D）中的信息；
- ▶ **自动标记：**通过大量特斯拉测试车辆以及用户车辆行驶产生的图像数据，上传到服务器对同一地点进行深度学习与自动标记，完善特斯拉数据库；
- ▶ **模拟迭代：**通过虚拟环境进行学习，通常用在测试极端情况、难以标记的复杂环境、闭塞路况等现实世界中案例极少的情况，进一步提高自动驾驶系统应对复杂情况的能力。

特斯拉通过“影子模式”，形成数据、训练、部署的模型优化闭环，从而不断解决 Corner case 问题。在“影子模式”下，自动驾驶电脑进行实时同步计算，但不参与车辆控制，当驾驶员的操作和自动驾驶模型的判断出现分歧，特斯拉的自动驾驶电脑记录案例并上传给总部，通过这种方式收集大量数据再进行场景分类和训练，使得整个识别算法更加智能。此外，人类司机的操作数据可以为神经网络提供质量更高的半监督学习或监督学习引导。

图表 45：特斯拉“影子模式”（Shadow Mode）原理




资料来源：特斯拉官网，中金公司研究部

“影子模式”针对 **corner case** 搜集大量类似案例数据进行修正。初始的自动驾驶神经网络模型被送到车端后，庞大的车队开始进入试用阶段，自驾神经模型开始以各种模式开始运作，识别自动驾驶输出命令与人类司机操作系统的 **inaccuracy** 状态，则有两种方法进行干预。在发现 **inaccuracy** 状态后，特斯拉会快速将问题场景在车队内扩散，搜集大量类似信息，上报到神经网络的训练模型，以这种方式快速参考大量 **corner case**，使得云端的自动驾驶神经网络模型得到快速锻炼和修正，这也是特斯拉自动驾驶技术的竞争壁垒。

“影子模式”导致对云端做标记的算力和人力要求大幅提升，需要提高数据闭环自动化比例。影子模式针对 **corner case** 的处理方法，导致特斯拉在云端必须具备足够的人力进行标记工作，以处理短期内大量的上报数据，否则上报数据的错误标注会导致已有的自动驾驶模型恶化。因此，数据标注、模型训练的自动化比例决定 **Autopilot** 算法自我演进的速度。

特斯拉 **Autopilot** 的识别网络能够识别接近一千种目标并作出目标预测。特斯拉纯视觉算法 **HydraNets** 可以基于不同摄像头的视觉内容进行识别，进行端到端的训练和推断。特斯拉 **Autopilot** 的 **HydraNet** 包含至少 48 个具体的神经网络结构，可以同时执行超过 1,000 个不同的识别、预测任务，进行一次充分训练所需要的周期是 7 万 GPU 小时。

图表 46：特斯拉 HydraNet 网络



资料来源：特斯拉官网，中金公司研究部

通过自动数据标注等全套流程，特斯拉实现 FSD 模型能力的不断进化。特斯拉通过基于海量的道路视频信息进行无监督学习，将结构化的、语义的道路信息用来训练 autopilot；结合基于视觉的自监督学习，进行视觉信息基础上的深度信息推断；根据历史信息对未来进行预测。基于自动驾驶神经网络模型-大量数据-数据处理-云端数据训练的闭环，特斯拉实现 FSD 模型能力的持续进化。

算力：大算力芯片元年开启，AIDC 助力大模型能力跃升


车端：2022 开启大算力芯片落地元年

自动驾驶算力先行，芯片格局“一超多强”

高级自动驾驶中算力助力算法但先行于算法，大算力是竞争焦点。自动驾驶汽车一般以多传感器融合的方式采集数据，处理数据需要强大的 AI 芯片提供算力支撑。自动驾驶级别越高，数据采集、传输、处理量指数级提升，对 AI 芯片算力要求随之提升。据高工智能汽车研究，L2/L3/L4/L5 级别自动驾驶芯片的算力最低要求分别约为 10/100/320/1,000 TOPS（TOPS：每秒万亿次操作）。从 AI 算力现状来看，特斯拉 FSD 1.0 提供 72 TOPS，其对应 HW 3.0 计算平台采用双芯片设计，可提供 144 TOPS 算力，超越主流芯片厂商，但仅可满足 L2/L3 级别自动驾驶需求，未来大算力芯片成为自动驾驶升级体验感的核心竞争点。

AI 芯片算力前置冗余存在必要性。自动驾驶车辆对感知的需求较高，像素和数据量均对算力提出了不断攀升的要求。此外，硬件迭代远慢于软件，整车出厂时定义为 L2 或 L2+级别自动驾驶，后期可通过软件的升级迭代支持各种附加功能，需要额外算力支持，因此算力需较算法需求具备前置冗余性。

图表 47：自动驾驶各级别对应像素数、数据量以及算力需求（估计值）



资料来源：智车科技，高工智能汽车研究，中金公司研究部


注：各级别自动驾驶算力需求，为结合高工智能汽车研究与智车科技的估测值

自动驾驶 AI 芯片竞争格局呈以英伟达为领导者的“一超多强”之势。

- ▶ **英伟达：**英伟达入局自动驾驶行业最早，于 2014 年布局 AI 芯片，先发优势明显。依托于 GPU 龙头地位、完善的 CUDA 生态建立了 AI 芯片上的领先地位。由于自动驾驶软硬件的高耦合性，英伟达通过发布软件平台进一步巩固了其先发优势。2015 年英伟达率先推出自动驾驶平台 DRIVE PX/PX2，又在 2019 年推出自动驾驶统一架构 DRIVE 和为汽车量产设计的 Orin 计算平台，成为自动驾驶芯片领域的领导者。
- ▶ **英特尔 Mobileye：**英特尔于 2017 年收购 PC 芯片巨头 Mobileye 入局 L2 自动驾驶市场。Mobileye 以视觉感知技术为基础，推出了算法+EyeQ 系列芯片组成的一系列解决方案，能帮助客户快速完成自动驾驶系统的研发，帮助车企实现从 L0 级的碰撞预警到 L2 级的 ICC 集成式巡航等 ADAS 功能。
- ▶ **高通：**高通打造自动驾驶软硬件的整合方案。硬件方面，高通在消费级芯片和座舱芯片上处于领导者地位，其自动驾驶芯片具备更高的性价比和更丰富和生态系统，在 ASIC 对 GPU 的替代趋势下，高通在自动驾驶芯片领域持续追赶。软件方面，高通发布 Snapdragon Ride 平台，和科创达等软件服务商合作推进该平台的落地，并收购自动驾驶公司 Veoneer 旗下 Arriver 业务，将其感知及决策软件系统纳入 ADAS 解决方案中增强综合实力。
- ▶ **特斯拉：**电动化+智能化的先行者，践行视觉 AI 路线，积累海量视频数据和算法模型，自研 FSD 芯片，完成数据、软件平台、硬件的全栈式自研。特斯拉曾采用 Mobileye 和英伟达的 AI 芯片，之后由于对算力需求较高转而自研 FSD 芯片，并在 2019 年量产入车。
- ▶ **地平线：**地平线专注于边缘人工智能芯片研发，推出国内首款车规级芯片，打破海外巨头垄断，是国内极少数实现量产的车规级 AI 芯片企业之一，截止 2021 年 9 月，芯片出货量已突破 50 万片。

域控制器能够打通硬件与软件需求，具备平台化、高兼容性和高性能的优势，芯片厂商自研或与第三方厂商合作。域控制器模式将整车划分为动力总成，智能座舱和智能驾驶等几个域，利用处理能力更强的多核 CPU/GPU 芯片相对集中地控制每个域，因此域控制器的潮流导致了芯片的计算能力快速提升，其具备平台化、兼容性、集成高、性能好等优势。现有域控制器在大算力芯片支持下发展迅速，特斯拉的 HW 计算平台采用双 FSD 芯片结构支持 144 TOPS 算力；华为 MDC300 和 600 平台分别支持 L3/L4 级自动驾驶；德赛西威推出的多款自动驾驶域控制器和多芯片巨头合作，新版本可支持 2,000 TOPS 算力。

图表 48：各供应商自动驾驶芯片发展进程概览



资料来源：各公司官网，中金公司研究部

图表 49：各供应商自动驾驶芯片发展进程概览

芯片厂商	芯片方案	最大算力 (TOPS)	功耗 (W)	算力/功耗	制程 (nm)	适用等级	量产时间	域控制器	算力 (TOPS)	主要搭载厂商
英伟达	作为GPU巨头，2015年，推出了Drive PX系列自动驾驶SoC									
	Atlan	1,000				L5	2025	Drive Atlan	1,000	全球6家Tier1，新势力蔚来、小鹏、理想，丰田，沃尔沃，奥迪等
	Orin	254	65	3.9	7	L4/L5	2022	Drive Orin	254	
	Xavier	30	30	1.0	12	L4/L5	2018	Drive AGX Pegasus	320	
英特尔 (Mobileye)	2017年，收购PC芯片巨头Mobileye，入局L2自动驾驶市场									
	EyeQ6	128	40	3.2	7	L4/L5	2023	EyeQ6	67	奥迪、蔚来、宝马、小鹏等
	EyeQ5	12	5	2.4	7	L2/L3	2021	EyeQ5	24	
	EyeQ4	2.5	3	0.8	28	L1/L2	2018	EyeQ4	3	
高通	作为座舱、ADAS芯片巨头，2016年推出820A SoC入局自动驾驶，2020年发布Snapdragon Ride平台									
	SA9000 PB	300	60	5.0	5	L4/L5	2022	Snapdragon Ride	700	长城等
特斯拉	车厂OEM自研，2017年开始研发，2019年推出HW 3.0平台和FSD芯片									
	FSD 2.0	432			14	L4/L5	2022	HW4.0（预计）		特斯拉
	FSD	72	72	1.0	5/7	L3	2019	HW	144	
华为	2019年，成立华为智能汽车解决方案部门，以高阶自动驾驶全栈解决方案为核心							MDC300/600	64/352	
	昇腾910	512	310	1.7	7	L4	2019.8月发布			
	昇腾610	160（估）	53（估）	3.0（估）	7（估）	L3	2022	MDC610	160	奥迪，一汽，沃尔沃等
	昇腾310	16	8	2.0	12	L2	2018	MDC600	352	
地平线	2015年成立，聚焦边缘AI芯片，2019年推出中国首款车规级 AI 芯片征程2									
	征程5/5P	128	30	4.3	7	L3	2022	Horizon Matrix FSD	200-1,000	长安、奇瑞、哪吒等
	征程3	5	2.5	2.0	16	L1/L2	2020	Matrix		
	征程2	4	2	2.0	28	L1/L2	2019	Matrix	40	

资料来源：各公司官网，中金公司研究部

2022 开启大算力自动驾驶芯片量产元年

2022 年为自动驾驶芯片量产元年，竞争格局变化为主因。根据英伟达、高通等头部厂商对其芯片的量产时点预测，英伟达 Orin、高通 Snapdragon Ride、地平线征程 5 等多款大算力芯片均计划于 2022 年量产入车，我们认为 2019-2020 年自动驾驶竞争格局发生剧变，叠加 1-2 年芯片厂商与车厂的合规、测试验证期，为 2022 年集中量产的背后原因：

- ▶ **特斯拉作为感知技术自研的先行者，引领域控制器架构，催化芯片厂商格局变化。**特斯拉于 2017 年启动自研，改变传统硬件架构，从雷达、摄像头分别计算再融合，引领自动驾驶域控制器架构，并通过自研感知算法进行融合和决策。在特斯拉的带动下，大量车企开始自研感知技术，摄像头或雷达系统内部的计算芯片不再必需，但传感器的种类和数量增加对域控制器内的计算芯片提出了更高的要求，自动驾驶计算架构也向集中计算架构转变。这一变革下，高通于 2018 年入局，特斯拉自研芯片于 2019 年搭载 Model S 等 3 款车型量产，英伟达也推出 Orin 系列大算力芯片，并于 2021 年抢占造车新势力卡位。
- ▶ **与车厂适配和测试需 1-2 年，周期较为刚性。**2020-2021 年为芯片厂商发布大算力芯片与计算平台的集中区间，也是与车厂 OEM 就未来车型建立合作卡位的时机，考虑到适配和测试周期较为刚性，2022 年为竞争格局开启的元年。

图表 50：巨头竞争节奏时间轴



资料来源：各公司官网，中金公司研究部

未来智能驾驶芯片格局研判：从强算力到开放性生态

大算力与能效比是首要竞争要素。自动驾驶 AI 芯片发展水平相较当下量产的 L2/L3 需求具备一定冗余，但尚不满足 L4/L5 级别需求，因此大算力依旧是核心竞争要素。激光雷达的广泛应用，将大大增强自动驾驶感知能力的精度和确定性，激光雷达与机器视觉组成的 AI 感知技术与大算力的深度融合，将会进一步提升自动驾驶感知、认知模块的运行效率。此外，地平线、高通分别采用 ASIC 芯片、ASIC 与 SoC 结合路径，具备更高能效比，同为重要竞争要素。

除算力比拼之外，开放性平台提供的丰富软件生态成为又一核心竞争要素，英伟达和高通生态具备天然优势，国内厂商地平线和华为紧随其后。建立丰富生态的意义在于，支持视觉、毫米波雷达、超声波雷达、激光雷达等多种传感器输入，并结合各类软件开发工具降低客户的开发难度，也可以灵活调整与客户的合作模式。

图表 51：四品牌智能驾驶芯片竞争优势

 对开发者最友好 - AI自动驾驶芯片的先发优势 - 技术上领先竞争对手两年左右 车、边、云端具备全面的GPU硬件架构和易开发的CUDA软件工具链	 - 凭借座舱芯片的强势卡位 - 自动驾驶芯片形成协同效应 - 树立生态壁垒
 地平线 通过大算力芯片+开源车载OS，吸引产业生态合作伙伴共同参与建设	 - 提供MDC智能驾驶计算平台 - 构建智能驾驶软件、传感器和执行器三大生态圈 - 通过硬件接口标准化、软件应用生态化，实现软件可升级、硬件可更换、传感器即插即用。

资料来源：各公司官网，中金公司研究部

- **英伟达**具备 AI 自动驾驶芯片的先发优势，技术上领先竞争对手两年左右，此外，在车、边、云端具备全面的 GPU 硬件架构和易开发的 CUDA 软件工具链，对开发者最友好。
- **高通**凭借座舱芯片的强势卡位，和自动驾驶芯片形成协同效应，树立生态壁垒。
- **地平线**通过大算力芯片+开源车载 OS，吸引产业生态合作伙伴共同参与建设。
- **华为**通过提供 Inside 全栈解决方案、MDC 智能驾驶计算平台，构建智能驾驶软件、传感器和执行器三大生态圈，通过硬件接口标准化、软件应用生态化，实现软件可升级、硬件可更换、传感器即插即用。

云端：AIDC 提供强算力后盾，助力算法模型能力快速提升

自动驾驶为什么需要 AIDC？


大算力能够处理大体量的回传数据，构建高精度模型训练壁垒，催化性能边界突破。当数据量较大时，需要大规模计算中心进行分布式并行训练，否则训练的耗时将无法接受。同时，大算力也足以支撑训练更精细的模型。依据特斯拉人工智能与自动驾驶视觉部门主管卡帕蒂，截至 2021 年 6 月，特斯拉需要对 60 亿个物体的距离、速度、加速度等进行标注，数据量高达 1.5PB。对于此类数据量大、神经网络参数高的模型进行训练，模型的高精度和高效率需要大规模云端超算中心提供算力支持。

此外，大模型路径是人工智能产业趋势，大模型迭代速度远高于硬件算力，催生大算力需求。近五年模型参数和复杂度近指数级增长，GPU 算力则远远滞后。依据 Percy Liang、李飞飞²等学术论文，计算机系统硬件是数据和大模型拓展的关键瓶颈。MIT 计算机科学家 Charles Leiserson 于《Science》发表的一篇文章³中指出深度学习正在逼近现有芯片的算力极限，目前计算能力提高 10 倍相当于三年的算法改进，因此随着算力持续提高，硬件成本、训练成本将越来越高。

² <https://arxiv.org/pdf/2108.07258.pdf>

³ <https://www.science.org/doi/10.1126/science.aam9744>

图表 52：GPU 迭代速度慢于模型参数迭代速度，催生更大算力需求




资料来源：《On the Opportunities and Risk of Foundation Models》(Rishi Bommasani, Drew A. Hudson 等, 2021)，中金公司研究部

从特斯拉 Dojo 超级计算机看自动驾驶 AIDC

Dojo 超级计算机核心解决数据交换的带宽和延迟痛点。据特斯拉芯片总工程师 Pete Bannon 于 2019 年的表述，自动驾驶需要至少 1TB/秒的带宽，FSD 芯片的 SRAM 能提供 2TB/秒，而 Dojo 创新性地设计了低延迟数据交换结构，对于每个 NOC Router 数据交换节点均加了四个方向 64bit 通道，其 D1 芯片内部带宽可达 10TB/秒，芯片外带宽也高达 4TB/秒，解决了特斯拉 AI 训练过程中的核心痛点。

图表 53：特斯拉 D1 芯片提供充足带宽，速度远快于 GPU



资料来源：特斯拉 AI Day，中金公司研究部

Dojo 采用自研的数据中心级 D1 芯片，为视频数据训练提供强劲性能支持。D1 芯片采用分布式结构和 7nm 工艺，单片 FP32 达到 22.6 TOPS 算力，可实现 50 万个训练节点无缝连接，变成超大规模计算阵列，得益于训练模块的独立运行能力和无限连接能力，由其组成的 Dojo 超级计算机的性能拓展在理论上无上限。从低精度算力支持来看，同成本下较 Fugaku 性能提高 5 倍，同能耗下性能提升 1.3 倍，占用空间降低 5 倍，能够支持特斯拉以软件定义自动驾驶，并通过 OTA 空中升级，革新程度超过传统燃油车的单次改款。从 FP32 算力（超算中心性能更常用衡量指标口径）来看，特斯拉 Dojo 排名世界第 5。

图表 54：全球主要超算中心排名（按 FP32 算力）

排名	名称	Rmax (TFlop/s)
1	Fugaku	442,010.0
2	Summit	148,600.0
3	Sierra	94,640.0
4	太湖之光	93,014.6
5	Dojo	67,800.0
6	Perlmutter	64,590.0

资料来源：CleanTechnica，中金公司研究部

注：数据截至 2021 年 6 月

特斯拉专注于神经网络优化的人工智能计算集群总算力达 1.1 EFLOPS，与谷歌、商汤同为当下第一梯队。谷歌于 2021 年 5 月发布新一代 ASIC 人工智能芯片 TPU v4，主要以 pod 形式应用，单个 pod 由 4,096 个 TPU v4 单芯片构成，可提供 1 EFLOP 的算力（对应每秒 10^{18} 次浮点运算）。截至 2021 年，商汤的超算集群可以提供 1.1 EFLOPS 算力（BF16，较低精度口径），临港 AIDC 建成后总算力超 4.8 EFLOPS。相比于谷歌、商汤的通用 AIDC，特斯拉的 Dojo 超级计算机则专注自动驾驶视频处理，可实现 1.1 EFLOPS 算力，以全球第一梯队实力支持自动驾驶大算力需求。

图表 55：特斯拉与谷歌 AI 超算中心

公司	建成时间	投资规模	算力
谷歌	2021年5月1日	-	推出新一代人工智能ASIC芯片TPU v4，主要与Pod相连发挥作用，每一个 TPU v4 Pod中有4096个TPU v4单芯片，能达到1 exaFLOP级的算力。
特斯拉	2021年6月1日	-	Dojo超级计算机使用特斯拉自研芯片及专门为神经网络优化涉及的计算机架构，浮点运算能力达1 exaFLOP/s。
商汤	预计2022年初	56亿人民币	截至2021年，商汤的超算集群可以提供1.1 EFLOPS算力，临港AIDC建成后总算力超4.8 EFLOPS。

资料来源：各公司官网，中金公司研究部

超算中心对于训练大模型、降低算法成本至关重要，巨头具备天然资本和技术优势。由于超算中心是支持大模型算力的关键，谷歌、特斯拉等巨头依托于资金优势，近几年大力投入 AIDC 基础设施建设，我们预测耗资十亿美元以上。对于自动驾驶，自研超算中心能实现高稳定性、低时延、大带宽、软硬件兼容性高等技术特点。新一代 AI 算法发展大背景下，Transformer 等大模型技术需要大算力技术平台做支撑，超算中心将会支持自动驾驶技术进入新阶段。

类似自有电商业务需求孕育了亚马逊、阿里巴巴等 CPU 时代云计算巨头，我们认为自动驾驶等 AI 巨头具备 GPU/ASIC 云计算市场的天然先发优势。相对于成熟的 x86 服务器市场，GPU 服务器规模仍较小，且 GPU 服务器目前阶段更多基于本地部署，基于 GPU 服务器的云计算市场仍处在发展初期阶段，且相关技术仍并未完全成熟，在大规模 GPU 并行计算的效率及稳定性等领域存在较多挑战，技术壁垒较高。回顾 CPU 时代云计算发展历史，正是自有业务的需求推动亚马逊、阿里巴巴等电商巨头前瞻地发展云计算相关技术，并在业务发展实践中不断打磨技术的效率及稳定性，从而形成先发优势。而 GPU/ASIC 时代底层技术变化较大，目前仍处在萌芽期，未来随着 GPU/ASIC 云计算市场持续发展，我们认为具备自有需求支撑的自动驾驶龙头、AI 龙头有望复制这一发展路径，在 GPU/ASIC 云计算市场发展占据先发优势。

作者信息



陈星宇

SAC 执证编号: S0080121020020
xingyu3.chen@cicc.com.cn



邓学

SAC 执证编号: S0080521010008
SFC CE Ref: BJV008
xue.deng@cicc.com.cn



于钟海

SAC 执证编号: S0080518070011
SFC CE Ref: BOP246
zhonghai.yu@cicc.com.cn



魏鹤霏

SAC 执证编号: S0080121070252
guanfei.wei@cicc.com.cn



CICC
中金公司

法律声明

一般声明

本报告由中国国际金融股份有限公司（已具备中国证监会批复的证券投资咨询业务资格）制作。本报告中的信息均来源于我们认为可靠的已公开资料，但中国国际金融股份有限公司及其关联机构（以下统称“中金公司”）对这些信息的准确性及完整性不作任何保证。本报告中的信息、意见等均仅供投资者参考之用，不构成对买卖任何证券或其他金融工具的出价或征价或提供任何投资决策建议的服务。该等信息、意见并未考虑到获取本报告人员的具体投资目的、财务状况以及特定需求，在任何时候均不构成对任何人的个人推荐或投资操作性建议。投资者应当对本报告中的信息和意见进行独立评估，自主审慎做出决策并自行承担风险。投资者在依据本报告涉及的内容进行任何决策前，应同时考量各自的投资目的、财务状况和特定需求，并就相关决策咨询专业顾问的意见对依据或者使用本报告所造成的一切后果，中金公司及/或其关联人员均不承担任何责任。

本报告所载的意见、评估及预测仅为本报告出具日的观点和判断，相关证券或金融工具的价格、价值及收益亦可能会波动。该等意见、评估及预测无需通知即可随时更改。在不同时期，中金公司可能会发出与本报告所载意见、评估及预测不一致的研究报告。

本报告署名分析师可能会不时与中金公司的客户、销售交易人员、其他业务人员或在本报告中针对可能对本报告所涉及的标的证券或其他金融工具的市场价格产生短期影响的催化剂或事件进行交易策略的讨论。这种短期影响的分析可能与分析师已发布的关于相关证券或其他金融工具的目标价、评级、估值、预测等观点相反或不一致，相关的交易策略不同于且也不影响分析师关于其所研究标的证券或其他金融工具的基本面评级或评分。

中金公司的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。中金公司没有将此意见及建议向报告所有接收者进行更新的义务。中金公司的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见不一致的投资决策。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现。过往的业绩表现亦不应作为日后回报的预示。我们不承诺也不保证，任何所预示的回报会得以实现。分析中所做的预测可能是基于相应的假设。任何假设的变化可能会显著地影响所预测的回报。

本报告提供给某接收人是基于该接收人被认为有能力独立评估投资风险并就投资决策能行使独立判断。投资的独立判断是指，投资决策是投资者自身基于对潜在投资的目标、需求、机会、风险、市场因素及其他投资考虑而独立做出的。

本报告由受香港证券和期货委员会监管的中国国际金融香港证券有限公司（“中金香港”）于香港提供。香港的投资者若有任何关于中金公司研究报告的问题请直接联系中金香港的销售交易代表。本报告作者所持香港证监会牌照的牌照编号已披露在报告首页的作者姓名旁。

本报告由受新加坡金融管理局监管的中国国际金融（新加坡）有限公司（“中金新加坡”）于新加坡向符合新加坡《证券期货法》定义下的认可投资者及/或机构投资者提供。提供本报告于此类投资者，有关财务顾问将无需根据新加坡之《财务顾问法》第 36 条就任何利益及/或其代表就任何证券利益进行披露。有关本报告之任何查询，在新加坡获得本报告的人员可联系中金新加坡销售交易代表。

本报告由受金融服务监管局监管的中国国际金融（英国）有限公司（“中金英国”）于英国提供。本报告有关的投资和服务仅向符合《2000 年金融服务和市场法 2005 年（金融推介）令》第 19（5）条、38 条、47 条以及 49 条规定的人士提供。本报告并未打算提供给零售客户使用。在其他欧洲经济区国家，本报告向被其本国认定为专业投资者（或相当性质）的人士提供。

本报告由中国国际金融日本株式会社（“中金日本”）于日本提供，中金日本是在日本关东财务局（日本关东财务局长（金商）第 3235 号）注册并受日本法律监管的金融机构。本报告有关的投资和服务仅向符合日本《金融商品交易法》第 2 条 31 项所规定的专业投资者提供。本报告并未打算提供给日本非专业投资者使用。

本报告将依据其他国家或地区的法律法规和监管要求于该国家或地区提供。

特别声明

在法律许可的情况下，中金公司可能与本报告中提及公司正在建立或争取建立业务关系或服务关系。因此，投资者应当考虑到中金公司及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。

与本报告所含具体公司相关的披露信息请访 <https://research.cicc.com/footer/disclosures>，亦可参见近期已发布的关于该等公司的具体研究报告。

中金研究基本评级体系说明：

分析师采用相对评级体系，股票评级分为跑赢行业、中性、跑输行业（定义见下文）。

除了股票评级外，中金公司对覆盖行业的未来市场表现提供行业评级观点，行业评级分为超配、标配、低配（定义见下文）。

我们在此提醒您，中金公司对研究覆盖的股票不提供买入、卖出评级。跑赢行业、跑输行业不等同于买入、卖出。投资者应仔细阅读中金公司研究报告中的所有评级定义。请投资者仔细阅读研究报告全文，以获取比较完整的观点与信息，不应仅仅依靠评级来推断结论。在任何情形下，评级（或研究观点）都不应被视为或作为投资建议。投资者买卖证券或其他金融产品的决定应基于自身实际具体情况（比如当前的持仓结构）及其他需要考虑的因素。

股票评级定义：

- 跑赢行业（OUTPERFORM）：未来 6~12 个月，分析师预计个股表现超过同期其所属的中金行业指数；
- 中性（NEUTRAL）：未来 6~12 个月，分析师预计个股表现与同期其所属的中金行业指数相比持平；
- 跑输行业（UNDERPERFORM）：未来 6~12 个月，分析师预计个股表现不及同期其所属的中金行业指数。

行业评级定义：

- 超配（OVERWEIGHT）：未来 6~12 个月，分析师预计某行业会跑赢大盘 10%以上；
- 标配（EQUAL-WEIGHT）：未来 6~12 个月，分析师预计某行业表现与大盘的关系在-10%与 10%之间；
- 低配（UNDERWEIGHT）：未来 6~12 个月，分析师预计某行业会跑输大盘 10%以上。

研究报告评级分布可从<https://research.cicc.com/footer/disclosures> 获悉。

本报告的版权仅为中金公司所有，未经书面许可任何机构和个人不得以任何形式转发、翻版、复制、刊登、发表或引用。

V190624
编辑：樊荣



北京

中国国际金融股份有限公司
中国北京建国门外大街 1 号
国贸写字楼 2 座 28 层
邮编: 100004
电话: (86-10) 6505 1166
传真: (86-10) 6505 1156

深圳

中国国际金融股份有限公司深圳分公司
深圳市福田区益田路 5033 号
平安金融中心 72 层
邮编: 518048
电话: (86-755) 8319-5000
传真: (86-755) 8319-9229

东京

中国国际金融日本株式会社
〒100-0005 東京都千代田区丸の内 3 丁目 2 番 3 号
丸の内二重橋ビル 2 1 階
Tel: (+813) 3201 6388
Fax: (+813) 3201 6389

纽约

CICC US Securities, Inc
32nd Floor, 280 Park Avenue
New York, NY 10017, USA
Tel: (+1-646) 7948 800
Fax: (+1-646) 7948 801

伦敦

China International Capital Corporation (UK)
Limited
25th Floor, 125 Old Broad Street
London EC2N 1AR, United Kingdom
Tel: (+44-20) 7367 5718
Fax: (+44-20) 7367 5719

上海

中国国际金融股份有限公司上海分公司
上海市浦东新区陆家嘴环路 1233 号
汇亚大厦 32 层
邮编: 200120
电话: (86-21) 5879-6226
传真: (86-21) 5888-8976

香港

中国国际金融（香港）有限公司
香港中环港景街 1 号
国际金融中心第一期 29 楼
电话: (852) 2872-2000
传真: (852) 2872-2100

旧金山

CICC US Securities, Inc. San Francisco Branch
Office
One Embarcadero Center, Suite 2350,
San Francisco, CA 94111, USA
Tel: (+1) 415 493 4120
Fax: (+1) 628 203 8514

新加坡

China International Capital Corporation
(Singapore) Pte. Limited
6 Battery Road, #33-01
Singapore 049909
Tel: (+65) 6572 1999
Fax: (+65) 6327 1278

法兰克福

China International Capital Corporation (Europe)
GmbH
Neue Mainzer Straße 52-58, 60311
Frankfurt a.M, Germany
Tel: (+49-69) 24437 3560