

人工智能十年展望（十二）：详解大模型时代的基础软件堆栈 AI Infra



韩蕊 分析员

SAC 执证编号: S0080523070010
rui.han@cicc.com.cn


于钟海 分析员

SAC 执证编号: S0080518070011
SFC CE Ref: BOP246
zhonghai.yu@cicc.com.cn

胡安琪 联系人

SAC 执证编号: S0080122070070
anqi.hu@cicc.com.cn

纵轴：相对值（%）



中金一级行业：科技

资料来源：Wind，彭博资讯，中金公司研究部

- 软件及服务 | 数智中国之海外数据库技术峰会速递：LLM相关进展备受瞩目，Data+AI持续演绎（2023.07.16）
- 软件及服务 | AI Answer：大模型助力B端落地先行范式（2023.06.18）
- 软件及服务 | 人工智能十年展望（八）：探索ChatGPT根基——数据与人工智能如何相互成就？（2023.04.03）
- 软件及服务 | 人工智能十年展望（六）：ChatGPT兴起，创成式AI能否重塑工具软件底层逻辑？（2023.03.02）
- 软件及服务 | 人工智能十年展望（五）：从ChatGPT到通用智能，新长征上的新变化（2023.02.02）

更多作者及其他信息请见文末披露页

观点聚焦

投资建议

类比计算机系统的基础软件层以及云计算三层架构的PaaS层级，我们认为，AI产业链中也有层级相似，定位于算力与应用之间的“桥梁”角色的基础软件设施层即AI Infra。新一轮生成式AI浪潮，对于上层应用而言机遇与挑战并存，而AI Infra作为必要的基础设施，我们认为其技术及商业发展前景的确定性或更强。本文我们聚焦AI Infra，揭示其内涵并总结目前国内项目的商业化进展，再从 workflow 视角详细梳理各环节及代表厂商。我们认为，AI Infra是AI产业必不可少的基础软件堆栈，“掘金卖铲”逻辑强、商业潜质高，建议投资者持续关注AI Infra相关投资机会。

理由

在预训练大模型时代，我们可以从应用落地过程里提炼出标准化的工作流，AI Infra的投资机会得以演绎。传统ML时代AI模型通用性较低，项目落地停留在“手工作坊”阶段，流程难以统一规范。而大规模预训练模型统一了“从0到1”的技术路径，具备解决问题的泛化能力，能够赋能“从1到100”的各类应用，并存在相对标准化的工作流，由此衍生出AI Infra投资机会。GPT 4 的开发经验也体现专业分工的必要性：根据OpenAI 的披露，在GPT 4 的开发过程中，其对 249 人研发团队进行了明确分工，并使用了数据标注、分布式计算框架、实验管理等点工具。我们认为这也说明了在大模型时代应用基础软件的必要性。目前，AI Infra产业处于高速增长的发展早期，我们预计未来 3-5 年内各细分赛道空间或保持 30%+ 的高速增长，且各方向均有变现实践与养成独角兽企业的潜力。

“AI = Data + Code”，组织AI所需的养料即数据，管理AI模型的训练部署过程，以及支持从模型到应用的整合是AI Infra工具的关键能力。1) 数据准备：无论是支持经典的机器学习模型还是大规模预训练模型，数据准备都是耗时较长、较为关键的一环。我们认为，LLM浪潮下高质量的标注数据和特征库需求将持续增长，未来海量训练数据的需求或由合成数据满足。此外，我们强调Data+AI平台厂商的关键卡位。2) 模型训练：预训练模型的获取使得模型库更加流行，LLM大规模训练需求也驱动底层分布式计算引擎和训练框架的迭代。此外，我们认为实验管理工具重要性较高。3) 模型部署：LLM模型端的突破释放出大规模应用落地的潜能，更多模型从实验走向生产环境，我们认为有望整体提振模型部署和监控的需求。4) 应用整合：LLM赋能应用催生对向量数据库和应用编排工具等的新需求。我们观察到经典的机器学习时代与大模型时代工具栈需求侧重点有所不同，同时，部分点工具正在拓宽产品功能边界，LLMOps平台型产品的可及市场空间天花板或更高。

风险

技术进展不及预期、应用落地不及预期、行业竞争加剧。

目录

初见：AI Infra 是连接算力和应用的 AI 中间层基础设施.....	5
类比基础软件和 PaaS，AI Infra 是 AI 时代的中间层基础设施	5
大模型通用性赋能下应用落地流程更加标准化，催生 AI Infra 投资机会	5
从 OpenAI 实践看分工必要性，核心关注 workflow 相关的基础软件工具栈.....	7
商业化起步中，已有变现实践，细分赛道或均有长出独角兽的潜力.....	9
探秘：从 workflow 视角梳理 AI Infra 投资机会.....	11
大模型时代和传统机器学习时代工具栈侧重点有所不同.....	11
数据准备：高质量标注数据、特征库需求持续，合成数据或成未来趋势	12
模型训练：模型库更加刚需，训练框架持续迭代，软件工具协助实验管理.....	15
模型部署：更多模型从实验走向真实业务环境，部署和监控需求提升	17
应用整合：催生向量数据库和应用编排框架新需求.....	19
点工具不断拓宽产品边界，LLMOps 一站式解决方案或更适应国内市场	21
求索：海外重点项目及公司一览（Scale、Hugging Face、Weight & Biases、Pinecone、Databricks、C3.AI）	22
国内 AI Infra 相关厂商巡礼	27
风险.....	33

图表

图表 1：一图详解大模型时代的基础软件堆栈——AI Infra	4
图表 2：AI Infra 是人工智能时代连接硬件和上层应用的中间层基础设施.....	5
图表 3：LLM 流行前的 AI 项目开发流程繁琐、通用性低，涉及数据和训练评估环节的多次循环难以标准化	6
图表 4：具有泛化能力的通用大规模预训练模型赋能下，后续 workflow 较为标准化，衍生出 AI Infra 投资机会	6
图表 5：Open AI《GPT-4 Technical Report》中披露的人员分工明确	7
图表 6：OpenAI 使用了 Scale 标注服务	7
图表 7：OpenAI 使用了分布式计算框架 Ray	7
图表 8：AI Infra 全景图	8
图表 9：AI Infra 细分赛道市场规模	9
图表 10：AI Infra 各赛道代表公司的商业模式一览.....	10
图表 11：从 workflow 视角梳理，大模型时代和传统 ML 时代工具栈侧重点有所不同.....	11
图表 12：高质量标注数据在 GPT 模型训练中起重要作用	12
图表 13：数据标注厂商正在寻求通过模型自动化提高效率.....	13
图表 14：特征库是生产、管理、运营 ML 过程中所需数据及特征的系统.....	13
图表 15：Instruct-Pix2Pix 借助 GPT-3、Stable Diffusion 生成指令-图像训练数据集.....	14
图表 16：Gartner 预测到 2030 年 AI 模型使用的绝大部分训练数据将是合成的	14
图表 17：Hugging Face 上托管了 NLP、机器视觉等各类模型.....	15
图表 18：Ray 产品文档中提供的一种生成式 AI 的常见训练框架	16
图表 19：以 Neptune 为例，记录每次实验的元数据，支持多实验结果对比.....	17
图表 20：Seldon 支持的单一模型、复杂多模型的推理过程示意	18
图表 21：以 WhyLabs 为例看模型可观测性在 workflow 中的具体环节定位	18
图表 22：向量数据库和 LLM 的具体交互过程	19

图表 23: Prompt Template 对输入改写	20
图表 24: 连接多个 Prompt Template 及搜索、数据库	20
图表 25: Agent 判断使用工具流程	20
图表 26: Entity Memory 提供长期上下文记忆能力	20
图表 27: AI Infra 领域独角兽企业一览	21
图表 28: Scale AI 的产品布局一览和企业级生成式 AI 平台方案	22
图表 29: Hugging Face 可以托管共享 ML 模型、数据集, 也可以构建、训练和部署模型	23
图表 30: W&B 产品拥有十大功能模块, 覆盖机器学习全流程	24
图表 31: Pinecone 承担大模型记忆“海马体”的角色	25
图表 32: Lakehouse AI 旨在给客户提供一个完整的生成式 AI 赋能应用的开发解决方案	26
图表 33: 顺应 LLM 趋势, 推出了 C3 生成式 AI 产品套件	26
图表 34: 基于星环产品栈的企业自有大模型应用构建流程示意图	27
图表 35: 机器学习平台 HyperCycle 的三个子产品	28
图表 36: 第四范式“式说”产品工作界面	28
图表 37: 云知声山海大模型能力概览	29
图表 38: 创新奇智 AI 技术栈	30
图表 39: 汉得 AIGC 中台产品架构	31
图表 40: 万达信息的 AI 落地战略	31



图表 1：一图详解大模型时代的基础软件堆栈——AI Infra



注：图中市场规模数据为我们在正文图表 9 相关资料来源基础上估算得到的约数；图中灰色文本框为我们的观点

资料来源：Grand View Research, Foresight News, Gartner, MarketsandMarkets, 拾象科技, Firstmark, a16z, 各公司官网, 中金公司研究部

初见：AI Infra 是连接算力和应用的 AI 中间层基础设施

本章主要讨论：1) AI Infra 在 AI 时代 IT 生态中的定位；2) 为什么大模型浪潮下需要格外关注 AI Infra 投资机会；3) AI Infra 基础软件工具栈涵盖内容；4) AI Infra 商业化初探。

类比基础软件和 PaaS，AI Infra 是 AI 时代的中间层基础设施

从类比的角度理解 AI Infra：AI 时代连接硬件和上层应用的中间层基础设施。传统本地部署时代，三大基础软件（数据库、操作系统、中间件）实现控制硬件交互、存储管理数据、网络通信调度等共性功能，抽象并隔绝底层硬件系统的复杂性，让上层应用开发者能够专注于业务逻辑和应用功能本身的创新实现。云时代同理，形成了 IaaS、PaaS、SaaS 三层架构，其中 PaaS 层提供应用开发环境和基础的数据分析管理服务。类比来看，我们认为，进入 AI 时代也有承担类似功能的、连接算力和应用的基础设施中间层即 AI Infra，提供基础模型服务、赋能模型微调和应用开发。

图表 2：AI Infra 是人工智能时代连接硬件和上层应用的中间层基础设施




资料来源：中金公司研究部

大模型通用性赋能下应用落地流程更加标准化，催生 AI Infra 投资机会

LLM 流行前，AI 模型通用性较低，项目落地停留在“手工作坊”阶段，流程难以统一规范。人工智能已有数十年的发展历史，尤其是 2006 年以来以深度学习为代表的训练方法的成熟推动第三波发展浪潮。然而，由于传统的机器学习模型没有泛化能力，大部分 AI 应用落地以定制化项目的形式，包括需求、数据、算法设计、训练评估、部署和运维等阶段，其中，数据和训练评估阶段往往需要多次循环，较难形成一套标准化的端到端的流程和解决方案，也由此造成了边际成本高、重复造轮子等问题。


图表 3：LLM 流行前的 AI 项目开发流程繁琐、通用性低，涉及数据和训练评估环节的多次循环难以标准化



资料来源：极市平台公众号，中金公司研究部

大规模预训练模型完成了“从 0 到 1”的技术统一，泛化能力和通用性释放出“从 1 到 100”的落地需求，且存在相对标准化的流程，衍生出 AI Infra 投资机会。基于 Transformer 算法、超大参数量的预训练模型拥有泛化能力，一定程度上解决了原先需要按项目定制训练的问题，过去正因为 ML 模型的非标和项目制，下游需求并未被完全激发出来，LLM 模型端的突破释放出更大规模的应用落地潜能。而后续的应用过程中主要涉及：高质量样本数据的准备、基础模型获取、模型微调及部署监控、应用编排开发上线等环节，工作流较为标准化，我们建议投资者持续关注 AI Infra 投资机会。

图表 4：具有泛化能力的通用大规模预训练模型赋能下，后续工作流较为标准化，衍生出 AI Infra 投资机会



资料来源：中金公司研究部

从 OpenAI 实践看分工必要性，核心关注 workflow 相关的基础软件工具栈


参考海外 OpenAI 的率先尝试，workflow 分工、点工具加持助力成功。一方面，OpenAI 在《GPT-4 Technical Report》论文中¹中披露了参与 GPT 4 开发的人员分工，共 249 人，角色分工明确，预训练、强化学习和对齐、部署等 6 个大方向下又拆分成不同小组，其中数据集/数据基础设施、分布式训练基础设施、推理基础设施等分别对应 workflow 中的数据准备、模型训练、部署应用等环节；另一方面，OpenAI 使用了 Scale 数据标注服务、Ray 分布式计算框架和 Weights and Biases (W&B) 实验管理工具，且 W&B 的创立灵感就来自于其创始人之一在 OpenAI 的实习经历。我们认为，OpenAI 的率先尝试经验一定程度上说明专业分工和 AI Infra 基础软件堆栈在大模型时代的必要性。

图表 5：Open AI《GPT-4 Technical Report》中披露的人员分工明确

数据准备	模型训练	模型部署、应用
Dataset contributions¹¹ Diogo Almeida, Mo Bavarian, Juan Felipe Cerón Uribe, Tyna Eloundou, Liam Fedus, Taro Gogineni, Rapha Gontijo-Lopes, Jonathan Gordon, Joost Huizinga, Sharan Jain, Roger Jiang, Lukasz Kaiser, Christina Kim, Jan Leike, Chak Ming Li, Stephanie Lin, Ryan Lowe, Jacob Menick, Luke Metz, Pamela Mishkin, Tong Mu, Oleg Murk, Ashvin Nair, Long Ouyang, Alex Passos, Michael (Rai) Pokorny, Vitchyr Pong, Shihani Santurkar, Daniel Selsam, Sarah Shoker, Carroll Wainwright, Matt Wiethoff, Jeff Wu, Kai Xiao, Kevin Yu, Marvin Zhang, Chong Zhang, William Zhuk, Barret Zoph Data infrastructure¹¹ Irwan Bello, Lenny Bogdonoff, Juan Felipe Cerón Uribe, Joshua Gross, Sharan Jain, Haozhun Jin, Christina Kitt, Aris Konstantinidis, Teddy Lee, David Medina, Jacob Menick, Luke Metz, Ashvin Nair, Long Ouyang, Michael (Rai) Pokorny, Vitchyr Pong, John Schulman, Jonathan Ward, Jiayi Weng, Matt Wiethoff, Sarah Yoo, Kevin Yu, Wojciech Zaremba, William Zhuk, Barret Zoph	Training run babysitting¹¹ Suchir Balaji, Mo Bavarian, Greg Brockman, Trevor Cai, Chris Hesse, Shantanu Jain, Roger Jiang, Yongjik Kim, Kyle Kosic, Mateusz Litwin, Jakub Pachocki, Alex Paino, Mikhail Pavlov, Michael Petrov, Nick Ryder, Szymon Sidor, Nikolas Tezak, Madeleine Thompson, Phil Tillet, Amin Tootoonchian, Chelsea Voss, Ben Wang, Tao Xu, Qiming Yuan Distributed training infrastructure¹¹ Greg Brockman, Trevor Cai, Chris Hesse, Shantanu Jain, Yongjik Kim, Kyle Kosic, Mateusz Litwin, Jakub Pachocki, Mikhail Pavlov, Szymon Sidor, Nikolas Tezak, Madeleine Thompson, Amin Tootoonchian, Qiming Yuan	GPT-4 API & ChatML deployment¹¹ Greg Brockman, Brooke Chan, Chester Cho, Atty Eleti, Rachel Lim, Andrew Peng, Michelle Pokrass, Sherwin Wu GPT-4 web experience¹¹ Valerie Balcom, Lenny Bogdonoff, Jason Chen, Dave Cummings, Noah Deutsch, Mike Heaton, Paul McMillan, Rajeev Nayak, Joel Parish, Adam Perelman, Eric Sigler, Nick Turley, Arun Vijayvergiya, Chelsea Voss Inference infrastructure¹¹ Brooke Chan, Scott Gray, Chris Hallacy, Kenny Hsu, Tomer Kaftan, Rachel Lim, Henrique Ponde de Oliveira Pinto, Raul Puri, Heather Schmidt, Felipe Petroski Such


资料来源：《GPT-4 Technical Report》(OpenAI, 2022)，中金公司研究部

图表 6：OpenAI 使用了 Scale 标注服务



资料来源：Scale 官网，中金公司研究部

图表 7：OpenAI 使用了分布式计算框架 Ray



资料来源：AnyScale 官网，中金公司研究部

¹ <https://arxiv.org/pdf/2303.08774.pdf> 《GPT-4 Technical Report》(OpenAI, 2022)

AI Infra 广义上包含了基础模型和基础软件栈两层，本篇报告核心关注其中和工作流相关的基础软件工具栈。工作流的视角下，LLM 的开发应用主要涉及数据准备、模型训练、模型部署、产品整合四个主要环节，每个环节都有对应的点工具，亦有集大成的 LLMops 平台型产品，我们将在下一章详细解读。

图表 8：AI Infra 全景图



资料来源：a16z 官网，拾象科技公众号，中金公司研究部

商业化起步中，已有变现实践，细分赛道或均有长出独角兽的潜力

商业化起步阶段，有望在未来几年快速成长为百亿美元量级的产业。我们认为，AI Infra 整体处于高速增长的发展早期，如图表 9 的整理，根据第三方数据，目前大部分细分赛道规模在几亿至几十亿美元量级，我们预计在未来 3-5 年内或将保持 30+% 的高速增长。同时，Data+AI、MLOps/LLMOps 等平台型产品的市场空间天花板可能更高，我们也观察到点工具厂商正在积极拓展产品边界。我们认为，AI Infra 是 AI 时代不可或缺的基础设施中间层，“掘金卖铲”逻辑的确定性高，有望持续受益于 LLM、AI 应用的繁荣。

图表 9：AI Infra 细分赛道市场规模

工作流	细分赛道	市场规模
数据准备	数据标注	根据Grand View Research 和 Research Nester 数据，2022 年全球数据注释工具市场规模达8亿美元，其预计到2035年底市场规模140亿美元，2023-2035年CAGR达到27% 根据观研报告网数据，国内2022年数据标注市场规模超过50亿元，其预计到2029年市场规模将超过200亿元
	特征库	开源项目如Feast，商业化公司如Tecton按使用量收费，数据和特征的质量决定了机器学习的上限，我们认为高质量特征库的需求将持续受益，同时国内数据要素市场的蓬勃发展长期看有望进一步推动市场规模增长
	合成数据	根据Cognilytica数据，目前合成数据市场刚起步，在小几亿美元量级，其预计2022-2027年将保持50+%的复合增长，同时根据Epoch AI Research的研究，高质量语言数据可能在2026年耗尽，我们认为届时合成数据市场有望进一步加速增长
	Data+AI平台	若以大数据相关软件市场整体衡量，沙利文预计2023年全球市场规模接近300亿美元、中国市场规模接近400亿元
模型训练	模型库	卡位关键，切入下游MLOps领域探索变现，比如Hugging Face提供AutoTrain（用户仅需定义创建任务并上传数据，系统自动选择模型并训练）、应用测试、模型推理功能，根据使用的硬件资源收费，还推出了个人和企业版会员，其中企业版平台整合了获取模型、实验、训练、应用上线等流程和功能。
	计算和训练框架	基础框架大多开源，也有商业化公司如AnyScale会提供Ray的商业版平台产品
	实验管理	Foresight News预计全球模型实验管理市场在2027年达到43亿美元
模型部署	模型部署	较多开源项目如BentoML、OctoML、Seldon core，另外模型训练框架一般也提供配套的模型部署模块。有商业化公司如Seldon提供开源项目的商业版产品；或提供Serving服务，打包IaaS资源一起收费
	模型监控	Gartner预计2023年整体IT系统全球可观测性市场将达到165亿美元，我们认为随着更多LLM模型落地部署到实际应用中，模型可观测性市场亦有望快速增长、在整体规模中的占比有望提升
应用整合	向量数据库	MarketsandMarkets预计2026 年全球向量数据库市场规模达到25亿美元
	应用编排	开源框架为主如LangChain、LlamaIndex、Fixie等，商业化仍在探索
平台型	MLOps/LLMOps	根据Allied Market Research，2021 年，全球 MLOPS 市场规模接近10亿美元，其预计到 2031 年将达到231亿美元，2022-2031年复合年增长率为37.5%

资料来源：Grand View Research, Foresight News, Gartner, MarketsandMarkets, Cognilytica, 沙利文, Allied Market Research, Research Nester, 中金公司研究部

海外厂商积极探索变现，细分赛道或均有长出独角兽的潜力。从微观的视角，我们整理了 AI Infra 各细分赛道海外代表公司的商业模式，基本遵循按使用量付费的定价模式。大多数创业公司成立时间较短，详见图表 10，目前收入体量在数千万至小几亿美元量级，其中数据相关的、平台型的厂商起步较早、已初具规模，我们认为这也符合数据需要前置于 AI 模型投入、平台型厂商收入天花板更高的逻辑。此外，我们认为 LLM 模型端突破将释放出更大规模应用落地的潜能，有望带动模型部署、应用整合等后续环节的逐步起量。

图 10：AI Infra 各赛道代表公司的商业模式一览

AI Infra代表公司的商业化进程						
对应流程	细分市场	代表厂商	成立年份	商业化策略	收入水平	估值水平
数据准备	数据标注	Scale AI	2016	按标注量计价，比如Scale Image起价为每张图片2美分、每条标注6美分；Scale Text 起价为每项任务5美分、每条标注3美分；此外也有针对enterprise 的打包收费	预计当前年化收入近3亿美元	73亿美元
	特征库	Tecton	2020	基于使用量收费，平均客单价可达15万美金	预计当前年化收入超过1千万美元	9亿美元
	合成数据	gretel	2020	基础费用+使用量收费；小团队（限制10个并行工作流），295美元/月基础费用，2.2美元/credit，1 credit = 5分钟API运行；企业单独议价	-	3.5亿美元
	Data+AI平台	Databricks	2013	按计算量收费，DBU（Databricks Unit）*单价，DBU主要由计算的数据量、复杂度和要求速度决定，单价由负载类型、订阅类型决定；另外需要额外支付IaaS部分费用	截至2022年下半年ARR已超过10亿美元	380亿美元
模型训练	模型库	Hugging Face	2016	AutoTrain 是 Hugging Face 当前的主要收入来源，根据时间和计算资源计费；此外还有模型推理服务，按照租用CPU/GPU使用量收费；正在尝试就模型库收取个人/企业会员费	-	20亿美元（或正在以40亿美元估值进行下一轮融资）
	计算和训练框架	AnyScale	2019	提供开源分布式计算框架Ray的商业版	-	10亿美元
	实验管理	Weight & Biases	2017	根据模型训练时间收费，针对10人以下的小团队，小于250小时免费；250-5,000个小时，50美元/月/用户；5,000-10,000个小时，100美元/月/用户；10,000-15,000个小时，150美元/月/用户	预计2023年ARR超过1亿美元	10亿美元
模型部署	模型部署	OctoML	2019	按使用量和GPU性能收费，Small: 0.4美元/小时（T4 GPU、16GB内存），Medium: 1.15美元/小时（A10G GPU、24GB内存），Large: 5.2美元/小时（A100 GPU、80GB内存）	-	8.5亿美元
	模型监控	Arize AI	2019	免费版限制2个模型、每个模型500K的预测结果；pro版本100美元/月，限制2个模型、每个模型10M的预测结果；企业版报价另询	-	最近一次融资3,800万美元
应用整合	向量数据库	Pinecone	2019	基于数据存储量和计算资源使用时长，存储量每个月每 GB 定价在0.025 美元，计算使用量则是每小时 0.1 - 1 美元不等	-	7.5亿美元
	应用编排	Langchain	2022	暂不明确	-	2亿美元
平台型	MLOps/LLMOps	Dataiku	2013	Free Edition、Discover、Business、Enterprise四大版本，付费版本分别适合小/中/大团队，定价另询	预计当前年化收入近3亿美元	37亿美元

注：估值取最近一次公开融资披露数据，统计截至 2023 年 7 月；收入水平中，Scale AI、Tecton、Dataiku 为 Growjo 网站预测，Databricks 来自公司官网披露，Weight&Biases 为海外独角兽公众号预计
资料来源：各公司官网，海外独角兽公众号，Growjo，中金公司研究部


探秘：从 workflow 视角梳理 AI Infra 投资机会

大模型时代和传统机器学习时代工具栈侧重点有所不同

本章从企业训练模型、构建 AI 赋能应用的工作流视角出发，详解涉及的主要环节，并关注 LLMops 和 MLOps 在流程上的侧重点差异。我们认为 $AI = Data + Code$ ，历经数据准备、模型训练、模型部署、产品整合，分环节看：

- **数据准备：高质量标注数据、特征库需求持续，合成数据或成未来趋势。**数据准备无论在传统的 MLOps 还是 LLMops 中都是耗时较长、较为重要的一环。无监督学习降低对标注数据的需求，但 RLHF 机制体现了高质量标注数据的重要性，我们认为未来超大参数量模型对海量训练数据的需求或由合成数据满足。此外，Data+AI 平台厂商卡位关键。
- **模型训练：模型库更加刚需，训练框架持续迭代，软件工具协助实验管理。**基于通用的 LLM 大模型微调、蒸馏出小模型成为高性价比的落地方式，因此需要能够高效便捷地获取预训练模型的模型库；也催生更适应 LLM 大规模训练需求的底层分布式计算引擎和训练框架。此外，我们认为实验管理工具的重要性或始终较高。
- **模型部署：更多模型从实验走向真实业务环境，部署和监控需求提升。**我们认为，LLM 模型端的突破释放出大规模应用落地的潜能，更多的模型从实验环境走向生产环境，有望整体提振模型部署和监控的需求。
- **应用整合：催生向量数据库和应用编排框架新需求。**LLM 赋能应用催生出对应用产品整合相关工具产品的需求，其中较为关键的是向量数据库和应用编排工具。

图表 11：从 workflow 视角梳理，大模型时代和传统 ML 时代工具栈侧重点有所不同




资料来源：拾象科技，Firstmark，a16z 官网，中金公司研究部

数据准备：高质量标注数据、特征库需求持续，合成数据或成未来趋势

数据是模型的起点，一定程度上决定了模型的效果和质量，数据准备无论在传统的 MLOps 还是 LLM Ops 中都是耗时较久、较为重要的一环。LLM 带来的新变化主要包括：1) 虽然 LLM 的无监督学习机制降低了对标注数据的需求，但 OpenAI 的 RLHF (Reinforcement Learning from Human Feedback) 体现了高质量标注数据重要性；2) 模型规模大幅提升，带来日益增长的训练数据需求，长期看可能无法仅通过真实世界数据满足，合成数据提供一种 AIGC 反哺 AI 的解法。此外，数据基础管理软件平台的卡位始终关键，Data+AI 平台化趋势持续演进。

数据标注：GPT 的成功说明了高质量标注数据对提升模型效果的重要性。数据标注位于模型开发的最上游，对图像、视频、文本、音频等非结构化原始数据添加标签，为 AI 提供人类先验知识的输入。近年，无监督学习（事先不定义明确目的）、强化学习（通过奖励函数来指导学习过程）等不需要标注数据的机器学习分支方法论的出现引发市场对于数据标注必要性的讨论与担忧。不过，OpenAI 通过 RLHF 即基于人类反馈的强化学习来优化模型，且从 OpenAI2 披露的分工中能看到有很多负责预训练、强化学习等的 AI 科学家也参与到数据准备中；最新开源的 LLAMA 2 的论文³中也有一段强调高质量数据对模型训练结果影响的表述，Meta 与第三方供应商合作收集了近 3 万个高质量标注，又向市场证明了高质量数据标注工作的重要性。

图表 12：高质量标注数据在 GPT 模型训练中起重要作用



资料来源：《Training language models to follow instructions with human feedback》(OpenAI, 2022)，中金公司研究部


数据标注厂商正在寻求智能化转型、减少对人力的依赖。在数据标注助力 AI 快速发展的同时，AI 也将反哺数据标注更加自动化、智能化，如利用模型进行数据预处理再人工审核等。今年 4 月 Meta AI 发布的 Segment Anything Model⁴的训练数据集 SA-1B，就是通过智能数据引擎来辅助自动化生成的，该数据引擎经历了辅助手动标注-半自动标注-自动化标注的训练过程。数据标注领域代表公司包括 Scale、Snorkel、Sugar.AI、海天瑞声等，也在寻求通过模型自动化提高效率。

² <https://arxiv.org/pdf/2303.08774.pdf> 《GPT-4 Technical Report》(OpenAI, 2022)

³ <https://ai.meta.com/research/publications/llama-2-open-foundation-and-fine-tuned-chat-models/>

⁴ <https://arxiv.org/pdf/2304.02643.pdf> 《Segment Anything》(Alexander Kirillov 等, 2023)


图表 13：数据标注厂商正在寻求通过模型自动化提高效率



资料来源：Snorkel 公司官网，中金公司研究部

特征库（Feature Store）：高质量特征库持续受益。特征是预测模型的输入信号，可以简单理解为模型中的自变量 X ，需要经过特征工程从原始数据中筛选得到。而特征库则是生产、管理、运营 ML 过程中所需数据及特征的系统，主要实现 1）运行各类数据管道（Pipeline）将原始数据转换为特征值；2）存储和管理特征和数据；3）为训练和推理提供一致的特征服务。目前该领域的代表性产品包括：开源项目如 Feast，独立商业化公司如 Tecton，大型科技厂商的 ML 平台如 Databricks、SageMaker 等中亦有相应模块。数据和特征的质量决定了机器学习的上限，我们认为高质量特征库有望持续受益，同时国内数据要素市场的蓬勃发展长期看有望为 AI 模型供应更多高质量的数据燃料。

图表 14：特征库是生产、管理、运营 ML 过程中所需数据及特征的系统



资料来源：Tecton 官网产品文档，中金公司研究部

合成数据：做真实数据的“平替”，用 AIGC 反哺 AI。一项来自 Epoch AI Research 团队的研究预测存量的高质量语言数据将在 2026 年耗尽⁵，低质量的语言和图像数据存量也将在未来的数十年间枯竭。面对潜在的数据瓶颈，合成数据即运用计算机模拟生成的人造数据，提供了一种成本低、具有多样性、规避了潜在隐私安全风险的解决方法，生成式 AI 的逐渐成熟进一步提供技术支撑。比如，自然语言修改图片的 Instruct-Pix2Pix 模型在训练的时候就用到 GPT3 和 Stable Diffusion 来合成需要的提示词和图像的配对数据集；Amazon 也利用合成数据来训练智能助手 Alexa⁶，以避免用户隐私问题。合成数据市场参与者较多，独立公司/项目如 gretel、MOSTLY AI、datagen、hazy 等，数据标注厂商如 Scale 亦推出相关产品，此外主流科技公司英伟达、微软、亚马逊等均有不同场景的尝试。


图表 15：Instruct-Pix2Pix 借助 GPT-3、Stable Diffusion 生成指令-图像训练数据集



资料来源：《InstructPix2Pix: Learning to Follow Image Editing Instructions》(Tim Brooks 等, 2022), 中金公司研究部

图表 16：Gartner 预测到 2030 年 AI 模型使用的绝大部分训练数据将是合成的

By 2030, Synthetic Data Will Completely Overshadow Real Data in AI Models



资料来源：Gartner, 中金公司研究部

⁵ 《Will we run out of data? An analysis of the limits of scaling datasets in Machine Learning》(Pablo Villalobos 等, 2022); <https://arxiv.org/pdf/2211.04325.pdf>

⁶ <https://www.statice.ai/post/types-synthetic-data-examples-real-life-examples>


数据科学基础平台：数据卡位始终关键，Data+AI 是行业趋势。广义的数据科学涵盖利用各类工具、算法理解数据蕴藏含义的全过程，机器学习可以视为其中的一种方式 and 手段；狭义的数据科学也可以仅指代机器学习的前置步骤，包括准备、预处理数据并进行探索性分析等。正如我们从报告《[人工智能十年展望（八）：探索 ChatGPT 根基——数据与人工智能如何相互成就？](#)》开始一直强调的观点，数据和 AI 一体两翼，数据是模型的起点、且一定程度上决定了模型的最终效果和质量，数据基础设施厂商卡位关键，从 Data 向 AI 布局是技术能力和业务逻辑的自然延伸。LLM 等大模型的渗透发展不仅额外增加了数据平台上 AI 相关的工作流负载，还可以带动底层 Data 基础设施的需求。积极布局 AI 的数据科学基础平台厂商包括 Databricks、Snowflake、星环科技、MongoDB 等。

模型训练：模型库更加刚需，训练框架持续迭代，软件工具协助实验管理

大模型具有一定通用性，开发者们可以“站在巨人的肩膀上”，在预训练模型的基础上通过少量增量训练蒸馏出专精的小模型以解决垂类场景的需求。LLM 带来的新变化主要包括：1）要想高效便捷地获取模型，则需要一个集成托管各类模型的社区也即**模型库**；2）催生更适应 LLM 大规模训练需求的底层**分布式计算引擎和训练框架**。此外，模型训练过程涉及多次往复的修改迭代，无论是 ML 还是 LLM 都需要借助**实验管理工具**进行版本控制和协作管理。

模型库（Model Hub）：把握从数据到模型的工作流入口。模型库顾名思义是一个托管、共享了大量开源模型的平台社区，供开发者下载各类预训练模型，除模型外，主流的 Model Hub 平台上还同时提供各类共享的数据集、应用程序 Demo 等，是 AI、ML 细分领域的“GitHub”。典型代表厂商包括海外的 Hugging Face、Replicate，国内关注 Gitee（开源中国推出的代码托管平台）和 ModelScope（阿里达摩院推出的 AI 开源模型社区）等项目。在商业模型上，Model Hub 厂商一般选择切入下游的 AutoTrain（自动创建、优化、评估模型）或模型推理服务，也在尝试就 Model Hub 功能收取订阅制会员费用。


图表 17：Hugging Face 上托管了 NLP、机器视觉等各类模型



资料来源：Hugging Face 官网，中金公司研究部

分布式计算和深度学习框架：大模型“炼丹炉”。分布式计算引擎方面，LLM 的训练过程需要大规模的 GPU 分布式计算集群，过去大数据已带动了以 MapReduce、Spark 为代表的分布式计算引擎的发展，但以 Ray 为代表的近年在 AI 大潮下兴起的分布式计算框架则更贴合 AI 需求（Ray 的首篇论文名为《Ray: A Distributed Framework for Emerging AI Applications⁷》，其核心模块 Ray Tune、Ray Rllib、Ray Train 分别对应机器学习调参、强化、深度学习调参的流程。Ray 在官网的用户案例中表示“Ray 是使 OpenAI 能够增强其训练 ChatGPT 和类似模型能力的关键”⁸。此外，Ray 作为更底层的分布式计算引擎，和 TensorFlow、PyTorch 等深度学习框架兼容，而 DeepSpeed、ColossalAI 等则是在 PyTorch 等基础框架之上针对 LLM 的优化训练设计的新一代框架。

图表 18：Ray 产品文档中提供的一种生成式 AI 的常见训练框架




资料来源：Ray 官网产品文档，中金公司研究部

实验管理：记录实验元数据，辅助版本控制，保障结果可复现。模型训练是一种实验科学，需要反复的修改与迭代，同时由于无法提前预知实验结果往往还涉及版本回溯、多次往复，因此模型的版本控制和管理就较为必要，实验管理软件可以辅助技术人员和团队追踪模型版本、检验模型性能。该领域代表厂商为 Weights and Biases (W&B) 和 Neptune，跟踪机器学习实验，记录实验元数据，包括训练使用数据集、框架、进度、结果等，支持以可视化的形式展现结果、多实验结果对比、团队协作共享等。此外，实验管理也是 LLMops/MLOps 平台型产品如星环科技 Sophon、Google Vertex AI 等产品中的重要模块之一。

⁷ <https://arxiv.org/pdf/1712.05889.pdf> 《Ray: A Distributed Framework for Emerging AI Applications》(Philipp Moritz 等, 2018)

⁸ <https://docs.ray.io/en/releases-2.4.0/ray-overview/use-cases.html>

图 19：以 Neptune 为例，记录每次实验的元数据，支持多实验结果对比




资料来源：Neptune 官网，中金公司研究部

模型部署：更多模型从实验走向真实业务环境，部署和监控需求提升

模型部署是让模型从实验环境走向真实生产环境的重要环节，借助**模型部署**工具能够解决模型框架兼容性差的问题并提升模型运行速度。**模型监控**通过对模型输出结果和性能指标的追踪，保障模型上线后的可用性。我们认为，过去由于 ML 模型的非标和项目制，大规模、持续性的模型部署和监控需求未被完全激发出来，LLM 模型端的突破释放出大规模应用落地的潜能，**更多的模型从实验环境走向生产环境，我们认为有望整体提振模型部署和监控的需求。**

模型部署：从实验走向生产的重要环节。模型部署指把训练好的模型在特定环境中运行，需要尽量最大化资源利用效率，保证用户使用端的高性能。模型部署领域参与者较多，比如 Ray、Tensorflow、PyTorch 等训练框架都提供配套的模型部署功能，模型库厂商如 Hugging Face、实验管理厂商如 W&B 也有相关产品，此外还有如 Seldon、BentoML、OctoML 等独立项目/产品。和训练框架自带的部署模块相比，三方的综合性产品能够为不同框架下训练出来的模型提供一套相对统一的部署方式。以 Seldon 为例，在复杂的多模型推理场景下，Seldon 通过模型可解释性、异常值检测等模块，最终选出表现最好的模型进行结果反馈。


图表 20: Seldon 支持的单一模型、复杂多模型的推理过程示意



资料来源: Seldon 官网产品文档, 中金公司研究部

模型监控: 模型可观测性保障可靠可用。可观测性在传统 IT 系统运维中就是重要的数智化手段之一, 通过监控各类机器、系统的运行数据对故障和异常值提前告警。模型监控同理, 监测模型上线后的数据流质量以及表现性能, 关注模型可解释性, 对故障进行根因分析, 预防数据漂移、模型幻觉等问题。模型可观测性领域有较多创业公司, 包括 Fiddler、WhyLabs、Evidently AI 等, 实验管理厂商如 W&B、模型部署厂商如 Seldon 也有所涉及, 此外, 传统的 IT 运维可观测性厂商也有机会切入 AI 模型监控领域, 海外如 Datadog 已经尝试将 Open AI 的模型服务加入纳管范畴, 我们也建议关注国内相关厂商如新炬网络等的后续进展。

图表 21: 以 WhyLabs 为例看模型可观测性在工作流中的具体环节定位



资料来源: WhyLabs 官网产品文档, 中金公司研究部


应用整合：催生向量数据库和应用编排框架新需求

正如前文提及，LLM 模型端的突破释放出更多应用落地的潜能，由此催生出对应用产品整合相关工具产品的需求，其中较为关键的是**向量数据库**和**LLM 应用编排工具**。

向量数据库：LLM 的外部知识库。让通用大模型具备专业知识主要有两种途径，一是通过微调将专有知识内化到 LLM 中；另一种则是利用向量数据库给 LLM 增加外部知识库，后者成本更低。向量数据库和 LLM 的具体交互过程为：用户首先将企业知识库的全量信息通过嵌入模型转化为向量后储存在向量数据库中，用户输入 prompt 时，先将其同样向量化，并在向量数据库中检索最为相关的内容，再将检索到的相关信息和初始 prompt 一起输入给 LLM 模型，以得到最终返回结果。

向量化技术本身已较为成熟，海外模型如 Word2Vec、FastText 等，国内中文 Embedding 模型有 MokaAI 开源的 M3E、IDEA CCNL⁹ 开源的二郎神系列。向量数据库厂商/产品主要包括 Pinecone、Zilliz、星环科技 Hippo 等，另外也有传统数据库、大数据平台厂商如 PGSQL、Databricks 通过增加向量查询引擎插件来实现支持。**我们认为，向量数据库是 AI Answers 类应用落地的刚需，同时本土厂商在中文 Embedding 方面可能更具优势。**

图表 22：向量数据库和 LLM 的具体交互过程




资料来源：Pinecone 官网，星环科技公众号，中金公司研究部

应用编排框架：LLM 应用“粘合剂”。LLM 应用编排框架是一个封装了各种大语言模型应用开发所需逻辑和工具的代码库，LangChain 是当下最流行的框架之一，还有 Anarchy、Dust、AutoGPT、LlamaIndex 等。初始化的大模型存在无法联网、无法调用其他 API、无法访问本地文件、对 Prompt 要求高、生成能力强但内容准确度无法保证等问题，应用编排框架提供了相应功能模块，帮助实现从 LLM 到最终应用的跨越。以 LangChain 为例，它主要包含以下几个模块：1) Prompt 实现指令的补全和优化；2) Chain 调用外部数据源、工具链；3) Agent 优化模块间的调用顺序和流程；4) Memory 增加上下文记忆。


⁹ 全称为 IDEA 研究院认知计算与自然语言研究中心

图表 23: Prompt Template 对输入改写




资料来源：海外独角兽公众号，中金公司研究部

图表 24: 连接多个 Prompt Template 及搜索、数据库




资料来源：海外独角兽公众号，中金公司研究部

图表 25: Agent 判断使用工具流程



资料来源：海外独角兽公众号，中金公司研究部

图表 26: Entity Memory 提供长期上下文记忆能力



资料来源：海外独角兽公众号，中金公司研究部

集成开发环境：交互式 Notebook 逐渐流行。在上述 AI 建模流程中，开发者需要处理大量代码编写、分析、编译、调试等工作，可以直接在对应环节或平台型产品的内置环境中进行，也可以使用专门的集成开发环境并调取所需功能。其中，Notebook 是一种交互式的开发环境，和传统的非交互式开发环境相比，Notebook 可以逐单元格（Cell）编写和运行程序，出现错误时，仅需调整并运行出现错误的单元格，大大提升开发效率，因此近年逐渐流行、深受数据科学家和算法工程师的喜爱，被广泛应用于 AI 算法开发训练领域。常见的 IDE 平台包括 PyCharm、Visual Studio Code、Jupyter Notebook 等，另外比如平台型厂商 Databricks 也推出了自己的 Notebook，星环科技 Sophon 也有内置开发环境。

点工具不断拓宽产品边界，LLMOps 一站式解决方案或更适应国内市场

点工具厂商正不断拓宽能力边界。前文我们详细介绍了模型训练、构建应用工作流涉及的主要环节及各环节点工具厂商，事实上，这些点工具厂商在强项环节之外亦不断拓宽产品能力边界，比如数据标注厂商 Scale AI 拓展合成数据业务并正在投入 LLMOps 领域的 Scale Spellbook（做一个基于大语言模型的开发者工具平台）；模型库厂商 Hugging face 切入 AutoTrain 和模型部署；实验管理厂商 W&B 切入模型部署和模型监控等。

MLOps/LLMOps 提供一站式平台解决方案，可及市场空间更大，多采取 Data+AI 一体化战略。除点工具外还有平台型的 MLOps/LLMOps 产品，基本涵盖了上述流程的主要环节，大型科技企业、数据基础软件厂商均参与其中，包括 Databricks 的 MLflow、亚马逊的 SageMaker、谷歌的 Vertex AI、星环科技的 Sophon 等，还有初创公司产品如 Dataiku、DataRobot 等。我们认为，基于整体数字化进程和软件付费意愿习惯判断，海外企业客户可能倾向于选取点工具自组工具栈，而国内客户可能倾向于一站式的解决方案。此外，从目前 AI Infra 领域独角兽的估值水平来看，平台型厂商多采取 Data+AI 一体化战略，起步较早、规模天花板更高。

图表 27：AI Infra 领域独角兽企业一览

	公司名称	成立时间	区域	产品简介	最新估值
	Databricks	2013	美国	以数据为中心的MLflow机器学习平台，引入Lakehouse等数据管理方式实现一体化模型管理	380亿美元
	Scale AI	2016	美国	为人工智能训练提供标注图像、激光雷达、地图数据等数据服务，数据标注领域龙头企业	73亿美元
	DataRobot	2012	美国	高度自动化、民主化的机器学习平台，使没有技术背景的人可以轻松获得准确的模型和预测结果	63亿美元
	Dataiku	2013	法国	致力于极致使用企业堆积的各类原始数据，并进行价值转化的智能数据顶尖公司	37亿美元
	Hugging Face	2016	美国	早期凭Transformer模型库受到关注，目前可托管共享各类ML模型，提供可视化面板的优化跟踪交互工具	20亿美元
	Weights&Biases	2017	美国	提供轻量级、可视化、互操作工具，帮助开发人员跟踪试验的深度学习平台	10亿美元
	Tecton	2020	美国	人工智能特征存储库鼻祖，实现了模型训练和推理之间的数据统一	10亿美元
	OctoML	2019	美国	使用机器学习来优化机器学习模型，便于多硬件适配部署	8.5亿美元
	星环科技	2013	中国	涵盖计算智能、知识图谱、边缘计算的人工智能平台Sophon，提供百种分布式算法、多模态、隐私计算能力	135亿元

注：统计截至 2023 年 7 月，最新估值截至各公司最近一次融资
资料来源：Crunchbase，中金公司研究部

求索：海外重点项目及公司一览（Scale、Hugging Face、Weight & Biases、Pinecone、Databricks、C3.AI）


数据准备：Scale

创始人抓住 AI 行业对数据不够重视的机会。Scale 由两位年轻华人 Alexandr Wang 和 Lucy Guo 创建，他们意识到 AI 需要更多优质数据但当时却没有专注于提供标准化工具或基础设施的厂商，因此在 2016 年 6 月创办了 Scale。截至 2021 年 4 月完成的融资，公司估值达到 73 亿美元，另外 Growth 网站最新预测公司年化收入接近 3 亿美元。

数据标注是核心业务，AI 辅助或能降低人工参与比例。Scale 从自动驾驶领域的标注起家，自动驾驶之后，公司的订单还来自政府、电商、机器人、大模型（RLHF）等领域，对应着过去几年 AI 行业的趋势。目前公司支持地图、商品目录、图像、视频、文档、音频等各类数据的标注，按标注量计价，比如 Scale Image 起价为每张图片 2 美分、每条标注 6 美分。数据标注产业较为依赖人力，但公司也在训练标注算法通过 AI 辅助降低人工参与比例。Open AI、Stability、Co:here 等领先的生成式 AI 厂商均为公司客户。

积极布局 LLMOps 领域，推出企业级生成式 AI 平台产品。顺应大模型趋势，Scale 推出了 LLMOps 应用开发平台工具 Scale Spellbook，用户仅需上传数据、编辑指令，并可以直接比较、微调不同 prompt、不同 LLM 的效果，快速构建智能问答、总结、生成、分类等功能的 LLM 应用。结合数据标注和 LLMOps 能力，Scale 能提供一整套企业 AI 应用开发解决方案。

图表 28：Scale AI 的产品布局一览和企业级生成式 AI 平台方案




资料来源：Scale 官网，中金公司研究部

模型训练：Hugging Face

Hugging Face 是当前最流行的 AI/ML 社区平台之一。LLM 浪潮下，Hugging Face 凭借高质量的 Transformers 模型库和社区受到关注。用户可以在 Hugging Face 上托管和共享 ML 模型、数据集、应用程序 Demo，也可以直接基于平台构建、训练和部署模型。截至 7 月底，Hugging Face 上有超过 26 万个预训练模型，是 ML 领域的“Github”，超过 5 千家机构正在使用。

Hugging Face 卡位关键，切入下游 MLOps 探索变现。商业化层面，Hugging Face 推出了个人和企业会员，个人会员每月 9 美元，在推理 API 和 AutoTrain 功能上享有优先级；企业版收费 20 美元/月/用户，覆盖整合了模型实验、自动训练、应用测试、最终上线部署等功能环节，同时提供更多企业级安全方面的支持。此外，AutoTrain（用户仅需定义创建任务并上传数据，系统自动选择模型并训练）、应用测试、模型推理功能亦支持单独根据使用的硬件资源按用量收费。

图表 29：Hugging Face 可以托管共享 ML 模型、数据集，也可以构建、训练和部署模型



资料来源：Hugging Face 官网，中金公司研究部

模型训练&部署：Weight & Biases

Weights & Biases 成立于 2017 年，从实验管理到 MLOps 全生命周期。W&B 创立灵感来源于创始人在 OpenAI 的一次实习经历，初衷是希望研发一款方便 AI/ML 团队协同的工具。因此 W&B 从模型实验管理环节起家，并延伸及对数据准备、模型训练和模型部署全生命周期的管理，为技术人员提供追踪模型版本、检验模型性能的功能，帮助其选择最优版本的模型进行上线。官网最新显示，目前其平台产品包含 10 大功能模块，在实验追踪、协作可视化、模型版本管理、超参调节基础功能之外，新增了 ML 工作流自动化、模型监控、LLM 提示词工程、ML 应用开发环境等。

W&B 支持云和本地化部署，从定价看，Personal 方案免费，只对个人用户开放；Starter 方案针对 10 人以下的小团队，按照模型训练时间范围收取每用户每月 50-150 美元不等的费用；Enterprise 方案针对 10 人以上的公司、定制化报价。作为 MLOps 模型管理赛道中的翘楚，公司受益于大模型发展红利高速增长，OpenAI、DeepMind 等都是其客户。公司于 2021 年 10 月完成 C 轮融资，融资 1.35 亿美元，估值超过 10 亿美元。

图表 30：W&B 产品拥有十大功能模块，覆盖机器学习全流程




资料来源：Weights & Biases 官网，中金公司研究部

应用整合：Pinecone

商业化向量数据库的领先实践。Pinecone 的 CEO Edo Liberty 曾在 AWS 领导 Sagemaker 产品，而后担任亚马逊 AI Lab 的负责人。在亚马逊期间，Edo 观察到很多公司运用 ML 的难点不在于训练或部署模型，而在于实时处理海量的向量数据，由此萌生创业念头。2021 年初 Pinecone 公司正式成立。Pinecone 在成立之初就确立了闭源商业化的运营思路，按照存储 0.025 美元每个月每 GB，计算每小时 0.1 - 1 美元不等收费。目前 Pinecone 是海外最流行的向量数据库之一，我们观察到在大多数 ML 工作流上下游厂商官网的适配名单中都有 Pinecone 的身影，在海外逐渐形成了“OpenAI+Pinecone”的 AI 应用开发技术栈共识。

图表 31：Pinecone 承担大模型记忆“海马体”的角色



资料来源：Pinecone 官网，中金公司研究部


Data+AI: Databricks

Databricks 提供全球领先的数据科学计算分析平台，强调以数据为中心的机器学习模式。

Databricks 是 Spark 官方发行版的开发公司，提供一体化的数据湖仓平台产品，实现对海量结构及非结构化数据的存储、分析，并重视平台对数据科学、机器学习等 AI 相关工作流的支持，直接提供 Machine Learning 平台产品，涵盖数据准备、模型训练到模型投入生产的全流程，此外，Databricks 还在 2018 年开发并开源了 MLOps 工具链项目 MLflow，也是其 ML 平台的重要能力组件之一。

今年 6 月底召开的峰会上发布多项 Data+AI 技术进展。1) 生成式 AI 相关进展主要集中在自然语言交互、AI 应用开发工具链两方面：Databricks 发布 SDK for Spark、LakehouseIQ，实现开发、查询、检索等场景的自然语言交互；发布 Lakehouse AI 旨在更高效便捷地组织 AI 应用开发工作流。2) 数据管理平台基础能力亦持续迭代：Databricks 发布 UniForm 存储格式与 Hudi、Iceberg 互通等。自研之外，Databricks 亦通过收购扩大能力圈，近期 AI 相关交易频繁。更详细的技术解析请见《[数智中国之海外数据库技术峰会速递：LLM 相关进展备受瞩目，Data+AI 持续演绎](#)》。

图表 32: Lakehouse AI 旨在给客户id提供一套完整的生成式 AI 赋能应用的开发解决方案




资料来源: Databricks 官网, 中金公司研究部

企业级解决方案: C3.AI

C3 AI 是领先的企业 AI 解决方案提供商。 C3 AI 平台赋能企业从数据、模型到应用的全流程开发, 更高效、经济、安全地构建企业级 AI 应用, 覆盖制造、电力、政府、医疗、金融等下游行业场景。顺应 LLM 趋势, 推出了 C3 生成式 AI 产品套件, 将语义理解、生成式 AI、智能检索模型和强化学习等方面的最新创新实践与 C3 AI 平台结合。

图表 33: 顺应 LLM 趋势, 推出了 C3 生成式 AI 产品套件




资料来源: C3.AI 官网, 中金公司研究部

国内 AI Infra 相关厂商巡礼

星环科技：Data+AI 平台型厂商

提供完整大模型工具链、发布向量数据库，助力企业打造垂类大模型、开发专属 AI 应用。今年 5 月底公司举办技术峰会，并发布了多项 Data+AI 产品进展。Sophon LLMOps 是在公司原有的 Sophon MLOps 平台基础之上，针对大语言模型及其衍生数据、模型、应用问题进行相应功能增强后的大模型开发运维一站式工具链，赋能企业客户微调垂类领域专属大模型。同时，星环推出自研的企业级分布式向量数据库 Hippo，支持存储、索引、管理海量向量式数据集，为大模型补充实时、变化、专有领域的知识信息并能解决输入 token 数量有限的问题，拓展大模型的时间和空间维度，赋能企业客户构建基于大模型的个性化应用。

图表 34：基于星环产品栈的企业自有大模型应用构建流程示意图



资料来源：WAIC 大会，星环科技公众号，中金公司研究部

除工具外，星环计划推出两个自研行业垂类大模型：1）金融大模型“无涯”，发布百亿及千亿参数两个版本，使用公告、新闻、政策等语料二次训练，能构建包括政策、舆情、风险、量价、产业链在内的六类因子库；2）大数据分析大模型“求索”，具备大数据行业需求理解、推理、各类（含多模型）结构化查询语言和 OpenCypher 代码生成、文本生成、嵌入向量生成、知识推理等能力。

第四范式（未上市）：人工智能解决方案供应商，发布企业级类 GPT 产品

第四范式致力于为企业提供以平台为中心的 AI 解决方案。授人以鱼不如授人以渔，除了提供 AI 业务应用之外，第四范式为企业自行机器学习模型开发场景提供了企业级 AI 操作系统 4Paradiagm AIOS 和人工智能机器学习平台 HyperCycle。4Paradiagm AIOS 拥有面向 AI 时代的“数据治理”、“资源管理”和“应用管理”三方面核心能力；HyperCycle 中包含 ML 模块，覆盖机器学习从模型构建到应用全流程，集成了全流程的 AutoML 能力，降低开发门槛、提高落地效率。

图表 35：机器学习平台 HyperCycle 的三个子产品



资料来源：第四范式官网，中金公司研究部

LLM 趋势下推出企业级类 GPT 产品“式说”，助力企业利用内部知识解决问题。第四范式通过将类 GPT 语言模型与垂直领域知识进行融合，推出“式说”产品，旨在解决大型生成式语言模型在企业内部使用场景下的局限，满足企业场景下的 AIGC 需求。“式说”主打三大产品特点：1) 数据安全，通过私有化部署解决企业客户对数据安全的顾虑；2) 内容可信，“式说”基于企业内部数据库，并且在提供回答时标注信息原始出处，增加了回答的可信性和可靠性；3) 成本可控，“式说”算力成本相对可控，对数据标注量的需求较小。

图表 36：第四范式“式说”产品工作界面



资料来源：第四范式公司官网，中金公司研究部

云知声（未上市）：发布山海大模型，赋能医疗等垂类场景

山海大模型发布，模型兼具通用能力与行业落地能力。云知声成立于 2012 年，是中国 AGI 技术产业化的先驱之一，2016 年开始建立 Atlas 人工智能基础设施，并据此开发了拥有 600 亿个参数的专有大模型山海大模型，于 2023 年 5 月正式发布。山海大模型通用能力包括语言生成、语言理解、知识问答、推理能力、数学能力、代码能力和安全合规能力；落地能力包括插件扩展、领域增强和企业定制，并支持企业私有化部署。

山海大模型可以从多个场景进行赋能，医疗是标杆赛道。云知声选择的垂类包括智慧医疗（手术记录撰写助手、门诊病历撰写助手）、商保智能理赔系统、云贝销售管理系统、山海知识管理系统（企业服务通用管理）、教育（山海 AI 口语）和智慧物联（智能物业管家，贴心生活助手），应用具备横向拓展性。

图表 37：云知声山海大模型能力概览



资料来源：云知声山海大模型发布会，中金公司研究部

九章云极（未上市）：机器学习平台供应商

九章云极定位人工智能基础软件供应商。九章云极成立于 2013 年，专注数据科学平台的研发，提供机器学习建模能力、自动机器学习(AutoML)能力和实时数据计算能力。目前其核心产品主要有 DataCanvas APS，是集数据准备、特征工程、算法实现、模型开发、模型发布、模型生产化管理于一体的机器学习平台；和 DataCanvas RT，支持分布式流数据实时处理，能够将多种数据流接入实时处理并分析，将 ETL、业务模型、机器学习、人工智能、可视化扩展到实时的大数据产品。

创新奇智：领先的“AI+制造”解决方案供应商，推出 AlnoGC

企业级 AI 解决方案供应商，专注于“AI+制造”领域。创新奇智致力于用前沿的人工智能技术为企业提供 AI 产品及解决方案，包括 AI 平台、算法、软件及 AI 赋能设备等。自研的“MMOC 人工智能技术平台”具有深度学习能力，支持自动化、低代码技术开发，以及“云、边、端”一体化部署交付，能端到端支持 AI 解决方案创新、研发和交付。同时，公司 2018 年成立以来聚焦于 AI+制造领域，根据 IDC 数据¹⁰，2022 年创新奇智位居中国工业数据智能市场领导者象限，连续 3 年位居中国第二大 AI 工业质检厂商。

创新奇智推出以工业预训练大模型为核心的 AIGC 引擎奇智孔明 AlnoGC。拥有内容生成、智能问答、多轮对话、推理能力、代码生成等多项能力，可以快速把 AIGC 的能力带到以制造业为主的垂类场景中。AlnoGC 具有：1) 适合工业场景的基础大模型；2) 完善的企业级 Fine Tune 机制和 Prompt 工程支持；3) 丰富的 API/SDK 和 MaaS 服务等产品特征。

图 38：创新奇智 AI 技术栈



资料来源：机器之心，中金公司研究部

汉得信息（未覆盖）：基于汉得融合中台 HZERO，发布 AIGC 中台

发布 AIGC 中台，打造汉得 AI 知识、智慧交互平台。汉得基于融合中台 HZERO，着手打造 AIGC 中台，预置“百模”对接和大量 AIGC 通用应用功能，并提供低代码 AIGC 应用编排工具。具体组件来看，构建 AIGC 中台-知识库组件，帮助企业更便捷地应用 AIGC 知识问答能力；提供智慧交互助手，预置语音、数据查询、业务处理等能力，提供一个企业“AI 助手”基础版本，降低在各业务场景下构筑 AIGC 应用的难度。

¹⁰ https://mp.weixin.qq.com/s/WYGs59rNYz-EgxQLupO_GQ

图表 39：汉得 AIGC 中台产品架构¹¹




资料来源：汉得信息官网，中金公司研究部

万达信息（未覆盖）：自研 AI 中台，和华为盘古合作打造行业垂类大模型

自研 AI 科技中台、参与制定 MLOps 能力成熟度模型。2022 年的人工智能大会上，公司发布了 AI 科技中台，提供 AI 模型训练和应用开发、部署、运维的全生命周期管理服务，构建了数据、算法、应用、服务的全链路 AI 闭环，旨在通过标准化支撑能力实现 AI 应用快速创新和应用落地。此外，公司还参与制定全国首个 AI 模型开发管理标准《人工智能研发运营一体化 (Model/MLOps) 能力成熟度模型》系列标准¹²。

面向智慧城市、医疗卫生等行业研发 AI 场景与平台，与华为盘古合作打造行业大模型。万达信息基于传统主政务信息化、医疗信息化等行业 know-how 结合 AI 能力，形成了数百项行业人工智能算法模型及多项 AI 解决方案与产品。此外，今年 7 月，公司与华为云签署合作协议¹³，成为盘古大模型生态合作伙伴，计划基于盘古大模型打造智慧城市、医疗健康垂类行业大模型，推动城市数字化转型。

图表 40：万达信息的 AI 落地战略



资料来源：万达信息公开电话会，中金公司研究部

¹¹ <https://www.hand-china.com/news/15915.html>

¹² <https://www.wondersgroup.com/05161643118326.html>

¹³ <https://www.wondersgroup.com/07101657518645.html>

软通动力（未覆盖）：天璇 MaaS 平台持续迭代，和百度、华为大模型合作

软通天璇 MaaS 平台迭代至 2.0 版本。软通天璇 2.0 是基于昇思 MindSpore 人工智能框架打造的包含大模型技术底座、行业大模型及管理、场景大模型应用以及大模型一站式运营服务、数据治理和安全服务五要素的 MaaS 平台。分为三个层级：在 L0 级（大模型技术底座），有升级的软通训推一体化平台并扩展大模型接入；在 L1 级（行业大模型及管理），基于产业服务需求打造软通动力行业模型管理平台（ISS Model Ops Platform），形成了软通动力应用开发平台（ISS Model Dev Tools）；在 L2 级（场景大模型应用），打造了软通动力场景 Plugin 应用服务平台（ISS Model Plugin Store），通过把法律、招聘等方面的积累和应用打包成 Plugin，为客户提供专业服务。

与百度、华为云达成战略签约，共筑大模型产业化落地。今年 7 月，软通动力和百度正式签订战略合作协议¹⁴，推动文心千帆大模型平台与软通天璇 2.0 MaaS 平台的互补优势，共建面向工业、能源、制造、金融等多行业、多领域的智能应用。同月，软通动力与华为云签约，成为盘古大模型的垂域模型标注训练、服务交付、应用解决方案和昇腾迁移领域的合作伙伴，并计划共同打造保险行业大模型。

海天瑞声（未覆盖）：国内领先的数据标注厂商

海天瑞声是国内领先的数据标注厂商。通过设计数据集结构、组织数据采集、对取得的原料数据进行加工，形成可供 AI 算法模型训练使用的专业数据集，并以软件形式向客户交付。公司所提供的训练数据涵盖智能语音、计算机视觉、自然语言等领域，服务于人机交互、智能家居、智能驾驶、智慧金融、智能安防等应用场景。公司公告披露，截至 2022 年底，公司客户累计数量 810 家，覆盖科技互联网、社交、IoT、智能驾驶、智慧金融、教育科研以及部分政企机构，包括阿里巴巴、腾讯、百度、科大讯飞、海康威视、字节跳动、微软、亚马逊、三星、中国科学院、清华大学等。

Gitee（未上市）：开源中国旗下代码托管及 DevOps 平台

开源中国旗下代码托管及 DevOps 平台。开源中国（Open Source China，OSC）是国内的一个开源技术社区，成立于 2008 年，官网数据显示目前 OSCHINA 有 600 万活跃开发者¹⁵。2013 年，OSCHINA 建立了代码托管与 DevOps 平台“码云 Gitee”，为广大开发者提供团队协作、源码托管、代码质量分析、代码评审、测试、CI/CD 与代码演示等功能，官网数据显示目前 Gitee 社区开发者超过 1,000 万，托管项目超过 2,500 万，汇聚几乎所有本土原创开源项目¹⁶，并于 2016 年推出企业版。

¹⁴ <https://mp.weixin.qq.com/s/h0lYFNptWHwhUhlVgZcy-Q>

¹⁵ <https://www.oschina.net/home/aboutosc>

¹⁶ <https://gitee.com/about-us>

风险

技术进展不及预期：人工智能作为前沿新兴技术，仍处于技术的快速发展期，其进展有一定的不确定性，若技术进展不及预期，可能导致产业化进展缓慢。

应用落地不及预期：应用及商业化落地是人工智能能否顺利走向下一阶段的关键点，若国内应用及商业化落地节奏不及预期，对人工智能的进展将带来负面影响。

行业竞争加剧：人工智能是产业的热点，未来商业价值显著，科技巨头、初创公司均在此领域布局，未来垂类及应用层的行业竞争可能会进一步加剧。



作者信息



韩蕊 分析员

SAC 执证编号: S0080523070010
rui.han@cicc.com.cn



于钟海 分析员

SAC 执证编号: S0080518070011
SFC CE Ref: BOP246
zhonghai.yu@cicc.com.cn



胡安琪 联系人

SAC 执证编号: S0080122070070
anqi.hu@cicc.com.cn



王之昊 分析员

SAC 执证编号: S0080522050001
SFC CE Ref: BSS168
zhihao3.wang@cicc.com.cn



魏鹄霏 分析员

SAC 执证编号: S0080523060019
SFC CE Ref: BSX734
guanfei.wei@cicc.com.cn



CICC
中金公司

法律声明

一般声明

本报告由中国国际金融股份有限公司（已具备中国证监会批复的证券投资咨询业务资格）制作。本报告中的信息均来源于我们认为可靠的已公开资料，但中国国际金融股份有限公司及其关联机构（以下统称“中金公司”）对这些信息的准确性及完整性不作任何保证。本报告中的信息、意见等均仅供投资者参考之用，不构成对买卖任何证券或其他金融工具的出价或征价或提供任何投资决策建议的服务。该等信息、意见并未考虑到获取本报告人员的具体投资目的、财务状况以及特定需求，在任何时候均不构成对任何人的个人推荐或投资操作性建议。投资者应当对本报告中的信息和意见进行独立评估，自主审慎做出决策并自行承担风险。投资者在依据本报告涉及的内容进行任何决策前，应同时考量各自的投资目的、财务状况和特定需求，并就相关决策咨询专业顾问的意见对依据或者使用本报告所造成的一切后果，中金公司及/或其关联人员均不承担任何责任。

本报告所载的意见、评估及预测仅为本报告出具日的观点和判断，相关证券或金融工具的价格、价值及收益亦可能会波动。该等意见、评估及预测无需通知即可随时更改。在不同时期，中金公司可能会发出与本报告所载意见、评估及预测不一致的研究报告。

本报告署名分析师可能会不时与中金公司的客户、销售交易人员、其他业务人员或在本报告中针对可能对本报告所涉及的标的证券或其他金融工具的市场价格产生短期影响的催化剂或事件进行交易策略的讨论。这种短期影响的分析可能与分析师已发布的关于相关证券或其他金融工具的目标价、评级、估值、预测等观点相反或不一致，相关的交易策略不同于且也不影响分析师关于其所研究标的证券或其他金融工具的基本面评级或评分。

中金公司的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。中金公司没有将此意见及建议向报告所有接收者进行更新的义务。中金公司的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见不一致的投资决策。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现。过往的业绩表现亦不应作为日后回报的预示。我们不承诺也不保证，任何所预示的回报会得以实现。分析中所做的预测可能是基于相应的假设。任何假设的变化可能会显著地影响所预测的回报。

本报告提供给某接收人是基于该接收人被认为有能力独立评估投资风险并就投资决策能行使独立判断。投资的独立判断是指，投资决策是投资者自身基于对潜在投资的目标、需求、机会、风险、市场因素及其他投资考虑而独立做出的。

本报告由受香港证券及期货事务监察委员会监管的中国国际金融香港证券有限公司（“中金香港”）于香港提供。香港的投资者若有任何关于中金公司研究报告的问题请直接联系中金香港的销售交易代表。本报告作者所持香港证监会牌照的牌照编号已披露在报告首页的作者姓名旁。

本报告由受新加坡金融管理局监管的中国国际金融（新加坡）有限公司（“中金新加坡”）于新加坡向符合新加坡《证券期货法》定义下的合格投资者及/或机构投资者提供。本报告无意也不应直接或间接地分发或传递给新加坡的任何其他人。提供本报告于合格投资者及/或机构投资者，有关财务顾问将无需根据新加坡之《财务顾问法》第 45 条就任何利益及/或其代表就任何证券利益进行披露。有关本报告之任何查询，在新加坡获得本报告的人员可联系中金新加坡持牌代表。

本报告由受金融行为监管局监管的中国国际金融（英国）有限公司（“中金英国”）于英国提供。本报告有关的投资和服务仅向符合《2000 年金融服务和市场法 2005 年（金融推介）令》第 19（5）条、38 条、47 条以及 49 条规定的人士提供。本报告并未打算提供给零售客户使用。在其他欧洲经济区国家，本报告向被其本国认定为专业投资者（或相当性质）的人士提供。

本报告由中国国际金融日本株式会社（“中金日本”）于日本提供，中金日本是在日本关东财务局（日本关东财务局长（金商）第 3235 号）注册并受日本法律监管的金融机构。本报告有关的投资产品和服务仅向符合日本《金融商品交易法》第 2 条 31 项所规定的专业投资者提供。本报告并未打算提供给日本非专业投资者使用。

本报告亦由中国国际金融股份有限公司向符合日本《金融商品交易法施行令》第 17 条第 3 款第 1 项及《金融商品交易法》第 58 条第 2 款但书前段所规定的日本金融机构提供。在该情形下，本报告有关的投资产品和服务仅向日本受监管的金融机构提供。

本报告将依据其他国家或地区的法律法规和监管要求于该国家或地区提供。

特别声明

在法律许可的情况下，中金公司可能与本报告中提及公司正在建立或争取建立业务关系或服务关系。因此，投资者应当考虑到中金公司及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。

与本报告所含具体公司相关的披露信息请访问 <https://research.cicc.com/footer/disclosures>，亦可参见近期已发布的关于该等公司的具体研究报告。

中金研究基本评级体系说明：

分析师采用相对评级体系，股票评级分为跑赢行业、中性、跑输行业（定义见下文）。

除了股票评级外，中金公司对覆盖行业的未来市场表现提供行业评级观点，行业评级分为超配、标配、低配（定义见下文）。

我们在此提醒您，中金公司对研究覆盖的股票不提供买入、卖出评级。跑赢行业、跑输行业不等同于买入、卖出。投资者应仔细阅读中金公司研究报告中的所有评级定义。请投资者仔细阅读研究报告全文，以获取比较完整的观点与信息，不应仅仅依靠评级来推断结论。在任何情形下，评级（或研究观点）都不应被视为或作为投资建议。投资者买卖证券或其他金融产品的决定应基于自身实际具体情况（比如当前的持仓结构）及其他需要考虑的因素。

股票评级定义：

- 跑赢行业（OUTPERFORM）：未来 6~12 个月，分析师预计个股表现超过同期其所属的中金行业指数；
- 中性（NEUTRAL）：未来 6~12 个月，分析师预计个股表现与同期其所属的中金行业指数相比持平；
- 跑输行业（UNDERPERFORM）：未来 6~12 个月，分析师预计个股表现不及同期其所属的中金行业指数。

行业评级定义：

- 超配（OVERWEIGHT）：未来 6~12 个月，分析师预计某行业会跑赢大盘 10%以上；
- 标配（EQUAL-WEIGHT）：未来 6~12 个月，分析师预计某行业表现与大盘的关系在-10%与 10%之间；
- 低配（UNDERWEIGHT）：未来 6~12 个月，分析师预计某行业会跑输大盘 10%以上。

研究报告评级分布可从<https://research.cicc.com/footer/disclosures> 获悉。

本报告的版权仅为中金公司所有，未经书面许可任何机构和个人不得以任何形式转发、翻版、复制、刊登、发表或引用。

V190624
编辑：张莹，赵静



更多中金研究，欢迎登录中金点睛

北京

中国国际金融股份有限公司
中国北京建国门外大街 1 号
国贸写字楼 2 座 28 层
邮编: 100004
电话: (86-10) 6505 1166
传真: (86-10) 6505 1156

深圳

中国国际金融股份有限公司深圳分公司
深圳市福田区益田路 5033 号
平安金融中心 72 层
邮编: 518048
电话: (86-755) 8319-5000
传真: (86-755) 8319-9229

东京

中国国际金融日本株式会社
〒100-0005 東京都千代田区丸の内 3 丁目 2 番 3 号
丸の内二重橋ビル 2 1 階
Tel: (+813) 3201 6388
Fax: (+813) 3201 6389

纽约

CICC US Securities, Inc
32nd Floor, 280 Park Avenue
New York, NY 10017, USA
Tel: (+1-646) 7948 800
Fax: (+1-646) 7948 801

伦敦

China International Capital Corporation (UK)
Limited
25th Floor, 125 Old Broad Street
London EC2N 1AR, United Kingdom
Tel: (+44-20) 7367 5718
Fax: (+44-20) 7367 5719

上海

中国国际金融股份有限公司上海分公司
上海市浦东新区陆家嘴环路 1233 号
汇亚大厦 32 层
邮编: 200120
电话: (86-21) 5879-6226
传真: (86-21) 5888-8976

香港

中国国际金融（香港）有限公司
香港中环港景街 1 号
国际金融中心第一期 29 楼
电话: (852) 2872-2000
传真: (852) 2872-2100

旧金山

CICC US Securities, Inc. San Francisco Branch
Office
One Embarcadero Center, Suite 2350,
San Francisco, CA 94111, USA
Tel: (+1) 415 493 4120
Fax: (+1) 628 203 8514

新加坡

China International Capital Corporation
(Singapore) Pte. Limited
6 Battery Road, #33-01
Singapore 049909
Tel: (+65) 6572 1999
Fax: (+65) 6327 1278

法兰克福

China International Capital Corporation (Europe)
GmbH
Neue Mainzer Straße 52-58, 60311
Frankfurt a.M, Germany
Tel: (+49-69) 24437 3560