

证券研究报告 2023.12.14

# 人工智能十年展望（十四）：从 Perplexity 看 AI+搜索的破局之道



于钟海 分析员

SAC 执证编号：S0080518070011  
SFC CE Ref: BOP246  
zhonghai.yu@cicc.com.cn


魏鹤霏 分析员

SAC 执证编号：S0080523060019  
SFC CE Ref: BSX734  
guanfei.wei@cicc.com.cn

王之昊 分析员

SAC 执证编号：S0080522050001  
SFC CE Ref: BSS168  
zhihao3.wang@cicc.com.cn

纵轴：相对值（%）



| 股票     | 股票   | 目标    | P/E (x) |       |
|--------|------|-------|---------|-------|
| 名称     | 评级   | 价格    | 2023E   | 2024E |
| 科大讯飞-A | 跑赢行业 | 70.00 | 245.7   | 189.3 |
| 中科达-A  | 跑赢行业 | 88.00 | 47.9    | 47.6  |
| 鼎捷软件-A | 跑赢行业 | 24.66 | 49.6    | 36.1  |
| 商汤-H   | 跑赢行业 | 2.00  | N.M.    | N.M.  |

中金一级行业：科技

资料来源：Wind，彭博资讯，中金公司研究部

- 软件及服务 | 人工智能十年展望（十三）：AI应用商业化的“成败之论”（2023.10.09）
- 软件及服务 | 人工智能十年展望（十二）：详解大模型时代的基础软件堆栈AI Infra（2023.08.08）
- 软件及服务 | 人工智能十年展望（十一）：LLM+工业，由业务支持走向核心生产设计（2023.07.14）
- 软件及服务 | AI Answer：大模型助力B端落地先行范式（2023.06.18）
- 软件及服务 | 人工智能十年展望（十）：AI+教育，大模型浪潮下的高景气赛道（2023.06.06）

更多作者及其他信息请见文末披露页

## 观点聚焦

### 投资建议

大模型（LLM）路线于 2023 年带来学术和产业界颠覆式变革，ChatGPT 等应用依托领先模型技术而建立先发优势。在产业趋势下，Perplexity 以“生成式+搜索”建立差异化优势。自 2023 年 2 月 1 日至 10 月 25 日，网页端的周度访问量由 275 万增加至 1,113 万，增长 3 倍，彰显 LLM+搜索引擎新业态的粘性和潜力。本文以 Perplexity 为例，对其技术原理、商业模式及未来展望进行探讨，以期作为国内搜索及 C 端生态演进借鉴参考。

### 理由

Perplexity 是 AI+搜索引擎的创新者和领先者，卡位 LLM+搜索引擎新业态。Perplexity 于 2022 年 8 月成立，公司创始人曾任职于 OpenAI，公司获 OpenAI、Meta 内部 AI 负责人等注资。Perplexity 基于 GPT-3.5 微调模型等通用智能生成能力及微软 Bing 搜索引擎构建，对比 ChatGPT 等生成式 AI 时效性更强、具备可溯源属性，对比谷歌等传统搜索引擎答案凝练、可实现上下文响应。我们认为，Perplexity 依托于 LLM+搜索的产品力、工程化能力、快速迭代能力在 To C 应用中突围。

检索增强生成成为核心技术，召回能力与响应速度树立差异化。检索增强生成技术（RAG）包含检索、生成两个环节。RAG 融合外部知识库与模型先验知识，外部知识库丰富且易于更新的数据有效弥补了大模型数据滞后、伴有幻觉的劣势。Perplexity 以 RAG 为基，在算法侧对检索系统的核心“召回”环节进行创新，召回率和精确度在同类产品中排名第一；在响应速度方面，Perplexity 采用自研推理堆栈 pplx-api，并在推理端使用 TensorRT-LLM 加速，延迟大幅降低；模型侧，公司对 GPT-3.5 进行微调，在降低成本的同时进一步提升响应速度。

展望未来，我们认为对话式搜索引擎新业态有望成长为主流生态，但竞争趋于多元化，场景和数据闭环为核心要素。需求侧，Perplexity 快速增长的用户数量验证了对话式搜索引擎的刚性需求，LLM+搜索的产品形态或将长期存在。供给侧，Perplexity 产品定位对标 New Bing、Bard，谷歌等互联网巨头具备数据和场景卡位优势，更易于实现 AI Agent 的场景闭环，竞争格局趋于多元化。但随着 Perplexity 社群、pplx-api 生态的逐步完善，我们认为独立第三方的开放生态也有望助力公司夯实自身壁垒。

### 盈利预测与估值

维持行业内覆盖公司的盈利预测、估值和目标价不变。

### 风险

商业化风险；数据闭环风险；行业竞争加剧风险。

## 目录

|                                     |           |
|-------------------------------------|-----------|
| <b>AI+搜索引擎，重塑知识发现新范式</b>            | <b>4</b>  |
| Perplexity: AI 对话式搜索引擎              | 4         |
| 公司定位: LLM+搜索引擎的新业态，生成与检索兼容并包        | 6         |
| 历史沿革: 2022 年成立即聚焦于 AI+搜索引擎，踏浪生成式变革  | 8         |
| 创始团队: 具备 AI 基因+搜索行业经验，获产业界名人注资      | 9         |
| <b>以检索增强生成技术为基，召回能力树立差异化</b>        | <b>11</b> |
| 技术原理: 以 RAG 为技术核心，召回与生成式 AI 优点兼容并包  | 11        |
| 技术优势: Perplexity 召回与响应速度领先，夯实差异化产品力 | 13        |
| <b>订阅制与 API 调用为商业模式之基，广告收入未来可期</b>  | <b>16</b> |
| 商业模式: 收入源于订阅付费和 API 调用，广告有望成为增长点    | 16        |
| 潜在方向: 自研大模型与内部搜索引擎或为未来探索方向          | 17        |
| <b>LLM+搜索引擎的模式探讨</b>                | <b>18</b> |
| 未来展望: 竞争多元化，Perplexity 有望通过生态夯实先发优势 | 18        |
| 风险探讨: AI 时代，产品形态与场景闭环为发展关键          | 19        |

## 图表

|                                        |    |
|----------------------------------------|----|
| 图表 1: Perplexity 用户搜索界面及回答             | 4  |
| 图表 2: ChatGPT 回答界面                     | 5  |
| 图表 3: 谷歌 Bard 回答界面                     | 5  |
| 图表 4: New Bing 回答界面                    | 5  |
| 图表 5: Perplexity 支持多个垂类领域搜索            | 5  |
| 图表 6: Perplexity APP 下载量（日度）           | 6  |
| 图表 7: 海外搜索网页端 AI 应用访问量（周度）             | 6  |
| 图表 8: Perplexity 与 ChatGPT、传统搜索引擎差异化定位 | 6  |
| 图表 9: Perplexity vs ChatGPT 及传统搜索引擎    | 7  |
| 图表 10: Perplexity 发展历程                 | 8  |
| 图表 11: Copilot 产品界面                    | 9  |
| 图表 12: Bird SQL 产品界面                   | 9  |
| 图表 13: Profile 产品界面                    | 9  |
| 图表 14: Perplexity Labs 产品界面            | 9  |
| 图表 15: Perplexity 创始人团队                | 10 |
| 图表 16: Perplexity 融资状况及投资者             | 10 |
| 图表 17: 传统搜索引擎、问答引擎与大模型技术对比             | 11 |
| 图表 18: 检索增强生成（RAG）技术原理                 | 11 |
| 图表 19: RAG 在开放域问答测试中成绩领先               | 12 |
| 图表 20: 生成任务和分类任务中各模型能力对比               | 12 |
| 图表 21: Perplexity 技术路径，“检索-召回-大模型推理”   | 13 |
| 图表 22: 传统搜索引擎技术路线                      | 13 |
| 图表 23: 生成式搜索引擎能力对比                     | 13 |
| 图表 24: Perplexity API 其他 API 的延迟对比     | 14 |

|                                                     |    |
|-----------------------------------------------------|----|
| 图表 25: GPT-3.5 微调模型性能大幅超过 GPT-3.5, 与 GPT-4 接近 ..... | 15 |
| 图表 26: GPT-3.5 微调模型将延迟减少 80%.....                   | 15 |
| 图表 27: GPT-3.5 微调模型大大降低推理成本 .....                   | 15 |
| 图表 28: Perplexity 商业模式 .....                        | 16 |
| 图表 29: 截至 12 月 10 日, API 调用定价情况.....                | 17 |
| 图表 30: Bing Search API 进行防御性提价 .....                | 17 |
| 图表 31: 调用 GPT-4 Turbo 及 GPT-3.5 微调模型的成本测算.....      | 17 |
| 图表 32: Perplexity 推出 Collections .....              | 18 |
| 图表 33: 谷歌搜索引擎商业模式 .....                             | 19 |
| 图表 34: 可比公司估值表 .....                                | 20 |



## AI+搜索引擎，重塑知识发现新范式

### Perplexity: AI 对话式搜索引擎


Perplexity 是大模型+搜索引擎的领先实践者，融合“生成”与“搜索”，相比于 ChatGPT 具备时效性强、支持溯源、支持垂类检索等特点。Perplexity 基于 GPT-3.5 或 GPT-4 的通用智能生成式能力，以及微软 Bing 搜索引擎构建。当用户输入 prompt 提问，Ask 会生成引用来源、回答内容以及其他相关问题，用户可以直接点击来源链接查看。Perplexity 与 ChatGPT 等大模型相比具备更强的时效性，与 Bard 等具备联网功能的对话机器人相比能够生成带有引用的答案支持用户溯源，与 New Bing 相比回答内容有用性突出。此外，Perplexity 在搜索时可以选择学术、写作、YouTube 等垂类领域，具备较强针对性。

图表 1：Perplexity 用户搜索界面及回答




资料来源：深思 SenseAI 公众号，中金公司研究部

图表 2：ChatGPT 回答界面




资料来源：深思 SenseAI 公众号，中金公司研究部

图表 3：谷歌 Bard 回答界面




资料来源：深思 SenseAI 公众号，中金公司研究部

图表 4：New Bing 回答界面



资料来源：新智元公众号，中金公司研究部


图表 5：Perplexity 支持多个垂类领域搜索



资料来源：深思 SenseAI 公众号，中金公司研究部


**周度访问量环比高增，用户基础持续扩张彰显高粘性和成长性。**Perplexity 成立于 2022 年 8 月，致力于开发基于 AI 能力的对话式搜索引擎，以优化用户发现和共享知识的方式。2022 年 12 月公司正式发布首个对话式搜索引擎 Ask，此后其用户规模不断扩大，在四个月内月活跃用户数达到 200 万。根据 Similar Web 数据，截至 2023 年 10 月 25 日，Perplexity APP 的日度下载量为 14,163 次；2023 年 2 月 1 日至 10 月 25 日，Perplexity 网页端的周度访问量由 275 万增加至 1,113 万，增长 3x；与同类别的 AI 搜索应用 YouChat 相比增长势头强劲。

图表 6：Perplexity APP 下载量（日度）



注：数据截至 2023 年 10 月 25 日  
资料来源：Similar Web，中金公司研究部

图表 7：海外搜索网页端 AI 应用访问量（周度）




注：数据截至 2023 年 10 月 25 日  
资料来源：Similar Web，中金公司研究部

## 公司定位：LLM+搜索引擎的新业态，生成与检索兼容并包

Perplexity 在 ChatGPT 与传统搜索引擎的基础上开发，兼具大模型的生成与推理能力，又囊括传统搜索引擎中内容的广度和时效性，是 AI 能力与搜索引擎的融合，定位与 New Bing 和 Bard 类似。搜索引擎具备搜索的实时性，但信息颗粒度以网页来衡量，未能实现搜索目的的“最后一公里”；而 ChatGPT 以生成式 LLM 为基础，实现了信息粒度的细化和融合，但实时性与幻觉<sup>1</sup>问题随之而来。Perplexity 定位于 LLM+搜索引擎的中间态，将二者优点相结合，侧重搜索体验的产品力而非基模型。

图表 8：Perplexity 与 ChatGPT、传统搜索引擎差异化定位



资料来源：公司官网，中金公司研究部

<sup>1</sup> 指模型生成的内容与现实世界事实或用户输入不一致的现象

- **Perplexity vs ChatGPT 具备以下核心优势：**（1）**信息时效性强：**ChatGPT 等大模型只包含训练时的数据和语料，后续信息无法及时更新。Perplexity 基于底层传统搜索引擎开发而得，具备时效性强的优点。（2）**易于溯源：**Perplexity 生成的每一句话都附有引用链接，在保证可靠性的同时便于用户溯源或深入研究。（3）**减轻幻觉：**Perplexity 检索内核及标示来源的方式大大降低了幻觉，没有查到相关内容时会主动表示，减少了大模型有时出现的“胡言乱语”的情况。
- **Perplexity vs Google 等传统搜索引擎具备以下核心优势：**（1）**页面简洁凝练：**输入一个问题时，传统搜索引擎呈现多个并列链接，其中穿插大量广告，而 Perplexity 会结合部分最相关的链接直接生成精炼答案。（2）**支持细分领域精细搜索：**Perplexity 支持用户选择学术、写作、YouTube 等垂类领域精确搜索，使结果更具针对性。（3）**上下文连贯响应：**类似于 ChatGPT，Perplexity 可以进行上下文响应，而传统搜索引擎却无法保证逻辑的延续性。（4）**问题拆解和追问能力：**基于大模型的理解能力，Perplexity 可以对用户提问逐步拆解并追问澄清，精确把控用户需求。（5）**反馈功能：**Perplexity 生成回答后，用户可以对其准确性进行反馈，以强化学习的反馈机制帮助其进一步提升模型准确性。
- **Perplexity vs Bard：**Bard 为基于 Gemini Pro 大模型的 AI 助手，产品形态与 ChatGPT 类似，但集成了谷歌搜索引擎，具备时效性。生成答案后，用户可点击下方“Google”按钮进行搜索，Bard 同时对 AI 生成的内容进行核查，分别标注有、无搜索结果支持的内容（此功能目前只支持英语），用户可点击链接进一步查看。Perplexity 对比 Bard 主要具备三点优势：（1）**易于溯源：**Bard 提供的链接为 Google 搜索到的相关信息，并不代表其答案由该链接总结生成，用户无法对生成答案直接进行溯源验证。（2）**幻觉较低：**生成式 AI 在 Bard 中发挥主要作用，需要外部信息时启动搜索功能，因此仍然具有幻觉。（3）**细分领域精细检索。**
- **Perplexity vs New Bing：**New Bing 定位于 AI 搜索产品，功能与 Perplexity 较为接近，但 Perplexity 具备以下优势：（1）**性能更加强大。**与 New Bing 相比 Perplexity 的生成速度和内容有用性更高，在第二章我们会对此进行详细说明。（2）**支持细分领域精细检索。**

**图表 9：Perplexity vs ChatGPT 及传统搜索引擎**

|             | 信息时效性           | 易于溯源 | 页面简洁 | 细分领域检索 | 上下文响应 | 反馈功能 | 精确可靠程度    |
|-------------|-----------------|------|------|--------|-------|------|-----------|
| Perplexity  | ✓               | ✓    | ✓    | ✓      | ✓     | ✓    | 相对较高      |
| ChatGPT     | 通过插件联网<br>保证时效性 | ×    | ✓    | ×      | ✓     | ✓    | 可能会出现幻觉   |
| 传统搜索引擎      | ✓               | ✓    | ×    | ×      | ×     | ×    | 对问题把控程度较低 |
| Google Bard | ✓               | ×    | ✓    | ×      | ✓     | ✓    | 可能会出现幻觉   |
| New Bing    | ✓               | ✓    | ✓    | ×      | ✓     | ✓    | 相对较高      |

资料来源：公司官网，中金公司研究部

## 历史沿革：2022 年成立即聚焦于 AI+搜索引擎，踏浪生成式变革

Perplexity 成立于 2022 年 8 月，早期即确定 AI 搜索引擎路径，侧重产品力及快速迭代。成立之初，公司技术定位于 text2sql（将自然语言翻译转化为 SQL），但受制于技术的先进性以及 SQL 市场难以建立通用解决方案，这条路径并没有行通。2022 年 11 月 30 日 ChatGPT 推出的背景下，业界迅速认可大模型的泛化通用能力。2022 年 12 月，公司借势推出第一款核心产品 Perplexity Ask，定位 AI 搜索引擎，并推陈出新，先后推出 BirdSQL、Copilot、Profile、pplx-api 等产品，同时对 Perplexity Ask 及 Copilot 进行了快速迭代。纵观整体产品矩阵，我们可以发现公司始终专注于支持引用的 AI 搜索引擎，通过创新迭代优化其性能，不断提升客户的用户体验。


- **Perplexity Ask**：全球首个对话式搜索引擎，基于 GPT-3.5 和微软 Bing 构建。用户输入问题后，Ask 生成由大模型提炼后的回答，右上角附有引用链接，下方展示引用来源，用户可以直接点击链接溯源进行验证。此外，Ask 还会提示后续相关问题，点击即可生成对应答案，帮助用户优化搜索闭环。
- **Copilot**：2023 年 5 月份公司发布 Copilot，由 GPT-4 提供支持。Copilot 通过提出问题的形式对问题中的细节进行补充，可以精准把控用户需求，改善搜索体验。例如，用户让 Copilot 帮助挑选一款头戴式耳机，它会让用户选出理想的耳机类型、特征及价格区间，进而推荐合适的产品；通过选择目的地、活动类型等，Copilot 还可以量身定制履行计划。在 GPT-4 的理解和规划能力赋能下，Copilot 作为生产力工具切实提升用户的生产生活效率。2023 年 8 月，公司对 Copilot 进行了更新，使用微调过的 GPT-3.5 达到与 GPT-4 在特定任务上的近似效果，在大幅降低成本的同时提升了整体性能。
- **BirdSQL**：BirdSQL 是基于公司 text2sql 路线开发得到的 Twitter 搜索界面，使用 OpenAI Codex 将自然语言转换为 SQL。输入需求后，Bird SQL 会给出搜索结果及 SQL 代码，还能进一步对数据进行可视化产出统计图表，让不懂代码的人也可以实现轻松“爬虫”。但 2023 年 2 月底，Twitter 关闭了相关接口，BirdSQL 下架。

图表 10：Perplexity 发展历程




资料来源：公司官网，中金公司研究部

图表 11: Copilot 产品界面



资料来源: 海外独角兽公众号, 中金公司研究部


图表 12: Bird SQL 产品界面



资料来源: 海外独角兽公众号, 中金公司研究部


- **Profile:** Profile 为用户提供个性化的 AI 问答体验。通过自我介绍, 用户可以输入自己的基本情况建立画像, Perplexity 针对性地进行回答, 成为个性化的 AI 助手。
- **Perplexity Labs:** Perplexity Labs 为用户提供多种大模型交互体验, 包含 Mistral、Llama、CodeLlama 等开源大模型以及 Perplexity 的自研模型 pplx-7b、pplx-70b。pplx-7b 和 pplx-70b 是在 mistral-7b、llama2-70b 模型基础上微调增强所得。2023 年 11 月 29 日在 Labs 中开放了自研模型的 online 版本, 可以使用 Perplexity 的内部索引获取互联网信息, 保证信息的时效性。

图表 13: Profile 产品界面



资料来源: 海外独角兽公众号, 中金公司研究部

图表 14: Perplexity Labs 产品界面



资料来源: 新智元公众号, 中金公司研究部

## 创始团队: 具备 AI 基因+搜索行业经验, 获产业界名人注资

**创始人兼具技术实力与行业洞察力。**Perplexity 创始人为 Aravind Srinivas、Denis Yarats、Andy Konwinski 以及 Johnny Ho 四位。Srinivas 曾于 Google、DeepMind 实习且曾就职于 OpenAI。Yarats 曾在微软 Bing、问答网站 Quora、Facebook 担任人工智能研究人员或工程

师。Konwinski 为 DataBricks 的联合创始人。Johnny Ho 曾在 Quora 担任工程师，研究排名与后端系统，引领系统快速迭代。

**团队成员经验丰富，对 LLM 及搜索引擎有深入见解。**截至 2023 年 10 月，Perplexity 团队不足 50 人，但大多数员工都拥有在谷歌、英伟达、Quora 等科技企业的工作经验，对大模型及搜索引擎有着独到而深入的理解，为公司开发出性能优异的产品及后续的高速迭代夯实基础。

**图表 15: Perplexity 创始人团队**



资料来源：公司官网，中金公司研究部

**Perplexity 获多位 AI 产业界名人投资。**2022 年 9 月，公司完成种子轮融资，金额共计 310 万美元；2023 年 3 月，公司完成 2,560 万美元的 A 轮融资。Perplexity 吸引了诸多 AI 领域的知名人物投资，其中包括 Meta 首席 AI 科学家及图灵奖获得者 Yann LeCun、微软前总裁 Bob Muglia、前 GitHub 首席执行官 Nat Friedman、Open AI 创始成员 Andrej Karpathy 等。

**图表 16: Perplexity 融资状况及投资者**

| 融资轮次 | 融资金额<br>(万美元) | 投资者                                          | 时间      |
|------|---------------|----------------------------------------------|---------|
| 种子轮  | 310           | Elad Gil (Color Health 创始人)                  | 2022年9月 |
|      |               | Nat Friedman (GitHub 前CEO)                   |         |
|      |               | Pieter Abbeel (UC伯克利教授，曾获2021ACM计算奖)         |         |
|      |               | Yann LeCun (Meta 首席科学家，2019年图灵奖获得者)          |         |
|      |               | Andrej Karpathy (OpenAI 创始成员)                |         |
|      |               | Ashish Vaswani (Transformer首席发明者)            |         |
|      |               | Amjad Masad (Replit CEO)                     |         |
|      |               | Clem Delangue (HuggingFace CEO)              |         |
| A轮融资 | 2,560         | Peter Sonsini (Databricks 董事会成员)             | 2023年3月 |
|      |               | Elad Gil (Color Health 创始人)                  |         |
|      |               | Nat Friedman (GitHub 前CEO)                   |         |
|      |               | Susan Wojcicki (Youtube 前CEO)                |         |
|      |               | Bob Muglia (Microsoft 前总裁)                   |         |
|      |               | Paul Buchheit (Gmail 的发明者)                   |         |
|      |               | Soleio (曾在Facebook、Messenger、Dropbox 领导设计工作) |         |
|      |               | Databricks Ventures                          |         |


资料来源：公司官网，中金公司研究部

## 以检索增强生成技术为基，召回能力树立差异化

### 技术原理：以 RAG 为技术核心，召回与生成式 AI 优点兼容并包

我们认为以 RAG（Retrieval Augmented Generation，检索增强生成）技术为核心的对话式搜索引擎有望成为新产品形态。前文中，我们将以 ChatGPT 为代表的通用大模型与 Perplexity 进行了对比，LLM 主要的问题为内容时效性差和缺乏索引带来的潜在幻觉风险。LLM 无法生成训练数据与语料库之外的内容，也无法为生成内容提供精确索引和参考依据。2020 年，Meta 的研究人员通过引入 RAG 解决了这一问题，把与问题相关的事实交给 LLM 加工和学习，不仅结合了生成模型的先验知识，也汲取了检索模型的实时性和内容丰富性优势。


图表 17：传统搜索引擎、问答引擎与大模型技术对比



生成式 AI 语言理解与生成能力突出，但存在幻觉、数据缺乏实时性等劣势。生成式 AI（Generative AI）是一种基于 AI 技术的机器学习模型，它对海量训练数据进行学习并根据其特征生成与原始数据相似的全新内容，生成内容可以为图像、视频、音乐、语音和文本等。近年来计算机硬件性能的提升和预训练技术的发展使生成式 AI 能力实现跃迁，以 ChatGPT 为代表的大型语言模型具备语言理解能力强大、多样化生成能力等优点，被广泛应用于各行各业。但生成式 AI 无法做到实时更新，且受限于训练数据，可能无法覆盖相对小众、缺乏通用性的长尾知识。同时，生成式 AI 对生成内容的可控性较差，存在“幻觉”问题，用户也难以对答案进行直接验证。

检索增强生成（RAG）融合外部知识与模型先验知识，有效弥补生成式 AI 缺陷。检索增强生成（Retrieval Augmentation Generation）由检索和生成两部分组成，首先在知识库中根据需求召回最匹配的文档内容，再作为提示词输入模型生成答案。

图表 18：检索增强生成（RAG）技术原理



- **检索系统 (Retriever):** 检索环节包括需求编码器 (Query Encoder) 和文档索引 (Document Index)。使用两个不同的 BERT 模型将需求  $q$  与文档  $z$  分别编码为  $q(x)$  和  $d(z)$ ，进而使用最大内积搜索算法获取内积最大的文档，将其与需求共同输入生成部分。
- **生成系统 (Generator):** 在此环节，生成器根据检索器总结输出最终答案。大模型会根据输入预测下一个词的出现概率，并生成概率最大的单词。共有两种方式计算生成概率：1) RAG-Sequence: 使用同一个文档预测，先确定文档再计算候选词概率；2) RAG-Token: 使用不同文档预测，每个候选词的概率为所有文档的条件概率之和。

**RAG 技术下知识源于非参数记忆与参数记忆，覆盖范围广且易于更新。**非参数记忆为检索系统召回的文档链接，参数记忆为预训练模型储存的知识，对应 Meta 的技术论文中，二者分别为维基百科和 BART 模型<sup>2</sup>。相较于生成式 AI，RAG 路径下源于外部知识库的非参数记忆更新可以轻松实现，确保了生成内容的覆盖广度和实时性。在生成答案时，RAG 技术也可以将引用的外部来源进行标记，便于溯源。

**RAG 在开放域知识问答及生成式问答中性能领先。**Meta 的技术论文对 RAG 技术进行了详细测评，包括开放域问答、开放域问题生成、抽取式问答及分类推理任务。在开放域问答中，RAG-Token 和 RAG-Seq 得分处于领先地位；在生成任务和分类任务中，RAG 表现优于 BART 模型。

图表 19: RAG 在开放域问答测试中成绩领先

|             | Model          | NQ   | TQA       | WQ   | CT   |
|-------------|----------------|------|-----------|------|------|
| Closed Book | T5-11B [52]    | 34.5 | - /50.1   | 37.4 | -    |
|             | T5-11B+SSM[52] | 36.6 | - /60.5   | 44.7 | -    |
| Open Book   | REALM [20]     | 40.4 | - / -     | 40.7 | 46.8 |
|             | DPR [26]       | 41.5 | 57.9/ -   | 41.1 | 50.6 |
|             | RAG-Token      | 44.1 | 55.2/66.1 | 45.5 | 50.0 |
|             | RAG-Seq.       | 44.5 | 56.8/68.0 | 45.2 | 52.2 |

注: NQ、TQA、WQ、CT 分别为 Natural Questions、Trivia QA、Web Questions 和 Curated Trec 四个数据集。

资料来源: Lewis, Patrick, et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks." ArXiv abs/2005.11401 (2020): n. pag., 中金公司研究部

图表 20: 生成任务和分类任务中各模型能力对比

| Model    | Jeopardy B-1 | MSMARCO QB-1 | R-L B-1 | FVR3 Label | FVR2 Acc.  |
|----------|--------------|--------------|---------|------------|------------|
| SotA     | -            | -            | 49.8*   | 49.9*      | 76.8 92.2* |
| BART     | 15.1         | 19.7         | 38.2    | 41.6       | 64.0 81.1  |
| RAG-Tok. | 17.3         | 22.2         | 40.1    | 41.5       | 72.5 89.5  |
| RAG-Seq. | 14.7         | 21.4         | 40.8    | 44.2       |            |


注: 1) Jeopardy 为开放域问题生成数据集; 2) MSMARCO 为抽取式问答数据集; 3) FVR3、FVR2 为分类任务数据集，分别表示三分类与二分类数据集。

资料来源: Lewis, Patrick, et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks." ArXiv abs/2005.11401 (2020): n. pag., 中金公司研究部

**Perplexity 的 RAG 技术路径是“搜索引擎检索—高效召回相关内容—大模型推理—生成具备索引定位的回答”。**用户输入查询时，Perplexity 会对查询进行理解重构，然后将需求发送到 Bing 搜索引擎，从外部索引中“召回”最相关的链接，再将用户提问与检索答案合成 Prompt (提示) 提交给大模型，由大模型完成整合、生成简洁回答及标注来源的任务。在此技术路径下，Perplexity 将传统搜索引擎的知识广度与大模型的推理、生成能力相结合，为用户提供精简可溯源的答案，优化了用户的搜索体验。

<sup>2</sup> Lewis, Patrick, et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks." ArXiv abs/2005.11401 (2020): n. pag.

图表 21: Perplexity 技术路径, “检索-召回-大模型推理”




资料来源：公司官网，中金公司研究部

**“召回”和“排序”为传统搜索引擎的决定性环节。**传统搜索引擎的技术路线分为数据、检索以及匹配三步：1) 收集互联网上的海量数据并进行初步处理；2) 为每个数据打上合适的“标签”并设计一套精妙的检索方案以便随时找到合适的数据；3) 收到搜索指令后，对其进行拆解分析，把与指令有关的数据按照相关性进行排序，最终呈现最佳答案。而在搜索引擎的设计中，最核心的技术则是“召回”和“排序”，他们决定了搜索引擎的精确程度和性能上限。其中，“召回”指根据搜索指令从数据库中获取尽可能多的正确结果，“排序”指根据用户搜索内容的相关性对召回结果进行排序。


### 技术优势：Perplexity 召回与响应速度领先，夯实差异化产品力

图表 22: 传统搜索引擎技术路线



资料来源：昆仑万维公众号，中金公司研究部

图表 23: 生成式搜索引擎能力对比




注：1) 有用性(perceived utility): 回复对用户查询来说是否是有用且有信息量的；  
2) 引用召回(citation recall): 指由其相关引文完全支持的、值得验证的句子的比例。  
资料来源：Liu, Nelson F., Tianyi Zhang and Percy Liang. "Evaluating Verifiability in Generative Search Engines." ArXiv abs/2304.09848 (2023), 中金公司研究部

**Perplexity 算法侧进行创新，召回率和准确率先。**当大模型被引入后，它对搜索技术的重塑贯穿每一个环节。例如，在召回环节，大模型能够模仿人类的识别判断能力，更有效地召回结

果；在排序环节，大模型可以考虑更多语言细节，提升排序性能。[据 Perplexity 创始人 Aravind Srinivas 公开演讲](#)，Perplexity 在召回和排序环节都对算法侧进行了创新，保证内容的有用性及引用的精确程度。在 2023 年 4 月的论文中，斯坦福的研究人员对 YouChat、Perplexity.AI、NeevaAI 及 BingChat 四个生成式搜索引擎进行了人工评估<sup>3</sup>。结果显示，Perplexity.ai 生成内容有用性的评分为 4.56 分，排名第二；引文召回率和精确度为 68.7，排名第一；在泛搜索引擎类的体验中，综合能力位于最前列。

**公司自研推理堆栈，大幅提升响应速度。**除引用内容精确外，Perplexity 的生成速度快于 GPT 类通用模型。从技术路径分析，一方面，Perplexity 检索后由大模型总结，而检索本身响应速度快于预训练大模型的推理速度；另一方面，在采访中 Aravind Srinivas 表示 Perplexity 未使用 Hugging Face 等第三方推理栈，而是基于自定义的简化推理堆栈，即 pplx-api，进一步提升响应速度。公司使用英伟达的 TensorRT-LLM 对大模型推理进行精心设计和优化，底层基础设施为英伟达 A100 提供支持的 AWS P4d 实例。在于其他 API 的对比中，pplx-api 的总延迟降低了 65%，初始响应延迟降低了 77%，处理 token 的速度较 TGI 领先 47%-85%。除内部使用外，pplx-api 还面对开发人员提供开源大模型集成服务，使其可以轻松地集成 Mistral 7B、Llama2 13B、Code Llama 34B、Llama2 70B、replit-code-v1.5-3b 等尖端开源 LLM，易用优势显著。

**图表 24：Perplexity API 其他 API 的延迟对比**




资料来源：公司官网，中金公司研究部

**模型侧，基于 GPT-3.5 API 进行微调，降低成本、进一步降低延迟性。**2023 年 8 月，Perplexity 宣布对 Copilot 进行重大更新，由微调的 GPT-3.5 提供支持，在性能、速度和成本三方面显著改进。在性能方面，公司考虑对复杂查询的精确响应，在搜索的特定领域显著优于 GPT-3.5，基本与 GPT-4 对等。在速度方面，微调模型能够将延迟减少 80%，将平均输出结果的时间由 3.15 秒缩短至 0.65 秒。在成本方面，微调模型的输入/输出成本分别为 0.012/0.016 美元/1K tokens，而 GPT-4 Turbo 的输入/输出成本分别为 0.01/0.03 美元/1K tokens。在用户不额外为 GPT-4 付费的高阶版本下，基于微调 GPT-3.5 版本的推理性能已与 GPT-4 相近，根据创始人公开演讲，公司预计基于微调 GPT-3.5 版本推理性能有望在 2024 年中达到 GPT-4 水平。


<sup>3</sup> Liu, Nelson F., Tianyi Zhang and Percy Liang. "Evaluating Verifiability in Generative Search Engines." ArXiv abs/2304.09848 (2023): n. pag.

图表 25: GPT-3.5 微调模型性能大幅超过 GPT-3.5, 与 GPT-4 接近



资料来源: 公司官网, 中金公司研究部

图表 26: GPT-3.5 微调模型将延迟减少 80%



资料来源: 公司官网, 中金公司研究部

图表 27: GPT-3.5 微调模型大大降低推理成本



资料来源: 公司官网, 中金公司研究部

## 订阅制与 API 调用为商业模式之基，广告收入未来可期


### 商业模式：收入源于订阅付费和 API 调用，广告有望成为增长点

**订阅付费为收入主要来源。**目前，公司的收入来源为 Perplexity Pro 订阅付费项目，定价为 20 美元/月或 200 美元/年，月费价格与 ChatGPT Plus 相同。**付费会员主要享有四大权益：**（1）单日使用 Copilot 的次数多达 300+，而免费用户为 5 次/4 小时。（2）更加强大多元的模型选择：付费用户可以选择 Copilot 底层模型，包括微调的 GPT-3.5、GPT-4、Claude-2.1 与 Perplexity 70B，能够使用更强大的大模型生成更精准的答案。（3）无限制的文件上传，付费用户能够无限制地上传文件，Perplexity 可以对文档进行解析进而回答相关问题。（4）API 积分，每月可以免费获得 5 美元的 pplx-api 额度。Perplexity Pro 目前付费用户数量已达到约 15,000 人，为其商业化打开了良好开端。

**API 调用基于使用情况付费。**pplx-api 根据输入输出 tokens 数量计费，不同参数的模型对应不同价格。结合搜索功能的 online 模型输入 tokens 免费，但除输出外每千个请求额外收取 5 美元。7B 参数模型为 pplx-7b-chat 和 Mistral-7b，13B 参数模型为 Llama2-13b，34B 参数模型为 Codellama-34b，70B 参数模型为 pplx-70b-chat 和 Llama2-70b。Online 模型中，7B 和 70B 参数模型分别为 pplx-7b-online 和 pplx-70b-onlie。其中，pplx-7b 和 pplx-70b 是在 mistral-7b、llama2-70b 模型基础上微调增强所得。

**广告有望成为新增付费点。**传统搜索引擎的商业模式为广告分成，公司创始人认为当用户需要 Perplexity 推荐相关商品时，广告模式仍有可能被嵌入对话式搜索引擎中，公司也将继续探索广告在 AI 搜索引擎中的可能性。

图表 28：Perplexity 商业模式



资料来源：公司官网，中金公司研究部

图表 29：截至 12 月 10 日，API 调用定价情况

| 模型参数规模        | Input            | Output           |
|---------------|------------------|------------------|
| 7B            | \$0.28/1M tokens | \$0.07/1M tokens |
| 13B           | \$0.14/1M tokens | \$0.56/1M tokens |
| 34B           | \$0.35/1M tokens | \$1.40/1M tokens |
| 70B           | \$0.70/1M tokens | \$2.80/1M tokens |
| Online 模型参数规模 | 额外收费             | Output           |
| 7B            | \$5/每千个问题        | \$0.28/1M tokens |
| 70B           | \$5/每千个问题        | \$2.80/1M tokens |

资料来源：公司官网，中金公司研究部

## 潜在方向：自研大模型与内部搜索引擎或为未来探索方向

据我们测算，Perplexity 调用 Bing 搜索引擎及 GPT-4 的单个问题成本约为 0.03 美元，年成本约为 6,000 万美元。Perplexity 成本主要来源于两部分，即调用 Bing Search API 查找相关内容的成本、调用 GPT 生成答案的成本。由于免费用户也享有每 4 小时使用 5 次 Copilot 的权益，因此在测算 GPT API 成本时直接使用最新的 GPT-4 Turbo 成本，即输入 0.01 美元/1k tokens，输出 0.03 美元/1k tokens。按照输入问题 50 个、输出答案为 400 个英文单词，添加调用 Bing Search API 的费用，得出单次提问成本为 0.03 美元。考虑潜在增长，若周度访问量为 1200 万次，每次访问提问问题个数为 3，每年所需成本为 5,944 万美元。

使用 GPT-3.5 微调模型降低成本，自研模型与内部索引或为未来探索方向。Perplexity 官网显示，目前 Copilot 已经可以基于自研的 GPT-3.5 微调模型提供服务，与 GPT-4 性能基本对等，且能减少 4-5 倍延迟，输入成本可以控制在 0.012 美元/1k tokens，输出成本可以控制在 0.016 美元/tokens。按照同样的计算方法，单次提问成本降至 0.02 美元，年成本 4568 万美元。此外，公司创始人也表明，除使用自研模型之外，搜索引擎 API 调用成本受到 Bing 和 Google 的防御性机制而走高，我们认为建立内部搜索引擎也有望使得成本端下降，公司也计划在这两方面持续探索更加健康的发展方式。

图表 30：Bing Search API 进行防御性提价

| 实例    | Free     | S1       | S2        | S3        | S4        | S5        | S6        | S7        | S8        | S9        |
|-------|----------|----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|
| 每秒事务数 | 3 TPS    | 250 TPS  | 100 TPS   | 100 TPS   | 100 TPS   | 100 TPS   | 100 TPS   | 150 TPS   | 150 TPS   | 30 TPS    |
| 调价前价格 | 每月千次调用免费 | 7美元/千次调用 | 3美元/千次调用  | 4美元/千次调用  | 4美元/千次调用  | 4美元/千次调用  | 3美元/千次调用  | 5美元/千次调用  | 6美元/千次调用  | 3美元/千次调用  |
| 调价后价格 | 每月千次调用免费 | 7美元/千次调用 | 15美元/千次调用 | 18美元/千次调用 | 18美元/千次调用 | 18美元/千次调用 | 15美元/千次调用 | 20美元/千次调用 | 22美元/千次调用 | 15美元/千次调用 |
| 提价幅度  | 0        | 0        | 400%      | 350%      | 350%      | 350%      | 400%      | 300%      | 267%      | 400%      |

资料来源：Microsoft 官网，中金公司研究部

图表 31：调用 GPT-4 Turbo 及 GPT-3.5 微调模型的成本测算

|                | 单次 Bing Search 调用成本（美元） | 输入词数 | 输出词数 | Input（美元/1K tokens） | Output（美元/1K tokens） | 单次提问成本（美元） | 周度访问量（百万次） | 单次访问提问次数 | 年成本（百万美元） |
|----------------|-------------------------|------|------|---------------------|----------------------|------------|------------|----------|-----------|
| 调用 GPT-4 Turbo | 0.015                   | 50   | 400  | 0.01                | 0.03                 | 0.03       | 12         | 3        | 59.44     |
| 使用自研模型         | 0.015                   | 50   | 400  | 0.012               | 0.016                | 0.02       | 12         | 3        | 45.68     |

注：1）英文词数与 tokens 转换比例为 750words-1000tokens；2）综合未来成长性假设周度访问量为 120 万次；3）假设单次访问提问次数为 3

资料来源：OpenAI，Microsoft，公司官网，Similar Web，中金公司研究部

## LLM+搜索引擎的模式探讨

### 未来展望：竞争多元化，Perplexity 有望通过生态夯实先发优势


**需求侧，对话式搜索引擎模式或将长期存在。**Perplexity 的出现及高热度验证了大模型与传统搜索引擎结合的刚性需求，对比之下 LLM 的幻觉与时效性、传统搜索引擎的繁琐链接与大量广告均限制了使用效果。虽然目前，Perplexity 在短期内无法撼动商业模式完备成熟的搜索引擎市场，但我们认为未来以 Perplexity 为代表的对话式搜索引擎模式或将长期存在。

**供给侧，随着传统搜索引擎与大模型厂商的入局，我们认为未来格局有望呈现百花齐放态势。**Perplexity 的主要竞争对手可以分为两大类，一类是以谷歌为代表的传统搜索引擎厂商，另一类是以 OpenAI 为代表的通用智能大模型厂商。

- ▶ **传统搜索引擎厂商：**对搜索技术富有独到见解，在多年发展过程中持续打磨搜索技术，积累大量用户基础，在对话式搜索引擎中具有天然优势。即使在 ChatGPT 热度高增的同时嵌入 New Bing，谷歌搜索的领先优势并未受到冲击。此外，谷歌不断拓展 AI 边界，发布 Gemini 等性能同样领先的大模型，[Bard 也将在 2024 年由 Gemini Ultra 提供支持](#)，具备 AI 赋能搜索引擎的能力。短期来看，对话式搜索引擎目前仍处于发展的早期阶段，尚无完善的商业化落地方式，传统搜索引擎厂商此时大力研发可能对其传统业务产生冲击，转型需要依赖内部较大战略变革。长期来看，虽然目前 Perplexity 有较好的产品性能和用户体验，我们认为谷歌等搜索引擎厂商仍有可能基于前期沉淀实现弯道超车，并凭借自建数据闭环、场景闭环建立优势。
- ▶ **OpenAI 等大模型破局者：**具备先进的模型能力，引入搜索引擎并进行调整优化即可打造对话式搜索引擎。2023 年 5 月，OpenAI 向 ChatGPT Plus 用户推出网络浏览插件，赋予大模型联网能力，未来也可能将通用智能与搜索引擎相结合，与 Perplexity 直接竞争。

**Perplexity 有望打造知识平台，成为生态入口。**基于对话式搜索引擎，Perplexity 支持用户将搜索问题及答案分享至社区，供其他用户学习讨论。2023 年 9 月，公司发布 Collections，可以根据项目、主题或其他分类创建收藏夹，整合梳理查询对话并拓展新问题，还可以邀请其他参与者协作管理 Collections，创建知识共享平台。随着 Collections、pplx-api 等业态的逐步成熟，我们认为 Perplexity 有望建立特定社群，进一步夯实对话式搜索引擎的领先生态优势。

图表 32：Perplexity 推出 Collections



资料来源：SkyNet AI 公众号，中金公司研究部

## 风险探讨：AI 时代，产品形态与场景闭环为发展关键

**商业化风险：**对话式搜索引擎仍需进一步探索明晰的商业化路径。从成本端来看，Perplexity 采用的 GPT-3.5 微调模型与 Bing 搜索引擎均为外部 API，2023 年 5 月微软上调 Bing Search API 定价，加高产品使用门槛。随着 Perplexity 用户数量的持续增长，若未来 Bing 及 GPT API 费用再次增加，将对公司成本造成不利影响。从收入端来看，目前 Perplexity 的唯一收入来源为订阅付费，pplx-api 和广告都处于早期阶段，盈利路径尚未明晰。而谷歌等搜索引擎均建立了成熟的商业机制，“用户-商家-内容创作者”和广告生态形成业务及场景闭环，支撑搜索引擎持续更新高质量内容以留存用户，谷歌获取大额广告收入。按照 Perplexity 的技术路线，谷歌搜索引擎的闭环生态难以借鉴，仍需进一步探索。

图表 33：谷歌搜索引擎商业模式



**数据闭环风险：**对话形式下反馈机制有效性降低，难以打造数据飞轮。网页端搜索引擎通常具有完备严谨的指标体系，根据用户的浏览和点击行为总结偏好，并反馈至排序和广告竞价系统提升搜索性能。而对话形式下用户通常缺乏主动性点击 Like/Dislike 进行反馈，且用户自发反馈缺乏公允标准，难以反映生成结果的真实价值，意味着 Perplexity 也难以根据先发优势和海量用户数据打造数据飞轮，进行模型快速迭代。

**行业竞争加剧风险：**AI Agent 为 AI 落地下半场，落地需实现场景闭环，数据量及应用场景丰富的传统互联网巨头具备优势。为进一步拓宽用户客群、打造产业生态，谷歌已于海量垂类应用厂商建立场景闭环，实现购物、订票、资料检索等多元化需求。虽然 Perplexity Copilot 具备购买产品、制定旅行计划等功能，但在生活助手或购物助手等应用场景下，场景卡位丰富的互联网巨头更具优势，Perplexity 作为独立第三方企创业公司在完成“旅行路线规划”类的后续“订票、订酒店”功能难以短期形成场景闭环，亟待差异化破局之道。

图表 34：可比公司估值表

| 股票代码      | 公司名称  | 财报货币 | 收盘价<br>12-13 | 市值（百万<br>元） | 市盈率   |       |       | 市销率   |       |       |
|-----------|-------|------|--------------|-------------|-------|-------|-------|-------|-------|-------|
|           |       |      |              |             | 2022A | 2023E | 2024E | 2022A | 2023E | 2024E |
| 600588.SH | 用友网络* | CNY  | 18.01        | 61,568      | 282.1 | 515.2 | 89.2  | 6.7   | 5.9   | 5.0   |
| 300634.SZ | 彩讯股份  | CNY  | 22.19        | 9,926       | 29.9  | 26.5  | 24.5  | 5.7   | 6.4   | 4.9   |
| 688095.SH | 福昕软件* | CNY  | 80.52        | 7,367       | N.M.  | N.M.  | 218.1 | 12.7  | 12.1  | 10.7  |
| 603039.SH | 泛微网络* | CNY  | 50.07        | 13,048      | 58.5  | 160.5 | 64.3  | 5.6   | 5.1   | 4.1   |
| 688369.SH | 致远互联* | CNY  | 42.08        | 4,846       | 34.6  | 63.0  | 27.7  | 3.1   | 4.0   | 3.1   |
| 600570.SH | 恒生电子* | CNY  | 29.34        | 55,746      | 39.3  | 32.1  | 23.2  | 6.6   | 7.0   | 5.8   |
| 300674.SZ | 宇信科技* | CNY  | 17.32        | 12,309      | 48.7  | 28.9  | 22.0  | 2.9   | 2.4   | 1.9   |
| 002230.SZ | 科大讯飞* | CNY  | 48.90        | 113,237     | 202.5 | 245.7 | 189.3 | 6.0   | 5.4   | 4.7   |
| 300253.SZ | 卫宁健康* | CNY  | 7.63         | 16,387      | 151.1 | 39.2  | 23.7  | 5.3   | 4.3   | 3.6   |
| 300451.SZ | 创业慧康* | CNY  | 7.15         | 11,076      | 260.6 | 43.5  | 26.1  | 7.3   | 6.5   | 5.6   |
| 688777.SH | 中控技术* | CNY  | 46.39        | 36,459      | 45.7  | 32.7  | 26.1  | 5.5   | 3.9   | 2.9   |
| 688083.SH | 中望软件* | CNY  | 101.62       | 12,327      | N.M.  | 222.5 | 82.7  | 20.5  | 14.9  | 11.3  |
| 603859.SH | 能科科技* | CNY  | 38.37        | 6,391       | 32.2  | 21.3  | 16.8  | 5.2   | 3.9   | 3.4   |
| 300378.SZ | 鼎捷软件* | CNY  | 22.87        | 6,159       | 46.1  | 49.6  | 36.1  | 3.1   | 2.8   | 2.4   |
| 002315.SZ | 焦点科技* | CNY  | 35.56        | 11,129      | 36.8  | 30.1  | 25.9  | 7.6   | 6.4   | 5.6   |
| 688365.SH | 光云科技* | CNY  | 12.34        | 5,255       | N.M.  | N.M.  | N.M.  | 10.0  | 10.0  | 8.8   |
| 300687.SZ | 赛意信息* | CNY  | 23.65        | 9,585       | 38.3  | 34.5  | 27.0  | 4.2   | 4.0   | 3.3   |
| 300496.SZ | 中科创达* | CNY  | 84.11        | 38,683      | 50.1  | 47.9  | 47.6  | 7.1   | 6.6   | 6.1   |
| 00020.HK  | 商汤-W* | CNY  | 1.22         | 37,531      | N.M.  | N.M.  | N.M.  | 9.5   | 8.7   | 7.6   |

注：标\*公司为中金覆盖，采用中金预测数据；其余使用市场一致预期

资料来源：Wind，彭博资讯，公司公告，中金公司研究部

## 作者信息



**于钟海 分析员**

SAC 执证编号: S0080518070011  
SFC CE Ref: BOP246  
zhonghai.yu@cicc.com.cn



**魏黔霏 分析员**

SAC 执证编号: S0080523060019  
SFC CE Ref: BSX734  
guanfei.wei@cicc.com.cn



**王之昊 分析员**

SAC 执证编号: S0080522050001  
SFC CE Ref: BSS168  
zhihao3.wang@cicc.com.cn



**游航 分析员**

SAC 执证编号: S0080523010001  
SFC CE Ref: BTI822  
hang.you@cicc.com.cn



## 法律声明

### 一般声明

本报告由中国国际金融股份有限公司（已具备中国证监会批复的证券投资咨询业务资格）制作。本报告中的信息均来源于我们认为可靠的已公开资料，但中国国际金融股份有限公司及其关联机构（以下统称“中金公司”）对这些信息的准确性及完整性不作任何保证。本报告中的信息、意见等均仅供投资者参考之用，不构成对买卖任何证券或其他金融工具的出价或征价或提供任何投资决策建议的服务。该等信息、意见并未考虑到获取本报告人员的具体投资目的、财务状况以及特定需求，在任何时候均不构成对任何人的个人推荐或投资操作性建议。投资者应当对本报告中的信息和意见进行独立评估，自主审慎做出决策并自行承担风险。投资者在依据本报告涉及的内容进行任何决策前，应同时考量各自的投资目的、财务状况和特定需求，并就相关决策咨询专业顾问的意见对依据或者使用本报告所造成的一切后果，中金公司及/或其关联人员均不承担任何责任。

本报告所载的意见、评估及预测仅为本报告出具日的观点和判断，相关证券或金融工具的价格、价值及收益亦可能会波动。该等意见、评估及预测无需通知即可随时更改。在不同时期，中金公司可能会发出与本报告所载意见、评估及预测不一致的研究报告。

本报告署名分析师可能会不时与中金公司的客户、销售交易人员、其他业务人员或在本报告中针对可能对本报告所涉及的标的证券或其他金融工具的市场价格产生短期影响的催化剂或事件进行交易策略的讨论。这种短期影响的分析可能与分析师已发布的关于相关证券或其他金融工具的目标价、评级、估值、预测等观点相反或不一致，相关的交易策略不同于且也不影响分析师关于其所研究标的证券或其他金融工具的基本面评级或评分。

中金公司的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。中金公司没有将此意见及建议向报告所有接收者进行更新的义务。中金公司的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见不一致的投资决策。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现。过往的业绩表现亦不应作为日后回报的预示。我们不承诺也不保证，任何所预示的回报会得以实现。分析中所做的预测可能是基于相应的假设。任何假设的变化可能会显著地影响所预测的回报。

本报告提供给某接收人是基于该接收人被认为有能力独立评估投资风险并就投资决策能行使独立判断。投资的独立判断是指，投资决策是投资者自身基于对潜在投资的目标、需求、机会、风险、市场因素及其他投资考虑而独立做出的。

本报告由受香港证券及期货事务监察委员会监管的中国国际金融香港证券有限公司（“中金香港”）于香港提供。香港的投资者若有任何关于中金公司研究报告的问题请直接联系中金香港的销售交易代表。本报告作者所持香港证监会牌照的牌照编号已披露在报告首页的作者姓名旁。

本报告由受新加坡金融管理局监管的中国国际金融（新加坡）有限公司（“中金新加坡”）于新加坡向符合新加坡《证券期货法》定义下的合格投资者及/或机构投资者提供。本报告无意也不应直接或间接地分发或传递给新加坡的任何其他人。提供本报告于合格投资者及/或机构投资者，有关财务顾问将无需根据新加坡之《财务顾问法》第 45 条就任何利益及/或其代表就任何证券利益进行披露。有关本报告之任何查询，在新加坡获得本报告的人员可联系中金新加坡持牌代表。

本报告由受金融行为监管局监管的中国国际金融（英国）有限公司（“中金英国”）于英国提供。本报告有关的投资和服务仅向符合《2000 年金融服务和市场法 2005 年（金融推介）令》第 19（5）条、38 条、47 条以及 49 条规定的人士提供。本报告并未打算提供给零售客户使用。在其他欧洲经济区国家，本报告向被其本国认定为专业投资者（或相当性质）的人士提供。

本报告由中国国际金融日本株式会社（“中金日本”）于日本提供，中金日本是在日本关东财务局（日本关东财务局长（金商）第 3235 号）注册并受日本法律监管的金融机构。本报告有关的投资产品和服务仅向符合日本《金融商品交易法》第 2 条 31 项所规定的专业投资者提供。本报告并未打算提供给日本非专业投资者使用。

本报告亦由中国国际金融股份有限公司向符合日本《金融商品交易法施行令》第 17 条第 3 款第 1 项及《金融商品交易法》第 58 条第 2 款但书前段所规定的日本金融机构提供。在该情形下，本报告有关的投资产品和服务仅向日本受监管的金融机构提供。

本报告将依据其他国家或地区的法律法规和监管要求于该国家或地区提供。

#### 特别声明

在法律许可的情况下，中金公司可能与本报告中提及公司正在建立或争取建立业务关系或服务关系。因此，投资者应当考虑到中金公司及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。

与本报告所含具体公司相关的披露信息请访问 <https://research.cicc.com/footer/disclosures>，亦可参见近期已发布的关于该等公司的具体研究报告。

#### 中金研究基本评级体系说明：

分析师采用相对评级体系，股票评级分为跑赢行业、中性、跑输行业（定义见下文）。

除了股票评级外，中金公司对覆盖行业的未来市场表现提供行业评级观点，行业评级分为超配、标配、低配（定义见下文）。

我们在此提醒您，中金公司对研究覆盖的股票不提供买入、卖出评级。跑赢行业、跑输行业不等同于买入、卖出。投资者应仔细阅读中金公司研究报告中的所有评级定义。请投资者仔细阅读研究报告全文，以获取比较完整的观点与信息，不应仅仅依靠评级来推断结论。在任何情形下，评级（或研究观点）都不应被视为或作为投资建议。投资者买卖证券或其他金融产品的决定应基于自身实际具体情况（比如当前的持仓结构）及其他需要考虑的因素。

#### 股票评级定义：

- 跑赢行业（OUTPERFORM）：未来 6~12 个月，分析师预计个股表现超过同期其所属的中金行业指数；
- 中性（NEUTRAL）：未来 6~12 个月，分析师预计个股表现与同期其所属的中金行业指数相比持平；
- 跑输行业（UNDERPERFORM）：未来 6~12 个月，分析师预计个股表现不及同期其所属的中金行业指数。

#### 行业评级定义：

- 超配（OVERWEIGHT）：未来 6~12 个月，分析师预计某行业会跑赢大盘 10%以上；
- 标配（EQUAL-WEIGHT）：未来 6~12 个月，分析师预计某行业表现与大盘的关系在-10%与 10%之间；
- 低配（UNDERWEIGHT）：未来 6~12 个月，分析师预计某行业会跑输大盘 10%以上。

研究报告评级分布可从<https://research.cicc.com/footer/disclosures> 获悉。

本报告的版权仅为中金公司所有，未经书面许可任何机构和个人不得以任何形式转发、翻版、复制、刊登、发表或引用。

V190624  
编辑：赵静



### 北京

中国国际金融股份有限公司  
中国北京建国门外大街 1 号  
国贸写字楼 2 座 28 层  
邮编: 100004  
电话: (86-10) 6505 1166  
传真: (86-10) 6505 1156

### 深圳

中国国际金融股份有限公司深圳分公司  
深圳市福田区益田路 5033 号  
平安金融中心 72 层  
邮编: 518048  
电话: (86-755) 8319-5000  
传真: (86-755) 8319-9229

### 东京

中国国际金融日本株式会社  
〒100-0005 東京都千代田区丸の内 3 丁目 2 番 3 号  
丸の内二重橋ビル 2 1 階  
Tel: (+813) 3201 6388  
Fax: (+813) 3201 6389

### 纽约

CICC US Securities, Inc  
32<sup>nd</sup> Floor, 280 Park Avenue  
New York, NY 10017, USA  
Tel: (+1-646) 7948 800  
Fax: (+1-646) 7948 801

### 伦敦

China International Capital Corporation (UK)  
Limited  
25th Floor, 125 Old Broad Street  
London EC2N 1AR, United Kingdom  
Tel: (+44-20) 7367 5718  
Fax: (+44-20) 7367 5719

### 上海

中国国际金融股份有限公司上海分公司  
上海市浦东新区陆家嘴环路 1233 号  
汇亚大厦 32 层  
邮编: 200120  
电话: (86-21) 5879-6226  
传真: (86-21) 5888-8976

### 香港

中国国际金融（香港）有限公司  
香港中环港景街 1 号  
国际金融中心第一期 29 楼  
电话: (852) 2872-2000  
传真: (852) 2872-2100

### 旧金山

CICC US Securities, Inc. San Francisco Branch  
Office  
One Embarcadero Center, Suite 2350,  
San Francisco, CA 94111, USA  
Tel: (+1) 415 493 4120  
Fax: (+1) 628 203 8514

### 新加坡

China International Capital Corporation  
(Singapore) Pte. Limited  
6 Battery Road, #33-01  
Singapore 049909  
Tel: (+65) 6572 1999  
Fax: (+65) 6327 1278

### 法兰克福

China International Capital Corporation (Europe)  
GmbH  
Neue Mainzer Straße 52-58, 60311  
Frankfurt a.M, Germany  
Tel: (+49-69) 24437 3560