

# 人工智能十年展望（十六）：成本决定落地节奏，大模型轻量化、线性化趋势渐起



于钟海 分析员

SAC 执证编号：S0080518070011  
SFC CE Ref: BOP246  
zhonghai.yu@cicc.com.cn



魏黔 分析员


SAC 执证编号：S0080523060019  
SFC CE Ref: BSX734  
guanfei.wei@cicc.com.cn



王之昊 分析员

SAC 执证编号：S0080522050001  
SFC CE Ref: BSS168  
zhihao3.wang@cicc.com.cn

纵轴：相对值（%）



中金一级行业：科技

资料来源：Wind，彭博资讯，中金公司研究部

- 软件及服务 | 人工智能十年展望（十五）：AI Agent：远期场景闭环，交互重塑（2023.12.18）
- 软件及服务 | 人工智能十年展望（十四）：从Perplexity看AI+搜索的破局之道（2023.12.14）
- 软件及服务 | AI动态跟踪：多模态模型和应用涌现，24年产业进展的下一“高地”（2023.12.04）
- 软件及服务 | 人工智能十年展望（十三）：AI应用商业化的“成败之论”（2023.10.09）
- 软件及服务 | 人工智能十年展望（十二）：详解大模型时代的基础软件堆栈AI Infra（2023.08.08）

更多作者及其他信息请见文末披露页

## 观点聚焦

### 投资建议

2023 年ChatGPT引领产业界高度重视，产业落地节奏成为核心关注点。我们于 2021 年在《[人工智能十年展望（二）](#)》提出边际成本决定竞争力，并提出大模型的泛化能力有望从算法侧解决这一问题。即便如此，在产业趋势起点，我们看到海外WAU~1,000 万的应用Perplexity基于微调GPT-3.5 的算法成本约为 4,500 万美元/年；国内智谱GLM-4 的API调用价格约为 50 元/百万中文字符，成本依然是阻碍应用落地的核心矛盾。我们持续看好Transformer之外的模型轻量化、线性化的应用前景，将在本文对两大趋势进行探讨，有望为模型降本、应用落地、端侧部署带来新的可能。

### 理由

算法框架革新为AI应用降本、大规模落地的有效路径。算力成本在摩尔定律指引下具备下降趋势外，如何在保证性能的同时降低成本，是AI大规模落地的首要问题。轻量化和线性化以不同思路显著提升计算效率，为算法革新提供思路，我们认为有望以降低成本逻辑打开AI应用普及天花板。

► **轻量化：以小型化为基，混合专家模型（MoE）为主流路线，通过稀疏化优化性能与计算效率。**小型化模型以 Mistral-7B、Gemini Nano、面壁 MiniCPM、Gemma 为代表，基于十亿级参数量，通过高质量 AI 基础设施、高效训练方法与优质数据集优化模型性能，降低大模型的使用门槛。MoE 在模型小型化基础上兼具灵活性与准确性，以激活部分参数的稀疏特点提升推理速度，进一步降低模型成本。Mixtral 8\*7B 以 12.9B 推理参数量达到媲美 GPT-3.5 的性能，Gemini 1.5 Pro 性能对标 Gemini 1.0 Ultra，验证了 MoE 的潜力。

► **线性化：兼具 RNN 与 Transformer 优势，或为大模型时代下的降本破局之道。**循环神经网络（RNN）将历史序列信息压缩至固定大小的隐藏状态中，具有线性复杂度，但具备无法并行训练的明显不足；Transformer 模型引入自注意力机制，具有二次方的推理复杂度，计算成本较高。在此背景下，线性化路径取二者优势，衍生出线性注意力方法与选择性状态空间方法，代表模型为 RWKV、RetNet 与 Mamba，即通过压缩上下文信息实现线性复杂度、并结合 Transformer 并行训练，显著提升训练效率、压缩落地成本，我们认为线性化路径对大模型的端侧落地及广泛应用具有重要意义。

### 盈利预测与估值

维持行业内覆盖公司的盈利预测、估值和目标价不变。

### 风险

算法落地过程中的内存、微调挑战，提示工程依赖度提升。

## 目录

|                                                               |    |
|---------------------------------------------------------------|----|
| 总览：模型轻量化、线性化为算法降本带来新机遇.....                                   | 4  |
| 产业视角：算法边际成本高阻碍产业落地，框架革新注入新可能 .....                            | 4  |
| 学界视角：轻量化与线性化模型尚有改进空间，发展前景可期.....                              | 4  |
| 模型轻量化：MoE 为基本路线，大模型降本新方向 .....                                | 5  |
| 模型小型化：压缩参数数量，以高效训模方法和优质数据扩展性能.....                            | 5  |
| 混合专家模型（MoE）：以稀疏化分而治之，实现计算效率优化.....                            | 6  |
| 不足及未来方向探讨.....                                                | 11 |
| 模型线性化：降低模型落地成本的探路者，兼具 Transformer 与 RNN 模型优势.....             | 13 |
| 线性化：主流路径从 RNN 到 Transformer，线性化兼收并蓄 .....                     | 13 |
| 线性注意力模型：以 RWKV 和 RetNet 为例，实现 RNN 与 Transformer 思想的有效融合 ..... | 14 |
| 选择性状态空间模型：以 Mamba 为代表，实现线性复杂度和高吞吐量 .....                      | 18 |
| 不足及未来方向探讨.....                                                | 19 |
| 总结：模型轻量化、线性化对 AI 行业潜在影响 .....                                 | 21 |
| 风险提示.....                                                     | 22 |

## 图表

|                                                              |    |
|--------------------------------------------------------------|----|
| 图表 1：在多个测试集上，Mistral 7B 的表现均优于 LLaMA2 13B、LLaMA 34B 模型 ..... | 5  |
| 图表 2：Gemini Nano 模型表现 .....                                  | 6  |
| 图表 3：多项主流测评榜单中，MiniCPM 中英文平均成绩均超越 Mistral-7B.....            | 6  |
| 图表 4：Switch Transformer 论文中的 MoE 架构.....                     | 6  |
| 图表 5：不同专家对多元化任务进行针对性处理 .....                                 | 7  |
| 图表 6：MoE 架构下模型训练速度提高 7 倍 .....                               | 8  |
| 图表 7：谷歌 GLaM 与 GPT-3 的推理成本（左）和训练能耗（右）对比 .....                | 8  |
| 图表 8：Switch Transformer 论文中的 MoE 架构.....                     | 8  |
| 图表 9：Mixtral 模型中的 MoE 层.....                                 | 9  |
| 图表 10：Mistral、Mixtral 与 LLaMA2 的测试结果.....                    | 9  |
| 图表 11：Mixtral、LLaMA2 70B 与 GPT-3.5 的测试结果 .....               | 9  |
| 图表 12：Gemini 1.5 Pro 突破 100 万 token 上下文长度 .....              | 10 |
| 图表 13：Gemini 1.5 Pro 保持高水平性能 .....                           | 10 |
| 图表 14：abab6 在复杂场景下表现亮眼，模型性能超越 GPT-3.5 .....                  | 10 |
| 图表 15：MoE-Tuning 流程图 .....                                   | 11 |
| 图表 16：MoE-LLaVA 在幻觉性能上和其他 LVLM 的比较 .....                     | 11 |
| 图表 17：混合专家模型总结.....                                          | 12 |
| 图表 18：结合 RNN、Transformer 路径的优势，线性化模型将空间复杂度降低为线性 .....        | 13 |
| 图表 19：RWKV-6 模型架构 .....                                      | 15 |
| 图表 20：RWKV-5 7B 多语言能力超越 Mistral-7B .....                     | 16 |
| 图表 21：RWKV-5 7B 英文能力接近 LLaMa2 .....                          | 16 |
| 图表 22：RWKV-6 模型表现 .....                                      | 16 |
| 图表 23：RWKV 的文本生成时间呈线性增长，而非二次方增长 .....                        | 16 |
| 图表 24：RWKV 在全球产业届受到广泛认可 .....                                | 17 |

|                                                        |    |
|--------------------------------------------------------|----|
| 图表 25: RWKV 作为端侧模型合作方出现 Intel 发布会 .....                | 17 |
| 图表 26: RetNet 的并行结构 .....                              | 17 |
| 图表 27: RetNet 的循环结构 .....                              | 17 |
| 图表 28: 相较于 Transformer, RetNet 实现低成本训练和良好性能 .....      | 18 |
| 图表 29: Mamba 模型架构 .....                                | 19 |
| 图表 30: 随序列长度增加, Mamba 与其他模型表现对比 .....                  | 19 |
| 图表 31: 相较于规模相当的 Transformer 架构, Mamba 具备 5 倍的吞吐量 ..... | 19 |
| 图表 32: 模型线性化总结 .....                                   | 20 |
| 图表 33: 可比公司估值表 .....                                   | 22 |



## 总览：模型轻量化、线性化为算法降本带来新机遇

### 产业视角：算法边际成本高阻碍产业落地，框架革新注入新可能

**Transformer 为大模型的主流架构，边际成本是大模型落地的一大痛点。**2017 年，Transformer 模型的发布打破了循环神经网络（RNN）的统治地位，凭借其强大的语言理解能力在自然语言处理、图像处理等领域得到了学术界广泛共识。目前，各厂商的均脱胎于 Transformer 架构开发预训练大语言模型，千亿级参数为其带来性能跃迁，但训练和推理时需要充分的算力资源。此外，Transformer 模型架构中核心的注意力机制意味着计算复杂度随序列长度增加呈二次方增长。**算力成本在摩尔定律指引下具备下降趋势之外，如何在保证性能的同时降低算法的边际成本，是 AI 大规模落地的首要问题。**

**轻量化和线性化以不同思路显著提升计算效率，为算法框架革新的两条有效路径。**AI 应用的普及一定程度上需要以逆向思维，即大模型小型化，来降低训练与推理成本。2020 年以 GPT-3 为代表的大模型路径彰显出优越性能以来，全球的研究人员持续对底层算法框架进行革新，轻量化和线性化为两大研究方向。其中，1) **轻量化**以 Mixtral 8\*7B 模型为代表，其核心思路是采用混合专家模型，架构中基于多个专家并行机制，推理时只激活部分专家，以稀疏性压缩了参数数量和推理成本；2) **线性化**则包含线性注意力与选择性状态空间模型两种方法，分别以 RWKV、RetNet 及 Mamba 模型为代表，模型性能较优且推理复杂度从二次方降为线性增长。我们认为轻量化及线性化路径有望为大模型广泛落地、实现端侧部署提供重要启示。

### 学界视角：轻量化与线性化模型尚有改进空间，发展前景可期

**轻量化：Mixtral 8\*7B 模型性能比肩 GPT-3.5，更大参数量下有望实现性能突破。**轻量化首先基于模型小型化基础，即以十亿级别参数量训练更大体量数据。混合专家模型（MoE）最早可追溯至 1991 年，此后与主流算法框架持续融合迭代，当前发展较为成熟。Mixtral 8\*7B 以 46.7B 的总参数量与 12.9B 的推理参数量实现了与 GPT-3.5 比肩的优越性能，充分展现了模型轻量化的潜力，我们认为随着参数规模的逐渐扩大，MoE 有望实现性能突破。但同时，MoE 具有占用较大内存、微调时易出现过拟合的现象，学术界尚亟待进一步解决。

**线性化：融合 RNN 路径思路，性能可达到类似规模的 Transformer 架构模型，兼具速度与成本优势。**Transformer 架构模型在推理时与上下文内容进行逐字对比，而线性化模型对前文信息进行了压缩，实现了复杂度线性化，意味着更快的推理速度和更低的计算成本。然而面对细节问题时，线性化路径与 RNN 具备类似的不足，削弱了模型回望之前信息的能力，其表现较 Transformer 模型可能具备一定差异。

**大模型趋势下降本道阻且长，轻量化与线性化提供丰富想象力。**当下所有的开发生态均围绕 Transformer 架构展开，模型部署成本下降为重要课题，轻量化和线性化为大模型落地提供了其他可能，我们认为以上技术趋势值得关注，有望打开大模型应用普及的天花板。

## 模型轻量化：MoE 为基本路线，大模型降本新方向


### 模型小型化：压缩参数数量，以高效训模方法和优质数据扩展性能

当下，大模型成为各家科技公司的必争之地，国内外大模型持续涌现，一大特点就是愈来愈多的参数数量和更为优越的模型性能。但与此同时，部分厂商另辟蹊径，聚焦于小型化的技术路线，通过高质量 AI 技术设施、高效训练方法与优质数据集探索十亿级参数量下的模型性能极限。小型化基于十亿级别参数量，通过架构调整训练更大体量数据，从而实现匹敌千亿级参数的模型效果。小型化意味着更低的使用成本和部署门槛，部分模型甚至可以在手机等终端设备使用，拓宽了大模型的赋能场景，商业意义显著。

### 小型化模型一览：以 Mistral-7B、Gemini Nano、面壁 MiniCPM 为例

**Mistral-7B：以小规模参数实现优越性能。**Mistral 7B 基于 Transformer 架构设计，包含 70 亿参数。Mistral 7B 架构中，最核心的部分为滑动窗口注意力机制，其本质是在大小固定的注意力窗口之间进行运算，相较于普通的注意力机制可以提高训练速度。模型还设定了分组查询注意力机制，将查询拆分后与关键值的子集进行运算并输出结果，提高查询吞吐且降低运算量。

图表 1：在多个测试集上，Mistral 7B 的表现均优于 LLaMA2 13B、LLaMA 34B 模型



资料来源：Jiang, Albert Qiaochu et al. “Mistral 7B.” ArXiv abs/2310.06825 (2023): n. pag., 中金公司研究部

**Gemini Nano：可在端侧设备高效运行。**2023 年 12 月，[谷歌发布 Gemini 系列模型](#)，其中 Gemini Nano 包含 1.8B 及 3.25B 两种参数规模，通过参数量更大的 Gemini 模型蒸馏得到，可在端侧设备落地使用，且已在智能手机 Pixel 8 Pro 上集成。虽然与 Gemini Ultra、GPT-4 等大参数量模型对比尚有一定距离，但 Gemini Nano 在事实、总结、推理、编码等任务中仍表现出较为强大的性能，提高了 AI 功能的可得性。

**面壁 MiniCPM：2B “小钢炮”，性能超越 Mistral-7B。**面壁智能自 2021 年持续探索“高效”技术路线，算力、算法、数据全面发力，基于全流程高效 infra、模拟沙盒实验和高质量数据激活小参数模型的潜能。在模型表现方面，MiniCPM 在 MT-Bentch 上表现优异，在多项主流测评中性能超越 Mistral-7B，甚至与 Llama2-13B 等更大参数量模型比肩。在模型能力方面，MiniCPM 开辟了多模态能力在手机端部署的先河，同时具备代码能力。在能效方面，MiniCPM 支持 CPU 推理，使用骁龙 855 芯片 170 万 tokens 的推理成本仅为 1 元人民币，一张显卡即可高效参数微调，是越级性能、高效率、低成本的集大成者。



图表 2：Gemini Nano 模型表现

|                                | Gemini Nano 1 |                   | Gemini Nano 2 |                   |
|--------------------------------|---------------|-------------------|---------------|-------------------|
|                                | accuracy      | normalized by Pro | accuracy      | normalized by Pro |
| BoolQ                          | 71.6          | 0.81              | 79.3          | 0.90              |
| TyDiQA (GoldP)                 | 68.9          | 0.85              | 74.2          | 0.91              |
| NaturalQuestions (Retrieved)   | 38.6          | 0.69              | 46.5          | 0.83              |
| NaturalQuestions (Closed-book) | 18.8          | 0.43              | 24.8          | 0.56              |
| BIG-Bench-Hard (3-shot)        | 34.8          | 0.47              | 42.4          | 0.58              |
| MBPP                           | 20.0          | 0.33              | 27.2          | 0.45              |
| MATH (4-shot)                  | 13.5          | 0.41              | 22.8          | 0.70              |
| MMLU (5-shot)                  | 45.9          | 0.64              | 55.8          | 0.78              |

资料来源：Gemini 技术报告，中金公司研究部

图表 3：多项主流测评榜单中，MiniCPM 中英文平均成绩均超越 Mistral-7B

|            | 平均分   | 英文均分  | 中文均分  | 中文知识   |       | 英文知识  |
|------------|-------|-------|-------|--------|-------|-------|
|            |       |       |       | C-Eval | CMMLU | MMLU  |
| Mistral-7B | 47.18 | 47.76 | 44.54 | 46.12  | 42.96 | 62.69 |
| MiniCPM    | 52.33 | 52.6  | 51.1  | 51.13  | 51.07 | 53.46 |


|            | 代码        |       | 数学    |       | 逻辑    | 常识问答  |       |           |
|------------|-----------|-------|-------|-------|-------|-------|-------|-----------|
|            | HumanEval | MBPP  | GSM8K | MATH  | BBH   | ARC-E | ARC-C | HellaSwag |
| Mistral-7B | 27.44     | 45.2  | 33.13 | 5     | 41.06 | 83.92 | 70.73 | 80.43*    |
| MiniCPM    | 50        | 47.31 | 53.83 | 10.24 | 36.87 | 85.44 | 68    | 68.25     |

资料来源：面壁智能公众号，中金公司研究部

## 混合专家模型（MoE）：以稀疏化分而治之，实现计算效率优化

混合专家模型（MoE）的基本思想是将输入数据进行拆解并分配给不同专家进行处理，以稀疏性提升模型的整体性能。在谷歌的 Switch Transformer 论文中<sup>1</sup>，研究人员将 MoE 思想与 Transformer 模型融合，由 MoE 层替换 Transformer 模型中的前馈神经网络（FFN）层，FFN 层原本旨在对输入序列进行非线性变换以捕捉复杂特征，该步替换大幅提高了计算效率和模型性能。MoE 模型主要由两个核心部分组成，即门控模型和专家模型：

图表 4：Switch Transformer 论文中的 MoE 架构



资料来源：Fedus, William et al. "Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity." J. Mach. Learn. Res. 23 (2021): 120:1-120:39., 中金公司研究部

- **门控模型 / 路由（Gating Network / Router）**：门控模型的作用是决定任意 token 被发送到哪个/哪些个专家进行处理。在下图示例中，“More”被发送到第二个专家，而“Parameters”被发送到第一个专家。输入数据后，门控模型接收数据并输出权重，衡量


每个专家处理输入数据的贡献程度。若某个专家的权重为 0，则表明其不参与该 token 的计算操作。

- **专家模型 (Experts)：**每个专家模型都是一个独立的神经网络，处理输入数据产生输出，并根据门控模型计算出的权重进行加权组合，生成最终结果。Switch Transformer 论文中，共有四个专家模型，门控模型选择一个专家进行处理。

### 混合专家模型在性能、速度与成本方面体现综合性优势

**混合专家模型充分汲取不同专家的优势，兼具准确性与灵活性。**MoE 架构中，每个专家都是独立的神经网络，能够基于不同数据或领域进行训练，以针对性处理任务的不同部分。此外，门控网络可以根据任务需要激活效果最佳的专家模型，满足多个任务场景。混合专家模型既能结合多个专家的优势解决问题，又能实现对输入数据的灵活处理，面对复杂任务时具备准确性与灵活性的特点。

图表 5：不同专家对多元化任务进行针对性处理




资料来源：Mustafa, Basil et al. "Multimodal Contrastive Learning with LIMoE: the Language-Image Mixture of Experts." ArXiv abs/2206.02770 (2022): n. pag., 中金公司研究部

**稀疏性赋予混合专家模型更快的预训练速度与推理速度。**在传统的稠密模型中，模型通常为输入复用所有参数。但混合专家模型根据输入数据的特点只激活部分专家对输入进行处理，大多数专家包含的参数并未被调用，从而实现稀疏性。MoE 模型调用部分专家的稀疏性使其计算效率大幅提升，预训练与推理均能以更快的速度完成。例如，在相同的训练效果下，Switch Transformer 模型的训练速度相较于稠密模型 T5 提升了 7 倍。


**与相同参数量的稠密模型相比，混合专家模型的训练及推理算力成本更低，有望驱动大模型普惠发展。**训练阶段，算力取决于参数数量、训练数据集的大小、训练轮次与批次大小。MoE 模型的稀疏性使得训练过程中调用的参数量减少，算力成本随之下降，模型厂商在一定的预算条件下可以显著增加参数规模并提升模型性能。谷歌的 GLaM 模型包含 12,000 亿参数，大约是 GPT-3 参数量的 7 倍，但其训练成本仅为 GPT-3 的 40%。推理阶段，MoE 模型激活部分参数进行预测，公有 API 调用及私有模型部署两种方式下，AI 应用厂商成本均有所下降。我们认为，MoE 有望降低应用成本，使大模型的普惠发展成为可能。

图表 6：MoE 架构下模型训练速度提高 7 倍



注：1) 32e、64e、128e 分别表示 32、64 与 128 个专家；2) T5 为稠密模型  
资料来源：Fedus, William et al. "Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity." J. Mach. Learn. Res. 23 (2021): 120:1-120:39., 中金公司研究部

图表 7：谷歌 GLaM 与 GPT-3 的推理成本（左）和训练能耗（右）对比

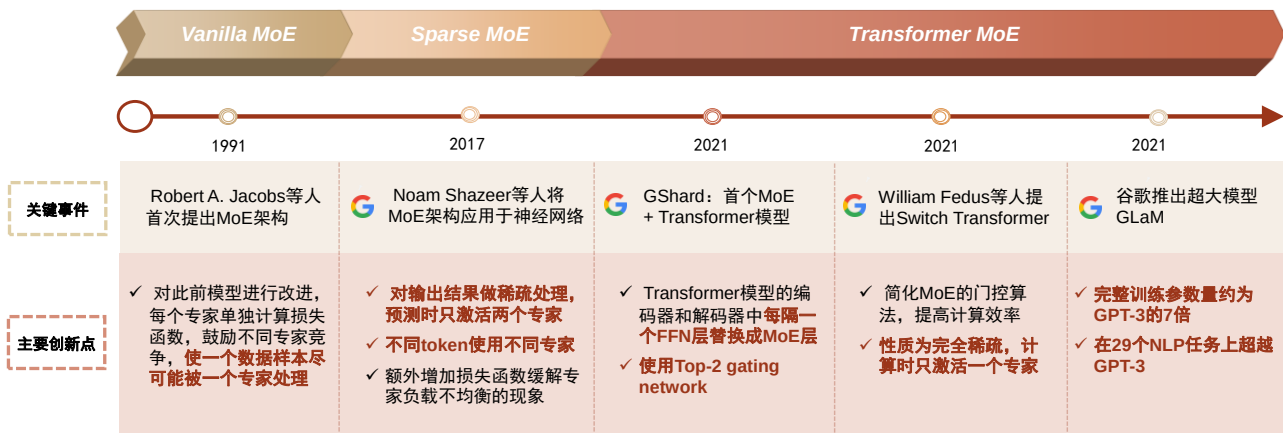


注：1) GLaM 模型为 MoE 模型，GPT-3 为稠密模型  
资料来源：Du, Nan et al. "GLaM: Efficient Scaling of Language Models with Mixture-of-Experts." ArXiv abs/2112.06905 (2021): n. pag., 中金公司研究部

## 发展历程：与主流算法框架持续交汇融合

从 Vanilla MoE、Sparse MoE 到 Transformer MoE，混合专家模型与主流算法框架持续融合。1991 年，MoE 架构被首次提出，奠定每个数据样本被不同专家处理的基本思想。2017 年，RNN 时代下，Sparse MoE 将模型规模横向扩展，针对不同 token 激活两个专家进行处理，成功将参数规模扩大至 137B。2020 年至今，Transformer 成为主流算法，谷歌将 MoE 架构与 Transformer 模型有效融合，先后发布 GShard、Switch Transformer 与 GLaM，其中 GLaM 在 29 个语言任务上超越 GPT-3，一定程度上验证了 MoE 架构的有效性。

图表 8：Switch Transformer 论文中的 MoE 架构



资料来源：Robert A. Jacobs, Michael I. Jordan, et al. Adaptive Mixtures of Local Experts. Neural Comput 1991; 3 (1): 79–87. doi:., Shazeer, Noam M. et al. "Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer." ArXiv abs/1701.06538 (2017): n. pag., Lepikhin, Dmitry et al. "GShard: Scaling Giant Models with Conditional Computation and Automatic Sharding." ArXiv abs/2006.16668 (2020): n. pag., Fedus, William et al. "Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity." J. Mach. Learn. Res. 23 (2021): 120:1-120:39., Du, Nan et al. "GLaM: Efficient Scaling of Language Models with Mixture-of-Experts." ArXiv abs/2112.06905 (2021): n. pag., 中金公司研究部




模型示例：MoE 技术路线得到学界认可，代表模型频出

► 海外：Mixtral 8\*7B 性能比肩 GPT-3.5，Gemini 1.5 Pro 展示性能突破

**Mixtral 8\*7B：高质量的稀疏混合专家模型。**继 Mistral 7B 之后，Mistral AI 于 2023 年 12 月发布稀疏的混合专家模型 Mixtral 8\*7B，采用 decoder-only 结构。Mixtral 模型的数据由开放网络中提取所得，在预训练时对路由网络和专家参数进行同时训练。对于每一个输入 token，路由器网络从八个专家中选择其中两个进行处理，最终输出累加组合。除八个专家外，Mixtral 其余部分的参数为各个专家共享，因此模型参数总规模为 46.7B 而非 56B（8\*7B）。但在训练和推理阶段，MoE 架构使每个 token 只激活 12.9B 参数，由此提升模型的灵活性、优化时延。

**Mixtral 表现优于 LLaMA2 70B，性能比肩 GPT-3.5。**Mixtral 具备处理 32K 上下文与五国语言的核心能力。在论文中，研究人员针对综合任务、数学、推理、阅读理解、代码等任务对 Mixtral、LLaMA 与 GPT-3.5 进行测试。结果显示，Mixtral 在大多数基准测试中的表现优于 LLaMA2 70B，同时推理速度提高了 6 倍；在大多数基准测试中与 GPT-3.5 表现相当。此外，Mixtral 在数学和代码生成领域尤为突出。综上，通过 MoE 模型，Mixtral 一方面达到了 46.7B 参数模型的优越性能，另一方面以 12.9B 参数模型相同的速度和成本处理输入，对比 Mistral 7B 实现了性能跃迁。


图表 9：Mixtral 模型中的 MoE 层



注：在 Mixtral 模型中，MoE 层替换 Transformer 模型中的 FFN 层

资料来源：Jiang, Albert Q. et al. "Mixtral of Experts." (2024)., 中金公司研究部

图表 10：Mistral、Mixtral 与 LLaMA2 的测试结果



注：1) 横轴表示被激活参数数量；2) 由于 Llama 2 34B 未开源，使用 Llama 1 34B 模型结果

资料来源：Jiang, Albert Q. et al. "Mixtral of Experts." (2024)., 中金公司研究部


图表 11：Mixtral、LLaMA2 70B 与 GPT-3.5 的测试结果

|                                          | LLaMA 2 70B  | GPT-3.5     | Mixtral 8x7B |
|------------------------------------------|--------------|-------------|--------------|
| <b>MMLU</b><br>(MCQ in 57 subjects)      | 69.9%        | 70.0%       | <b>70.6%</b> |
| <b>HellaSwag</b><br>(10-shot)            | <b>87.1%</b> | 85.5%       | 86.7%        |
| <b>ARC Challenge</b><br>(25-shot)        | 85.1%        | 85.2%       | <b>85.8%</b> |
| <b>WinoGrande</b><br>(5-shot)            | <b>83.2%</b> | 81.6%       | 81.2%        |
| <b>MBPP</b><br>(pass@1)                  | 49.8%        | 52.2%       | <b>60.7%</b> |
| <b>GSM-8K</b><br>(5-shot)                | 53.6%        | 57.1%       | <b>58.4%</b> |
| <b>MT Bench</b><br>(for Instruct Models) | 6.86         | <b>8.32</b> | 8.30         |

注：MMLU、MT Bench 为综合性测试；Hella Swag、ARC Challenge、WinoGrande 针对常识推理任务；MBPP 针对代码任务；GSM-8K 针对数学任务  
资料来源：Jiang, Albert Q. et al. "Mixtral of Experts." (2024)., 中金公司研究部

谷歌 Gemini 1.5 版本基于 MoE 架构，实现 100 万 token 长上下文处理，模型效率大幅提升。在谷歌 Gemini 1.0 和 MoE 前沿研究的基础上，[谷歌于 2024 年 2 月发布基于 Transformer 和 MoE 架构的 Gemini 1.5](#)，突破 100 万 tokens 的上下文窗口（即超过 70 万单词，或 1 小时视频、11 小时音频、超过 3 万行代码）。模型效果方面，1.5 Pro 可在给定提示内无缝分析、分类和总结大量内容，针对视频等不同模态执行复杂的理解和推理任务，同时具备实现代码定制、代码定位、代码修改等能力。与 Gemini 1.0 Pro 相比，Gemini 1.5 Pro 性能在数学、科学、推理、多语言、视频理解维度实现突破；与谷歌最大模型 Gemini 1.0 Ultra 相比，Gemini 1.5 Pro 在半数以上的基准测试中表现更优，同时具备更少的训练资源。

图表 12：Gemini 1.5 Pro 突破 100 万 token 上下文长度 图表 13：Gemin 1.5 Pro 保持高水平性能



资料来源：Google Blog, 中金公司研究部

| Gemini 1.5 Pro                   | Relative to 1.0 Pro                   | Relative to 1.0 Ultra                 |
|----------------------------------|---------------------------------------|---------------------------------------|
| Long-Context Text, Video & Audio | from 32k up to 10M tokens             | from 32k up to 10M tokens             |
| Core Capabilities                | Win-rate: 87.1%<br>(27/31 benchmarks) | Win-rate: 54.8%<br>(17/31 benchmarks) |
| Text                             | Win-rate: 100%<br>(13/13 benchmarks)  | Win-rate: 77%<br>(10/13 benchmarks)   |
| Vision                           | Win-rate: 77%<br>(10/13 benchmarks)   | Win-rate: 46%<br>(6/13 benchmarks)    |
| Audio                            | Win-rate: 60%<br>(3/5 benchmarks)     | Win-rate: 20%<br>(1/5 benchmarks)     |

资料来源：Gemini 1.5 Pro 技术报告, 中金公司研究部

### ► 国内：学界业界持续探索，由文本生成扩展至多模态

**MiniMax：发布 MoE 大模型，测试结果超越 GPT-3.5。**自 2023 年 6 月，MiniMax 开始进行混合专家模型的相关研究，第一版 MoE 模型已应用于 C 端产品，abab6 在此基础上将参数进一步扩大，能够从训练预料中总结更精细的规律并完成复杂任务，同时具备较高的计算效率。目前，abab6 是国内首个千亿参数量以上的混合专家模型。MiniMax 在用户指令遵循（IFEval）、英文综合能力（MT-Bench）与中文综合能力（AlignBench）三方面对 abab6 模型进行测评。模型表现相较于前一代稠密模型 abab5.5 显著提升，同时全面超越 Claude-2.1 与 GPT-3.5，总体优于 Mistral-Medium，与 GPT-4 仍有一定差距。

图表 14：abab6 在复杂场景下表现亮眼，模型性能超越 GPT-3.5

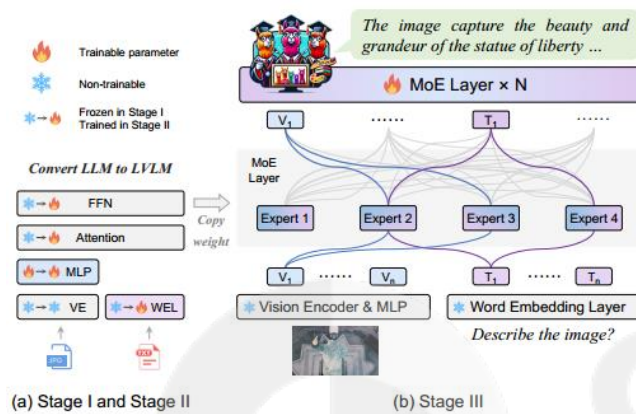
|            | abab6 | abab5.5 | Claude | Mistral | GPT-3.5 | GPT-4 |
|------------|-------|---------|--------|---------|---------|-------|
| IFEval     | 0.67  | 0.49    | 0.57   | 0.56    | 0.55    | 0.75  |
| MT-Bench   | 8.61  | 6.63    | 8.18   | 8.61    | 8.39    | 9.32  |
| AlignBench | 7.41  | 5.50    | 6.62   | 6.42    | 6.08    | 8.01  |

注：对比模型均为各自最佳版本，分别为 Claude-2.1、Mistral-Medium 商用、GPT-3.5-Turbo-0613、GPT-4-1106-preview  
资料来源：MiniMax 公众号, 中金公司研究部

**北大和中山 MoE-LLaVA 模型：将 MoE 架构扩展至多模态大模型，视觉理解能力强大。**来自北京大学、中山大学等机构的研究人员将混合专家模型扩展至多模态领域，并于 2024 年 1 月


发布 MoE-LLaVA 系列开源模型<sup>1</sup>。MoE-LLaVA 采用三阶段训练策略：第一阶段只训练多层感知器（MLP）使 LLM 理解图片语义、第二阶段除视觉编码器（VE）外均进行训练以加强模型的多模态理解能力、第三阶段只训练 MoE 层。MoE-LLaVA 的激活参数数量为 3B，在视觉理解数据集上的表现却与 LLaVA-1.5-7B 近似，在物体幻觉基准测试中表现超越 LLaVA-1.5-7B，与 LLaMA-VID 等其他大型视觉语言模型（LVLM）相比兼具参数量与性能优势，充分验证 MoE 架构的优势。

图表 15：MoE-Tuning 流程图



资料来源：Lin, Bin et al. "MoE-LLaVA: Mixture of Experts for Large Vision-Language Models." (2024)., 中金公司研究部

图表 16：MoE-LLaVA 在幻觉性能上和其他 LVLM 的比较



资料来源：Lin, Bin et al. "MoE-LLaVA: Mixture of Experts for Large Vision-Language Models." (2024)., 中金公司研究部

## 不足及未来方向探讨

**混合专家模型面临内存及微调挑战。**混合专家模型激活部分参数的思想实现了对模型规模的“压缩”，相较于稠密模型具备更快的推理速度与更低的算力成本。在预算有限的情况下，使扩大模型规模成为了可能。但同时，混合专家模型也具有一定缺陷。我们认为，应结合实际应用场景进行选择：当内存较少且对吞吐量要求不高时，可以使用稠密模型（即传统大模型路径）；当面对内存资源充足且高吞吐量的场景时，稀疏模型则是计算资源固定下的最优选择。

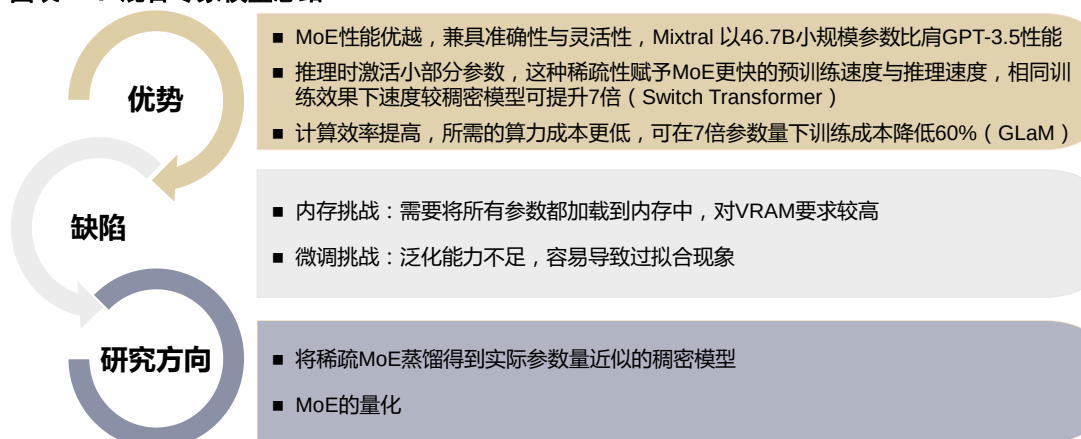
- **内存挑战：**虽然在预训练和推理过程中只使用模型中的部分参数，但 MoE 模型包含多个专家模型和门控网络，需要将所有参数都加载到内存中，对 VRAM 的要求比较高。
- **微调挑战：**稀疏模型通常存在众多参数，大量的参数数量可能导致模型学习训练数据的细节性特征，甚至用于拟合训练数据中的噪声，从而对训练数据的变化较为敏感。因此混合专家模型面临泛化能力不足的问题，容易导致过拟合现象。此外，完全微调 MoE 架构意味着更新所有参数，仍然需要大量计算资源。在实践中，可以使用权重衰减、使用更高比例的 dropout 等正则化技术减少参数数量，减轻模型的过拟合风险。

**稀疏 MoE 的蒸馏与 MoE 的量化为前沿探索方向。**首先，可以考虑从稀疏混合专家模型蒸馏得到具备更少参数总量但实际参数量近似的稠密模型。蒸馏过程可以提取原始 MoE 模型中的知

<sup>1</sup> Lin, Bin et al. "MoE-LLaVA: Mixture of Experts for Large Vision-Language Models." (2024).

识，保留原有的模型性能，同时提高模型的内存效率并优化泛化能力。其次，MoE 的量化也是一个新颖的研究领域。2023 年 10 月，来自奥地利科技学院（ISTA）的研究人员提出一种全新的模型量化方法 QMoE<sup>2</sup>，在轻微精度损失的情况下将 1.6 万亿参数的 Switch Transformer 模型所需的存储从 3.2TB 压缩至 160GB，解决了 MoE 面临的内存挑战。

图表 17：混合专家模型总结



资料来源：中金公司研究部



<sup>2</sup> Frantar, Elias and Dan Alistarh. "QMoE: Practical Sub-1-Bit Compression of Trillion-Parameter Models." ArXiv abs/2310.16795 (2023): n. pag.

## 模型线性化：降低模型落地成本的探路者，兼具 Transformer 与 RNN 模型优势



### 线性化：主流路径从 RNN 到 Transformer，线性化兼收并蓄

**RNN 将序列信息压缩至隐藏状态，复杂度低但无法并行训练。**循环神经网络（RNN）与人类的语言理解逻辑类似，注重上下文的顺序及逻辑关系。RNN 将历史序列信息压缩到固定大小的隐藏状态中，输入序列的每一项时更新隐藏状态，模型从输入和上步隐藏状态中提取信息并输出权重。虽然这种方法具有线性复杂度，但对前步结果的依赖限制了模型的可扩展性，使得 RNN 无法并行训练，且在长序列时存在梯度消失现象。

**Transformer 模型引入自注意力机制，性能较为优越，2020 年以来成为主流路径，但计算成本较高。**Transformer 模型的核心为自注意力机制，使得模型自主学习输入序列中不同位置之间的依赖关系，对上下文内容完全没有压缩，但每次推理时都需要跟上下文进行比较，因此具有二次复杂度，且在长序列任务中计算成本高、占用内存多。

**线性化模型兼具 RNN 与 Transformer 模型优点，存在线性注意力与选择性状态空间模型两种实现路径，或成为大模型背景下的破局之道。**目前，线性化模型的代表为 RetNet、RWKV 与 Mamba，RetNet 与 RWKV 为线性注意力方法，Mamba 为选择性状态空间方法。其共同点为通过压缩上下文信息实现线性复杂度，并结合 Transformer 模型可以并行训练的优势，带来了显著的效率提升、落地成本压缩，对大模型的端侧落地及广泛应用具有重要意义。

图表 18：结合 RNN、Transformer 路径的优势，线性化模型将空间复杂度降低为线性

|       | RNN                                                                                                                   | Transformer                                                                                                           | 模型线性化                                                                                    |
|-------|-----------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------|
| 基本思想  | 将历史序列信息压缩到隐藏状态中，模型从输入和隐藏状态中提取信息并输出权重                                                                                  | 采用自注意力机制，使模型自主学习输入序列中不同位置之间的依赖关系                                                                                      | 结合 RNN 和 Transformer 的优势，对历史信息进行压缩，同时可以并行训练                                              |
| 模型架构  |                                    |                                   | <ul style="list-style-type: none"> <li>✓ 线性注意力</li> <li>✓ 选择性状态空间</li> </ul>             |
| 优势    | <ul style="list-style-type: none"> <li>✓ 线性复杂度</li> </ul>                                                             | <ul style="list-style-type: none"> <li>✓ 能够实现高度并行处理</li> <li>✓ 注意力机制使其能够处理长距离依赖关系</li> <li>✓ 模型性能强大，具备可扩展性</li> </ul> | <ul style="list-style-type: none"> <li>✓ 线性复杂度</li> <li>✓ 高度并行化，提高了可扩展性</li> </ul>       |
| 缺陷    | <ul style="list-style-type: none"> <li>✓ 在训练长序列时容易出现梯度消失问题</li> <li>✓ 无法并行计算，可扩展性有限</li> <li>✓ 无法捕捉长距离依赖关系</li> </ul> | <ul style="list-style-type: none"> <li>✓ 具有二次复杂度</li> <li>✓ 长序列任务中计算成本高且占用内存多</li> </ul>                              | <ul style="list-style-type: none"> <li>✓ 限制模型回忆上下文细节的能力</li> <li>✓ 提示工程的重要性增加</li> </ul> |
| 时间复杂度 | $O(1)$                                                                                                                | $O(N)$                                                                                                                | $O(1)$                                                                                   |
| 空间复杂度 | $O(N)$                                                                                                                | $O(N*N)$                                                                                                              | $O(N)$                                                                                   |

注：时间及空间复杂度描述中，N 代表 context 长度  
资料来源：机器之心公众号，中金公司研究部



## 线性注意力模型：以 RWKV 和 RetNet 为例，实现 RNN 与 Transformer 思想的有效融合

线性注意力的基本思想是将 Transformer 自注意力机制中的 Softmax 函数转换为线性表达式，同时引入衰减向量将前步信息压缩为状态矩阵，既能降低计算复杂度，又能保证模型性能。我们将以 RWKV 和 RetNet 为例，对线性注意力的实现方法和效果进行分析。

### RWKV：在 Transformer 时代重塑 RNN，端侧布局的重要参与者

**非 Transformer 开源大模型，致力于打造 AI 时代的开源生态。** RWKV 模型由香港大学物理系毕业的彭博开发，截至 2024 年 1 月，彭博秉持开源理念将模型迭代至 RWKV-6 版本。2023 年彭博与刘潇、孔晴、罗璇联合成立元始智能，其愿景是成为 AI 时代的安卓，目前已开展两轮融资。


**改写 AFT 的线性注意力公式，解决当前架构的局限性。** 2021 年，苹果发布《An Attention Free Transformer》，提出一种不需要注意力机制的 Transformer 模型。RWKV 的开发者彭博对论文中的公式进行改写，添加时间衰减向量  $W$ ，将 AFT 转变为 RNN 形式，将复杂信息量压缩为 1 个 token 加入模型，推理的计算复杂度降为线性增长。同时，RWKV 将 RNN 拆分为多个层级，每层的隐藏状态可以独立用于计算同层的下一个隐藏状态，从而允许模型并行计算，兼具 Transformer 与 RNN 的优点。RWKV 的模型架构由多个 RWKV Block（区块）组成，再由语言建模网络（Language Modeling Head）输出下一个 token 的分布概率。每个区块内均包含时间、通道混合模块。

- ▶ **时间混合（time-mixing）模块：**时间混合模块在不引入二次复杂度的情况下，扮演注意力机制的角色，其主要作用在于整合历史的文本信息并将其加权为隐状态。在推理阶段，RWKV 可以写为 RNN 的递归形式，只依赖当前输入和状态解码，实现  $O(1)$  的时间复杂度，每一步只需要较小的内存和计算量。
- ▶ **通道混合（channel-mixing）模块：**通道混合模块将  $t$  时刻与  $t-1$  时刻状态同时加入时间、通道混合模块融合，以更新状态。通过 Token-shift 的能力，模型得以遍历前序所有层信息。此外，通道混合模块内部设置了“遗忘门”用于遗忘不必要的历史信息，只保留关键信息，同时加强了模型的非线性能力。

**RWKV 的三大核心环节包括：循环、时间衰减和 Token-shift，来捕捉和传播序列信息。**

RWKV 基于 RNN 的算法思路，通过循环结构，以时间传递局部信息和捕捉序列中的复杂信息；此外，通过时间衰减，逐步减小历史信息的影响，隐式引入位置信息；通过 Token-shift 在当前和上一个输入之间线性插值，因此，模型得以聚合和控制输入信息。

**图表 19: RWKV-6 模型架构**



资料来源：GitHub 官网，中金公司研究部

**RWKV-5 多语言能力超过 Mistral, RWKV-6 实现再升级。**此前学术界有研究者尝试将 Transformer 模型改写为 RNN 架构, 皆以性能损失为代价。RWKV 不仅避免了性能的损失, 还在模型规模扩大时呈现出性能超越 Transformer 大模型的趋势。RWKV-5 “Eagle” 7B 在仅训练 1.1T tokens 语料的前提下, 多语言能力显著超过现有的同规模主流 Transformer 模型 (包括 Mistral-7B), 英文能力接近 LLaMa2。而 RWKV-5 在训练过程中并未添加多语言任务数据, 模型的多语言能力完全依靠语言间的迁移实现。2024 年 2 月 9 日, RWKV-6 Finch 1.6B 已完成测试并正式开源。相较于 RWKV-5, RWKV-6 展现出更加强大的多语言能力, 数据相同的情况下 RWKV-6 在角色扮演方面的表现也更加优越。

图表 20: RWKV-5 7B 多语言能力超越 Mistral-7B

| Model                         | params | Tokens    | MultiLang |
|-------------------------------|--------|-----------|-----------|
| RWKV-5 "Eagle" World-v2 ctx4k | 7.52 B | 1.1 T     | 61.4%     |
| RWKV-4 "Dove" World-v1 ctx4k  | 7.52 B | 590 B     | 57.4%     |
| Mistral-7B-v0.1               | 7.24 B | 2 - 7 T ? | 58.2%     |
| Llama-2-7b                    | 6.74 B | 2 T       | 56.6%     |
| falcon-7b                     | 6.92 B | 1.5 T     | 55.8%     |
| mpt-7b-8k                     | 6.65 B | 1T        | 55.6%     |
| open_llama_7b_v2              | 6.74 B | 1T        | 54.0%     |
| RedPajama-INCITE-7B-Base      | 6.86 B | 1T        | 51.2%     |
| pythia-6.9b-v0                | 6.86 B | 300 B     | 50.8%     |

资料来源: RWKV Blog, 中金公司研究部

图表 21: RWKV-5 7B 英文能力接近 LLaMa2

| Model                         | params | Tokens    | LAMBADA<br>ppl | English<br>avg% |
|-------------------------------|--------|-----------|----------------|-----------------|
| Mistral-7B-v0.1               | 7.24   | 2 - 7 T ? | 3.18           | 74.7%           |
| Llama-2-7b                    | 6.74   | 2 T       | 3.40           | 71.0%           |
| falcon-7b                     | 6.92   | 1.5 T     | 3.37           | 70.7%           |
| RWKV-5 "Eagle" World-v2 ctx4k | 7.52   | 1.1 T     | 3.36           | 70.2%           |
| RWKV-4 "Dove" World-v1 ctx4k  | 7.52   | 590 B     | 3.93           | 65.8%           |
| mpt-7b-8k                     | 6.65   | 1T        | 3.29           | 70.5%           |
| open_llama_7b_v2              | 6.74   | 1T        | 3.82           | 69.4%           |
| RedPajama-INCITE-7B-Base      | 6.86   | 1T        | 3.92           | 68.3%           |
| pythia-6.9b-v0                | 6.86   | 300 B     | 4.30           | 65.1%           |

资料来源: RWKV Blog, 中金公司研究部


图表 22: RWKV-6 模型表现

| lm-evaluation-harness          | params | LAMBADA | English | LAMBADA | PIQA  | StoryCloze16 | Hellaswag | WinoGrande | arc_challenge | arc_easy | headQA_en | openbookQA | sciq  | ReCoRD | COPA  | MultiLang | xLBD  | xSC   | xWG   | xCOPA |
|--------------------------------|--------|---------|---------|---------|-------|--------------|-----------|------------|---------------|----------|-----------|------------|-------|--------|-------|-----------|-------|-------|-------|-------|
| model                          | B      | ppl     | avg%    | acc     | acc   | acc          | acc_norm  | acc        | acc_norm      | acc      | acc_norm  | acc_norm   | acc   | em     | acc   | avg%      | acc   | acc   | acc   | acc   |
| pythia-1.4b-v0                 | 1.41   | 6.58    | 58.1%   | 60.4%   | 71.2% | 67.7%        | 50.8%     | 57.0%      | 28.6%         | 57.7%    | 33.3%     | 31.0%      | 85.5% | 81.4%  | 73.0% | 46.7%     | 27.6% | 50.1% | 57.1% | 52.2% |
| RWKV-4 Pile ctx1k              | 1.52   | 6.91    | 58.5%   | 57.4%   | 72.1% | 68.0%        | 52.8%     | 54.7%      | 29.2%         | 60.6%    | 34.8%     | 34.0%      | 84.2% | 77.0%  | 77.0% | 47.8%     | 29.6% | 50.9% | 57.1% | 53.5% |
| RWKV-4 "Dove" World-1 ctx4k    | 1.58   | 6.14    | 58.9%   | 60.1%   | 71.4% | 70.9%        | 51.6%     | 56.8%      | 30.1%         | 59.9%    | 31.8%     | 35.2%      | 85.1% | 77.5%  | 76.0% | 51.2%     | 33.1% | 54.8% | 62.2% | 54.9% |
| RWKV-5 "Eagle" World-2 ctx4k   | 1.58   | 5.11    | 61.8%   | 65.5%   | 71.2% | 72.5%        | 55.0%     | 59.8%      | 33.5%         | 64.3%    | 33.6%     | 36.4%      | 89.7% | 82.7%  | 77.0% | 55.1%     | 39.8% | 56.3% | 66.9% | 57.5% |
| RWKV-6.0 "Finch" World-2 ctx4k | 1.60   | 4.67    | 62.5%   | 66.3%   | 72.3% | 74.1%        | 57.1%     | 59.4%      | 34.1%         | 64.2%    | 34.5%     | 34.6%      | 90.4% | 83.6%  | 79.0% | 56.2%     | 40.9% | 56.7% | 69.0% | 58.1% |
| mamba-1.4b                     | 1.37   | 5.04    | 62.5%   | 64.9%   | 74.2% | 70.8%        | 59.1%     | 61.3%      | 33.0%         | 65.5%    | 36.0%     | 36.4%      | 87.1% | 83.2%  | 78.0% | 51.1%     | 34.6% | 52.7% | 62.7% | 54.5% |
| falcon-rw-1b                   | 1.31   | 7.37    | 62.1%   | 55.0%   | 75.2% | 71.4%        | 61.6%     | 61.0%      | 32.3%         | 63.2%    | 33.3%     | 35.0%      | 89.9% | 84.9%  | 82.0% | 43.0%     | 16.4% | 49.3% | 53.9% | 52.3% |
| Qwen-1.8B                      | 1.84   | 7.68    | 61.7%   | 57.0%   | 73.0% | 73.1%        | 60.3%     | 58.8%      | 34.8%         | 63.8%    | 32.8%     | 33.8%      | 91.9% | 82.2%  | 79.0% | 46.9%     | 21.8% | 52.3% | 59.8% | 53.8% |
| OLMo-1B                        | 1.18   | 7.50    | 61.4%   | 56.3%   | 75.0% | 71.4%        | 62.9%     | 60.0%      | 31.1%         | 63.3%    | 33.1%     | 36.2%      | 86.8% | 83.2%  | 77.0% | 45.1%     | 22.5% | 50.5% | 55.9% | 51.7% |
| TinyLlama-1.1B-step-1431k-3T   | 1.10   | 6.93    | 60.9%   | 58.8%   | 73.3% | 71.0%        | 59.2%     | 59.1%      | 30.1%         | 60.3%    | 32.5%     | 36.0%      | 88.8% | 84.0%  | 78.0% | 49.2%     | 31.2% | 51.5% | 61.1% | 53.0% |
| Sheared-LLaMA-1.3B             | 1.35   | 6.38    | 60.6%   | 61.2%   | 73.6% | 69.7%        | 59.4%     | 58.1%      | 29.1%         | 61.0%    | 31.5%     | 34.4%      | 87.2% | 82.8%  | 79.0% | 48.7%     | 33.1% | 50.8% | 57.8% | 53.2% |
| TransNormerLLM-1B              | 1.02   | 6.51    | 60.2%   | 58.1%   | 71.9% | 67.0%        | 56.5%     | 60.7%      | 35.2%         | 63.6%    | 31.3%     | 36.6%      | 89.8% | 79.6%  | 72.0% | 50.4%     | 35.7% | 50.4% | 62.0% | 53.7% |
| mpt-1b-redpajama-200b          | 1.31   | 7.22    | 59.0%   | 58.0%   | 71.4% | 69.3%        | 53.2%     | 57.3%      | 29.1%         | 60.7%    | 32.1%     | 33.4%      | 85.4% | 83.1%  | 75.0% | 46.8%     | 27.5% | 49.8% | 57.2% | 52.7% |
| bloom-1b7                      | 1.72   | 12.58   | 55.3%   | 46.2%   | 68.7% | 65.9%        | 48.0%     | 56.9%      | 26.9%         | 56.3%    | 32.6%     | 30.0%      | 85.1% | 77.6%  | 70.0% | 49.7%     | 26.7% | 55.2% | 61.8% | 55.1% |

资料来源: RWKV 元始智能公众号, 中金公司研究部

推理效率和成本优势显著, 成为英特尔、联想、联发科、高通等厂商端侧布局的合作伙伴, 大模型端侧落地可期。复杂度方面, RWKV 的累计文本生成时间随序列长度线性增长, 而 Transformer 则呈现平方增长。除性能外, 同等参数下 RWKV 的速度和显存占用较 Transformer 模型都更为优越。据 RWKV 元始智能公众号, RWKV 模型基于推理效率和成本优势目前已适配多种平台, CPU 上支持 Intel 和 AMD, 同时正在适配华为 Atlas 和爱芯元智等厂商。此外, 2023 年 RWKV 曾作为英特尔、联想、联发科、高通的端侧模型合作伙伴出席其新品发布会, 我们认为未来有望充分释放大模型在 PC、手机、汽车等端侧落地的潜力。

图表 23: RWKV 的文本生成时间呈线性增长, 而非二次方增长



资料来源: Peng, Bo et al. "RWKV: Reinventing RNNs for the Transformer Era." Conference on Empirical Methods in Natural Language Processing (2023)., 中金公司研究部

图表 24：RWKV 在全球产业届受到广泛认可



资料来源：RWKV 元始智能公众号，中金公司研究部

图表 25：RWKV 作为端侧模型合作方出现 Intel 发布会




资料来源：RWKV 元始智能公众号，中金公司研究部

## RetNet: Transformer 的继承和部分替代

**RetNet 引入多尺度保持机制替代标准的自注意力机制，实现递推与分块处理。**与 Transformer 模型的标准自注意力机制相比，RetNet 的保持机制具备以下特点：（1）采用位置相关的指数衰减项代替 Softmax 函数，简化计算的同时以指数衰减形式保留前步信息；（2）引入复数空间表达位置信息，取代绝对或相对位置编码，容易转换为递归形式；（3）使用多尺度的衰减率增加模型的表达能力，并利用 GroupNorm（组归一化）的缩放不变性提高数值精度。RetNet 共有三种等价形式，分别为并行、循环和分块：


图表 26：RetNet 的并行结构



注：Q、K、V 分别表示查询（Query）、键值（Key）与内容（Value）；D 矩阵表示指数加权方案；“GN”是 GroupNorm 的缩写。

资料来源：Sun, Yutao et al. "Retentive Network: A Successor to Transformer for Large Language Models." ArXiv abs/2307.08621 (2023): n. pag., 中金公司研究部

图表 27：RetNet 的循环结构



注：Q、K、V 分别表示查询（Query）、键值（Key）与内容（Value）；S 表示状态（State）；“GN”是 GroupNorm 的缩写。

资料来源：Sun, Yutao et al. "Retentive Network: A Successor to Transformer for Large Language Models." ArXiv abs/2307.08621 (2023): n. pag., 中金公司研究部

- **并行结构**：并行结构与 Transformer 相似，但将自注意力机制中的 Softmax 函数替换为线性表示。Transformer 模型中，Softmax 函数的作用在于对序列的不同部分进行加权以及引入非线性。RetNet 引入指数衰减矩阵 D 保留前步信息，同时采用 GroupNorm 运算增强非线性，保留 Transformer 模型并行训练的优势，在训练阶段提高计算效率。
- **循环结构**：循环结构则与 RNN 更为相似。在推理阶段，RetNet 计算当前时间步的输出只依赖于当前的 Q（Query）、K（Key）、V（Value）以及前步的状态矩阵，摒弃了




Transformer 思想中保留所有历史 K、V 的 Token 交互计算模式，在内存和计算方面实现高效的  $O(1)$  推理，使得部署成本和延迟显著降低。

- **分块结构**：分块结构将并行、循环结构进行结合，即将输入序列划分为不同的区块，区块内采用并行编码以提高计算速度，区块间采用循环结构以节省 CPU 内存，使得模型能够执行高效的长序列建模工作。

在保证模型性能的情况下，RetNet 推理速度为 Transformer 模型的 8.4 倍，内存占用减少 70%，有望降低大模型的使用门槛。相较于 Transformer，RetNet 占用的 GPU 内存减少 70%，推理速度高达 8.4 倍，延迟也大幅下降。在模型性能方面，随着模型参数规模扩大，RetNet 的困惑度逐渐下降至低于 Transformer。我们认为，RetNet 有望在保证性能不弱于 Transformer 的情况下，提升模型运行效率，降低大模型的训练与使用门槛，有效促进大模型在应用层及手机、电脑等终端设备上的发展。

图表 28：相较于 Transformer，RetNet 实现低成本训练和良好性能



资料来源：Sun, Yutao et al. "Retentive Network: A Successor to Transformer for Large Language Models." ArXiv abs/2307.08621 (2023): n. pag., 中金公司研究部

## 选择性状态空间模型：以 Mamba 为代表，实现线性复杂度和高吞吐量


2023 年 12 月，来自卡内基梅隆大学和普林斯顿大学的学者发布选择性状态空间模型 Mamba，可以根据内容动态过滤和处理信息，具有线性扩展的优势<sup>3</sup>。测试显示，Mamba 的模型性能与 Transformer 模型相媲美，同时具有高达 5 倍的推理吞吐量。

- **选择机制**：Mamba 通过“参数化 SSM 的输入”设计一个简单的选择机制，使得模型可以过滤掉不相关的信息并永久记住相关信息，可以在固定的状态大小下压缩上下文。
- **硬件感知算法**：为了保证模型在 GPU 上的高效运算，论文设计了一种硬件感知算法，通过扫描来计算模型。在更高速的 SRAM 内存中完成离散化和递归操作后将输出写回 HBM，当输入从 HBM 加载到 SRAM 时不保存中间状态，而是在反向传播中重新计算。
- **模型架构**：将此前的状态空间模型架构设计与 Transformer 的多层感知机模块（该模块主要负责每个位置的特征向量进行非线性变换和组合）进行合并，形成了一种包含选择性状态空间的简单、同质的架构设计。

<sup>3</sup> Gu, Albert and Tri Dao. "Mamba: Linear-Time Sequence Modeling with Selective State Spaces." ArXiv abs/2312.00752 (2023): n. pag.




图表 29: Mamba 模型架构



注: H3 是大多是 SSM 模型的基础模块; MLP 为多层感知机模块


资料来源: Gu, Albert and Tri Dao. "Mamba: Linear-Time Sequence Modeling with Selective State Spaces." ArXiv abs/2312.00752 (2023): n. pag., 中金公司研究部

图表 30: 随序列长度增加, Mamba 与其他模型表现对比



资料来源: Gu, Albert and Tri Dao. "Mamba: Linear-Time Sequence Modeling with Selective State Spaces." ArXiv abs/2312.00752 (2023): n. pag., 中金公司研究部

图表 31: 相较于规模相当的 Transformer 架构, Mamba 具备 5 倍的吞吐量



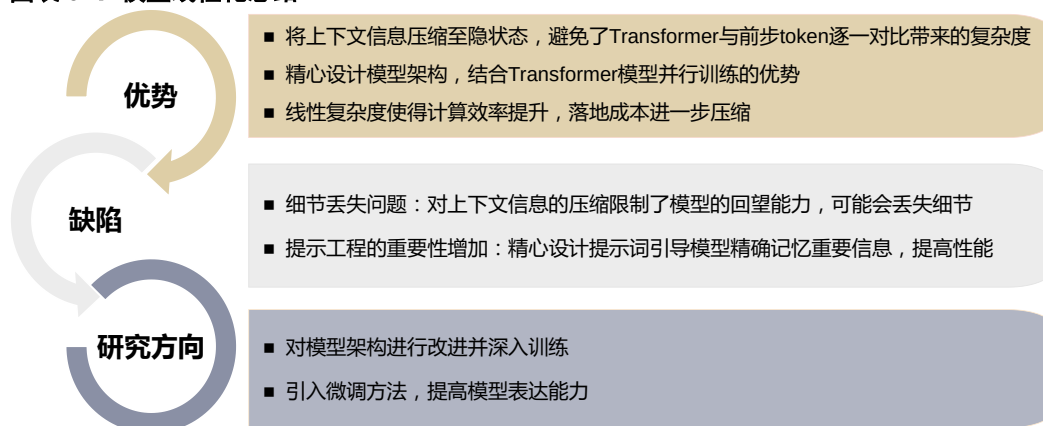
资料来源: Gu, Albert and Tri Dao. "Mamba: Linear-Time Sequence Modeling with Selective State Spaces." ArXiv abs/2312.00752 (2023): n. pag., 中金公司研究部

## 不足及未来方向探讨

线性化路径可能存在丢失细节的缺陷, 提示工程或对任务表现更为关键:

- ▶ **细节丢失问题:** 通过前文分析, 可知线性化的核心思想是将前文信息压缩为隐状态并进行更新, 避免了 Transformer 模型中保持保留全部信息、与前文逐一对比带来的复杂度问题。但这种压缩的方法可能会限制模型对上下文细节的记忆能力, 与完全的自注意力机制相比仍有信息丢失。在实际应用过程中, 需要在计算效率和完备信息之间做出权衡。
- ▶ **提示工程的重要性有所增加:** 提示词 (Prompt) 指用户输入给大模型, 让其完成特定任务的自然语言文本。大模型生成内容时, 会先对输入指示词进行处理, 再根据对提示词的理解预测下一个词出现的概率, 逐字进行输出。因此, 高质量的提示词可以最大化大模型潜力, 引导其精确理解任务。线性化限制了前文的信息传递, 因此精心设计提示词可能对模型在任务上的表现更加关键。

图表 32：模型线性化总结



资料来源：中金公司研究部



## 总结：模型轻量化、线性化对 AI 行业潜在影响

我们认为模型轻量化、线性化趋势在大模型背景下具备重要意义，主要体现在降低算力需求、降低算法成本、释放端侧 AI 的潜力、加速应用层落地等方面：

- ▶ **算力层面，模型轻量化及线性化或将缓解推理算力需求：**算力是大模型研发及应用落地的基座，决定模型上限，自 GPT 引发 AI 浪潮以来英伟达 A100、H100 等芯片供不应求，各厂商的研发资源也主要集中于 GPU 等高性能芯片。虽然单个推理场景对计算性能要求较低，但实际应用过程中仍需要基于大量 GPU 并行计算，我们认为大规模 AI 应用也有望拉动推理成本指数级提升，从而限制应用层落地。通过轻量化及线性化路径，大模型的推理成本有望下降，对算力的需求或涉及更少数量 GPU、甚至 CPU 主体，例如，RWKV 在 CPU 上支持 Intel 和 AMD，在 BF16 的新 Intel 芯片上速度仍然较快。我们认为有望部分抵消推理侧算力供给不足的情况，为 AI 应用落地打开天花板。
- ▶ **算法层面，成本有望进一步降低，市场份额或向拥有高性能轻量化或线性化模型的厂商集中。**当前主流模型仍为 Transformer 大模型，轻量化与线性化仍处于探索进步阶段。我们认为，随着轻量化、线性化模型的性能表现与商业化成熟，其成本与计算效率优势将进一步凸显，加速赋能多种应用场景。此外，我们认为拥有高性能轻量化或线性化模型的厂商市场份额也有望提升。
- ▶ **端侧 AI 视角，短期端侧模型有望基于现有芯片合理利旧，发挥效能；长期或将加速 AI PC、AI 手机更新换代。**短期来看，Transformer 大模型在 PC、手机等终端的部署需要依靠高通 X Elite 等专用 AI 芯片实现，唯有换机方能享受 AI 功能。线性化路径下，大模型可以依靠现有芯片完成端侧落地。我们认为，基于现有端侧芯片，线性化模型有望释放利旧空间，带来端侧 AI 能力的早期渗透。**长期来看**，我们认为 AI 成为 PC 产品创新驱动力，联想、戴尔、惠普和华硕等 PC 厂商陆续发布 AI PC 产品，华为、三星、荣耀等手机厂商纷纷布局 AI 手机并发布相关产品，模型创新带来的端侧 AI 能力也有望进一步强化 AI PC、AI 手机的周期性，加速换机潮的到来。
- ▶ **应用落地视角，我们认为模型轻量化及线性化等趋势有望强化应用层厂商的使用意愿，促进应用层百花齐放。**在 AI 应用落地的过程中，成本、投入产出比是应用层厂商决策的核心要素。我们认为，模型轻量化、线性化等趋势能够显著降低训练及推理成本，或加速应用层的不断创新和生态繁荣。

## 风险提示

**算法落地过程中的内存、微调挑战。**混合专家模型包含多个专家模型和门控网络，需要将所有参数都加载到内存中，对内存要求较高。此外，对其进行微调将更新所有参数，仍需大量计算资源，面临一定挑战。

**提示工程依赖度提升。**线性化路径通过对上下文信息的压缩避免 Transformer 模型与前步信息逐步对比所引致的二次复杂度，因此压缩过程中或将根据提示词对重要信息进行过滤，对提示工程的依赖程度有所提升。

图表 33：可比公司估值表

| 股票代码      | 公司名称  | 财报货币 | 收盘价<br>02-21 | 市值（百万<br>元） | 市盈率     |       |       | 市销率     |       |       |
|-----------|-------|------|--------------|-------------|---------|-------|-------|---------|-------|-------|
|           |       |      |              |             | 2023A/E | 2024E | 2025E | 2023A/E | 2024E | 2025E |
| 600588.SH | 用友网络* | CNY  | 11.79        | 40,304      | N.M.    | 134.1 | 67.4  | 4.1     | 3.6   | 3.1   |
| 300634.SZ | 彩讯股份  | CNY  | 16.82        | 7,532       | 20.0    | 18.6  | 14.6  | 4.9     | 3.8   | 3.0   |
| 688095.SH | 福昕软件* | CNY  | 47.20        | 4,318       | N.M.    | 127.8 | N.M.  | 7.1     | 6.3   | N.M.  |
| 603039.SH | 泛微网络* | CNY  | 38.10        | 9,929       | 122.2   | 48.9  | N.M.  | 3.9     | 3.2   | N.M.  |
| 688369.SH | 致远互联* | CNY  | 23.11        | 2,661       | 34.6    | 15.2  | N.M.  | 2.2     | 1.7   | N.M.  |
| 600570.SH | 恒生电子* | CNY  | 22.64        | 43,016      | 32.0    | 29.3  | 26.1  | 5.9     | 5.3   | 4.8   |
| 300674.SZ | 宇信科技* | CNY  | 12.64        | 8,983       | 21.1    | 16.1  | N.M.  | 1.7     | 1.4   | N.M.  |
| 002230.SZ | 科大讯飞* | CNY  | 45.02        | 104,252     | 152.1   | 146.4 | 130.9 | 5.2     | 4.8   | 4.4   |
| 300253.SZ | 卫宁健康* | CNY  | 6.61         | 14,227      | 34.0    | 20.5  | N.M.  | 3.7     | 3.1   | N.M.  |
| 300451.SZ | 创业慧康* | CNY  | 4.36         | 6,754       | 26.5    | 15.9  | N.M.  | 4.0     | 3.4   | N.M.  |
| 688777.SH | 中控技术* | CNY  | 40.38        | 31,897      | 30.0    | 25.0  | 19.8  | 3.6     | 3.0   | 2.4   |
| 688083.SH | 中望软件* | CNY  | 80.56        | 9,772       | 177.2   | 66.0  | 35.8  | 11.8    | 9.0   | 7.0   |
| 603859.SH | 能科科技* | CNY  | 33.71        | 5,615       | 18.7    | 14.8  | 11.4  | 3.5     | 3.0   | 2.5   |
| 300378.SZ | 鼎捷软件* | CNY  | 16.79        | 4,522       | 36.4    | 26.5  | 17.7  | 2.1     | 1.8   | 1.5   |
| 002315.SZ | 焦点科技* | CNY  | 30.38        | 9,508       | 25.7    | 22.1  | N.M.  | 5.5     | 4.8   | N.M.  |
| 688365.SH | 光云科技* | CNY  | 7.40         | 3,151       | N.M.    | N.M.  | N.M.  | 6.0     | 5.3   | N.M.  |
| 300687.SZ | 赛意信息* | CNY  | 17.08        | 7,005       | 25.0    | 21.6  | 18.6  | 2.8     | 2.5   | 2.3   |
| 300496.SZ | 中科创达* | CNY  | 53.94        | 24,813      | 30.7    | 30.5  | N.M.  | 4.3     | 3.9   | N.M.  |
| 00020.HK  | 商汤-W* | CNY  | 0.91         | 28,010      | N.M.    | N.M.  | N.M.  | 6.5     | 5.6   | N.M.  |

注：标\*公司为中金覆盖，采用中金预测数据；其余使用市场一致预期

资料来源：Wind，彭博资讯，公司公告，中金公司研究部



## 作者信息



**于钟海 分析员**

SAC 执证编号: S0080518070011  
SFC CE Ref: BOP246  
zhonghai.yu@cicc.com.cn



**魏黔霏 分析员**

SAC 执证编号: S0080523060019  
SFC CE Ref: BSX734  
guanfei.wei@cicc.com.cn



**王之昊 分析员**

SAC 执证编号: S0080522050001  
SFC CE Ref: BSS168  
zhihao3.wang@cicc.com.cn



**游航 分析员**

SAC 执证编号: S0080523010001  
SFC CE Ref: BTI822  
hang.you@cicc.com.cn



**CICC**  
**中金公司**

## 法律声明

### 一般声明

本报告由中国国际金融股份有限公司（已具备中国证监会批复的证券投资咨询业务资格）制作。本报告中的信息均来源于我们认为可靠的已公开资料，但中国国际金融股份有限公司及其关联机构（以下统称“中金公司”）对这些信息的准确性及完整性不作任何保证。本报告中的信息、意见等均仅供投资者参考之用，不构成对买卖任何证券或其他金融工具的出价或征价或提供任何投资决策建议的服务。该等信息、意见并未考虑到获取本报告人员的具体投资目的、财务状况以及特定需求，在任何时候均不构成对任何人的个人推荐或投资操作性建议。投资者应当对本报告中的信息和意见进行独立评估，自主审慎做出决策并自行承担风险。投资者在依据本报告涉及的内容进行任何决策前，应同时考量各自的投资目的、财务状况和特定需求，并就相关决策咨询专业顾问的意见对依据或者使用本报告所造成的一切后果，中金公司及/或其关联人员均不承担任何责任。

本报告所载的意见、评估及预测仅为本报告出具日的观点和判断，相关证券或金融工具的价格、价值及收益亦可能会波动。该等意见、评估及预测无需通知即可随时更改。在不同时期，中金公司可能会发出与本报告所载意见、评估及预测不一致的研究报告。

本报告署名分析师可能会不时与中金公司的客户、销售交易人员、其他业务人员或在本报告中针对可能对本报告所涉及的标的证券或其他金融工具的市场价格产生短期影响的催化剂或事件进行交易策略的讨论。这种短期影响的分析可能与分析师已发布的关于相关证券或其他金融工具的目标价、评级、估值、预测等观点相反或不一致，相关的交易策略不同于且也不影响分析师关于其所研究标的证券或其他金融工具的基本面评级或评分。

中金公司的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。中金公司没有将此意见及建议向报告所有接收者进行更新的义务。中金公司的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见不一致的投资决策。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现。过往的业绩表现亦不应作为日后回报的预示。我们不承诺也不保证，任何所预示的回报会得以实现。分析中所做的预测可能是基于相应的假设。任何假设的变化可能会显著地影响所预测的回报。

本报告提供给某接收人是基于该接收人被认为有能力独立评估投资风险并就投资决策能行使独立判断。投资的独立判断是指，投资决策是投资者自身基于对潜在投资的目标、需求、机会、风险、市场因素及其他投资考虑而独立做出的。

本报告由受香港证券及期货事务监察委员会监管的中国国际金融香港证券有限公司（“中金香港”）于香港提供。香港的投资者若有任何关于中金公司研究报告的问题请直接联系中金香港的销售交易代表。本报告作者所持香港证监会牌照的牌照编号已披露在报告首页的作者姓名旁。

本报告由受新加坡金融管理局监管的中国国际金融（新加坡）有限公司（“中金新加坡”）于新加坡向符合新加坡《证券期货法》定义下的合格投资者及/或机构投资者提供。本报告无意也不应直接或间接地分发或传递给新加坡的任何其他人。提供本报告于合格投资者及/或机构投资者，有关财务顾问将无需根据新加坡之《财务顾问法》第 45 条就任何利益及/或其代表就任何证券利益进行披露。有关本报告之任何查询，在新加坡获得本报告的人员可联系中金新加坡持牌代表。

本报告由受金融行为监管局监管的中国国际金融（英国）有限公司（“中金英国”）于英国提供。本报告有关的投资和服务仅向符合《2000 年金融服务和市场法 2005 年（金融推介）令》第 19（5）条、38 条、47 条以及 49 条规定的人士提供。本报告并未打算提供给零售客户使用。在其他欧洲经济区国家，本报告向被其本国认定为专业投资者（或相当性质）的人士提供。

本报告由中国国际金融日本株式会社（“中金日本”）于日本提供，中金日本是在日本关东财务局（日本关东财务局长（金商）第 3235 号）注册并受日本法律监管的金融机构。本报告有关的投资产品和服务仅向符合日本《金融商品交易法》第 2 条 31 项所规定的专业投资者提供。本报告并未打算提供给日本非专业投资者使用。

本报告亦由中国国际金融股份有限公司向符合日本《金融商品交易法施行令》第 17 条第 3 款第 1 项及《金融商品交易法》第 58 条第 2 款但书前段所规定的日本金融机构提供。在该情形下，本报告有关的投资产品和服务仅向日本受监管的金融机构提供。

本报告将依据其他国家或地区的法律法规和监管要求于该国家或地区提供。

#### 特别声明

在法律许可的情况下，中金公司可能与本报告中提及公司正在建立或争取建立业务关系或服务关系。因此，投资者应当考虑到中金公司及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。

与本报告所含具体公司相关的披露信息请访问 <https://research.cicc.com/footer/disclosures>，亦可参见近期已发布的关于该等公司的具体研究报告。

#### 中金研究基本评级体系说明：

分析师采用相对评级体系，股票评级分为跑赢行业、中性、跑输行业（定义见下文）。

除了股票评级外，中金公司对覆盖行业的未来市场表现提供行业评级观点，行业评级分为超配、标配、低配（定义见下文）。

我们在此提醒您，中金公司对研究覆盖的股票不提供买入、卖出评级。跑赢行业、跑输行业不等同于买入、卖出。投资者应仔细阅读中金公司研究报告中的所有评级定义。请投资者仔细阅读研究报告全文，以获取比较完整的观点与信息，不应仅仅依靠评级来推断结论。在任何情形下，评级（或研究观点）都不应被视为或作为投资建议。投资者买卖证券或其他金融产品的决定应基于自身实际具体情况（比如当前的持仓结构）及其他需要考虑的因素。

#### 股票评级定义：

- 跑赢行业（OUTPERFORM）：未来 6~12 个月，分析师预计个股表现超过同期其所属的中金行业指数；
- 中性（NEUTRAL）：未来 6~12 个月，分析师预计个股表现与同期其所属的中金行业指数相比持平；
- 跑输行业（UNDERPERFORM）：未来 6~12 个月，分析师预计个股表现不及同期其所属的中金行业指数。

#### 行业评级定义：

- 超配（OVERWEIGHT）：未来 6~12 个月，分析师预计某行业会跑赢大盘 10%以上；
- 标配（EQUAL-WEIGHT）：未来 6~12 个月，分析师预计某行业表现与大盘的关系在-10%与 10%之间；
- 低配（UNDERWEIGHT）：未来 6~12 个月，分析师预计某行业会跑输大盘 10%以上。

研究报告评级分布可从<https://research.cicc.com/footer/disclosures> 获悉。

本报告的版权仅为中金公司所有，未经书面许可任何机构和个人不得以任何形式转发、翻版、复制、刊登、发表或引用。

V190624  
编辑：张莹



### 北京

中国国际金融股份有限公司  
中国北京建国门外大街 1 号  
国贸写字楼 2 座 28 层  
邮编: 100004  
电话: (86-10) 6505 1166  
传真: (86-10) 6505 1156

### 深圳

中国国际金融股份有限公司深圳分公司  
深圳市福田区益田路 5033 号  
平安金融中心 72 层  
邮编: 518048  
电话: (86-755) 8319-5000  
传真: (86-755) 8319-9229

### 东京

中国国际金融日本株式会社  
〒100-0005 東京都千代田区丸の内 3 丁目 2 番 3 号  
丸の内二重橋ビル 2 1 階  
Tel: (+813) 3201 6388  
Fax: (+813) 3201 6389

### 纽约

CICC US Securities, Inc  
32<sup>nd</sup> Floor, 280 Park Avenue  
New York, NY 10017, USA  
Tel: (+1-646) 7948 800  
Fax: (+1-646) 7948 801

### 伦敦

China International Capital Corporation (UK)  
Limited  
25th Floor, 125 Old Broad Street  
London EC2N 1AR, United Kingdom  
Tel: (+44-20) 7367 5718  
Fax: (+44-20) 7367 5719

### 上海

中国国际金融股份有限公司上海分公司  
上海市浦东新区陆家嘴环路 1233 号  
汇亚大厦 32 层  
邮编: 200120  
电话: (86-21) 5879-6226  
传真: (86-21) 5888-8976

### 香港

中国国际金融（香港）有限公司  
香港中环港景街 1 号  
国际金融中心第一期 29 楼  
电话: (852) 2872-2000  
传真: (852) 2872-2100

### 旧金山

CICC US Securities, Inc. San Francisco Branch  
Office  
One Embarcadero Center, Suite 2350,  
San Francisco, CA 94111, USA  
Tel: (+1) 415 493 4120  
Fax: (+1) 628 203 8514

### 新加坡

China International Capital Corporation  
(Singapore) Pte. Limited  
6 Battery Road, #33-01  
Singapore 049909  
Tel: (+65) 6572 1999  
Fax: (+65) 6327 1278

### 法兰克福

China International Capital Corporation (Europe)  
GmbH  
Neue Mainzer Straße 52-58, 60311  
Frankfurt a.M, Germany  
Tel: (+49-69) 24437 3560