

人工智能十年展望（十七）：大模型兴起之后，多模态涌现之前



于钟海 分析员

SAC 执证编号：S0080518070011
SFC CE Ref: BOP246
zhonghai.yu@cicc.com.cn



王之昊 分析员


SAC 执证编号：S0080522050001
SFC CE Ref: BSS168
zhihao3.wang@cicc.com.cn



魏鹤霏 分析员

SAC 执证编号：S0080523060019
SFC CE Ref: BSX734
guanfei.wei@cicc.com.cn

纵轴：相对值（%）



中金一级行业：科技

资料来源：Wind，彭博资讯，中金公司研究部

- 软件及服务 | 人工智能十年展望（十六）：成本决定落地节奏，大模型轻量化、线性化趋势渐起 (2024.02.23)
- 软件及服务 | AI动态跟踪：从OpenAI Sora看视频生成模型技术进展 (2024.02.19)
- 软件及服务 | 人工智能十年展望（十五）：AI Agent：远期场景闭环，交互重塑 (2023.12.18)
- 软件及服务 | AI动态跟踪：多模态模型和应用涌现，24年产业进展的下一“高地” (2023.12.04)
- 软件及服务 | 人工智能十年展望（十三）：AI应用商业化的“成败之论” (2023.10.09)

更多作者及其他信息请见文末披露页

观点聚焦

投资建议

近年来，以GPT为代表的大模型在语言领域取得了重大突破，人类探索AGI的路径初见曙光。而在大模型兴起之后，产业也试图在图像、视频、音频等更多模态领域复现“Scaling Law”的成功，继续实现大模型的“智能涌现”。本文中我们从技术脉络、产业趋势、应用展望等多个角度，遍历海外和国内的一二级进展，对多模态这一方向进行全面的阐释分析，我们看好在全球AI浪潮延续，期待攻克多模态这一AI产业发展的下一个高地。

理由

多模态是迈向通用人工智能的“必经之路”。多模态的本质要利用视觉、听觉、触觉、味觉等语言之外更加丰富的感知通道，去模拟人类理解与表达信息的能力。理想中的多模态大模型具备跨模态的泛化理解和生成能力，其更符合人类感知世界的方式，我们认为其或能进一步打开AI能力的上限。产业界也在积极探索多模态大模型可行的技术路径，在多模态领域“复刻”大语言模型的成功。但目前多模态大模型的技术栈也尚未收敛，多模态学习和跨模态对齐仍为技术难点，未来产业发展仍有无限可能。

产业探索步步为营，视觉等模态领域进展不断。图像方面，技术路径已经逐步成熟，扩散模型成为图像生成领域的主流架构，而后产业界也开始将Transformer架构引入，产生了ViT、DiT等扩展性更好的生成模型，过去数年产业界也已诞生多款文生图流行应用；**视频**方面，文生视频基于文生图像的技术路线，而今年年初Sora的出现也在视频领域延续了DiT架构与“Scaling Law”的成功；**音频**方面，Transformer加持下的语音合成技术发展也更趋成熟；**3D模型**方面，初期探索下技术方向已逐渐清晰，我们认为3D生成也可能成为未来视觉多模态领域取得突破性进展的下一场景。

多模态AI进展带来更多应用场景的全新可能。自动驾驶领域，多模态模型具备零样本学习（zero-shot）等泛化能力，我们认为其或能加速多模态模型和世界模型在学术界的前沿探索；**AI Agent**领域，我们认为多模态进展能够为AI Agent带来更为丰富的信息感知来源与任务处理范式，也是其未来大规模商业化落地的前提条件；**具身智能**领域，我们认为多模态AI迭代有望进一步提升机器人的感知决策能力，结合伺服驱动和运动控制技术的提升，加速人形机器人的产业化落地。

盈利预测与估值

我们持续看好全球AI产业浪潮，并判断多模态可能是未来数年大模型产业技术突破和产业催化较为集中的领域，建议重点关注相关产业趋势进展。

风险

技术进展不及预期；应用落地不及预期；行业竞争加剧。

目录

多模态：迈向通用人工智能的“必经之路”	5
如何理解多模态大模型的意义和价值？	5
产业界对于多模态大模型的探索有何进展？	7
图像：技术路径收敛，应用百花齐放	12
技术演进：源起 CNN，扩散模型为主流生图架构	12
公司巡礼：文生图底层能力来源，应用百花齐放	18
视频：优化时序对齐，生成效果突破	23
技术基础：图片生成模型叠加时序对齐实现视频生成	23
模型改良：Transformer 代替 U-Net，模型可拓展性大幅增强	25
公司巡礼：2023 年以来应用快速涌现，商业化仍处于早期	30
语音：Transformer 加持，AI 配音兴起	33
技术前沿：Transformer 加持下的语音合成发展更趋成熟	33
公司巡礼：AI 赋予语音产业新机会，竞争者差异化布局	34
3D：产业持续探索，方向初见端倪	37
3D 生成任务要素：数据表征、数据集、生成模型、应用	37
产业进展：海内外前沿 3D 生成工作介绍	38
应用展望：多模态 AI 典型创新应用场景概览	40
自动驾驶：大模型赋能多模态与世界模型学术研究	40
Agent：以多模态信息为感知基础，打造远期场景闭环	42
具身智能：多模态 AI 迭代有望进一步提升机器人的感知决策能力	44
附录：国内多模态 AI 相关创业公司巡礼	47
风险提示	52

图表

图表 1：多模态是大模型通往 AGI 发展的“必经之路”	5
图表 2：多模态大模型应当能够实现“Any-to-Any”的多模态、跨模态生成	6
图表 3：产学研界旨在多模态领域“复刻”LLM 语言大模型的成功	7
图表 4：多模态大模型的一种典型架构	8
图表 5：多模态大模型领域的技术栈尚未收敛	9
图表 6：Gemini 支持文本、图像、音频和视频输入，支持输出图像和文本输出	9
图表 7：Code-2 能够实现复杂的多模态交互生成	10
图表 8：典型的多模态领域——视觉场景近年来的主要工作概览	11
图表 9：扩散模型已成为目前多模态图像技术的主流路线	12
图表 10：CNN 通过卷积层和池化层提取图像的特征，再通过全连接层进行分类	13
图表 11：2012 年吴恩达团队利用 1.6 万个 CPU 耗时三天生成的猫脸图像	13
图表 12：VAE 通过学习数据的潜在空间分布来生成新的数据	13
图表 13：GAN 采用“对抗游戏”框架训练，旨在生成高质量、高分辨率的图像	13
图表 14：CycleGAN 无需配对样本数据，即可实现不同图像之间风格的转换	14
图表 15：ViT 模型架构与原始 Transformer 差异在于以图像替代自然语言作为输入	14
图表 16：OpenAI 通过 4 亿组图像文本对进行训练，CLIP 可以“理解”图像的内容并将其与文本描述强关联	14

图表 17: Diffusion model 包含扩散及逆扩散两个过程.....	15
图表 18: LDMs 在潜空间上扩散提高生图效率	15
图表 19: SDXL 将 U-Net 主干扩大三倍.....	16
图表 20: SDXL 在 A100 GPU 上, 生成一张 512x512 的图像仅需 3 秒.....	16
图表 21: Diffusion Transformer (DiT)体系架构.....	16
图表 22: DALL-E 3 新增“图像字幕器”(image captioner), 生成细节丰富的图-文描述	17
图表 23: CLIP 验证发现数据集中 95%的 AI 合成文本描述+5%图像使用人工描述时, 训练效果最好	17
图表 24: 人工评估方法下, DALL-E3 表现突出.....	17
图表 25: 相同提示词下, DALL-E 系列文生图效果演进	18
图表 26: DALL-E3 严格遵照用户的文本指令产生图片	19
图表 27: DALL-E 系列的 API 选择种类多样	19
图表 28: Midjourney 模型在细节刻画与光影处理方面不断进步	19
图表 29: Midjourney 会员定价在 10-120 美元/月不等, 截至 2024 年 3 月	20
图表 30: Firefly image 2 可给出 5 组提示词优化建议.....	20
图表 31: 商汤秒画实现提示词补全功能, 图像质量提升	21
图表 32: “式说”大模型以生图能力有效辅助工业 CAD 设计	22
图表 33: 2023 年视频生成类 AI 大模型和产品进度, 4Q23 以来论文和应用快速涌现	23
图表 34: 基于扩散模型的文生视频模型主要文献	23
图表 35: VDM 模型的 3D U-Net 架构.....	24
图表 36: 通过加入时间注意层和 3D 卷积层, 实现时序对齐	24
图表 37: 同一视频的不同帧之间的噪声具备关联关系	25
图表 38: W.A.L.T.模型首次在视频生成领域将 Transformer 与扩散模型整合	26
图表 39: VideoPoet 模型架构.....	27
图表 40: Sora 可能的模型架构.....	27
图表 41: Sora 展现了明显的可拓展性 (Scalable), 伴随训练计算量增加而性能明显提升.....	28
图表 42: Sora 将视频单元划分为 Patches, 实现类似 LLM 模型中的 Tokens 角色.....	29
图表 43: Sora 本质是扩散模型, 通过 Transformer 去噪生成“干净”的 Patches	29
图表 44: 主要 AI 视频生成类应用, 截至 2023 年底	30
图表 45: SVD 模型的文生视频功能.....	31
图表 46: SVD 的 3D 视角合成功能.....	31
图表 47: Pika 视频风格转换功能 (转换前)	31
图表 48: Pika 视频风格转换功能 (转换后)	31
图表 49: Pika 的拓展画布功能	32
图表 50: Pika 的指定区域编辑功能	32
图表 51: Gen-2 运动笔刷功能演示之一.....	32
图表 52: Gen-2 运动笔刷功能演示之二.....	32
图表 53: 深度学习驱动当前语音技术快速发展, Transformer 成为主流路线	33
图表 54: Whisper 词错率 (WER) 受噪音影响最小	34
图表 55: 音频语言模型仿照语言模型进行序列预测.....	34
图表 56: ElevenLabs AI 视频翻译工具操作便捷	35
图表 57: 星火语音大模型达到国际领先水平	36
图表 58: 讯飞听见等应用拥有千万级活跃用户.....	36
图表 59: 3D 生成领域涵盖 3D 表示、3D 生成模型、数据集、应用	37
图表 60: Instant3D 模型架构.....	38
图表 61: DreamFusion 技术架构图.....	39

图表 62: NeRF 训练过程.....	39
图表 63: 大语言模型和多模态大模型在智能驾驶领域的代表性应用	40
图表 64: DriveDreamer 整体架构概览.....	41
图表 65: AI Agent = Brain 控制端 + Perception 感知端 + Action 行动端	42
图表 66: AI Agent 的工作示例.....	42
图表 67: AI Agent 感知端: 感知并处理来自外部环境的多模态信息	43
图表 68: 软件架构从过程导向迁移到目标导向, 长期有望迎来 Agent-Centric 时代.....	43
图表 69: 人形机器人核心技术	44
图表 70: 机器人领域的基础大模型.....	45
图表 71: PaLM-E 模型架构	45
图表 72: TD-MPC2 展示出可拓展性 (Scalable), 在多任务控制中表现优异.....	46
图表 73: CogView3 效果超越 Stable diffusion XL, 相比 DALL-E3 约在 91.4% ~99.3%的水平之间	47
图表 74: GLM-4 文生图模型 CogView3 可以做到高精度的 prompt 理解和遵循, 支持连续指令修改生图	47
图表 75: ChatImg 具备较强的图片和视频理解功能.....	48
图表 76: 生数科技多模态模型覆盖 2D、3D 与视频生成	49
图表 77: PixWeaver 对语义细节的遵循准确度较高	49
图表 78: 出门问问 TTS 引擎已迭代至第六代	49
图表 79: 魔音工坊首创“捏声音”功能	50
图表 80: 云知声全栈技术架构及产业化体系	50
图表 81: MiniMax 语音大模型产品架构.....	51
图表 82: MiniMax 三类语音 API 价格下调至 5 元/万字符, 截至 2024 年 1 月	51
图表 83: 可比公司估值表	52


多模态：迈向通用人工智能的“必经之路”

如何理解多模态大模型的意义和价值？

多模态的本质是利用更加丰富的感知通道，去模拟人类理解与表达信息的能力。多模态是指通过结合多种感知通道，例如视觉、听觉、触觉、味觉等，来对信息进行理解和处理。人类的智能即是用多模态的方式来进行信息和交互处理的，因此在人工智能领域，产业也在探索一种能够处理多种类型数据（包括文本、图像、音频和视频）的多模态人工智能模型，进而更好地去模拟人类的智能，实现 AGI 通用人工智能。

多模态打开 AI 模型能力的“上限”，是由 LLM 语言大模型迈向 AGI 的“必经之路”。近一年多以来，以 GPT 为代表的 LLM 自然语言大模型在自然语言领域取得了较大成果，人工智能在语言文字领域的通用泛化能力取得突破，同时出现一定的智能“涌现”的迹象。但在现实世界中，人类智能处理的更多的信息量是还以视觉、听觉、触觉等其他模态存在的，我们认为在未来长期通往 AGI 的道路中，能够支持对于多种模态通用泛化的输入输出是未来 AGI 需要具备的必要能力。

图表 1：多模态是大模型通往 AGI 发展的“必经之路”



资料来源：Jina AI，中金公司研究部

产学研界旨在多模态领域“复刻”大模型在语言的成功。在过去数年中，以 Transformer 作为架构核心的 LLM 已经在文字模态领域取得了显著成果，“Scaling Law”持续得到验证，大模型在语言领域呈现出了初步“智能涌现”的特征；因此产业也开始愈发关注如何基于在语言单模态领域 LLM 的成功经验，将 Transformer 引入至图像、视频等更多模态的任务场景中，充分发挥 Transformer 大模型的可扩展性，使“Scaling Law”能够在更多的模态领域得以发挥，最终在多模态领域复现出 LLM 大模型的“智能涌现”。


理想中的多模态大模型应呈现哪些形态与特征？我们认为其首先是要多模态且具备跨模态的泛化能力，即在训练端模型是基于文字、图像、视频、音频等多种模态训练，具备对于多种不同模态的感知和推理能力，即能够实现“Any-to-Any”的多模态、跨模态的输入和输出；并且需要具有 LLM 大模型“智能涌现”的特征，即能够充分发挥 Transformer 大模型的可扩展性，在达到一定的参数量规模后，能够“涌现”出一定的泛化多模态理解及生成能力，具备一定的 Zero/Few Shot 推理、上下文学习、CoT 思想链等更高阶的模型智能表现特征。而如何去构建、训练符合以上特征目标的 MLLM 多模态大模型在近年来也已成为了人工智能产学研界的一大热点。

图表 2：多模态大模型应当能够实现“Any-to-Any”的多模态、跨模态生成



- ▶ **多模态大模型更符合人类感知世界的方式，具备处理更为复杂任务的可能。**人类的智能是接受多种感官模态的输入并进行输出，而多种模态之间的跨模态混合交互也起到了互补的作用，进而产生了更高维度的“智能”来处理更为复杂的任务。而多模态大模型就是要在训练、输入、输出数据的模态丰富度上与人类智能进一步对齐，进而力求实现更高维度的智能“涌现”，以及处理更为通用、泛化的复杂任务的能力。
- ▶ **多模态大模型具有更为丰富的学习数据来源，具有进一步突破能力上限的机会。**单模态语言大模型仅基于人类的文字语料进行训练，其数据来源有限且正处在迅速的学习消耗过程中。但多模态大模型可以利用自然界中天然存在的更为丰富的图像、声音等数据与信息进行训练，我们认为其“智能”的上限在理论上或将高于单模态大模型。
- ▶ **多模态大模型在交互上更贴近人类的习惯，提供更优化的大模型使用体验。**单模态语言模型在交互方式上较为单一，而多模态大模型能够对多种类型的输入进行支持，用户也得以以更加灵活便捷的方式与模型进行交互操作，达到更为友好的使用体验。

图表 3：产学研界旨在多模态领域“复刻” LLM 语言大模型的成功



资料来源：《Multimodal Foundation Models: From Specialists to General-Purpose Assistants》(Tang et al., 2023)，中金公司研究部

产业界对于多模态大模型的探索有何进展？


如何去“学习”多种模态的特征以及模态之间隐含的关系是构建多模态大模型的重点。在构建和训练多模态大模型时，本质上是把多种不同的模态在一致的特征向量空间中进行表征，进而让模型能够对不同模态隐含的特征以及不同模态之间隐含的关系进行学习。在这一过程中，需要找到更合适的对于各种模态信息的特征表达，以及让模型训练出更合适的将不同的模态特征映射至一致的向量空间中的投影方法，进而让模型达到更好的推理效果，最终实现多模态领域的“智能涌现”。

多模态大模型的一种典型架构：各模态的编解码器+投影/压缩网络+生成网络。对于多模态大模型的架构，过去数年来产业界也尝试了多种路线的探索，其中一种较为典型的架构如下图所示，主要由三部分构成。

- **文字、图像、视频等多种模态的编解码器（多模态信息的感知和抓取）**，编码器负责将输入的多模态信息转换成特征表示，进而能够让模型对输入的信息进行理解。由于编码器的类型可以有多种不同的选取方式，因此其转换出的特征表示的形式和维度仍存在区别，实际上是处于不同的向量空间中；解码器则负责在最后将前部分模型输出的特征表示解码还原成文字、图像、视频等不同类型的模态信息，最终得到模型输出。
- **投影/压缩网络（多模态信息的对齐和交互）**，多模态大模型需要对不同模态的特征进行理解 and 处理，因此在不同模态的输入信息通过编码器得到特征表示后，还需要通过中间层的投影/压缩网络进行处理，使得不同模态的特征能够在一致的向量空间中进行表征，进而能够让后续的生成网络进行统一处理。同理在生成网络输出向量特征后，也需要对其进行反解，将其解压缩并还原至原有的向量空间中。

- **生成网络**，其处于多模态大模型的中间部分，负责将不同模态信息的特征表示在统一的向量空间中进行处理，进而达到模型预设的多模态任务训练目标。目前产业界的许多工作是希望将大模型在语言领域“Scaling Law”的成功在多模态领域复现，因此目前很多多模态大模型中的生成网络都是由 Transformer 来担当。


图表 4：多模态大模型的一种典型架构



资料来源：《NExT-GPT: Any-to-Any Multimodal LLM》(Wu et al., 2023)，中金公司研究部

多模态大模型领域的技术栈尚未收敛。实际上目前产业界在多模态大模型的架构路线上也仍存在一定分歧，比如有一些路线是采用“**全 Token 化的方式**”，即直接将文字、图像、视频等不同的模态信息特征都进行 Token 化，在 LLM 能够一致处理的向量空间中进行表征，进而用 Transformer 进行统一处理。但也有一些路线是对于不同的模态选取不同的方式进行特征提取和处理，再通过**训练多模态转换器或者感知器**，对特征表示进行投影，进而让预训练好的 LLM 对图像、视频等其他模态特征进行感知和处理。总体来看，产业界对于多模态大模型的技术路线探索尚未成熟收敛，不同的路线都有大量的工作正在尝试进行中。


图 5：多模态大模型领域的技术栈尚未收敛



资料来源：《How to Bridge the Gap between Modalities: A Comprehensive Survey on Multimodal Large Language Model》(Song et al., 2023)，中金公司研究部

多模态大模型的探索案例：Google Gemini，打造原生多模态大模型。2023 年 12 月，谷歌发布多模态大模型 Gemini 系列，谷歌直接使用图像、音频、视频和文本等多模态数据对 Gemini 模型进行预训练，并使用额外的多模态数据微调（即“原生”多模态），使其具备泛化理解与推理能力，可以跨模态理解和推理不同模态类型的信息。目前 Google Gemini 已经迭代至 Pro 1.5，并公开发布 Ultra 1.0 版本，现版本已经能够支持文本和图像等模态数据的输入及输出，其 Ultra 版本也已经开始向用户进行收费（每月 20 美元）。


图 6：Gemini 支持文本、图像、音频和视频输入，支持输出图像和文本输出



资料来源：Gemini 技术报告，中金公司研究部

多模态大模型的探索案例：CoDi-2，多模态融合生成领域的最新进展。CoDi（Composable Diffusion，可扩散生成模型）是 2023 年 5 月北卡大学教堂山分校与微软联合提出的一种在统一多模态领域的尝试，2023 年 12 月 UC Berkeley、微软、北卡教堂山分校等诸多研究机构发布了其迭代后的新版本 CoDi-2。CoDi-2 能够接受复杂的多模态交错上下文指令，以 zero-shot 交互的形式生成任何模态（文本、视觉、音频）。比如 CoDi-2 可以实现文+图+图生成图（学习图片 A 和风格，结合语言指令和图片 B，生成一张新的图片）；文+声+图生成图（学习声音中隐含的信息，结合语言指令和图片，生成一张新的图片）；文+图+图生成声（学习两张图片之间的关联，结合语言指令生成声音）。

图表 7：Code-2 能够实现复杂的多模态交互生成



资料来源：《CoDi-2: In-Context, Interleaved, and Interactive Any-to-Any Generation》(Zineng Tang, Ziyi Yang, Mahmoud Khademi, Yang Liu, Chenguang Zhu, Mohit Bansal, UC Berkeley, Microsoft Azure AI, Zoom, UNC Chapel Hill, 2023)，中金公司研究部

多模态大模型的探索并非一蹴而就，近年来产业聚焦在视觉等重点模态领域逐步突破。对于我们上文所提到的理想中的“Any-to-Any”大模型，Google Gemini、Codi-2 等均是处于探索阶段的方案，其最终技术方案的成熟还需要在各个模态领域的路线跑通，实现多模态知识学习，跨模态信息对齐共享，进而实现理想中多模态大模型。现阶段产业主要的工作还是聚焦在视觉等典型的重点模态，试图将 Transformer 大模型架构进一步在图像、视频、3D 模型等模态领域引入使用，完善各个模态领域的感知和生成模型，再进一步实现更多模态之间的跨模态打通和融合。

- **图像：**早在 2023 年 LLM 的流行之前，过去产业界在对于图像的理解和生成模型领域已经打下了坚实的基础，其中也产生了 CLIP、Stable Diffusion、GAN 等典型的模型成果，孕育出了 Midjourney、DALL·E 等成熟的文生图应用。而更进一步，产业界也在积极探索将 Transformer 大模型引入图像相关任务领域（ViT，Vision Transformer；DiT，Diffusion Transformer），探索统一视觉大模型的建立，以及将 LLM 大语言模型与视觉模型进行更加密切的融合，包括近年来的 GLIP、SAM、GPT-V 都是其中的重点成果。
- **视频：**由于视频本质上是由很多帧的图像叠加而成，因此本质上语言与视频模态的融合和语言和图像具有相当多的互通之处，产业界也在尝试将图像生成模型迁移到视频生成，先基于图像数据进行训练，再结合时间维度上的对齐，最终实现文生视频的效果。其中近年来也产生了 VideoLDM、W.A.L.T.等典型的成果，并在近期也出现了 Sora 这样具有明显突

破性效果的模型，其在视频生成领域沿用了 Diffusion Transformer 架构，并在视频类场景首次呈现出“智能涌现”的迹象。

- **3D 模型**：实际上 3D 是由 2D+空间信息构成，因此类似于由图像生成到视频生成的延伸，2D 图片的生成方法理论上也可以迁移到 3D 中。近年来产业界也在积极探索将图像领域的 GAN、自回归、Diffusion、VAE 等骨干模型在 3D 模型生成任务中的扩展，其中也产生了 3D GAN、MeshDiffusion、Instant3D 等重点模型成果。但相比图像和视频生成，目前的 3D 模型生成技术还处于早期发展阶段，相关模型的成熟度仍有较大提升空间。
- **音频**：语音相关的 AI 技术在过去多年中已经较为成熟，但近年来 Transformer 大模型在 AI 音频领域的投入应用，还是成功推动了相关技术再上台阶，实现更优的音频理解和生成效果，其中重点的项目成果包括 Whisper large-v3、VALL-E 等。
- **更多模态**：除了上面我们提到的几种典型的模态之外，还有很多目前没有办法很好的以数据形式抓取的模态（比如嗅觉、味觉、触觉等，可能是以脑信号的形式，需要脑科学的进一步发展），以及应用场景相对细分的模态（比如结构化数据等）。我们认为未来 AI 在多模态的领域拓展以及模型能力边界的提升仍有无限的可能。而在下面的各个章节中，我们也会依次从图像、视频、音频、3D 等几个典型的模态领域入手，分别就产业技术发展的脉络和未来趋势进行阐述。

图表 8：典型的多模态领域——视觉场景近年来的主要工作概览




资料来源：《Multimodal Foundation Models: From Specialists to General-Purpose Assistants》(Chunyuan Li, Zhe Gan, Zhengyuan Yang, Jianwei Yang, Linjie Li, Lijuan Wang, Jianfeng Gao, Microsoft Corporation, 2023)，中金公司研究部

图像：技术路径收敛，应用百花齐放

技术演进：源起 CNN，扩散模型为主流生图架构

以深度学习为基、GAN 为起点，AI 生成图像的技术发展历史经历四大阶段。最早期阶段中，20 世纪末的深度学习技术，尤其是卷积神经网络（CNN）在图像特征识别的能力为机器生成基础图像奠定了基础。此后，变分自编码器（VAE）和生成对抗网络（GAN）的问世，让计算机得以使用概率分布和对抗式训练精炼生成结果，为 AI 生成图像技术迈出了重要一步。随后，扩散模型（diffusion model）的出现，以其生成高质量图像的能力超越了传统以 GAN 为主流的生成模型。自 2022 年以来，基于 diffusion model 的 AI 生成图像模型呈现繁荣增长，各类生成模型在“理解”指令和绘画能力上都有大幅提升，显著提升了 AI 生成的图像质量和降低了优质内容的创作门槛。


图表 9：扩散模型已成为目前多模态图像技术的主流路线



资料来源：Fabianmosele, 量子位, OpenAI 官网, Stability AI 官网, 中金公司研究部

- **阶段一：20 世纪 90 年代开始，深度学习在图像特征自动识别方面的应用为后续 AI 生图奠定基础。**卷积神经网络（CNN）通过自动提取和学习图像的特征，为之后的图像生成技术奠定了基础。2012 年，由吴恩达和 Jeff Dean 领导的 Google Brain 利用一个由 1.6 万个 CPU 组成的庞大神经网络第一次让机器自主成功生成了模糊的猫脸图像，展示了神经网络自主学习和抽象图像特征的能力，为后续生成式对抗网络（GANs）和其他图像生成技术的发展提供了重要的技术储备。

图表 10: CNN 通过卷积层和池化层提取图像的特征, 再通过全连接层进行分类



资料来源: Phung and Rhee (2019) 'A high-accuracy model average ensemble of convolutional neural networks for classification of cloud image patches on small datasets', Applied Sciences, 9(21), p. 4500. doi:10.3390/app9214500. , 中金公司研究部


图表 11: 2012 年吴恩达团队利用 1.6 万个 CPU 耗时三天生成的猫脸图像



资料来源: 纽约时报中文网, 中金公司研究部


- **阶段二: 2013-2017 年间, 变分自编码器 (VAE) 和生成对抗网络 (GAN) 的出现, 助推 AI 在高质量图像生成方面实现突破。**2013 年 Kingma 和 Welling¹提出了 VAE, 利用编解码器架构, 能够压缩和生成数据, 为图像降维和特征学习提供了新途径。2014 年 Ian Goodfellow 提出生成对抗网络 (GAN), 核心突破在于由生成网络和判别网络组成的对抗机制, 标志着 AI 生图在质量上的重要突破, 演化出多种变体, 如英伟达推出 PGGANs (2017 年) 和 StyleGAN 系列 (首次发布于 2018 年底, 2019 年开源), 通过引入扩展训练层和风格迁移的技术, 提升了训练稳定性和生图的质量, 展现了广泛的应用潜力。

图表 12: VAE 通过学习数据的潜在空间分布来生成新的数据



资料来源: Kingma, Diederik P., and Max Welling. "Auto-encoding variational bayes." arXiv preprint arXiv:1312.6114 (2013). , 中金公司研究部


图表 13: GAN 采用“对抗游戏”框架训练, 旨在生成高质量、高分辨率的图像



资料来源: Generative Adversarial Networks (2014) . Authors: Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, 中金公司研究部

¹ Diederik P Kingma, et al., "Auto-Encoding Variational Bayes", 2013

图 14: CycleGAN 无需配对样本数据, 即可实现不同图像之间风格的转换




资料来源: Zhu, J.-Y. et al. (2017) 'Unpaired image-to-image translation using cycle-consistent adversarial networks', 2017 IEEE International Conference on Computer Vision (ICCV) [Preprint]. doi:10.1109/iccv.2017.244. , 中金公司研究部

- **阶段三: 模型工程化能力不断提升, diffusion model 替代 GANs 成为主流生成模型, 引领生成图像技术进入转型升级新阶段。**2018-2022 年间, AI 生成图像技术迎来了重要的发展里程碑, 技术从实验室研究转向更为广泛的产业端应用。这一时期主要存在两大突破: Transformer 在视觉领域的模型 (ViT) 推出, 以及 diffusion model 的兴起, 后者尤其改变了图像生成领域的主导技术格局。


Vision Transformer (ViT) 提高图像理解精度, CLIP 助力对齐度提升, 模型工程化能力及泛化能力进一步跃迁。 ViT 将图像切割成小块并将其视为序列数据来应用自注意力机制, 为处理图像分类和理解提供了更加灵活和高效的 Transformer 架构。而 CLIP (Contrastive Language-Image Pre-training) 模型通过同时学习视觉和语言信息, 能够理解并生成与文本描述相匹配的图像, 在多样化视觉任务上的展现出强大适应性和效果。

图 15: ViT 模型架构与原始 Transformer 差异在于以图像替代自然语言作为输入



资料来源: An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale, 中金公司研究部

图 16: OpenAI 通过 4 亿组图像文本对进行训练, CLIP 可以“理解”图像的内容并将其与文本描述强关联




资料来源: Learning Transferable Visual Models From Natural Language Supervision, 中金公司研究部

Diffusion model 的推出改变了 **GAN** 在图像生成领域的主导地位。与基于对抗性训练的 GAN 不同，diffusion model 通过模拟噪声的逐步添加和去除过程，提供了新的生图技术途径，在输出端能够生成更为逼真的图像。2021 年 5 月，OpenAI 的研究进一步验证了 diffusion model 在多个方面超越 GAN 的性能，尤其是在图像质量和多样性方面表现力显著提升。


Latent Diffusion Models (LDMs) 的推出进一步优化了 diffusion model 的性能，在生成质量、效率和灵活性等方面带来优化。以 DDPM (Denoising Diffusion Probabilistic Models) 为代表，早期 diffusion model 生成过程涉及多步迭代，每一步都需要模型预测和应用噪声的去除，这也导致了计算资源消耗高、生成速度慢以及难以调控等问题。后续 LDMs 的提出，则正是为了解决这些问题——LDMs 通过在潜在空间而不是像素空间上进行扩散过程，显著提高了生成图像的效率和质量。

图表 17: Diffusion model 包含扩散及逆扩散两个过程



资料来源: Ling Yang, et al., "Diffusion Models: A Comprehensive Survey of Methods and Applications", 2022, 中金公司研究部

图表 18: LDMs 在潜空间上扩散提高生图效率




资料来源: Robin Rombach, et al., "High-Resolution Image Synthesis with Latent Diffusion Models", 2021, 中金公司研究部

- 阶段四，2022 年以来以 diffusion model 逐渐成为主流架构，成本降低叠加开源生态助力生图模型迎来百花齐放。

基于 LDMs 模型不断改进，Stability AI 推出 Stable Diffusion 助推算法成本降低，开源生态方兴未艾。Stability AI 于 2022 年 8 月开发了图像生成模型 Stable Diffusion，并将其开源，相较于 LDMs，Stable Diffusion 基于优化的 U-Net 结构和更加精细的控制机制，实现了更高质量图像的生成，同时降低了对计算资源的需求。同年 11 月，Stability AI 推出升级版本 Stable Diffusion2，通过引入新的文本数据集和文本编码器 OpenCLIP，在图像生成的质量和效率上取得了明显改进。2023 年，Stability AI 再次陆续推出 SDXL 和 SDXL Turbo，通过扩展 UNet 架构、引入附加调节技术等方式，进一步增强生图质量，并降低计算成本。


Peebles William 和谢赛宁等于 2023 年发布 DiTs (Diffusion Transformers)，通过将 LDM 整合进视觉转换(Vision Transformer, ViT) 架构，进一步提升模型拓展性和效率。DiTs 通过将输入二维图像分解为潜在的补丁 (patches)，随后利用一系列的变换器模块 (Transformer blocks) 进行处理。与之前的技术相比，DiTs 在处理潜在的补丁上的操作使得其在可扩展性和效率方面大大超越传统的 U-Net 结构，其主要技术进步在于其能够利用 transformer 架构处理更高的计算复杂性，以实现更低的 FID (Frechet Inception Distance) 分数，生成更高质量的图像，也为后续视频生成应用打下技术基础。

图表 19: SDXL 将 U-Net 主干扩大三倍




资料来源: Dustin Podell, et al., “SDXL: Improving Latent Diffusion Models for High-Resolution Image Synthesis”, 2023, 中金公司研究部

图表 20: SDXL 在 A100 GPU 上, 生成一张 512x512 的图像仅需 3 秒



资料来源: Axel Sauer, et al., “Adversarial Diffusion Distillation”, 2023, 中金公司研究部

图表 21: Diffusion Transformer (DiT)体系架构



注: 时空补丁同时考虑了空间和时间信息, 能够捕捉视频中局部的视觉特征和动态变化

资料来源: Peebles & Xie - 2023 IEEE/CVF International Conference on Computer Vision (ICCV) – 2023, 中金公司研究部

以 OpenAI 技术路径选择为例, 推出的 DALL-E 系列模型从 VAE 架构转向 diffusion model。DALL-E, 作为 OpenAI 在 2021 年初推出的首个图像生成模型, 通过早期的 VAE 架构展现了对复杂概念和场景理解的能力, 但在图像质量和分辨率方面仍有较大提升空间。紧随初代 DALL-E 模型的脚步, OpenAI 于 2021 年底推出了 GLIDE (Guided Language to Image Diffusion for Generation and Editing)。相较于前一代图像生成模型 DALL-E 的 120 亿参数, GLIDE 的模型参数规模仅为 35 亿, 但却在图片质量和 prompt (提示词) 遵循上表现更佳, 这得益于其不仅采用了扩散模型来生成图像, 还通过结合 CLIP 模型进行图像生成引导。GLIDE 标志着 OpenAI 从 VAE 架构和 Transformer 模型向 diffusion model 的转变, 引领 OpenAI 在技术路径和生成质量方面引来突破。此后, 基于 GLIDE 沉淀的技术基础, OpenAI 在 2022 年推出了 DALL-E 2 作为迭代版本, 直接使用 CLIP 嵌入来调节扩散过程, 能够更准确地理解文本描述, 并生成更高质量、更细腻和更符合描述的图像。

DALL-E 3 借助 OpenAI 自研图像字幕器, 实现 AI 生成训练数据, prompt 遵循能力进一步提升。此后 OpenAI 持续致力于让生成模型更能“听懂”用户需求, 文生图的关键挑战在于模型可能会忽略某些文字描述中的词语及背后的含义 (prompt following 问题), 其背后原因为训练数

据集质量不够高，DALL-E 3 采用构建 image captioner 的方式，首先训练强大的图-文描述生成器（DALL-E 3 选用的架构是 Google 的 Coca），以详实的方式描述图像，并作用于文生图的数据集，实现数据集的双向优化。采用 CLIP Score 来评价 prompt following 生成效果，采用 95% 比例的 DSC 训练效果明显优于其他模型。


图表 22：DALL-E 3 新增“图像字幕器”（image captioner），生成细节丰富的图-文描述

Image	Alt Text	SSC	DSC
	now at victorian plumbing.co.uk	a white modern bathtub sits on a wooden floor.	this luxurious bathroom features a modern freestanding bathtub in a crisp white finish. the tub sits against a wooden accent wall with glass-like panels, creating a serene and relaxing ambience. three pendant light fixtures hang above the tub, adding a touch of sophistication. a large window with a wooden panel provides natural light, while a potted plant adds a touch of greenery. the freestanding bathtub stands out as a statement piece in this contemporary bathroom.
	is he finished...just about!	a quilt with an iron on it.	a quilt is laid out on an ironing board with an iron resting on top. the quilt has a patchwork design with pastel-colored strips of fabric and floral patterns. the iron is turned on and the tip is resting on top of one of the strips. the quilt appears to be in the process of being pressed, as the steam from the iron is visible on the surface. the quilt has a vintage feel and the colors are yellow, blue, and white, giving it an antique look.
	23 (19 of 30) 1200	a jar of rhubarb liqueur sitting on a pebble background.	rhubarb pieces in a glass jar, waiting to be pickled. the colors of the rhubarb range from bright red to pale green, creating a beautiful contrast. the jar is sitting on a gravel background, giving a rustic feel to the image.

注：SSC：图像的简短文本描述，包含主体内容；DSC：图像精细的文本描述，包含细节

资料来源：James Betker, et al., “Improving Image Generation with Better Captions”, 2023, 中金公司研究部

图表 23：CLIP 验证发现数据集中 95% 的 AI 合成文本描述+5%图像使用人工描述时，训练效果最好



资料来源：James Betker, et al., “Improving Image Generation with Better Captions”, 2023, 中金公司研究部

图表 24：人工评估方法下，DALL-E3 表现突出

Dataset	DALL-E 3	Midjourney 5.2	Stable Diffusion XL	DALL-E 2
DALL-E 3 Eval (prompt following)	153.3	-104.8	-189.5	-
DALL-E 3 Eval (style)	74.0	30.9	-95.7	-
MSCOCO (coherence)	71.0	48.9	-84.2	-
Drawbench	61.7	-	-34.0	-79.3

Table 2 – Human evaluation results for DALL-E 3 versus other text-to-image generation models. Scores reported are computed using the ELO algorithm from Nichol et al. (2022)

资料来源：James Betker, et al., “Improving Image Generation with Better Captions”, 2023, 中金公司研究部

展望未来，Image caption（图像描述）路线凝聚图文对齐共识，有望进一步推广。多模态技术进展迅速，数据重要性凸显，在实际应用中多模态数据不易获得、标注欠缺细节，而合成数据可提升训练的多样性及模态对齐的精确度，成为有效的数据增强手段。根据 DALL-E 3 论文结论²，在训练模型时结合合成标注有望提升模型 CLIP Score。我们认为 Image caption 将成为合成标注训练文生图模型的重要路径，普遍操作是使用微调后的图-文预训练模型生成高质量文本描述，此外细致的长文本标注将更有效优化模型表现。当前 OpenAI DALL-E 3、华为 PixelArt-α 均积极探索该路线。

² James Betker, et al., “Improving Image Generation with Better Captions”, 2023

立足二维图像出发点，向三维领域延拓。文生图模型 DiTs 依托 Transformer 架构实现更强大的计算能力，为处理更复杂的 3D、视频数据奠定基础，在后续 OpenAI 视频生成模型 Sora 中得到应用。我们认为随着 2D 图像生成模型在效率、一致性等方面的提升，有望推动 3D 模型与视频多模态领域技术变革。

公司巡礼：文生图底层能力来源，应用百花齐放

OpenAI：多模态功能集成于 ChatGPT，指令理解能力领先

DALL-E 3 构建于 ChatGPT 降低用户操作门槛，开源图像解码器助力开放生态。2021 年 OpenAI 推出 DALL-E、2022 年推出 DALL-E 2，公司文生图模型持续获得较高关注。2023 年 9 月 DALL-E 3 发布，相较于因为容易忽视文字描述而迫使用户学习提示词工程（prompt engineering）的其他文生图模型，DALL-E3 严格遵照用户的文本指令产生图片，降低用户的提示词门槛；DALL-E3 集成于 ChatGPT 中，用户可以在对话中直接调用其图像生成功能，ChatGPT 还能够帮助优化 prompt 提供生图灵感，实用性与便捷性得以提升。当前公司已开源 DALL-E 模型，2023 年 11 月开源图像的一致性解码器，可改善文生图模型质量，在图像中的文字、人脸、直线等方面表现优异，进一步完善开源生态。

图表 25：相同提示词下，DALL·E 系列文生图效果演进



注：提示词为“Stormtroopers in a grocery store（杂货店里的帝国冲锋队，帝国冲锋队：《星球大战》电影角色）”
资料来源：OpenAI 官网，中金公司研究部

直接收费与 API 调用并行，提供灵活的文生图能力选择。DALL-E 的付费模式分为两种形式：1) 直接付费，面向 Plus 用户和 Enterprise 用户，每人 20 美元/月；2) API 调用，根据模型、分辨率等提供多样化的灵活选择。

图表 26: DALL-E3 严格遵照用户的文本指令产生图片



资料来源: OpenAI 官网, 中金公司研究部

图表 27: DALL-E 系列的 API 选择种类多样

Model	Quality	Resolution	Price
DALL-E 3	Standard	1024×1024	\$0.040 / image
	Standard	1024×1792, 1792×1024	\$0.080 / image
DALL-E 3	HD	1024×1024	\$0.080 / image
	HD	1024×1792, 1792×1024	\$0.120 / image
DALL-E 2		1024×1024	\$0.020 / image
		512×512	\$0.018 / image
		256×256	\$0.016 / image

资料来源: OpenAI 官网, 中金公司研究部

底层多模态大模型支撑图像理解分析功能, 拓宽 ChatGPT 应用场景。 ChatGPT 具有强大图像识别、分析能力, 能够改善用户体验。Plus 用户和 Enterprise 用户可以上传图像, 要求 ChatGPT 进行分析并回答问题, 例如制定菜谱、修理自行车等, 拓宽 ChatGPT 的使用场景。根据 OpenAI 官网, ChatGPT 的图像理解功能由多模态的 GPT-3.5 和 GPT-4 驱动, 这些大模型可将其语言推理能力应用于包括照片、截图、含有图像和文字的文件等一系列图像中。

Midjourney: 生态优质的专业设计社群

始于 11 人初创团队, 底层模型已迭代至 V6 版本。Midjourney 是目前业界流行的商用文生图应用之一, 创始团队由 11 名正式员工组成。2022 年 3 月 Midjourney 首次亮相, 基于 diffusion model 打造文生图模型, 当年 8 月迭代至 V3 版本并引发广泛关注, 2023 年 12 月已迭代至 V6 版本。随着模型迭代, 生成图像质感不断上升, V6 对皮肤和毛发的细节刻画更为精致, 图像光影处理也更加自然真实。除了生图质量的进步, Midjourney V6 对自然语言提示的理解能力也进行了改进: 接受长文本提示, 提示词容量扩大至 350-500 词; 语义理解更为准确, 能正确呈现提及的元素和元素间的关系。

图表 28: Midjourney 模型在细节刻画与光影处理方面不断进步



注: 提示词为“CRT 电视机旁手持武器的野蛮人、电影级、8K、摄影棚照明”

资料来源: Arstechnica, 中金公司研究部

建立社区促进艺术共创, 庞大用户量形成数据飞轮。 Midjourney 在 Discord 平台上搭建开放社区, 支持图像创作、讨论反馈与信息共享。用户可通过与 Midjourney Bot 互动进行图像生成,

降低了使用门槛；社区的交互机制能让用户互相学习提示词的写法与创意，激发创作灵感，产生大量充满想象力的作品。据 Midjourney 创始人 David Holz 2023 年 12 月介绍，Midjourney Discord 服务器已拥有逾 1700 万用户³。庞大的用户数量促进数据集的积累，公司根据用户反馈进一步针对性地迭代模型，打造了良性循环。商业模式上主要面向社区用户进行订阅制收费，定价在 10-120 美元/月不等，此外，Midjourney 还在探索拓宽分销渠道，作为插件接入 Canva 等产品。

图表 29：Midjourney 会员定价在 10-120 美元/月不等，截至 2024 年 3 月


	Basic Plan	Standard Plan	Pro Plan	Mega Plan
Monthly Subscription Cost	\$10	\$30	\$60	\$120
Annual Subscription Cost	\$96 (\$8 / month)	\$288 (\$24 / month)	\$576 (\$48 / month)	\$1152 (\$96 / month)
Fast GPU Time	3.3 hr/month	15 hr/month	30 hr/month	60 hr/month
Relax GPU Time	-	Unlimited	Unlimited	Unlimited
Purchase Extra GPU Time	\$4/hr	\$4/hr	\$4/hr	\$4/hr
Work Solo In Your Direct Messages	✓	✓	✓	✓
Stealth Mode	-	-	✓	✓
Maximum Concurrent Jobs	3 Jobs 10 Jobs waiting in queue	3 Jobs 10 Jobs waiting in queue	12 Fast Jobs 3 Relaxed Jobs 10 Jobs in queue	12 Fast Jobs 3 Relaxed Jobs 10 Jobs in queue

资料来源：Midjourney 官网，中金公司研究部

Adobe：Firefly 工具巩固场景落地，优化 workflow 提升文生图可控性

Firefly 套件全方位升级，强化原有场景落地推广。 Adobe 是全球领先的创意设计软件供应商，2023 年 3 月 Adobe 发布 AIGC 平台 Firefly，集成文生图、生成式填充、文字特效等能力；2023 年 10 月公司更新三款 Firefly 多模态产品：1) **Firefly image 2**：文生图模型，相比 Firefly image 1 默认图像分辨率提升至 2048*2048，在人体渲染与纹理细节等方面精细度升级，色彩更加鲜艳；2) **Firefly vector**：Adobe 推出首个用于矢量图形（SVG 格式）生成的模型；3) **Firefly design**：通过简单的文字提示生成设计模板，应用于广告等领域。Firefly Image 2 在 PS 等软件中应用，Firefly vector 和 Firefly design 分别适用于 Adobe Illustrator 和 Adobe Express，多模态能力内嵌于公司丰富的产品矩阵，进一步强化原有落地场景、巩固应用生态。

图表 30：Firefly image 2 可给出 5 组提示词优化建议



资料来源：Adobe MAX 2023 大会，中金公司研究部

³ <https://finance.sina.cn/tech/2023-12-22/detail-imzywwtx6416449.d.html?from=wap>

优化图像编辑与提示词功能，改善图像生成可控性。Firefly image 2 新增若干功能以提高精细控制图片的能力，包括生成匹配功能（参考用户上传的图像，生成风格相近的新图像）；照片设置（为生成图像的二次编辑打造便捷工作流，控制景深、运动模糊、焦距等）；提示词优化（系统自动优化用户输入的提示词，帮助用户更精准生成所需要的图像）。Firefly 模型采用 Adobe Stock 授权图像、公开许可的内容以及版权过期的公共内容进行训练，降低版权争议风险，有利于商业化推进。目前 Firefly 已开始收费，会员每月可获得 100 个生成点数，价格 4.99 美元。

商汤：强化基模型能力，打造开放的模型平台

依托日日新文生图大模型底座，商汤秒画持续升级。商汤秒画是商汤推出的文生图创作平台，能力来自商汤自研的日日新-秒画文生图大模型，23 年 1 月内测上线，随基座模型更新经历多版本升级。23 年 7 月 3.0 版本基模型达 70 亿参数，实现提示词自动补全功能，降低生图难度；10 月 3.5 版本内置美学引导系统，在亚洲人像与二次元图像上表现力提升，此外结合 ControlNet 能力，可提取输入图像的轮廓、姿势等特征辅助新图像的创作，便捷作图流程；截至 24 年 2 月基模型已更新至 4.0 版本，达到百亿级参数，Mixture of text experts 等技术实现语义理解能力和生图质感的加强；结合对抗蒸馏技术，秒画 Turbo V4 相较基础版本推理实现 10 倍提速。

支持导入第三方模型、定制 LoRA 模型，打造“模型超市”。秒画平台支持用户导入 Hugging Face、Civitai 等三方社区的模型，提供算力支持和推理加速，使用户摆脱本地部署的算力掣肘；用户还可上传本地图像，结合商汤自研文生图模型或三方开源模型来训练个人专属的 LoRA 模型，据官方介绍，定制 LoRA 模型仅需 20 张图片训练集、训练 5 分钟，显著降低训练门槛。通过接纳三方模型、支持自训练模型，商汤秒画积极提高平台的开放程度，构建良好的模型社区生态。商汤秒画目前面向 C 端用户免费开放，并向企业客户提供 API 服务。根据官方公众号，秒画已服务超 60 家 B 端用户，API 每日调用量逾十万次。

图表 31：商汤秒画实现提示词补全功能，图像质量提升



资料来源：商汤 2023 年中报公开业绩会，中金公司研究部

第四范式：“式说”大模型多模态能力赋能企业软件重构

“式说”多模态能力叠加 Copilot 与思维链，提升 B 端软件使用体验。第四范式专注于企业级的人工智能，2023 年公司推出大模型产品“式说”，定位于为企业软件提质增效的开发平台。

“式说”1.0 可学习企业数据构建知识库，与员工智能交互，提效企业管理；2023 年 3 月升级 2.0 版本，基于序列 token 化的技术，引入多模态功能，接受图像、语音和视频模态的输入与输出，添加企业级 Copilot；同年 4 月 3.0 版本加入 CoT（Chain of Thoughts，思维链）能力。Copilot 叠加 CoT 使模型具备强大的推理能力，能更好调用多模态工具，解决生产中的复杂问题，从而赋能企业对多模态能力的使用体验。例如在物流行业，“式说”能通过计算与作图展现集装箱堆叠结果；在航空制造业，“式说”能在内部数据库搜索相似图片，并生成零件组装图，以上操作可以完全于内网完成，兼顾数据安全与生产效率。

图表 32：“式说”大模型以生图能力有效辅助工业 CAD 设计




资料来源：第四范式官方公众号，中金公司研究部

视频：优化时序对齐，生成效果突破

我们认为 2023 年是 AI 生成视频的元年，年初鲜见有面向公众的视频生成产品，但至年末新模型、新应用（包括文生视频、图生视频、视频生视频）快速涌现。2024 年 2 月 15 日 OpenAI 发布 Sora，成为视频生成领域的里程碑事件。本章我们梳理了视频生成模型（以文生视频模型为主）背后的技术原理和演进过程，并对未来的可能的技术方向进行了研判。

图表 33：2023 年视频生成类 AI 大模型和产品进度，4Q23 以来论文和应用快速涌现




资料来源：a16z，中金公司研究部

技术基础：图片生成模型叠加时序对齐实现视频生成

视频本质上是一系列图像的连续展示，图片生成是视频生成的基础。图片生成的主流技术即扩散模型同样也是视频生成的主流技术，目前主流的文生视频模型的技术路线为基于文生图模型，通过在时间维度加入卷积或注意力，在生成的关键帧基础上实现时序对齐得到视频。在此基础上，插帧+超分、初始噪声对齐、基于 LLM 增强描述等方法均有助于增强时序对齐能力，实现更高质量的视频生成。Zero-shot 领域的一系列研究则能够实现无需训练，直接将图片生成模型转化为视频生成模型。

图表 34：基于扩散模型的文生视频模型主要文献




资料来源：《A survey on video diffusion models》(Xing et al., 2023)，中金公司研究部

多阶段 T2V：关键帧生成+插帧+空间超分，实现高分辨率视频生成

T2V 模型早期尝试：基于 2D 模型拓展，采用时间注意力实现时序对齐。VDM 是较早探索扩散模型在视频生成领域应用的工作之一，其将 U-Net 架构中的 2D 卷积替换为 Space-only 的 3D 卷积保留空间注意力块，并加入时间注意力块（Temporal attention block）实现时序对齐，采用了时空分离注意力（先进行空间注意力再进行时间注意力）的方式来建立模型，能够对视频和图片生成进行联合训练。**MagicVideo**、**LVDM** 则基于潜扩散模型（LDM, latent diffusion model）探索视频生成的早期工作，通过在较低维度的隐空间中完成生成任务，降低计算复杂度提高处理效率。

图表 35：VDM 模型的 3D U-Net 架构




注：其中每个方块都代表一个四维的张量（即 frames*height*width*channels），该图中每个方块的纵轴长度表示张量的长或宽大小（即 height 或 width），横轴长度表示张量的通道大小

资料来源：《Video diffusion models》（Ho et al., 2022），中金公司研究部

Blattmann 等（2023）提出了三阶段 T2V 模型框架，即关键帧生成、插帧和空间超分。该模型在原有的空间层（Spatial layer）中加入了时间注意层（Temporal attention layer）和 3D 卷积层（3D convolution layer），使得生成的关键帧能够在时序上对齐；接下来训练了插帧模型，能够将关键帧“加密”，提高视频的帧率；最后使用空间超分模块提高视频的分辨率。类似地，**LAVIE (Wang et al., 2023)**和 **Show-1 (Zhang et al., 2023)**等工作均采用了三阶段 T2V 模型框架，实现高分辨率视频的生成。


图表 36：通过加入时间注意层和 3D 卷积层，实现时序对齐



资料来源：《Align your Latents: High-Resolution Video Synthesis with Latent Diffusion Models》（Blattmann 等, 2023），中金公司研究部

噪声初始化将生成关键帧过程的初始噪声关联，增强时序对齐表现。先前基于扩散模型的关键帧生成使用了独立的初始噪声，Luo 等（2023）研究者的工作 VideoFusion 将每一帧的噪声分解为两部分，即所有帧共享的基础噪声和沿时间轴变化的残余噪声，在去噪阶段使用了两个联合学习的网络来匹配噪声的分解。Ge 等（2023）的通过可视化说明了同一视频不同帧的噪声是聚合在一起的，并设计了两种噪声初始化策略，其一为将每一帧噪声分解为共享的分量与随机噪声的组合，其二为在前一阵噪声基础上增加随机分量。

图表 37：同一视频的不同帧之间的噪声具备关联关系



注：(a)展示了同一视频不同帧之间的噪声是聚合在一起的；(b)展示了文章提出的模型能够将初始噪声建立关联

资料来源：《Preserve Your Own Correlation: A Noise Prior for Video Diffusion Models》(Ge et al., 2023)，中金公司研究部

基于 U-Net 的扩散模型在生成效果上存在不足

基于 U-Net 的扩散模型在信息损失和输入多样性方面具备一系列缺点。U-Net 模型核心是卷积神经网络，这导致 U-Net 在图片生成过程中具备一些天然的缺点：1) U-Net 的下采样过程会造成信息的损失；2) 卷积神经网络要求输入的图片具有固定的分辨率，对输入的限制也造成了输出格式的限制（只能生成固定长宽比、固定分辨率的图片），模型的可拓展性较弱。

同样的，这些视频生成模型在像素稳定性和逻辑一致性等方面仍存在提升空间。我们总结先前的扩散模型存在较为一致的共性问题，主要包括：1) **画面像素和稳定性**：模型生成的视频普遍像素较低，且部分关键帧可能存在风格偏移，导致视频画面出现“闪烁”；2) **逻辑连续性**：尤其是在长视频生成任务过程中，较难保证视频前后的逻辑一致性；3) **生成时长较短**：多数视频生成模型和应用只能生成 3-4 秒钟的视频；4) **缺乏高质量数据集**：公开的视频缺少标注，目前还鲜有大型可以用于视频训练的数据。

模型改良：Transformer 代替 U-Net，模型可拓展性大幅增强

Transformer 代替 U-Net，可拓展性更强的视频生成模型得以出现。前文我们提到，基于 U-Net 的扩散模型是文生视频模型的主流技术，而这类扩散模型参数量相对较小，可拓展性相对较弱。为解决模型的可拓展性问题，学界和业界将 Transformer 架构引入视频生成任务，具体可以分为两类：1) 将 Transformer 代替 U-Net 引入扩散模型，构建 DiTs (Diffusion transformer)；2) 构建基于纯 Transformer 的视频生成模型。由于 Transformer 的全注意力机制产生的内存需求会随着输入序列的长度增加而呈现平方增长，因此处理高维信号（如视频）时，模型对计算量需求更大，训练和推理成本或明显高于基于 U-Net 的扩散模型。


W.A.L.T.：首次在视频生成领域将 Transformer 与扩散模型整合

2023 年底，Gupta 等发表论文《Photorealistic Video Generation with Diffusion models》，将 Transformer 架构整合到隐视频扩散模型（Latent video diffusion model, LVDM）中，主要工作有两项：

- **第一阶段：**用一个自动编码器将视频和图像映射到一个统一的低维潜空间，使得在图像和视频数据集上能够联合训练单个生成模型，降低生成高分辨率视频的计算成本；
- **第二阶段：**设计了一种用于隐视频扩散模型的新 Transformer 模块，对潜空间中的视频帧进行分块（Patchify），借助了 Magvit-v2 作为 tokenizer。模型引入了两种局部窗口，分别为：1）空间窗口（SW）学习单个关键帧里面的位置关系；2）时空窗口（STW）学习关键帧之间的时序关系。

W.A.L.T.开创性地将 Transformer 架构与扩散模型整合引入视频生成任务中，使用窗口注意力（而非全注意力）降低了高维视频信号对算力的需求，Transformer 处理视频数据得以实现。

图表 38：W.A.L.T.模型首次在视频生成领域将 Transformer 与扩散模型整合




资料来源：《Photorealistic Video Generation with Diffusion models》（Gupta 等，2023），中金公司研究部

VideoPoet：使用纯 Transformer 架构的文生视频模型

跳出扩散模型范畴，Google 在纯 Transformer 架构文生视频任务上的进展。2023 年 12 月，谷歌研究院发布 VideoPoet，采用纯解码器（Decoder-only）的 Transformer 架构处理多模态输入。其中在处理视觉（图片、视频）信号时，VideoPoet 使用了 Magvit-v2 编码器（类似 LLM 中 tokenizer 的分词效果）生成视频 tokens。与此同时，模型还分别使用了 t5 和 SoundStream 分别作为文本和音频的 tokenizer。与基于扩散模型+Transformer 融合架构的 W.A.L.T.不同，VideoPoet 通过自回归能够直接生成视频 tokens，并通过 Magvit-v2 解码为视频片段。

回顾 W.A.L.T.和 VideoPoet 模型，借助 MAGVIT 的视觉分词器对视频信号进行恰当的编码处理是关键。MAGVIT 是谷歌研究院在 2022 年 12 月发表的视频生成相关工作，论文中引入了视觉分词器（Visual tokenizer），其主要作用是借助 3D CNN 将视觉信号（图片、视频等）量化为 tokens（类似 LLM 模型中文本 tokens），从而能够将视频信号使用 Transformer 架构进行处理。2023 年 10 月，谷歌研究院提出 MAGVIT-v2 分词器，用时间因果 3D CNN（Casual 3D CNN）代替 MAGVIT 中的常规 3D CNN，并在视频和图像生成、视频压缩，动作识别等任务上验证了性能的提升。

图表 39: VideoPoet 模型架构




资料来源:《VideoPoet: A Large Language Model for Zero-Shot Video Generation》(Kondratyuk et al, 2023), 中金公司研究部

Sora: 基于 DiTs 架构, 实现长视频的高质量生成

Sora 展现了高质量的长视频生成能力, 相较先前的视频生成模型, 我们认为其最为突出的创新之处在于: 1) 视觉编码器实现时间空间维度压缩并进行 Patch (图块化) 处理, 使得长视频生成成为可能; 2) 借助 Transformer 的位置编码性质, 使用无限制输入形状的 DiTs, 能够创新性地实现任何像素和长宽比视频的生成; 3) 我们判断其训练数据集中可能包含带有物理信息的合成数据, 从而使模型展现出对物理信息的初步理解能力; 4) 复用 DALL·E 3 的重标注技术, 对视频数据生成高质量文字标注, 借助 GPT 对提示词进行扩展, 提升生成效果。

图表 40: Sora 可能的模型架构




资料来源: Sora 技术报告, 中金公司研究部

可能的模型架构: 以 DiTs 为核心, 展现出优异的可拓展性。根据 Sora 的技术报告, 其整体延续了 DiTs (Diffusion transformer) 架构, 将 Transformer 引入潜在扩散模型 (Latent diffusion model) 实现良好的可拓展性。技术报告展示了伴随模型扩大和训练次数增加而产生的规模效应 (Diffusion transformers scale effectively)。从架构上来看, 我们判断 Sora 可能主要由几部分组成:

- **Visual Encoder/Decoder (如 VAE 等)**: Encoder 将原始图片和视频数据编码进入隐空间, 降低维数节省算力; Decoder 将隐空间中的数据重新映射为图片和视频数据。
- **DiTs 模块 (基于 Transformer 的扩散模型)**: 模型的核心, 将扩散模型的骨干 U-Net 卷积网络替换为可伸缩性更强的 Transformer, 展现出优异的可拓展性。
- **Text embedding**: 将用户输入的 Prompt 编码为文本嵌入向量, 作为 DiTs 模块的 Conditioning, 引导模型生成符合文本描述的视频。

图表 41: Sora 展现了明显的可拓展性 (Scalable), 伴随训练计算量增加而性能明显提升




资料来源: Sora 技术报告, 中金公司研究部

Sora 的技术报告展示了数据处理和模型训练过程中创新, 我们总结并分析如下:

- **在 Visual Encoder/Decoder 阶段训练了新的视频压缩网络, 并进行 Patch (图块化) 处理**: OpenAI 训练了新的视频压缩网络 (Video compression network) 对原始视频数据在时间和空间上降维编码 (Encoder) 进入隐空间, 并训练了相应的解码器 (Decoder) 实现隐空间 (Latent space) 到视频像素空间 (Pixel space) 的映射; 同时类比 Transformer 在大语言模型中处理文本 Tokens, Sora 将视频进行 Patch (图块化) 处理, 并重组成一维数据进入 DiTs。我们认为时间维度上的压缩和 Patch 处理可能是 Sora 能够生成较长视频的原因之一。
- **在 DiTs 阶段, 借助 Transformer 的位置编码性质, 解除输入形状限制**: 将视频压缩并分割为“视觉图块 (Visual patches)”作为视频数据的有效表示后, 我们认为其可能借助 Transformer 的位置编码性质, 让模型更好地处理 Patch 之间的相对关系, 解除输入形状的限制, 从而能够生成任意分辨率 (1920*1080 以内)、任意长宽比、任意时长的视频, 这一特性与主流的视频生成模型相比具备优势 (基于 U-Net 的主流视频生成模型需要对视频进行缩放和裁剪, 保证训练数据可以被统一处理)。
- **复用 DALL·E 3 重标注技术, 实现高质量视频标注**: 在文字理解层面, Sora 没有基于人工标注的图片-文字数据集进行训练, 而是复用了 OpenAI 自家的 DALL·E 3 的重标注技术 (re-captioning), 训练了高质量的视频标注器, 并对训练集中的视频生成了文字标注。此外, Sora 还发挥了 OpenAI 的 GPT 的优势, 能够将用户给出的较短的提示词扩展为较长的提示词作为视频模型的输入, 实现更好的生成效果。

图表 42: Sora 将视频单元划分为 Patches, 实现类似 LLM 模型中的 Tokens 角色



资料来源: Sora 技术报告, 中金公司研究部

图表 43: Sora 本质是扩散模型, 通过 Transformer 去噪生成“干净”的 Patches



资料来源: Sora 技术报告, 中金公司研究部

Transformer 架构或充分发挥了 OpenAI 在算力和数据等领域的全方面优势。整体来看, 我们认为 Sora 在架构层面还是延续了 DiTs (Diffusion transformer), 在视觉编解码、图块划分等领域或具备一定的创新。我们认为 Transformer 架构的高扩展性充分发挥了 OpenAI 在算力 (借助微软的庞大算力群)、数据 (具备高质量的有标注视频数据集) 的优势, 在视频生成场景下实现了类似 LLM 领域的“GPT 时刻”。

模型仍具备提升空间, 视频内容生成门槛有望大幅降低。模型也展现出了一定程度的不足, 如模型对物理关系的理解能力不高 (如玻璃破碎无法很好展现), 以及模型生成视频的因果逻辑仍有待验证。尽管如此, 我们认为 Sora 打开了通过堆叠参数和数据规模实现性能提升的通道, 我们判断基于 DiTs 架构的视频生成模型或成为下一阶段的主流技术, 有望通过数据积累和参数规模上升实现持续的性能提升。伴随模型能力越来越强, 我们认为高质量视频内容生成成本和视频创作门槛或将大幅降低; 同时, 我们判断模型对物理信息的学习和提取也有望越来越强, 未来在智能驾驶、具身智能等领域也有望实现应用突破。

视频生成模型展望: 物理信息感知增强+视频生成时间延长。我们认为 Sora 具备了初步的物理关系理解能力, 在视频生成时长上也实现了从秒级到分钟级的突破。展望未来, 伴随参数规模的提升和训练数据的增加, 我们认为视频生成模型或能习得更多“物理运动规律”, 从而生成更贴合实际的视频; 另一方面, 模型规模的提升直接表现为对视频处理能力的增强, 类似自然语言领域 LLM 的迭代, 我们认为生成视频时长或持续提升, 未来“短片”甚至“电影”的生成或将成为可能。

Sora 有望掀起内容生成迁移至多模态的变革浪潮, 国内进展来看, 2024 年 2 月央视已推出国内首部 AI 动画片。2 月 26 日, 中国首部 AI 文生视频系列动画《千秋诗颂》于央视播出。《千秋诗颂》由中央广播电视总台与上海 AI 实验室联合打造, 总长 182 分钟, 底层技术基于央视听媒体大模型与书生通用大模型体系, 实现激发灵感、提升效率的作用。此外, 商汤也正在构建多模态大模型底座, 我们认为其文生视频等模态成果有望 2024 年在国内实现突破。

公司巡礼：2023 年以来应用快速涌现，商业化仍处于早期

2023 年以来文生视频应用快速涌现，但商业化仍在早期。伴随学界论文持续涌现、模型逐步成熟，产业界中的视频生成类应用也持续快速出现。这些应用通常支持数秒长度的视频生成，我们认为这类新兴应用的用户具备“尝鲜”性质，用户粘性或相对较低，因此这类应用的商业化或仍处于早期，其定价模式通常以按量收费（比如以月度维度购买一定量的 Credits 点数，用以生成一定量的视频）。

图表 44：主要 AI 视频生成类应用，截至 2023 年底

公司	生成类型	最大时长	支持 AI 拓展视频长度	支持相机控制	支持物体运动控制	其他功能
Runway	文生视频、图生视频、视频生视频	4秒	是	是	是	运动笔刷、增强画质
Pika	文生视频、图生视频	3秒	是	是	是	区域修改、放大画板、增强画质
Genmo	文生视频、图生视频	6秒	否	是	是	FX 预设
Kaiber	文生视频、图生视频、视频生视频	16秒	否	否	否	音画同步
Stability	图生视频	4秒	否	否	是	
Zeroscope	文生视频	3秒	否	否	否	
ModelScope	文生视频	3秒	否	否	否	
AnimateDiff	文生视频、图生视频、视频生视频	3秒	否	否	否	
Morph	文生视频	3秒	否	否	否	
Hotshot	文生视频	2秒	否	否	否	
Moonvalley	文生视频、图生视频	3秒	否	否	否	
Deforum	文生视频	14秒	否	是	否	FX 预设
Leonardo	图生视频	4秒	否	否	是	
Assistive	文生视频、图生视频	4秒	否	否	是	
Neural Frames	文生视频、图生视频、视频生视频	10秒	否	否	否	音画同步
Magic Hour	文生视频、图生视频	数秒	否	否	否	换脸、音画同步
Vispunk	文生视频	3秒	否	是	否	
Decohere	文生视频、图生视频	4秒	否	否	是	
Domo AI	图生视频、视频生视频	3秒	否	否	是	
FullJourney	文生视频、图生视频	8秒	否	是	否	换脸、口型对齐

资料来源：a16z，中金公司研究部

Stable Video Diffusion：开源文生视频模型和应用

2023 年 11 月 21 日，Stability AI 发布文生视频模型 Stable Video Diffusion (SVD)并开源，支持基于文字或图片生成帧率在 3-30 之间、总长 14 帧至 25 帧的短视频。Stability AI 表示 SVD 目前仅限于研究用途，不适用于商业应用，2024 年 2 月 SVD 正式开放公测，根据我们的试用体验，以文生视频为例，其通常先根据文字 Prompt 生成四幅图片供选择，再依据用户选择的图片来拓展生成数秒的视频。

- **3D 视角合成功能：**Stable Video Diffusion 包含多视角视频生成模型 SVD-MV，支持 3D 图像合成，即基于一张单视角的图片就能够生成多视角的短视频；
- **文生视频功能：**SVD 可根据简短的文字描述自动生成质量较高的短视频，而且具有较好的背景一致性，例如根据“在月球上行走的宇航员”这个提示词生成的短视频中，宇航员身后的月壤背景随着宇航员移动而有所变换；
- **图生视频功能：**部分网站（例如 fal.ai）已接入 SVD，用户可以上传图片并设置视频时长、文件大小等参数，SVD 即可根据图片生成相应的短视频。

图表 45: SVD 模型的文生视频功能



资料来源: 公司官网, 中金公司研究部

图表 46: SVD 的 3D 视角合成功能



资料来源: 公司官网, 中金公司研究部


Pika Labs: AI 文生视频新锐, 产品推出后快速流行

Pika Labs 成立于 2023 年 4 月, 其中 CEO Demi Guo 和 CTO Chenlin Meng 同为 Stanford AILab 的博士研究生, 11 月 29 日公司正式推出 Pika 1.0 并迅速流行。截至 2023 年 11 月 29 日公司已经完成总计 5500 万美元的融资, 投后估值 2-3 亿美元。

Pika 1.0: 根据官网的 Demo, Pika 能够实现文生视频、图生视频、视频风格转化、扩展画布、指定区域编辑等至少五类视频生成功能。

- ▶ **文生视频:** 与 Runway Gen-2 类似, Pika 可根据文字指令生成数秒短视频;
- ▶ **图生视频:** 通过上传图像 (如 Demo 中上传《最后的晚餐》) 并文字指定动画变换方式 (如 Demo 中指定 “Dolly out (拉远)”, 即可生成对应效果的短视频;
- ▶ **视频风格转化:** 用户只需要上传一段视频 (如骑马的黑白风格视频), 并输入指定的风格 (如沙漠中的牛仔), 即可生成对应效果的视频;

图表 47: Pika 视频风格转换功能 (转换前)



资料来源: 公司官网, 中金公司研究部


图表 48: Pika 视频风格转换功能 (转换后)



资料来源: 公司官网, 中金公司研究部


- ▶ **扩展画布:** 这一点与 Adobe 在图像编辑领域的 Generative Fill 类似, 只不过这次相似的效果是用在视频中, 只需要拓展画布即可实现画布大小的变化和内容的填充;
- ▶ **指定区域编辑:** 与 Generative Fill 类似, Pika 这次将指定区域编辑在视频生成中实现, 如给猩猩戴墨镜、给模特换装, 均有不错的生成效果。

图表 49: Pika 的拓展画布功能



资料来源：公司官网，中金公司研究部

图表 50: Pika 的指定区域编辑功能



资料来源：公司官网，中金公司研究部

Runway Gen-2: 文生视频早期应用，功能持续更新迭代

Runway Gen-2 是较早出现的文生视频应用。2023 年 6 月 8 日，Runway Gen-2 开放公测，支持文生视频功能。从订阅来看，分为免费版（Free）、标准收费版（Standard）、专业收费版（Pro）三类，其中标准收费版年订阅费用 96 美元（按月订阅价格则为每月 10 美元），相较产品推出初期定价 144 美元（按月订阅则价格为每月 15 美元）有明显降价，**我们认为这一定程度反映出新兴文生视频竞品应用快速增多且同质化程度较高。**相较免费版，收费版用户可以拥有更多的点数（Credits）、生成时间更长和清晰度更高的视频。

2023 年 11 月 20 日，Runway Gen-2 模型更新推出“运动笔刷”功能。给定一张图片并用笔刷“选中”，通过调节水平运动、竖直运动、距离远近三个参数，即可让图片中的对象“动起来”。我们认为 Gen-2 应用的更新相当于增加了图生视频功能，在原有的文字指令生成视频的基础上，生成方式进一步丰富。

图表 51: Gen-2 运动笔刷功能演示之一



资料来源：公司官网，中金公司研究部

图表 52: Gen-2 运动笔刷功能演示之二



资料来源：公司官网，中金公司研究部

语音：Transformer 加持，AI 配音兴起

技术前沿：Transformer 加持下的语音合成发展更趋成熟

语音技术沿革可分为三阶段，深度学习驱动发展加速。1950 年代语音技术处于技术早期，模版匹配、串联合成等技术得到发展，效果有限；1980 年代引入以 HMM（隐马尔可夫模型）为代表的参数统计模型，增加对语音信号的建模精度，提高语音识别的准确性以及语音合成的质量；2009 年后步入深度学习时代，采用神经网络进行声学建模，更灵活地捕捉文本特征与语音特征的复杂映射，从 DNN、RNN 到 Transformer，语音技术迎来高速发展。

图表 53：深度学习驱动当前语音技术快速发展，Transformer 成为主流路线



资料来源：厦门大学语音实验室，中金公司研究部


语音技术主要向增强泛化能力的方向持续延伸，Transformer 架构引领语音技术迭代浪潮。泛化能力是指模型对于未经训练的数据的适应能力，技术基础来自具有强大学习能力的网络架构和大量多样化的数据训练。语音模型泛化能力的增强主要体现在：从覆盖单一语种到多语种和方言，从处理人声到自然声音、音乐，从简单语音识别或合成到零样本学习和多任务集成。目前 Transformer 已成为语音技术的 baseline（基线）架构。Transformer 模型具备强大的泛化能力，高度受益于其并行训练能力和多头注意力机制：多头注意力机制允许模型从多角度学习序列特征，在捕捉复杂信息和处理长依赖问题时表现出色，提升模型在复杂场景下的鲁棒性；并行训练能力能够帮助模型处理更大规模、多样化的数据，间接提升模型通用性。

语音识别方面，Transformer 支撑模型提高训练效率、学习通用能力。2020 年谷歌提出 Transformer Transducer 应用于实时语音识别，该团队将传统 RNN-T 模型的编码器替换为


Transformer，利用并行训练的特征将训练时间从 3.5 天缩短至 1 天。2022 年 OpenAI 发布 Whisper，目前已开源 Whisper large-v3，作为基于 Transformer 的大模型路线代表。Whisper 在包含 98 种语言的 68 万小时数据集上进行弱监督训练，已获得零样本语音识别、语种识别等通用能力。在越粗糙和多样化的音频上 Whisper 的表现相较其他模型越出色。2024 年谷歌更新 Gemini 1.5，根据技术报告音频测试实现 100%召回率，音频能力已超越 Whisper。

语音合成方面，基于 Transformer 打造音频语言模型（Audio language model），离散化音频 token 助于模型理解和处理数据。语音合成领域当前的主流趋势是打造音频语言模型，压缩高密度连续音频，转换为离散 token，仿照 NLP 中 LLM 的训练方式，基于 Transformer 的自注意力机制学习序列的上下文关系，采用自回归方法逐步评估下一个 token 的概率，最终生成完整的音频序列。该方法采用更加稳定简单的中间特征，可减少存储与带宽需求、便于模型理解学习。2023 年 OpenAI 推出零样本音频语言模型 VALL-E，基于 6 万小时语音训练，只需 3 秒音频即可克隆声音特征；Google 也基于此架构发布一系列模型，其中 AudioLM 通过捕捉音乐的旋律节奏等特征，可续写连贯的钢琴音乐，将生成范围泛化至音乐领域。

图表 54：Whisper 词错率（WER）受噪音影响最小



图表 55：音频语言模型仿照语言模型进行序列预测



资料来源：Alec Radford, et al., Robust Speech Recognition via Large-Scale Weak Supervision, 2022, 中金公司研究部

公司巡礼：AI 赋予语音产业新机会，竞争者差异化布局


传媒发展与技术变革催化语音领域新需求，市场参与者差异化竞争。内容全球化与本地化成为浪潮，意味着平台与创作者面向全球受众时需要高质高效的语音翻译技术，我们认为 AI 有望通过赋能降本增效释放相关需求，以 ElevenLabs 为代表的语音企业在 AI 配音、AI 视频翻译等新兴领域积极布局。同时，随着 AI 语音功能迅速拓展，音频生成、声音转换和声音克隆质量与速度均提升，传统语音应用场景也具备更大的展望空间，科大讯飞等企业巩固技术与产业链优势，提供更高质量的语音产品与服务。

ElevenLabs：新晋智能语音独角兽，布局 AI 视频配音与翻译

打造便捷语音工作流，辅助全球内容创作者与企业。 ElevenLabs 成立于 2022 年，由前 Google 工程师 Piotr Dabkowski 和前 Palantir 战略师 Mati Staniszewski 创立，已成为当今炙手可热的 AI 智能语音公司。基于语音合成模型 Eleven Multilingual v2，公司的工具套件可支持覆盖 29 种语言的语音合成、语音克隆、语音翻译和语音创造，提供实时生成的功能。公司 2023 年 10 月推出 AI 视频翻译配音工具，可用几分钟的时间便捷翻译和替换视频中音轨，同时保留原始说话者的语音特征，辅助全球内容创作者推广作品，受到广泛欢迎。升级配音工作室，可以直接编辑调节所转录的视频，进一步优化工作流。公司以 UI 或 API 形式面向用户，据官网介绍，41% 的世界 500 强公司正在使用 ElevenLabs 技术。公司还创建语音库社区，激励用户分享制作的语音，构建用户数据飞轮。

大规模融资助力价值提升，未来动态值得关注。 [ElevenLabs 于 2024 年 1 月筹集了 8000 万美元 B 轮融资，由 Andreessen Horowitz、Nat Friedman、Daniel Gross 共同领投，红杉资本等跟投](#)。通过大规模融资公司将巩固语音领域优势，推进新产品研究并加强安全措施。公司宣布将上线新产品或功能，包括升级配音工作室；允许语音库社区分享用户克隆得到的语音副本；推出移动应用程序阅读器，可实时将文本和 URL 转为音频。

图表 56：ElevenLabs AI 视频翻译工具操作便捷



资料来源：ElevenLabs 官网，中金公司研究部

科大讯飞：语音算法打造技术壁垒，赛道多点开花

公司深耕智能语音领域，推出语音大模型维持算法领先地位。 科大讯飞成立于 1999 年，是中国智能语音与 AI 领域的领军企业。2016 年公司推出语音识别模型 DFCNN（深度全序列卷积神经网络），相较当时主流模型 BLSTM 识别率提升 15%；2022 年发布 SMART-TTS 框架并上线讯飞开放平台、讯飞有声以及学习强国，具备 11 种情感及每种情感 20 档的强弱调节；2024 年星火 V3.5 发布会上推出星火语音大模型，结合前沿的大语言模型架构以及自研语音属性解耦技术，可以实现多语种语音识别和合成，语音识别抗噪能力、语音合成拟人度与自然度大幅提升，在开源 Fleurs 等数据集上，已有 37 种语种的语音识别效果超过 Whisper V3。

图表 57：星火语音大模型达到国际领先水平



资料来源：星火 V3.5 发布会，中金公司研究部

图表 58：讯飞听见等应用拥有千万级活跃用户



资料来源：星火 V3.5 发布会，中金公司研究部

语音技术赋能各行各业，硬件集成优势技术展现潜能。公司语音技术在各行业赛道多点开花，包括教育行业中智能课堂、语音评测，城市治理中的智慧安防，医疗行业中智能导诊、电子病历等。汽车领域，公司已成为国内车载语音龙头企业。语音技术赋能讯飞听见、讯飞星火、讯飞输入法等产品，积累千万级的活跃用户。公司硬件销售额 23 年双 11 期间增长 126%，有望成为新的成长点。C 端硬件中录音笔、翻译机等集成领先的语音技术实现产品力提升，讯飞翻译机搭载最新语音大模型，升级 35 类语种自动识别与 AI 导游功能。


3D：产业持续探索，方向初见端倪

3D 生成任务要素：数据表征、数据集、生成模型、应用

3D 生成领域的整体思路：2D+空间信息。我们认为视频和 3D 的生成均可以视为 2D 图片生成任务的延伸，其中视频即为在图片生成的基础上增加时间信息，实现时序的对齐；3D 则为 2D 的基础上增加空间信息，实现高维的拓展。因此，在 2D 图片生成领域的主流主干模型（GAN、自回归、Diffusion、VAE 等）均可以在 3D 生成任务中实现模型扩展。在研究 3D 领域之前，《Advances in 3D Generation: A Survey》（Li 等，2024）对 3D 领域的**数据表示、训练数据集、训练数据集、3D 生成模型种类、应用**等做了归纳总结：

- ▶ **3D 数据表征：**包括网格（Mesh）、点云（Point clouds）等显式表示，以及 NeRF（Neural radiance fields，神经辐射场）等隐式表示，还包括体素（Voxel grids，3D 空间中的像素）这类混合表示，其中 NeRF 具有强大的三维表达能力和潜在的广泛应用范围，是 3D 数据表征的关键技术；
- ▶ **3D 数据集：**包括 3D 数据（数据量和精度有限）、多视角图片（用途最为广泛）、单张图片（使用仍具有较大难度）等。目前 3D 对象数据集仍然稀缺，代表性的数据集包括 ShapeNet（Chang 等，2015）构建了 5.1 万个 3D CAD 模型，为 3D 数据集的充实做出开创贡献；Deitke 等（2023）构建了 Objaverse 和 Objaverse-xl 数据集，分别有 80 万和 1000 万个 3D 对象；
- ▶ **3D 生成模型：**前馈生成（通过前向传递中直接生成结果）、基于优化的生成（每次生成需要迭代优化）、程序生成（根据规则创建 3D 模型）、生成式新视图合成（生成多视角图像）；
- ▶ **3D 应用：**包括 3D 人生成、3D 人脸生成、3D 物体生成、3D 场景生成等应用。

图表 59：3D 生成领域涵盖 3D 表示、3D 生成模型、数据集、应用



资料来源：《Advances in 3D Generation: A Survey》（Li et al., 2024），中金公司研究部

3D 生成可能是未来视觉多模态领域取得突破性进展的下一场景。回顾生成类大模型的发展进度，首先以 GPT-3 为代表的大模型在语言领域最先取得突破；接下来扩散模型逐步成熟使得图片生成任务能够很好完成；以图片为基础，我们认为视频可以看做图片在时间维度的扩展，以 Sora 为代表的大模型也产生了良好的效果，而 3D 模型则可以看做图片在空间维度的扩展，我们认为 3D 生成模型或成为下一个阶段学界和产业界进一步突破的方向，建议重点跟踪和关注前沿进展。

3D 模型生成技术的突破也会使产业迈向“世界模型”的探索更近一步。我们认为，若 3D 生成模型取得突破，则意味着大模型对空间信息的理解能力明显增强，能够学习到三维世界中的信息并生成三维物体和场景。结合视频（大模型对动作的时间变化的理解能力）领域取得的突破成果，大模型或能够具备对物理世界的时空信息具备更加完整把握能力，因此我们认为 3D 模型的潜在突破进展或能对构建理解一定物理信息的“世界模型”更进一步。


产业进展：海内外前沿 3D 生成工作介绍

3D 领域的生成式 AI 模型处于发展早期。目前看我们认为 3D 模型生成技术尚未收敛，基于优化的生成以及基于前馈网络直接生成均有相关工作，其中基于前馈网络的工作 Instant3D（Li 等，2023）能够实现 3D 对象的秒级快速生成；基于优化的生成则有 DreamFusion（Poole 等，2022）等工作。此外，我们也将简要介绍 3D 数据表征关键工作 NeRF。

Instant3D：基于前馈神经网络，实现 3D 对象快速生成

Instant3D 直接训练前馈神经网络，能在秒级时间内实现 3D 对象生成。为了解决基于优化的生成存在的生成耗时长、计算消耗大的缺点，Li 等（2023）提出了 Instant3D 模型，使用了条件解码器来实现文本提示词（prompt）到 3D 表征（使用了 Triplane）的映射，在此过程中交叉注意力（Cross-attention）、风格注入（Style injection）和 token-to-plane 转换相结合，生成 3D 表征。该方法还通过改进激活函数提高训练收敛速度、提出自适应的 Perp-Neg 算法来解决 3D 生成中的“多头”问题（同一个 2D 图像可能对应多个 3D 图像）。整体来看，该方法通过直接训练前馈神经网络，无需在每次生成中均进行优化，提升了 3D 对象的生成速度。

图表 60：Instant3D 模型架构




资料来源：《Instant3D: Fast Text-to-3D with Sparse-View Generation and Large Reconstruction Model》（Li et al., 2023），中金公司研究部

DreamFusion：基于 2D 扩散模型优化 NeRF

通过 2D 扩散模型优化 NeRF，实现文生 3D。在 NeRF 的基础上，近年来文生 3D 的主要模型框架为：通过初始化神经辐射场（NeRF）并在 2D 扩散模型的指导下进行参数优化，其中 2D 扩散模型通常为预训练的文生图像扩散模型。这类模型通常是基于优化的生成（Optimization-based generation），每次生成都需要较多次迭代来优化 NeRF，导致计算成本高昂且生成时间较长；其优势则在于不需要 3D 训练数据，也不需要图像扩散模型进行修改。典型的工作包括 DreamFusion（Poole 等，2022）、Latent-NeRF（Metzger 等，2023）、SJC（Jain 等，2022）、ProlificDreamer（Wang 等，2023）等。

图表 61：DreamFusion 技术架构图




资料来源：《DreamFusion: Text-to-3D using 2D Diffusion》（Poole et al., 2022），中金公司研究部

NeRF：隐式 3D 表征的代表模型

NeRF 是一种神经网络，能够通过 2D 图像重建 3D 场景。NeRF（Neural radiance fields，神经辐射场）由 Mildenhall 等研究者在 2020 年提出，其通过优化一个全连接神经网络 MLP（多层感知机），根据输入的二维图片来重新构建三维场景。NeRF 实现基于少量图片实现 3D 渲染，实现了三维几何模型的隐式表示，成为 3D 生成模型的重要基础技术。

具体来看，在训练阶段：a）首先沿相机光线采样出 5D 坐标（包括空间位置 x, y, z ）和视角方向坐标（ θ 和 ϕ ）；b）接下来将坐标输入 MLP 并生成颜色和体积密度；c）基于生成的颜色和体积密度值来得到一张图像；d）通过最小化合成图像和真实图像之间的残差进行优化。在生成阶段，则是基于某一视角来渲染得到神经辐射场：1）使相机光线“穿过”来生成一组 3D 采样点；2）基于这些点和视角方向作为 MLP 输入得到一组颜色和体积密度；3）基于这些值累加颜色和体积密度得到 2D 图像。

图表 62：NeRF 训练过程



资料来源：《Nerf: Representing scenes as neural radiance fields for view synthesis》（Mildenhall et al., 2020），中金公司研究部

应用展望：多模态 AI 典型创新应用场景概览

自动驾驶：大模型赋能多模态与世界模型学术研究

多模态模型凭借零样本学习等泛化能力，在智能驾驶各个模块均有应用潜力。在感知模块，多模态模型可以用于行人探测、语义分割、描述物体定位等，也有研究致力于探索将视觉信息转换为语言描述，并利用大语言模型的推理能力来识别语义异常探测。在决策模块，多模态模型可以用于语言导航、轨迹规划等，也可以利用大语言模型的思维链框架来将复杂的驾驶决策拆分为若干个细分问题。DriveGPT4 是多模态模型在智能驾驶领域的代表应用。详细解读参考[《探微智驾（二）：AI 大模型浪潮赋能智能驾驶》](#)。

图表 63：大语言模型和多模态大模型在智能驾驶领域的代表性应用

Method	Year	Tasks	Type	Contribution
Perception and Understanding				
NIC [25]	2020	IC	V2T, VTM	Introduce image captioning task to autonomous driving for traffic scene understanding.
VLPD [29]	2023	PD	VTM	Propose a vision-language extra-annotation-free method for pedestrian detection.
UMPD [30]	2023	PD	VTM	Propose a fully-unsupervised multi-view pedestrian detector without manual annotations.
MSG [26]	2023	SOR	VTF	Incorporate natural language with 3D LiDAR point cloud and camera image for LiDAR grounding task.
TransMOT [31]	2023	MOR-T	VTM	Propose Referring Multi-Object Tracking task, dataset, and benchmark based on KITTI.
PromptTrack [32]	2023	MOR-T	VTM	Propose Multi-view 3D Referring Multi-Object Tracking dataset based on nuScenes.
OpenScene [33]	2023	OV-3DSS	VTM	Propose a zero-shot method for extracting 3D dense features from open vocabulary embedding space.
CLIP2Scene [34]	2023	OV-3DSS	VTM	Distill CLIP knowledge to a 3D network for 3D scene understanding.
UP-VL [35]	2023	OV-3DOD-T	VTM	Introduce a semantic-aware unsupervised detection for objects in any motion state.
Zaida [36]	2023	LVR	VTM	Introduce a video analytic system using VLMs that delivers semantically diverse, high-quality results.
NuScenes-QA [21]	2023	VQA	M2T, VTF	Introduce visual question-answering task and baseline model in autonomous driving based on nuScenes.
Talk2BEV [23]	2023	VSR, OL-DM	M2T	Augment BEV maps with language to enable general-purpose visuo-linguistic reasoning for AD scenarios.
LLM-AD [43]	2023	SAD	LLM	Propose a framework to detect semantic anomalies leveraging LLMs' reasoning abilities.
Navigation and Planning				
TuV [44]	2019	LGN	M2T, VTF	Propose a modular framework following Language Instructions to provide accurate waypoints for LGN.
Gin [37]	2022	LGN	M2T, VTM	Present a vision language navigation tool to control vehicle movements based on language-driven commands.
ALT-Pilot [38]	2023	VLL, LGN	M2T, VTM	Propose an autonomous navigation system based on language-augmented topometric maps.
GPT-Driver [45]	2023	MP	LLM	Transform motion planning task into a language modeling problem.
CoverNet-T [28]	2023	TP	M2T, VTF	Introduce text and image representation for trajectory prediction.
Decision Making and Control				
Advisable-DM [46]	2020	OL-DM	M2T, VTF	Propose a advisable and explainable model for self-driving systems.
LanguageMPC [47]	2023	OL-DM	LLM	Devised a chain-of-thought framework for LLMs in driving scenarios that divides decision-making process into numerous sub-problems.
DaYS [48]	2023	OL-DM, MP	LLM	Provide a framework to integrate LLMs into autonomous vehicles.
DwLLMs [49]	2023	OL-C, VSR	LLM	Propose a model with object-level fusion for Explainable AD.
DiLU [50]	2023	CL-DM	LLM	Instill knowledge-driven capability into autonomous driving systems from the perspective of how humans drive.
SurrealDriver [51]	2023	CL-DM	LLM	Develop an LLM-based driver agent for complex urban environments.
DLAII [22]	2023	CL-DM	M2T, VTF	Show the feasibility and decision-making ability of LLM in driving scenarios in the simulated environment.
End-to-End Autonomous Driving				
DriveGPT4 [18]	2023	VQA, OL-C	M2T, VTF	Propose a multimodal model for interpretable AD with multimodal as input and control signal as output.
ADAPT [19]	2023	VSR, OL-DM	V2T, VTF	Propose an end-to-end action narration and reasoning framework for self-driving vehicles.
Data Generation				
DriveGAN [52]	2021	CVG	M2V, VTF	Propose an end-to-end controllable differentiable neural driving simulator for scenario re-creation.
GAIA-1 [20]	2023	CVG	M2V, VTF	Propose a multi-modal generative model to produce realistic driving scenarios with precise control over ego-vehicle actions and scene attributes.
DriveDreamer [24]	2023	CVG	M2V, VTF	Introduce the first world model derived from real-world driving scenarios, capable of generating high-quality driving videos and sound driving policies.
BEVControl [53]	2023	CIG	M2V, VTF	Present a sketch-based street-view images generative model based on nuScenes.

注：V2T 为图像到文本，VTM 为图像文本匹配，VTF 为图像文本融合，M2T 为多模态到文本，M2V 为多模态到图像，LLM 为大语言模型
资料来源：X. Zhou, M. Liu, et al., "Vision Language Models in Autonomous Driving and Intelligent Transportation Systems", 2023, 中金公司研究部

DriveGPT4 接受视频、文本、控制信号等多模态输入，输出问题回答和控制信号（文本形式）预测。多种模态的输入分别 token 化，合并后作为大语言模型的输入，大语言模型生成预测的 token，最后转换为自然语言。DriveGPT4 采用的大语言模型为 LLaMA 2。DriveGPT4 利用多模态大语言模型构建了一种可解释的端到端智能驾驶框架，论文⁴显示其在车辆行为描述与辩护、问题回答和控制信号预测等任务上表现良好，且展现出稳健的零样本泛化能力。

大语言模型和多模态大模型在智能驾驶中的应用仍处早期阶段，距离实际落地尚有一定距离。一方面，大模型自身能力上，仍面临幻觉、空间推理能力、动态规划能力等领域的挑战；另一方面，给定能力成熟的大模型，如何部署到车端算力平台等问题还有待深入探索。此外，我们认为，将时效性要求不高的困难场景上传至云端大模型寻求解决方案，引入记忆模块，或者通过云端大模型为车端小模型提供训练数据，也是有潜力的路径。


⁴ Z. Xu, Y. Zhang, et al., "DriveGPT4: Interpretable End-to-end Autonomous Driving via Large Language Model", 2023

世界模型：从判别式 AI 到生成式 AI，搭建智能驾驶 Foundation Model

世界模型（World model）是人工智能领域的重要概念，旨在让模型学习和理解关于整个环境的结构化时空特征表示。类似于人类基于主观认知和预测进行决策，世界模型希望通过无监督学习的方式让 AI 模型压缩习得对相关环境的全面深刻认知。具体到智能驾驶领域，世界模型的目的是对驾驶环境动态建模，基于已有信息（历史视频、历史驾驶决策等），预测未来驾驶环境将如何演变，相应做出驾驶决策。

DriveDreamer 是近年世界模型领域具有代表性的探索工作，创新点在于将真实复杂的驾驶场景应用到世界建模。根据其论文⁵，DriveDreamer 接受包含初始参考帧、道路结构化信息和历史决策信息在内的多模态输入，生成未来时刻的驾驶场景视频与驾驶决策。其中，扩散模型（Diffusion model）是 DriveDreamer 的重要构件，能够习得图像复杂的数据分布情况。

图表 64：DriveDreamer 整体架构概览



资料来源：X. Wang, et al., "DriveDreamer: Towards Real-world-driven World Models for Autonomous Driving", 2023, 中金公司研究部

在业界，特斯拉、Wayve 和商汤均在探索世界模型，其中 Wayve 将其模型命名为 GAIA-1⁶。GAIA-1 架构包含图像 token 器（3 亿参数）、世界模型（65 亿参数）和视频解码器（26 亿参数）等组成部分，接受多模态输入，输出驾驶视频预测。根据 Wayve 的展示⁷，GAIA-1 的涌现能力包括学习高阶结构、理解 3D 环境、语境意识、创造性、对其他智能体做出交互反应等，还能成功推断训练数据以外的场景。我们认为这些能力的出现，说明 GAIA-1 可以理解并重构现实世界的规则与行为、习得不同行为决策之间的交互关系，展现出世界模型有潜力诞生出与大语言模型类似的泛化能力。

智能驾驶世界模型的探索属于初期阶段，生成实时性和稳定性等诸多挑战有待解决。观察 GAIA-1 生成的场景，略偏模糊，连续帧可能存在车或背景形状颜色类型的跳边，这可能表明现阶段 GAIA-1 还没有很好地理解事物变化的连续性⁸。此外，由于智能驾驶最终目标是决策，世界模型的优化目标和工程设计可能更加复杂，并非只看生成的准确性⁹。

⁵ 资料来源：X. Wang, Z. Zhu, et al., "DriveDreamer: Towards Real-world-driven World Models for Autonomous Driving", 2023

⁶ 资料来源：https://mp.weixin.qq.com/s/5Uq1dDRWfpabc-2u4SXkxQ

⁷ 资料来源：1. A. Hu, L. Russell, et al., "GAIA-1: A Generative World Model for Autonomous Driving", 2023; 2. https://wayve.ai/thinking/introducing-gaia-1/

⁸ 资料来源：https://mp.weixin.qq.com/s/5Uq1dDRWfpabc-2u4SXkxQ


⁹ 资料来源：L. Chen, P. Wu, et al., "End-to-end Autonomous Driving: Challenges and Frontiers", 2023, P14

Agent：以多模态信息为感知基础，打造远期场景闭环

系统框架：AI Agent = Brain 控制端 + Perception 感知端 + Action 行动端


复旦大学 NLP 团队于 2023 年 9 月提出¹⁰，AI Agent 的概念框架包括 Brain（控制端）、Perception（感知端）和 Action（行动端）三个组成部分：控制端承担记忆、思考、决策等基础任务，感知端负责感知并处理来自外部环境的多模态信息，行动端则负责利用工具执行，从而对外界环境产生影响。详细解读参考《AI 十年展望（十五）：AI Agent：远期场景闭环，交互重塑》。

图表 65：AI Agent = Brain 控制端 + Perception 感知端 + Action 行动端



资料来源：《The Rise and Potential of Large Language Model Based Agents: A Survey》(Xi et al., 2023)，中金公司研究部

图表 66：AI Agent 的工作示例




资料来源：《The Rise and Potential of Large Language Model Based Agents: A Survey》(Xi et al., 2023)，中金公司研究部

文本、图像等多模态信息原始输入为 Agent 能力基础。对于人类和动物而言，感觉器官从周围环境中收集的信息是他们感知世界并与外界互动的基础。与之类似，对于 AI Agent 而言，通过各种传感器输入的文本、视觉、听觉等多模态信息同样是它们了解环境、作出决策和拓展任务解决能力的基础。

¹⁰ Zhiheng Xi. et al. The Rise and Potential of Large Language Model Based Agents: A Survey 2023. <https://arxiv.org/abs/2309.07864>.

图表 67：AI Agent 感知端：感知并处理来自外部环境的多模态信息



资料来源：《The Rise and Potential of Large Language Model Based Agents: A Survey》(Xi et al., 2023)，中金公司研究部

我们认为，多模态方向进展是 AI Agent 未来大规模商业化落地的前提条件。1) 从技术角度，由于大模型是 AI Agent 的重要基座，因而大模型的基础能力提升尤为关键；同时，在多模态方向进展是 AI Agent 未来发展的前提条件；此外，Agent 各模块之间如何配合、多个 Agent 如何交互、人类与 Agent 如何互动等方面均存在较大的技术提升空间。2) 从成本角度，Agent 产品需要将真实业务场景和工作流转化为底层大模型能理解的数据、进行多模块和多代理之间的交互，或将产生高昂的推理成本，不仅需要解决用户的需求，同时也要考虑实际部署中的成本管控问题。

长期展望：Agent 有望带来人机交互范式、软件架构、商业模式革新

理想状态下，有望带来人们观念的跃迁、变革人机交互方式同时推动 AI 基础设施化。目前大多数 AI 应用的定位具备明显的工具属性，我们认为，长期来看，AI Agent 应同时具备工具属性和人格属性，有望引发人们思想观念的跃迁。同时，目前的人机交互方式主要以图形界面和触控交互为主，我们认为未来 AI Agent 有望成为操作系统级别的入口，实现“对话即接口”的全新人机交互范式，或将带来全新的软件服务形态。从软件架构角度，我们认为，未来软件产品形态有望以 AI Agent 为核心，将传统软件预定义的部分调整成由 Agent 自主生成，并将任务解决范围拓展至无限域，生产方式或将从以人为核心、AI 为辅助，向以 AI 为核心、人为辅助演进，在长期有望迎来 Agent-Centric 时代。

图表 68：软件架构从过程导向迁移到目标导向，长期有望迎来 Agent-Centric 时代



资料来源：腾讯研究院，深度学习公众号，中金公司研究部

在商业模式上，代理即服务（Agent as a Service, AaaS）或是潜在方向。Zhiheng Xi 等指出¹¹，由于 AI Agent 比 LLM 模型本身更为复杂，未来中小型企业或个人很难依靠自身力量在本地独立构建。因此，我们认为未来海内外科技大厂或将逐步构建 AI Agent 生态体系，为广大开发者自主构建、自由交易 Agent 具体应用提供底层算力基础设施并打造 Agent 共享平台，从而逐渐把先发优势转化为生态壁垒。2023 年 11 月，OpenAI 在首届开发者大会上重磅宣布将推出 GPTs 的共享平台 GPT-Store¹²，我们认为，这不仅有望为 OpenAI 构建生态繁荣筑基，还有望引导商业模式向构建类 Agent 生态的方向演进。

从迭代方向上，AI Agent 下一步有望朝着多方向、多维度同时发展。我们认为，随着后续 AI Agent 系统框架逐渐完善、大模型基础能力和多模态能力的提升，AI Agent 应用有望从垂直行业场景发展到通用领域，从完成特定任务拓展到创新任务，在互补流程、任务范围等层面与人类更紧密地合作，最终逐步形成 Agent Society，进一步向通向 AGI 的道路迈进。

具身智能：多模态 AI 迭代有望进一步提升机器人的感知决策能力

人形机器人通过软硬件模拟人类的身体结构和运动方式，实现“具身智能”。具体而言，类比人类的运动方式，人形机器人的运动和行为也主要由“大脑、小脑、肢体”三大部分构成：

- ▶ “**大脑**”：AI 赋能感知和决策。具体来说，机器人的感知（物体检测、图像分割等）、决策（策略学习、任务规划等）能力均依赖 AI 模型赋能，当前与人类的交互方式仍然以文字交互为主。展望未来，我们认为多模态大模型有望加强机器人对图像和视频的理解能力，一方面有助于其对物理世界进行更为准确的感知，另一方面在于人的交互方式有望摆脱文字的束缚（如依据人类的动作或表情来做出反应）来支持更为丰富的交互方式。
- ▶ “**小脑**”：人形机器人的运动规划和控制模块。包括步态规划和控制算法、稳定控制算法、灵活性控制算法等，是人形机器人运动的核心技术，决定了机器人运动的协调性。
- ▶ “**肢体**”：人形机器人运动的执行环节。与人类运动过程中的关节类似，伺服驱动在人形机器人运动中也充当了“关节”的作用，是机器人稳定执行灵活、复杂、多样的基础。

图表 69：人形机器人核心技术



资料来源：优选招股说明书，中金公司研究部


¹¹ Zhiheng Xi. et al. The Rise and Potential of Large Language Model Based Agents: A Survey 2023. <https://arxiv.org/abs/2309.07864>.

¹² <https://finance.sina.com.cn/tech/2023-11-07/doc-imztztzhu2557260.shtml>

AI 模型赋能感知和决策，RT-X、PaLM-E 等模型实现文字、图像、动作等多模态打通。


《Foundation Models in Robotics: Applications, Challenges, and the Future》(Firoozi 等, 2023)总结了机器人领域大模型进展。整体来看，在机器人感知（包括物体检测、图像分割等）和决策（策略学习、任务规划等）领域均有学者发表了一系列工作。同时，以谷歌 RT-1、RT-2、RT-X、PaLM-E 等为代表的机器人 Transformer 模型整合了感知、决策、行动生成等任务框架，能够实现机器人端到端的控制。如 **PaLM-E** 模型（5620 亿参数）通过将其其他图像、状态等模态的信息注入预训练语言模型 PaLM 的语言嵌入空间，基于文字、图像等输入能够产生文本回答或者生成文本指令使机器人执行。

图表 70：机器人领域的基础大模型



资料来源：《Foundation Models in Robotics: Applications, Challenges, and the Future》(Firoozi et al., 2023)，中金公司研究部


图表 71：PaLM-E 模型架构



资料来源：《PaLM-E: An Embodied Multimodal Language Model》(Driess et al., 2023)，中金公司研究部

强化学习助力多任务控制，TD-MPC2 展现出良好的可拓展性。大模型在自然语言处理任务中展现了优异的可拓展性，伴随参数量增加实现性能持续提升，学界也在探索机器人领域模型的可拓展能力，试图通过低水平动作的学习来完成多样控制任务。其中强化学习能够模型来助力机器人从未分级数据（如混合质量数据）提取学习专家行为从而实现更好的控制性能，然而先前模型通常只能处理单任务学习。Hansen、Su、Wang（2023）等人提出 TD-MPC2 算法，成功训练了一个 3.17 亿参数的模型来执行多个领域中的 80 个任务，且模型展现出了良好的可拓展性（Scalable），伴随参数量的提升实现了控制能力的明显提升。

图表 72：TD-MPC2 展示出可拓展性（Scalable），在多任务控制中表现优异



资料来源：《TD-MPC2: Scalable, Robust World Models for Continuous Control》(Hansen, Su, Wang, 2023)，中金公司研究部

机器人领域的大模型仍然面临一系列挑战：

- **数据仍具稀缺性：**相较于互联网级别的文本和图像大模型训练数据，机器人领域数据相对缺乏。Firoozi 等（2023）总结了潜在的解决方案，如使用游戏数据而非经验数据、借助数据增强方法获取数据等；
- **实时性能要求高：**实时性是机器人响应的基本要求之一，然而部分模型的推理效率仍然需要持续提升。另一方面，许多基础模型都是通过云端 API 的方式进行调用，响应速度或受到一定影响；
- **模型的可靠性：**与文字、图片、视频等生成任务不同，机器人由于要与真实物理世界进行交互，其可靠性要求也将更高。当前 LLM 等大模型可能会产生“幻觉”的情况下，我们认为机器人运行过程中的安全性仍有待提升。

AI 大模型之外，伺服驱动和运动控制或也将成为机器人运动的“胜负手”。我们认为大模型对人形机器人的感知决策能力持续赋能，大模型的发展有望让机器人的“大脑”更为智能。另一方面，我们认为充当“小脑”功能的运动规划和控制模块以及充当机器人“关节”的伺服驱动系统或也有望成为决定机器人运动的“胜负手”，运动控制系统的精确程度以及伺服驱动系统的执行稳定性或将成为影响人形机器人运动表现的关键。

附录：国内多模态 AI 相关创业公司巡礼

智谱 AI：植根清华系血脉，CogView3 效果跃进


发源于清华系研究室团队，**CogView 文生图模型综合维度领先**。智谱 AI 成立于 2019 年，专注于 AI 大模型研发与应用，脱胎于清华大学计算机系团队。文生图模型 CogView 为智谱 AI 创始人唐杰教授团队研发成果，为智谱 AI 文生图多模态能力发展奠定基础。2022 年升级 CogView2，将推理速度从 5 分钟缩短至 45 秒，分辨率提升 4 倍，精细度跃进。2024 年 1 月迭代 CogView3，采用自研“中继扩散模型”技术，改善扩散模型生成不稳定的问题。据发布会介绍，CogView3 综合维度上超越开源最佳模型 Stable Diffusion XL，达到 DALL·E 3 90% 以上水平，同时语义理解能力增强。智谱已推出 All Tools 工具，可调用基于 CogView 系列模型的文生图能力，从而图片创作能够更好结合上下文语境，与用户连续交互，带来更丰富的场景体验。

图表 73：CogView3 效果超越 Stable diffusion XL，相比 DALLE3 约在 91.4% ~99.3% 的水平之间

CogView3：文生图								
	Alignment	Fidelity	Aesthetic	Safety	Composition & Layout	Lighting & Shadow	Color User	Emotional Response
SDXL (开源最佳)	0.467	0.740	0.694	0.978	0.739	0.717	0.720	0.597
DALLE3	0.770	0.852	0.735	0.980	0.772	0.772	0.746	0.649
CogView3	0.706	0.802	0.702	0.973	0.733	0.728	0.708	0.593
CogView3/DALLE3	91.7%	94.1%	95.5%	99.3%	94.9%	94.3%	94.9%	91.4%

资料来源：ZHITU DevDay，中金公司研究部

图表 74：GLM-4 文生图模型 CogView3 可以做到高精度的 prompt 理解和遵循，支持连续指令修改生图




资料来源：ZHITU DevDay，中金公司研究部

智子引擎：国内多模态大模型先行者，图像理解技术 B 端落地

传承人大高瓴学术基因，探索多模态大模型无人区。智子引擎成立于 2021 年，CEO 为人大高瓴人工智能学院博士高一钊，公司顾问为人大高瓴人工智能学院教授卢志武，后者兼任软通动力首席 AI 科学家。公司团队主要来自人大高瓴人工智能学院，在多模态领域积淀深厚，早在 2020 年，以卢志武为核心成员的高瓴团队率先开始从事多模态方向研究，研发“文澜”多模态大模型，引领国内多模态研究发展。2023 年 8 月，智子引擎已完成数千万元天使+轮融资，由两家头部投资机构联合领投，软通高科等多方跟投。

推出图像理解产品 ChatImg，聚焦 B 端巡检、安防等场景落地。依托“文澜”大模型研发经验，2023 年 3 月公司推出应用级多模态 ChatGPT 产品元乘象 ChatImg，ChatImg 参数约为 150 亿，具备图像理解、智能对话的功能。6 月迭代 ChatImg2.0，支持语音与视频输入，丰富多模态能力。10 月发布元乘象 ChatImg3.0，通过描述、检测、OCR 等多任务训练与指令微调，多模态模型实现更高的精细度与准确度，问答等能力比肩 GPT-4V。ChatImg 旨在解决 B 端行业的实际问题。公司联合软通智慧基于 ChatImg 打造城市治理云 GPT-Creator2.0，多个复杂场景的覆盖度与识别率高达 90%；与软通动力、华软科技合作推出智子•天穹等产品，应用于城市治理、园区管理等，已开始试点部署。

图表 75：ChatImg 具备较强的图片和视频理解功能




资料来源：智子引擎官方公众号元乘象，中金公司研究部

生数科技：打造通用多模态模型基础设施，2D 与 3D 图像多方位布局


人才与技术优势雄厚，结合 Diffusion 和 Transformer 自研通用多模态模型。生数科技成立于 2023 年，由瑞莱智慧 RealAI、蚂蚁和 BV 百度风投联合孵化，关注 AIGC 基础设施和应用建设，瑞莱前副总裁唐家渝担任公司 CEO。2023 年 6 月公司完成近亿元天使轮融资，蚂蚁集团领投；8 月再获数千万元天使+轮融资，在资本市场表现活跃。公司团队主要来自清华大学人工智能研究院，在贝叶斯模型、扩散概率模型上成果领先，人才优势支撑多模态大模型研发。2023 年 9 月推出自研多模态通用大模型，创新性地结合 Diffusion 和 Transformer，借助 Transformer 的序列化能力实现文本、2D、3D 和视频模态任意转换，面向游戏制作、广告营销行业提供多模态 MaaS 服务。

2D 图像生成遵循语义细节，3D 模型生成提效游戏开发。基于多模态通用大模型的模态转化能力以及先进的扩散模型算法，公司分别于 2D 图像与 3D 图像领域推出两款消费级产品。2D 领域推出文生图平台 PixWeaver，对于多类别元素、空间关系等语义信息理解准确；3D 领域推出 3D 资产创建工具 VoxCraft，支持文生 3D、图生 3D，在几何精细度、贴图可控性、生成速度等方面具备优势，直接对接工业管线，推进应用落地。目前公司已与多家游戏公司展开合作，辅助开发者快速设计 3D 游戏角色和特效。

图表 76：生数科技多模态模型覆盖 2D、3D 与视频生成 **图表 77：PixWeaver 对语义细节的遵循准确度较高**



资料来源：生数科技官方公众号，中金公司研究部



资料来源：生数科技官方公众号，中金公司研究部

出门问问：C 端配音应用魔音工坊出圈，注册用户超 800 万

序列猴子大模型赋能语音引擎，利用文本基座能力提升语音自然度与表现力。出门问问成立于 2012 年，是一家专注于 AIGC 和语音交互的人工智能公司。2015 年发布第一代 TTS（Text-To-Speech，文本转语音）系统，2024 年 1 月已迭代至第六代引擎 MeetVoice Pro。新一代引擎对离散化语音 token 建模，基于序列猴子大模型先进的文本基座能力，可以迁移 LLM 涵盖的常识知识，处理更复杂的文本到语音映射，精准呈现多音字、韵律情感，使 AI 配音接近真实人声水准。MeetVoice Pro 还优化了声音克隆功能，仅需几秒音频即可克隆声音；跨语种转换能力增强，能将不同语种转换为同音色的中文或英文。

图表 78：出门问问 TTS 引擎已迭代至第六代



资料来源：出门问问官方公众号，中金公司研究部

推出 AI 配音 C 端应用魔音工坊，语音编辑便捷，促进用户飞轮形成。魔音工坊是出门问问旗下一款集成写作、配音与剪辑的一站式 AI 软件，搭载了公司先进的语音引擎。魔音工坊具备

庞大的音频数据库，包括 1000+款音色、37 种语言与 15 种方言，首创“捏声音”功能，可根据自然语言 prompt 定制声音，丰富用户的选择。魔音工坊音频编辑操作便捷，用户可以对生成的配音直接调节停顿、语调、多音字发音等，在短视频创作者群体中收到欢迎，截至 2024 年 1 月已拥有 800 万注册用户与 60 万付费用户，有效促进数据飞轮形成。公司已推出海外版“DupDub”与可调 API 的企业版本，在专业配音领域具备高知名度。

图表 79：魔音工坊首创“捏声音”功能




资料来源：魔音工坊官网，中金公司研究部

云知声：专注语音技术场景落地，语音芯片出货量达千万级

基于山海大模型多模态能力，实现智慧医疗、智慧家居等多领域落地。云知声深耕 AI 语音交互领域多年，2016 年构建 Atlas AI 基础平台支持模型训练优化；2023 年打造山海大模型，成为云知大脑核心，升级多模态感知与生成能力，推进语音技术在行业的落地应用。医疗领域，2023 年 9 月公司的门诊病历生成系统率先落地北京友谊医院，可精准捕捉并总结医患对话，一键录入病历，有效提升诊断效率；政务领域，10 月打造深圳首个政务大模型“龙知政”，语音能力应用于客服机器人、医疗助手等；汽车领域，联合吉利睿蓝打造情感型 AI 虚拟助手，为用户提供个性化的语音交互服务；教育领域，12 月公司为学而思学习机 xPad2 Pro 的语音助手提供技术支持，并推出英语学伴 Utalk，截至 24 年 2 月用户量已破 10 万；生活领域，公司积极布局智能家居，“蜂鸟”芯片支持离线语音交互，并具备智能语义理解能力，已覆盖 TCL、美的、格力、海尔等大型厂商，出货量达千万级别。

图表 80：云知声全栈技术架构及产业化体系



资料来源：云知声官方公众号，中金公司研究部

MiniMax：自研语音大模型基于 6 秒音频克隆，开放多元 API 提升性价比

MiniMax 自研语音大模型，具备超自然、高延展与可定制性。MiniMax 是一家成立于 2021 年的人工智能创业公司，具备领先的多模态技术。2023 年 11 月，公司推出语音大模型 abab-speech-01。1 月语音大模型实现更新，基于数百万小时音频数据训练，能通过 6 秒音频实现语音克隆，TTS 字错率降至万分之五。MiniMax 语音大模型可生成超自然、多样化的语音，在用户定制化上亦具备优势。

- ▶ **超自然：**语音大模型能基于文本预测情感与语调，在断句、节奏韵律、戏剧张力上保持较高质量。
- ▶ **高延展：**覆盖超 8 种语言，组合数千种音色创造新的声音效果，于播客、有声书、数字人等多元场景应用。
- ▶ **可定制：**用户可通过字典功能定义文本读音，还可控制间隔时长精细调节语音节奏。

图表 81：MiniMax 语音大模型产品架构



资料来源：MiniMax 官方公众号，中金公司研究部

首次开放多角色配音商用接口，API 服务性价比提升。公司打造 2B 语音开放平台，已服务超 400 家企业，包括起点读书、高途、好未来等。2024 年 1 月，在原有 T2A（基础语音合成）、T2A Pro（支持单次输入 50000 字符及调参）API 基础之上率先更新多角色配音能力，可批量生成与克隆多角色音频；添加 T2A Stream，实现流式语音输出，即生成输出同步完成，降低时延；下调 3 类 API 价格，提升产品性价比。公司语音能力赋能星野、海螺问问等 C 端产品应用，其中海螺问问上线语音通话功能，并免费提供声音克隆能力，改善用户交互体验。

图表 82：MiniMax 三类语音 API 价格下调至 5 元/万字符，截至 2024 年 1 月

	abab-speech-01		abab-speech-01 + speech-02	
	功能	价格	功能	价格
语音合成功能	T2A	10 元/万字符	T2A	5 元/万字符
	T2A Pro		T2A Pro	
			T2A Stream	

新功能：字典、间隔时间控制；文本角色分类+角色音频生成

流式语音输出功能

资料来源：MiniMax 官方公众号，中金公司研究部

风险提示

技术进展不及预期。多模态大模型仍处于相对早期的发展阶段，尤其是 3D、具身智能等领域的多模态模型技术路线仍未收敛，学界和产业界仍然在持续探索，技术进展仍有不确定性。

应用落地不及预期。大模型的商业落地依赖于流行应用的出现，目前图片、视频等领域的多模态应用商业探索仍处于早期，商业模式尚未定型，应用的商业落地仍有不确定性。

行业竞争加剧。我们观察到近年来图片、视频等多模态模型快速涌现，相应的生成类应用也快速集中出现，市场竞争压力下部分应用推出以来已经有所降价。若行业竞争加剧，多模态 AI 应用价格或有所承压，压缩相关应用厂商的利润空间。

图表 83：可比公司估值表

股票代码	公司名称	财报货币	收盘价 03-04	市值（百万 元）	市盈率			市销率		
					2023A/E	2024E	2025E	2023A/E	2024E	2025E
600588.SH	用友网络*	CNY	12.91	44,133	N.M.	146.9	73.8	4.5	4.0	3.4
300634.SZ	彩讯股份	CNY	18.68	8,362	22.3	20.6	16.2	5.4	4.2	3.3
688095.SH	福昕软件*	CNY	56.18	5,140	N.M.	152.2	N.M.	8.5	7.5	N.M.
603039.SH	泛微网络*	CNY	40.08	10,445	128.5	51.5	N.M.	4.1	3.3	N.M.
688369.SH	致远互联*	CNY	23.94	2,757	35.8	15.8	N.M.	2.3	1.8	N.M.
600570.SH	恒生电子*	CNY	24.79	47,101	35.0	32.1	28.6	6.5	5.8	5.2
300674.SZ	宇信科技*	CNY	13.95	9,914	23.3	17.7	N.M.	1.9	1.6	N.M.
002230.SZ	科大讯飞*	CNY	52.33	121,164	176.9	170.2	152.2	6.0	5.5	5.1
300253.SZ	卫宁健康*	CNY	7.06	15,195	36.3	21.9	N.M.	4.0	3.3	N.M.
300451.SZ	创业慧康*	CNY	4.80	7,436	29.2	17.5	N.M.	4.4	3.8	N.M.
688777.SH	中控技术*	CNY	47.77	37,734	34.3	29.8	23.6	4.4	3.6	2.8
688083.SH	中望软件*	CNY	83.80	10,165	184.4	68.7	37.3	12.3	9.3	7.3
603859.SH	能科科技*	CNY	37.41	6,231	20.8	16.4	12.6	3.8	3.3	2.7
300378.SZ	鼎捷软件*	CNY	19.48	5,246	42.2	30.8	20.6	2.4	2.1	1.8
002315.SZ	焦点科技*	CNY	34.77	10,984	28.8	22.7	18.3	7.2	6.3	5.6
688365.SH	光云科技*	CNY	8.57	3,649	N.M.	N.M.	N.M.	7.0	6.1	N.M.
300687.SZ	赛意信息*	CNY	19.54	8,014	28.6	24.7	21.3	3.2	2.9	2.6
300496.SZ	中科创达*	CNY	63.41	29,169	36.1	35.9	N.M.	5.0	4.6	N.M.
00020.HK	商汤-W*	CNY	0.89	27,385	N.M.	N.M.	N.M.	6.3	5.5	N.M.

注：标*公司为中金覆盖，采用中金预测数据；其余使用市场一致预期

资料来源：Wind，彭博资讯，公司公告，中金公司研究部

作者信息



于钟海 分析员

SAC 执证编号: S0080518070011
SFC CE Ref: BOP246
zhonghai.yu@cicc.com.cn



王之昊 分析员

SAC 执证编号: S0080522050001
SFC CE Ref: BSS168
zhihao3.wang@cicc.com.cn



魏鹤隼 分析员

SAC 执证编号: S0080523060019
SFC CE Ref: BSX734
guanfei.wei@cicc.com.cn



谭哲贤 联系人

SAC 执证编号: S0080122070047
zhexian.tan@cicc.com.cn



肖楷 分析员

SAC 执证编号: S0080523060007
SFC CE Ref: BUF316
kai3.xiao@cicc.com.cn



游航 分析员

SAC 执证编号: S0080523010001
SFC CE Ref: BTI822
hang.you@cicc.com.cn



法律声明

一般声明

本报告由中国国际金融股份有限公司（已具备中国证监会批复的证券投资咨询业务资格）制作。本报告中的信息均来源于我们认为可靠的已公开资料，但中国国际金融股份有限公司及其关联机构（以下统称“中金公司”）对这些信息的准确性及完整性不作任何保证。本报告中的信息、意见等均仅供投资者参考之用，不构成对买卖任何证券或其他金融工具的出价或征价或提供任何投资决策建议的服务。该等信息、意见并未考虑到获取本报告人员的具体投资目的、财务状况以及特定需求，在任何时候均不构成对任何人的个人推荐或投资操作性建议。投资者应当对本报告中的信息和意见进行独立评估，自主审慎做出决策并自行承担风险。投资者在依据本报告涉及的内容进行任何决策前，应同时考量各自的投资目的、财务状况和特定需求，并就相关决策咨询专业顾问的意见对依据或者使用本报告所造成的一切后果，中金公司及/或其关联人员均不承担任何责任。

本报告所载的意见、评估及预测仅为本报告出具日的观点和判断，相关证券或金融工具的价格、价值及收益亦可能会波动。该等意见、评估及预测无需通知即可随时更改。在不同时期，中金公司可能会发出与本报告所载意见、评估及预测不一致的研究报告。

本报告署名分析师可能会不时与中金公司的客户、销售交易人员、其他业务人员或在本报告中针对可能对本报告所涉及的标的证券或其他金融工具的市场价格产生短期影响的催化剂或事件进行交易策略的讨论。这种短期影响的分析可能与分析师已发布的关于相关证券或其他金融工具的目标价、评级、估值、预测等观点相反或不一致，相关的交易策略不同于且也不影响分析师关于其所研究标的证券或其他金融工具的基本面评级或评分。

中金公司的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。中金公司没有将此意见及建议向报告所有接收者进行更新的义务。中金公司的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见不一致的投资决策。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现。过往的业绩表现亦不应作为日后回报的预示。我们不承诺也不保证，任何所预示的回报会得以实现。分析中所做的预测可能是基于相应的假设。任何假设的变化可能会显著地影响所预测的回报。

本报告提供给某接收人是基于该接收人被认为有能力独立评估投资风险并就投资决策能行使独立判断。投资的独立判断是指，投资决策是投资者自身基于对潜在投资的目标、需求、机会、风险、市场因素及其他投资考虑而独立做出的。

本报告由受香港证券及期货事务监察委员会监管的中国国际金融香港证券有限公司（“中金香港”）于香港提供。香港的投资者若有任何关于中金公司研究报告的问题请直接联系中金香港的销售交易代表。本报告作者所持香港证监会牌照的牌照编号已披露在报告首页的作者姓名旁。

本报告由受新加坡金融管理局监管的中国国际金融（新加坡）有限公司（“中金新加坡”）于新加坡向符合新加坡《证券期货法》定义下的合格投资者及/或机构投资者提供。本报告无意也不应直接或间接地分发或传递给新加坡的任何其他人。提供本报告于合格投资者及/或机构投资者，有关财务顾问将无需根据新加坡之《财务顾问法》第 45 条就任何利益及/或其代表就任何证券利益进行披露。有关本报告之任何查询，在新加坡获得本报告的人员可联系中金新加坡持牌代表。

本报告由受金融行为监管局监管的中国国际金融（英国）有限公司（“中金英国”）于英国提供。本报告有关的投资和服务仅向符合《2000 年金融服务和市场法 2005 年（金融推介）令》第 19（5）条、38 条、47 条以及 49 条规定的人士提供。本报告并未打算提供给零售客户使用。在其他欧洲经济区国家，本报告向被其本国认定为专业投资者（或相当性质）的人士提供。

本报告由中国国际金融日本株式会社（“中金日本”）于日本提供，中金日本是在日本关东财务局（日本关东财务局长（金商）第 3235 号）注册并受日本法律监管的金融机构。本报告有关的投资产品和服务仅向符合日本《金融商品交易法》第 2 条 31 项所规定的专业投资者提供。本报告并未打算提供给日本非专业投资者使用。

本报告亦由中国国际金融股份有限公司向符合日本《金融商品交易法施行令》第 17 条第 3 款第 1 项及《金融商品交易法》第 58 条第 2 款但书前段所规定的日本金融机构提供。在该情形下，本报告有关的投资产品和服务仅向日本受监管的金融机构提供。

本报告将依据其他国家或地区的法律法规和监管要求于该国家或地区提供。

特别声明

在法律许可的情况下，中金公司可能与本报告中提及公司正在建立或争取建立业务关系或服务关系。因此，投资者应当考虑到中金公司及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。

与本报告所含具体公司相关的披露信息请访问 <https://research.cicc.com/footer/disclosures>，亦可参见近期已发布的关于该等公司的具体研究报告。

中金研究基本评级体系说明：

分析师采用相对评级体系，股票评级分为跑赢行业、中性、跑输行业（定义见下文）。

除了股票评级外，中金公司对覆盖行业的未来市场表现提供行业评级观点，行业评级分为超配、标配、低配（定义见下文）。

我们在此提醒您，中金公司对研究覆盖的股票不提供买入、卖出评级。跑赢行业、跑输行业不等同于买入、卖出。投资者应仔细阅读中金公司研究报告中的所有评级定义。请投资者仔细阅读研究报告全文，以获取比较完整的观点与信息，不应仅仅依靠评级来推断结论。在任何情形下，评级（或研究观点）都不应被视为或作为投资建议。投资者买卖证券或其他金融产品的决定应基于自身实际具体情况（比如当前的持仓结构）及其他需要考虑的因素。

股票评级定义：

- 跑赢行业（OUTPERFORM）：未来 6~12 个月，分析师预计个股表现超过同期其所属的中金行业指数；
- 中性（NEUTRAL）：未来 6~12 个月，分析师预计个股表现与同期其所属的中金行业指数相比持平；
- 跑输行业（UNDERPERFORM）：未来 6~12 个月，分析师预计个股表现不及同期其所属的中金行业指数。

行业评级定义：

- 超配（OVERWEIGHT）：未来 6~12 个月，分析师预计某行业会跑赢大盘 10%以上；
- 标配（EQUAL-WEIGHT）：未来 6~12 个月，分析师预计某行业表现与大盘的关系在-10%与 10%之间；
- 低配（UNDERWEIGHT）：未来 6~12 个月，分析师预计某行业会跑输大盘 10%以上。

研究报告评级分布可从<https://research.cicc.com/footer/disclosures> 获悉。

本报告的版权仅为中金公司所有，未经书面许可任何机构和个人不得以任何形式转发、翻版、复制、刊登、发表或引用。

V190624
编辑：赵静



北京

中国国际金融股份有限公司
中国北京建国门外大街 1 号
国贸写字楼 2 座 28 层
邮编: 100004
电话: (86-10) 6505 1166
传真: (86-10) 6505 1156

深圳

中国国际金融股份有限公司深圳分公司
深圳市福田区益田路 5033 号
平安金融中心 72 层
邮编: 518048
电话: (86-755) 8319-5000
传真: (86-755) 8319-9229

东京

中国国际金融日本株式会社
〒100-0005 東京都千代田区丸の内 3 丁目 2 番 3 号
丸の内二重橋ビル 2 1 階
Tel: (+813) 3201 6388
Fax: (+813) 3201 6389

纽约

CICC US Securities, Inc
32nd Floor, 280 Park Avenue
New York, NY 10017, USA
Tel: (+1-646) 7948 800
Fax: (+1-646) 7948 801

伦敦

China International Capital Corporation (UK)
Limited
25th Floor, 125 Old Broad Street
London EC2N 1AR, United Kingdom
Tel: (+44-20) 7367 5718
Fax: (+44-20) 7367 5719

上海

中国国际金融股份有限公司上海分公司
上海市浦东新区陆家嘴环路 1233 号
汇亚大厦 32 层
邮编: 200120
电话: (86-21) 5879-6226
传真: (86-21) 5888-8976

香港

中国国际金融（香港）有限公司
香港中环港景街 1 号
国际金融中心第一期 29 楼
电话: (852) 2872-2000
传真: (852) 2872-2100

旧金山

CICC US Securities, Inc. San Francisco Branch
Office
One Embarcadero Center, Suite 2350,
San Francisco, CA 94111, USA
Tel: (+1) 415 493 4120
Fax: (+1) 628 203 8514

新加坡

China International Capital Corporation
(Singapore) Pte. Limited
6 Battery Road, #33-01
Singapore 049909
Tel: (+65) 6572 1999
Fax: (+65) 6327 1278

法兰克福

China International Capital Corporation (Europe)
GmbH
Neue Mainzer Straße 52-58, 60311
Frankfurt a.M, Germany
Tel: (+49-69) 24437 3560